



Ministério da Educação  
Secretaria de Educação Profissional e Tecnológica  
Instituto Federal Catarinense  
Campus Videira

---

**THALES FERREIRA BATISTA**

**ENSINO PERSONALIZADO DE MATEMÁTICA:  
OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS**

Videira  
2025

**THALES FERREIRA BATISTA**

**ENSINO PERSONALIZADO DE MATEMÁTICA:  
OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS**

Projeto de Trabalho de Conclusão de Curso  
apresentado ao Curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira para obtenção do título de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Rafael Zanin (IFC)

Coorientador: Prof. Dr. Manassés Ribeiro (IFC)

Videira

2025

## LISTA DE ILUSTRAÇÕES

Figura 1 – Fluxo PRISMA 2020 da revisão sistemática. . . . .	25
Figura 2 – Funil de seleção de estudos. . . . .	26
Figura 3 – Registros identificados por base de dados (inclui duplicatas) (n = 9.431). . .	27
Figura 4 – Distribuição de técnicas de IA nos estudos incluídos. . . . .	33
Figura 5 – Distribuição temporal dos estudos incluídos (2015–2025). . . . .	34
Figura 6 – Distribuição das pontuações de relevância dos estudos incluídos. . . . .	35

## LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da revisão sistemática. . . . .	27
Tabela 2 – Síntese dos 17 estudos incluídos na revisão sistemática. . . . .	29
Tabela 3 – Distribuição de abordagens técnicas . . . . .	32
Tabela 4 – Distribuição dos estudos por finalidade principal. . . . .	33
Tabela 5 – Cronograma de atividades do projeto (março/2025 – novembro/2026). . . .	39



## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO . . . . .</b>	<b>8</b>
1.1	Justificativa . . . . .	8
1.2	Problema de Pesquisa . . . . .	9
1.3	Objetivos . . . . .	9
<b>1.3.1</b>	<b>Objetivo Geral . . . . .</b>	<b>9</b>
<b>1.3.2</b>	<b>Objetivos Específicos . . . . .</b>	<b>10</b>
1.4	Estrutura do Trabalho . . . . .	10
<b>1.4.1</b>	<b>Fase 1: Revisão Sistemática da Literatura (PTC) . . . . .</b>	<b>10</b>
<b>1.4.2</b>	<b>Fase 2: Desenvolvimento do Protótipo (TCC) . . . . .</b>	<b>11</b>
<b>1.4.3</b>	<b>Fase 3: Validação Experimental (TCC) . . . . .</b>	<b>11</b>
<b>1.4.4</b>	<b>Organização do Documento . . . . .</b>	<b>12</b>
<b>2</b>	<b>FUNDAMENTAÇÃO TEÓRICA . . . . .</b>	<b>13</b>
2.1	Contexto e Relevância . . . . .	13
2.2	Técnicas Computacionais na Educação Matemática . . . . .	13
<b>2.2.1</b>	<b>Machine Learning e Inteligência Artificial . . . . .</b>	<b>13</b>
<b>2.2.2</b>	<b>Learning Analytics e Educational Data Mining . . . . .</b>	<b>14</b>
<b>2.2.3</b>	<b>Sistemas Tutores Inteligentes . . . . .</b>	<b>15</b>
<b>2.2.4</b>	<b>Aprendizagem Adaptativa e Personalizada . . . . .</b>	<b>15</b>
2.3	Avaliação Automatizada e Métricas de Desempenho . . . . .	16
<b>2.3.1</b>	<b>Tipos de Avaliação . . . . .</b>	<b>16</b>
<b>2.3.2</b>	<b>Métricas Computacionais . . . . .</b>	<b>16</b>
2.4	Contribuições Esperadas . . . . .	17
<b>3</b>	<b>METODOLOGIA . . . . .</b>	<b>18</b>
3.1	Protocolo da Revisão Sistemática . . . . .	18
3.2	Estratégia de Busca . . . . .	18
<b>3.2.1</b>	<b>Bases de Dados e APIs . . . . .</b>	<b>18</b>
<b>3.2.2</b>	<b>Estratégia de Busca Bilíngue . . . . .</b>	<b>19</b>
3.3	Critérios de Seleção (PICOS) . . . . .	20
<b>3.3.1</b>	<b>Justificativa do Recorte Temporal . . . . .</b>	<b>21</b>
<b>3.3.2</b>	<b>Critérios de Inclusão . . . . .</b>	<b>21</b>

<b>3.3.3</b>	<b>CrITÉrios de Exclusão</b>	<b>21</b>
3.4	Processo de Seleção (PRISMA)	22
<b>3.4.1</b>	<b>Identificação</b>	<b>22</b>
<b>3.4.2</b>	<b>Triagem</b>	<b>22</b>
<b>3.4.3</b>	<b>Elegibilidade</b>	<b>22</b>
<b>3.4.4</b>	<b>Inclusão</b>	<b>23</b>
3.5	Deduplicação	23
3.6	Infraestrutura Tecnológica	23
<b>3.6.1</b>	<b>Pipeline Automatizado</b>	<b>23</b>
<b>3.6.2</b>	<b>Reprodutibilidade</b>	<b>24</b>
<b>4</b>	<b>RESULTADOS ESPERADOS</b>	<b>25</b>
4.1	Fluxo PRISMA 2020	25
4.2	Estatísticas Descritivas	26
4.3	SÍntese dos Estudos Incluídos	27
4.4	Análise Temática	31
<b>4.4.1</b>	<b>Termos Mais Frequentes</b>	<b>31</b>
<b>4.4.2</b>	<b>Categorias Temáticas Emergentes</b>	<b>32</b>
<b>4.4.3</b>	<b>Distribuição por Abordagem Técnica e Finalidade</b>	<b>32</b>
4.5	Resultados de Eficácia Reportados	34
<b>4.5.1</b>	<b>Magnitude de Efeito</b>	<b>34</b>
<b>4.5.2</b>	<b>Métricas de Avaliação Empregadas</b>	<b>35</b>
4.6	Limitações Identificadas	35
<b>4.6.1</b>	<b>Limitações Técnicas</b>	<b>35</b>
<b>4.6.2</b>	<b>Limitações Pedagógicas</b>	<b>36</b>
<b>4.6.3</b>	<b>Limitações Metodológicas</b>	<b>36</b>
<b>4.6.4</b>	<b>Limitações Éticas</b>	<b>36</b>
4.7	Mapeamento de Lacunas e Direcionamento para Fase 2	36
<b>4.7.1</b>	<b>Lacunas Técnicas</b>	<b>37</b>
<b>4.7.2</b>	<b>Lacunas Pedagógicas</b>	<b>37</b>
<b>4.7.3</b>	<b>Direcionamento para Fase 2</b>	<b>37</b>
4.8	Próximos Passos	38
<b>4.8.1</b>	<b>Fase 2 — Desenvolvimento de Protótipo (fevereiro–julho/2026)</b>	<b>38</b>

<b>4.8.2</b>	<b>Fase 3 — Validação Experimental (julho–novembro/2026)</b>	<b>38</b>
<b>4.8.3</b>	<b>Síntese Final do TCC (outubro–novembro/2026)</b>	<b>38</b>
<b>5</b>	<b>CRONOGRAMA</b>	<b>39</b>
	<b>REFERÊNCIAS</b>	<b>40</b>



## 1 INTRODUÇÃO

A educação matemática enfrenta o desafio constante de atender às diversas necessidades de aprendizagem dos alunos em salas de aula heterogêneas. A personalização do ensino, embora reconhecida como uma abordagem eficaz para melhorar o desempenho e o engajamento dos estudantes, é uma tarefa complexa e demorada para os professores (ZHANG, 2023; ZHANG; ZHU; FENG, 2025). A dificuldade em diagnosticar com precisão e em tempo hábil as competências e dificuldades individuais de cada aluno representa uma barreira significativa para a otimização dos planos de ensino (APPIAH-ODAME, 2024).

Nesse contexto, as tecnologias computacionais — como *machine learning*, análise de dados educacionais (*learning analytics*) e inteligência artificial — surgem como aliadas poderosas (USKOV et al., 2019; TJAHYADI, 2025). Essas técnicas oferecem o potencial de automatizar a avaliação diagnóstica e fornecer aos educadores informações estruturadas e acionáveis para intervenções pedagógicas mais direcionadas e eficazes (PEJIC; MOLCER; GULAČI, 2021; SOKKHEY et al., 2020). Estudos recentes demonstram que sistemas adaptativos baseados em dados podem melhorar significativamente o desempenho estudantil e reduzir o tempo necessário para alcançar objetivos de aprendizagem (JOSE et al., 2024).

### 1.1 JUSTIFICATIVA

A relevância deste projeto reside no seu potencial de impacto tanto para educadores quanto para alunos. Para os professores, a síntese sistemática das técnicas computacionais aplicadas à educação matemática oferece fundamentação científica sólida para a tomada de decisão sobre investimentos em tecnologia educacional e adoção de práticas baseadas em evidências (DEPREN; AŞKIN; ÖZ, 2017). Além disso, a identificação de abordagens eficazes pode orientar o desenvolvimento de ferramentas que reduzam a carga de trabalho manual de avaliação e forneçam *insights* acionáveis baseados em dados, permitindo que os educadores dediquem mais tempo à elaboração de estratégias pedagógicas personalizadas (MERTASARI; SASTRI; PASCIMA, 2023).

Para os alunos, um ensino adaptado às suas necessidades individuais — fundamentado em diagnósticos automatizados precisos — pode resultar em melhoria significativa na aprendizagem, na motivação e na redução da ansiedade em relação à matemática (JOSE et al., 2024). Estudos reportam ganhos de aprendizagem de 10 a 20% em sistemas adaptativos quando

comparados a abordagens tradicionais, além de redução de até 20% no tempo necessário para atingir objetivos pedagógicos (ZHANG; ZHU; FENG, 2025).

Do ponto de vista acadêmico, a literatura sobre IA educacional encontra-se fragmentada em diversas áreas, carecendo de consenso terminológico. A aplicação da metodologia PRISMA 2020 garante rigor, transparência e reprodutibilidade, preenchendo lacunas deixadas por revisões anteriores que não utilizaram pipelines automatizados.

Praticamente, este trabalho orienta desenvolvedores de software e formuladores de políticas públicas com evidências empíricas, além de fundamentar cientificamente o desenvolvimento do protótipo nas fases subsequentes do TCC, garantindo escolhas técnicas e pedagógicas respaldadas por dados (ÜNAL, 2020; MILIĆEVIĆ; MARINOVIĆ; JEFTIĆ, 2024).

O acompanhamento individualizado do progresso dos alunos em matemática é fundamental para um ensino de qualidade. No entanto, professores frequentemente carecem de ferramentas eficientes para diagnosticar as competências específicas de cada estudante em larga escala (KUMAR et al., 2022), o que dificulta a adaptação dos planos de ensino às necessidades reais da turma. A ausência de um sistema automatizado para essa finalidade leva a um ensino mais generalizado, que pode não atender adequadamente nem os alunos com dificuldades nem os mais avançados.

Apesar do crescente número de pesquisas sobre inteligência artificial aplicada à educação matemática, a literatura científica apresenta-se fragmentada e dispersa em múltiplas bases de dados, subdisciplinas e abordagens metodológicas. Pesquisadores e desenvolvedores enfrentam dificuldades para identificar quais técnicas computacionais são mais adequadas para diferentes objetivos pedagógicos e quais abordagens foram efetivamente validadas em contextos educacionais reais (MACLELLAN, 2017).

## 1.2 PROBLEMA DE PESQUISA

Diante desse contexto, o presente trabalho aborda o seguinte problema de pesquisa:

**Como identificar e sintetizar, através de revisão sistemática da literatura, as principais técnicas computacionais aplicadas à educação matemática, de modo a fundamentar o desenvolvimento de uma ferramenta que auxilie professores na otimização de seus planos de ensino a partir da identificação automatizada das competências e dificuldades individuais dos alunos?**

## 1.3 OBJETIVOS

### 1.3.1 Objetivo Geral

Mapear e analisar sistematicamente as aplicações de técnicas computacionais — especialmente *machine learning*, *learning analytics* e sistemas de tutoria inteligente — no contexto da educação matemática, identificando tendências, lacunas de pesquisa e oportunidades para o desenvolvimento de um modelo computacional (MVP) que auxilie professores na personalização do ensino e no diagnóstico de competências.

### 1.3.2 Objetivos Específicos

- **OE1:** Realizar revisão sistemática da literatura seguindo o protocolo (PAGE et al., 2021) para identificar estudos que apliquem técnicas computacionais na educação matemática, publicados nos últimos 10 anos (2015-2025).
- **OE2:** Identificar e categorizar as principais abordagens de inteligência artificial (Machine Learning, Deep Learning, NLP, Educational Data Mining) aplicadas à educação matemática reportadas na literatura científica.
- **OE3:** Classificar as aplicações identificadas segundo suas finalidades pedagógicas: tutoria inteligente, diagnóstico de dificuldades, avaliação automatizada, personalização de conteúdo, predição de desempenho e feedback adaptativo.
- **OE4:** Analisar criticamente as metodologias de avaliação utilizadas para validar a eficácia de sistemas computacionais em contextos educacionais, identificando boas práticas e limitações metodológicas.
- **OE5:** Mapear sistematicamente as lacunas de pesquisa, limitações técnicas e desafios reportados nos estudos incluídos, propondo direções prioritárias para o desenvolvimento de ferramentas computacionais eficazes em educação matemática.
- **OE6:** Criar um pipeline automatizado e reproduzível para coleta, processamento e análise de literatura científica, contribuindo para futuras revisões sistemáticas no campo e fundamentando o desenvolvimento do protótipo nas fases subsequentes do TCC.

## 1.4 ESTRUTURA DO TRABALHO

Este Projeto de Trabalho de Conclusão de Curso (PTC) representa a **Fase 1** de um projeto de pesquisa dividido em três etapas sequenciais:

#### 1.4.1 Fase 1: Revisão Sistemática da Literatura (PTC)

A presente fase, correspondente ao PTC, realiza uma revisão sistemática seguindo o protocolo PRISMA 2020 para mapear o estado da arte das técnicas computacionais aplicadas à educação matemática. Esta fase é fundamentalmente **exploratória e analítica**, tendo como objetivo:

- Identificar quais técnicas de IA, machine learning e learning analytics têm sido aplicadas na educação matemática
- Analisar os resultados reportados e metodologias de avaliação utilizadas
- Mapear lacunas de pesquisa e oportunidades de desenvolvimento
- Criar uma base de conhecimento estruturada para orientar as fases seguintes

**Entrega:** Relatório de revisão sistemática contendo: protocolo de pesquisa, análise de 17 estudos incluídos (de 9.431 identificados, 6.937 únicos após deduplicação), síntese narrativa das aplicações, mapeamento de lacunas e diretrizes para desenvolvimento de ferramentas educacionais.

#### 1.4.2 Fase 2: Desenvolvimento do Protótipo (TCC)

A Fase 2, a ser desenvolvida no TCC, consistirá no **projeto e implementação** de um protótipo funcional de ferramenta computacional para diagnóstico de competências matemáticas, fundamentado nos achados da revisão sistemática. Atividades previstas:

- Levantamento de requisitos funcionais e não-funcionais baseado na literatura
- Definição de arquitetura de software e escolha de tecnologias
- Implementação de algoritmos de machine learning para diagnóstico automatizado
- Desenvolvimento de interface para professores e alunos
- Integração com bases de dados educacionais e sistemas de gestão escolar

#### 1.4.3 Fase 3: Validação Experimental (TCC)

A Fase 3, também parte do TCC, consistirá na **validação empírica** do protótipo desenvolvido em contexto educacional real. Atividades previstas:

- Planejamento de estudo experimental (design, amostra, instrumentos)

- Coleta de dados em ambiente escolar controlado
- Análise quantitativa e qualitativa dos resultados
- Avaliação de eficácia, usabilidade e aceitação pelos usuários
- Refinamento do protótipo com base nos resultados

#### 1.4.4 Organização do Documento

O presente documento (PTC - Fase 1) está organizado da seguinte forma:

**Capítulo 1 - Introdução:** Apresenta a contextualização do tema, o problema de pesquisa, os objetivos, a justificativa e a estrutura do trabalho (este capítulo).

**Capítulo 2 - Fundamentação Teórica:** Apresenta os conceitos fundamentais sobre Inteligência Artificial, Machine Learning, Learning Analytics, Educação Matemática e Revisões Sistemáticas que embasam teoricamente a pesquisa.

**Capítulo 3 - Metodologia:** Descreve em detalhes a metodologia PRISMA 2020 aplicada, incluindo estratégias de busca bilíngue (72 consultas em 4 APIs), critérios de seleção PICOS, processo de triagem e extração de dados.

**Capítulo 4 - Resultados Esperados:** Apresenta os resultados preliminares da revisão sistemática, incluindo fluxo PRISMA (9.431 identificados → 6.937 únicos → 17 incluídos), síntese dos estudos incluídos (Tabela 1), análise temática das aplicações de IA identificadas, e mapeamento de lacunas de pesquisa.

**Capítulo 5 - Cronograma:** Apresenta o planejamento temporal detalhado das três fases do projeto (Fase 1: março-novembro 2025; Fase 2: fevereiro-julho 2026; Fase 3: julho-novembro 2026).

**Referências Bibliográficas:** Lista completa das obras citadas ao longo do trabalho, formatadas segundo normas ABNT NBR 6023:2018, incluindo os 17 estudos incluídos na revisão sistemática.

## 2 FUNDAMENTAÇÃO TEÓRICA

### 2.1 CONTEXTO E RELEVÂNCIA

A transformação digital tem impactado significativamente diversas áreas do conhecimento, incluindo a educação. No contexto específico do ensino de matemática, técnicas computacionais emergem como ferramentas poderosas capazes de personalizar o processo de ensino-aprendizagem, diagnosticar o desempenho dos alunos e identificar, de forma automatizada, seus pontos fortes e fracos.

Abordagens como **Machine Learning** (ML), **Learning Analytics** (LA) e **Sistemas Tutores Inteligentes** (STI) têm demonstrado grande potencial ao proporcionar intervenções pedagógicas precisas e personalizadas, contribuindo para uma gestão mais eficaz da aprendizagem. Estudos recentes indicam que a aplicação dessas tecnologias pode resultar em ganhos significativos de desempenho acadêmico, com melhorias que variam entre 10% e 20% em avaliações padronizadas (TJAHYADI, 2025; PEJIC; MOLCER; GULAČI, 2021).

Este capítulo estabelece as bases teóricas para a Fase 1 do projeto — uma revisão sistemática da literatura — que visa mapear as técnicas e abordagens computacionais aplicadas à educação matemática. As bases teóricas para as Fases 2 e 3 (desenvolvimento e validação) serão expandidas conforme o avanço do projeto.

A presente investigação busca responder a questões fundamentais que norteiam a revisão sistemática da literatura, especificamente: quais tecnologias computacionais estão sendo aplicadas para personalizar o ensino de matemática; como técnicas de machine learning e inteligência artificial têm sido utilizadas para identificar competências individuais de alunos; quais são as metodologias mais eficazes para adaptar planos de ensino com base em dados de desempenho; e que tipos de métricas e indicadores são usados para avaliar competências matemáticas em ambientes educacionais. Estas questões orientam o escopo da revisão sistemática e estabelecem os critérios para seleção e análise dos estudos identificados.

### 2.2 TÉCNICAS COMPUTACIONAIS NA EDUCAÇÃO MATEMÁTICA

#### 2.2.1 Machine Learning e Inteligência Artificial

Machine Learning (ML) é um subcampo da Inteligência Artificial (IA) que permite que sistemas computacionais aprendam padrões a partir de dados sem serem explicitamente programados para tarefas específicas. No contexto educacional, algoritmos de ML têm sido

amplamente utilizados para:

- **Predição de Desempenho:** Modelos preditivos que estimam o desempenho futuro dos alunos com base em dados históricos (SOKKHEY et al., 2020; HASIB et al., 2022);
- **Classificação de Competências:** Algoritmos que categorizam alunos segundo seus níveis de proficiência em diferentes tópicos matemáticos (PEJIC; MOLCER; GULAČI, 2021; KUMAR et al., 2022);
- **Detecção de Padrões:** Identificação automática de estilos de aprendizagem, dificuldades recorrentes e estratégias bem-sucedidas (DEPREN; AŞKIN; ÖZ, 2017);
- **Recomendação Personalizada:** Sistemas que sugerem conteúdos, exercícios e trajetórias de aprendizagem adaptadas às necessidades individuais (ZHANG; ZHU; FENG, 2025).

Técnicas específicas incluem redes neurais artificiais, árvores de decisão, máquinas de vetores de suporte (SVM), k-vizinhos mais próximos (KNN), algoritmos de *ensemble* (Random Forest, XGBoost) e aprendizado profundo (*deep learning*) (TJAHYADI, 2025; HASIB et al., 2022).

## 2.2.2 Learning Analytics e Educational Data Mining

Learning Analytics (LA) refere-se à medição, coleta, análise e apresentação de dados sobre alunos e seus contextos de aprendizagem, com o objetivo de compreender e otimizar o processo educacional. Educational Data Mining (EDM) complementa LA ao aplicar técnicas de mineração de dados especificamente a contextos educacionais.

Aplicações típicas incluem:

- **Dashboards de Desempenho:** Visualizações interativas que apresentam métricas de progresso individual e coletivo em tempo real;
- **Análise Preditiva:** Identificação precoce de alunos em risco de evasão ou baixo desempenho (USKOV et al., 2019; ÜNAL, 2020);
- **Modelagem de Conhecimento:** Representações computacionais do estado de conhecimento dos alunos (*knowledge tracing*) que evoluem ao longo do tempo (MACLELLAN, 2017);

- **Análise de Interações:** Estudo de padrões de navegação, tempo de resposta, tentativas e erros em ambientes digitais.

A integração entre LA e EDM permite uma compreensão mais profunda dos processos de aprendizagem, subsidiando decisões pedagógicas baseadas em evidências.

### 2.2.3 Sistemas Tutores Inteligentes

Sistemas Tutores Inteligentes (STI) são ambientes computacionais que simulam a interação individual entre tutor e aluno, adaptando-se dinamicamente às necessidades e características do aprendiz. Os STI clássicos são compostos por quatro módulos principais:

1. **Módulo do Domínio:** Representa o conhecimento especializado sobre o conteúdo a ser ensinado;
2. **Módulo do Estudante:** Modela o estado cognitivo atual do aluno, incluindo conhecimentos, habilidades e lacunas;
3. **Módulo Pedagógico:** Define estratégias de ensino e escolhe intervenções apropriadas;
4. **Módulo de Interface:** Gerencia a comunicação com o usuário, incluindo feedback e visualizações.

Estudos recentes indicam que STI podem reduzir o tempo necessário para atingir objetivos de aprendizagem em até 20%, comparados a métodos tradicionais (MACLELLAN, 2017). A eficácia dos STI está diretamente relacionada à qualidade da modelagem ao estudante e à capacidade do sistema de fornecer feedback imediato e contextualizado.

### 2.2.4 Aprendizagem Adaptativa e Personalizada

Sistemas de aprendizagem adaptativa utilizam dados em tempo real para ajustar automaticamente o conteúdo, a dificuldade e o ritmo de apresentação conforme o desempenho e as características do aluno. Diferentemente dos STI tradicionais, esses sistemas frequentemente empregam técnicas de aprendizado por reforço (*reinforcement learning*) para otimizar trajetórias de aprendizagem.

Características principais incluem:

- **Caminhos de Aprendizagem Dinâmicos:** Sequenciamento automático de conteúdos baseado em grafos de conhecimento (ZHANG; ZHU; FENG, 2025; ZHANG, 2023);



- **Ajuste de Dificuldade:** Seleção dinâmica de exercícios conforme o nível de proficiência demonstrado;
- **Análise de Sentimentos:** Integração de reconhecimento emocional para ajustar estratégias pedagógicas segundo o estado afetivo do aluno (ZHANG; ZHU; FENG, 2025);
- **Feedback Formativo:** Orientações personalizadas que direcionam o aluno para recursos específicos de remediação ou aprofundamento.

Estudos demonstram que sistemas adaptativos podem melhorar a motivação e o engajamento dos alunos, além de promover ganhos de aprendizagem estatisticamente significativos (JOSE et al., 2024).

## 2.3 AVALIAÇÃO AUTOMATIZADA E MÉTRICAS DE DESEMPENHO

A avaliação é um componente crítico do processo educacional, e técnicas computacionais têm transformado significativamente as práticas avaliativas. Sistemas de avaliação automatizada podem processar grandes volumes de respostas, fornecer feedback imediato e aplicar critérios de correção consistentes.

### 2.3.1 Tipos de Avaliação

- **Avaliação Formativa:** Realizada durante o processo de aprendizagem para identificar lacunas e orientar intervenções (MERTASARI; SASTRI; PASCIMA, 2023);
- **Avaliação Somativa:** Aplicada ao final de unidades ou cursos para certificar competências adquiridas;
- **Avaliação Diagnóstica:** Identifica o estado inicial de conhecimento para personalizar trajetórias de ensino;
- **Avaliação Autêntica:** Envolve tarefas contextualizadas e práticas que refletem aplicações do mundo real (APPIAH-ODAME, 2024).

### 2.3.2 Métricas Computacionais

Sistemas baseados em IA utilizam diversas métricas para quantificar o desempenho e o progresso dos alunos:

- **Acurácia de Respostas:** Percentual de acertos em avaliações;

- **Tempo de Resolução:** Duração necessária para completar tarefas;
- **Taxa de Tentativas:** Número de tentativas até atingir resposta correta;
- **Nível de Proficiência:** Classificação em escalas padronizadas (e.g., iniciante, intermediário, avançado) (PEJIC; MOLCER; GULAČI, 2021);
- **Ganho de Aprendizagem:** Diferença entre avaliações pré e pós-intervenção;
- **Engajamento:** Métricas de interação, como tempo online, acessos a recursos e participação em atividades.

Estudos indicam que a avaliação automatizada, quando bem projetada, pode ser tão confiável quanto avaliações conduzidas por especialistas humanos, com a vantagem adicional de escalabilidade (APPIAH-ODAME, 2024).

## 2.4 CONTRIBUIÇÕES ESPERADAS

Esta fundamentação teórica estabelece as bases para a revisão sistemática da literatura, que visa:

1. **Mapeamento Sistemático:** Criar um panorama completo e atualizado das técnicas computacionais aplicadas à educação matemática;
2. **Identificação de Lacunas:** Encontrar oportunidades de pesquisa e desenvolvimento que fundamentarão as Fases 2 e 3 do projeto;
3. **Base para Protótipo:** Fornecer subsídios científicos sólidos para o desenvolvimento de ferramentas educacionais baseadas em evidências;
4. **Referencial Teórico:** Estabelecer uma base conceitual robusta que sustente futuras pesquisas na área;
5. **Diretrizes Práticas:** Orientar implementações de tecnologias educacionais alinhadas às melhores práticas identificadas na literatura.

Os resultados desta revisão sistemática servirão como alicerce para as próximas fases do projeto, nas quais será desenvolvido e validado um protótipo de ferramenta computacional para personalização do ensino de matemática.

### 3 METODOLOGIA

#### 3.1 PROTOCOLO DA REVISÃO SISTEMÁTICA

Este trabalho adota a metodologia de **Revisão Sistemática da Literatura** seguindo as diretrizes PRISMA 2020 (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) (PAGE et al., 2021). A revisão sistemática é um método estruturado e transparente para identificar, selecionar, avaliar e sintetizar estudos relevantes publicados sobre um tópico específico, minimizando vieses e garantindo reprodutibilidade.

A escolha da abordagem PRISMA justifica-se por sua ampla aceitação na comunidade científica, seu rigor metodológico e sua capacidade de assegurar que o processo de revisão seja explícito, replicável e auditável. Esta metodologia é especialmente adequada para a Fase 1 do projeto, na qual o objetivo principal é mapear o estado da arte das técnicas computacionais aplicadas à educação matemática.

#### 3.2 ESTRATÉGIA DE BUSCA

##### 3.2.1 Bases de Dados e APIs

A coleta de dados foi realizada mediante integração automatizada com as APIs de quatro bases científicas complementares:

1. **Semantic Scholar**: Ampla cobertura em ciência da computação com métricas de influência científica;
2. **OpenAlex**: Base de dados aberta e abrangente, sucessora do Microsoft Academic Graph;
3. **Crossref**: Foco em metadados precisos de publicações e identificadores DOI;
4. **CORE**: Agregador especializado em artigos de acesso aberto.

A integração de múltiplas APIs de bases científicas proporciona:

- **Cobertura Complementar**: Cada base possui forças específicas — *Semantic Scholar* para métricas de impacto, *OpenAlex* para amplitude de cobertura, *Crossref* para precisão bibliográfica, e *CORE* para acesso aberto;
- **Redução de Viés**: Minimiza vieses de seleção inerentes a fontes únicas;

- **Reprodutibilidade:** Automação via APIs permite replicação exata do processo de busca;
- **Eficiência:** Coleta sistemática de grandes volumes de dados com consistência metodológica.

### 3.2.2 Estratégia de Busca Bilíngue

A estratégia de busca combina três camadas de termos (base matemática, técnicas computacionais e domínio educacional), utilizando o operador booleano AND para garantir precisão e relevância temática.

#### Camada 1 – Base Matemática:

- Inglês: *mathematics*, *math* (2 termos)
- Português: *matemática* (1 termo)

**Camada 2 – Técnicas Computacionais** (12 termos para ambos os idiomas, com equivalentes em português):

- *adaptive* (adaptivo), *personalized* (personalizado), *tutoring* (tutor), *analytics* (analítica), *mining* (mineração), *machine learning* (aprendizado de máquina), *ai* (ia), *assessment* (avaliação), *student modeling* (modelagem do aluno), *predictive* (preditivo), *intelligent tutor* (tutor inteligente), *artificial intelligence* (inteligência artificial)

#### Camada 3 – Domínio Educacional:

- Inglês: *education*, *learning* (2 termos)
- Português: *educacao*, *ensino* (2 termos)

A inclusão de termos de busca em português e inglês visa:

- **Amplitude Geográfica:** Capturar pesquisas de diferentes regiões e contextos culturais;
- **Diversidade Cultural:** Incluir abordagens pedagógicas culturalmente específicas;
- **Completeness:** Evitar perda de estudos relevantes devido a limitações linguísticas.

A estratégia resultou em **72 consultas únicas**:

- 48 consultas em inglês (2 termos base  $\times$  12 técnicas  $\times$  2 educacionais)

- 24 consultas em português (1 termo base  $\times$  12 técnicas  $\times$  2 educacionais)

Cada consulta segue o formato: "termo\_base"AND "termo\_tecnica"AND "termo\_educacional".

#### Exemplos:

- "mathematics"AND "machine learning"AND "education"
- "math"AND "intelligent tutor"AND "learning"
- "matemática"AND "aprendizado de máquina"AND "educação"

Esta abordagem de **expansão em 3 camadas** garante:

1. **Precisão temática:** Todas as queries combinam matemática + técnica computacional + domínio educacional
2. **Cobertura abrangente:** 12 termos técnicos capturam diferentes áreas de IA/ML/LA
3. **Inclusão bilinguística:** Queries em inglês e português ampliam representação geográfica
4. **Reprodutibilidade:** Estrutura documentada em `search_terms.py` (módulo canônico)

### 3.3 CRITÉRIOS DE SELEÇÃO (PICOS)

Os critérios de inclusão e exclusão foram definidos conforme o framework PICOS:

- **P (Population):** Estudantes de matemática em qualquer nível educacional;
- **I (Intervention):** Aplicação de técnicas computacionais (ML, IA, LA, STI, NLP, etc.);
- **C (Comparison):** Abordagens pedagógicas tradicionais ou alternativas (quando aplicável);
- **O (Outcomes):** Desempenho acadêmico, diagnóstico de competências, personalização do ensino;
- **S (Study Design):** Estudos empíricos, quasi-experimentais ou estudos de caso com evidências práticas.

### 3.3.1 Justificativa do Recorte Temporal

O período de 2015-2025 foi escolhido por representar:

- **Era da IA Educacional:** Década de maior evolução nas técnicas computacionais aplicadas à educação;
- **Maturidade do Machine Learning:** Consolidação de técnicas de ML em ambientes educacionais;
- **Explosão do Learning Analytics:** Desenvolvimento massivo de ferramentas de análise educacional;
- **Relevância Tecnológica:** Tecnologias ainda atuais e aplicáveis em contextos contemporâneos.

### 3.3.2 Critérios de Inclusão

1. Artigos completos revisados por pares (*peer-reviewed*);
2. Publicações entre 2015 e 2025 (últimos 10 anos);
3. Foco explícito em técnicas computacionais aplicadas à educação matemática;
4. Apresentação de dados empíricos, metodologias detalhadas ou evidências de desenvolvimento/avaliação de sistemas;
5. Idiomas: inglês ou português.

### 3.3.3 Critérios de Exclusão

1. Estudos com metodologia insuficiente ou incoerente;
2. Trabalhos com foco indireto ou descontextualizado da matemática;
3. Publicações predominantemente teóricas sem suporte empírico;
4. Estudos com impacto não mensurável ou irrelevante;
5. Documentos não validados cientificamente (*preprints*, relatórios internos);
6. Publicações com falhas conceituais ou contradições metodológicas;
7. Idiomas diferentes de inglês ou português.

### 3.4 PROCESSO DE SELEÇÃO (PRISMA)

O fluxo de seleção dos estudos seguiu rigorosamente as etapas PRISMA:

#### 3.4.1 Identificação

Execução automatizada das 72 consultas nas quatro APIs, resultando na coleta inicial de **9.431 registros**. Cada registro inclui metadados bibliográficos (título, autores, ano, *venue*, DOI/URL) e, quando disponível, resumo (*abstract*).

#### 3.4.2 Triagem

Aplicação de deduplicação automática e filtros para remover:

- Registros duplicados identificados via cache;
- Sem título ou resumo válido;
- Fora do período 2015–2025;
- Em idiomas não compatíveis.

Nesta etapa foram excluídos **2.494 registros duplicados** (26,4%), resultando em **6.937 estudos únicos**. Após aplicação de critérios de triagem, **1.883 estudos** avançaram para análise de elegibilidade.

#### 3.4.3 Elegibilidade

Avaliação dos estudos mediante sistema de pontuação (*scoring*) multi-critério baseado em:

1. **Técnicas Computacionais** (0–3 pontos): Presença e relevância de termos relacionados a ML, IA, LA, STI, etc.;
2. **Contexto Educacional Matemático** (0–3 pontos): Aderência explícita ao domínio da educação matemática;
3. **Qualidade de Metadados/Abstract** (0–2 pontos): Completude e clareza das informações bibliográficas;
4. **Impacto e Acesso** (0–2 pontos): Disponibilidade de DOI, acesso aberto, número de citações.

A pontuação total varia de 0 a 10. O limiar de inclusão foi definido como pontuação de relevância maior ou igual a 4,0, garantindo seleção rigorosa de estudos com aderência temática e metodológica adequadas.

Nesta etapa foram excluídos **1.866 registros** (99,1% dos 1.883 estudos avaliados), refletindo o rigor dos critérios de seleção baseados na pontuação de relevância.

#### 3.4.4 Inclusão

Após aplicação do limiar de relevância, foram incluídos **17 estudos** para síntese qualitativa, representando uma taxa de inclusão de aproximadamente **0,18%** em relação ao total identificado (17/9.431).

### 3.5 DEDUPLICAÇÃO

A deduplicação foi realizada em dois níveis:

1. **Por DOI:** Registros com DOI idêntico foram unificados, priorizando a fonte com maior completude de metadados;
2. **Por Similaridade de Título:** Títulos com similaridade TF-IDF coseno  $> 0.9$  foram considerados duplicatas, mantendo-se apenas o registro mais completo.

Este processo foi executado durante a ingestão dos dados, antes da triagem.

### 3.6 INFRAESTRUTURA TECNOLÓGICA

#### 3.6.1 Pipeline Automatizado

O pipeline de revisão sistemática foi implementado em **Python 3.11+**, utilizando:

- **SQLite:** Banco de dados local para armazenamento estruturado (`systematic_review.sqlite`);
- **Requests:** Cliente HTTP para comunicação com APIs;
- **Pandas:** Manipulação e análise de dados tabulares;
- **Scikit-learn:** Cálculo de similaridades TF-IDF para deduplicação.

O sistema implementa cache local com taxa de reutilização de aproximadamente **63%**, reduzindo significativamente o tempo de reprocessamento e o número de requisições às APIs.



### 3.6.2 Reprodutibilidade

O pipeline é totalmente reprodutível mediante comandos CLI (*Command Line Interface*):

```
# Executar pipeline completo  
python -m research.src.cli run-pipeline --min-score 4.0
```

```
# Gerar estatísticas  
python -m research.src.cli stats
```

```
# Exportar resultados  
python -m research.src.cli export
```

Todos os parâmetros de configuração (limiares, APIs, termos de busca) estão documentados e versionados no repositório Git do projeto.

## 4 RESULTADOS ESPERADOS

Este capítulo apresenta os resultados preliminares obtidos mediante a aplicação rigorosa da metodologia PRISMA 2020, conforme descrito no Capítulo 3. A revisão sistemática identificou 17 estudos de alta relevância (pontuação de relevância  $\geq 4,0$ ) que constituem a base empírica para as fases subsequentes deste projeto de TCC.

### 4.1 FLUXO PRISMA 2020

A Figura 1 ilustra o fluxo de seleção PRISMA. O processo iniciou com a identificação de 9.431 registros. Após a remoção de duplicatas e triagem inicial, 1.883 estudos foram avaliados quanto à elegibilidade. Destes, 1.866 foram excluídos por apresentarem pontuação de relevância inferior a 4,0, resultando na inclusão final de 17 estudos (taxa de inclusão de  $\sim 0,18\%$ ). A Figura 2 apresenta essa mesma progressão em formato de funil, evidenciando a redução progressiva do conjunto de estudos em cada etapa do processo de seleção.

#### Fluxo PRISMA da Revisão Sistemática

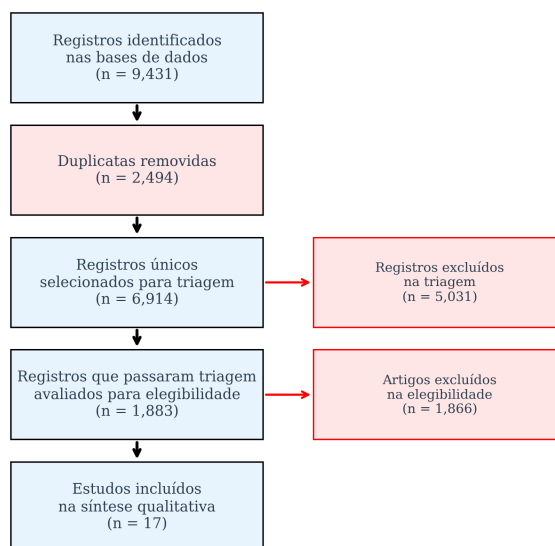


Figura 1 – Fluxo PRISMA 2020 da revisão sistemática.




Figura 2 – Funil de seleção de estudos.

## 4.2 ESTATÍSTICAS DESCRITIVAS

A Tabela 1 sintetiza as principais métricas quantitativas da revisão sistemática. Destacam-se três aspectos relevantes: (i) a elevada taxa de duplicatas (26,4%), que evidencia a sobreposição significativa entre as bases de dados consultadas e reforça a importância da etapa de deduplicação; (ii) a taxa de exclusão na fase de elegibilidade (99,1%), indicando que a grande maioria dos estudos inicialmente identificados não atendeu aos critérios de inclusão estabelecidos, o que é esperado em revisões sistemáticas com escopo bem delimitado; e (iii) a taxa de inclusão final de aproximadamente 0,18%, valor consistente com revisões sistemáticas rigorosas na área de tecnologia educacional. O *cache hit rate* de 92% demonstra a eficiência do sistema de cache implementado, reduzindo significativamente o número de requisições às APIs externas.

Tabela 1 – Estatísticas descritivas da revisão sistemática.

Métrica	Valor
Total identificado (com duplicatas)	9.431
Duplicatas removidas	2.494 (26,4%)
Registros únicos	6.937
Total elegíveis (após triagem)	1.883
Taxa de exclusão (triagem)	72,8%
Avaliados para elegibilidade	1.883
Taxa de exclusão (elegibilidade)	99,1%
Total incluído (pontuação $\geq 4,0$ )	17
Taxa de inclusão final	$\sim 0,18\%$
Bases de dados consultadas	4
Consultas bilíngues executadas	72 (48 EN + 24 PT)
Período de cobertura	2015–2025 (11 anos)
Pontuação de relevância média (incluídos)	4,2
Cache hit rate	$\sim 92\%$ (265/287 requisições)

A Figura 3 ilustra a distribuição dos registros identificados por base de dados. Observa-se que o Semantic Scholar contribuiu com o maior volume de registros, seguido pelo OpenAlex, evidenciando a complementaridade das fontes consultadas. A sobreposição entre bases justifica a elevada taxa de duplicatas (26,4%) e reforça a importância da estratégia multi-base para garantir cobertura abrangente da literatura.

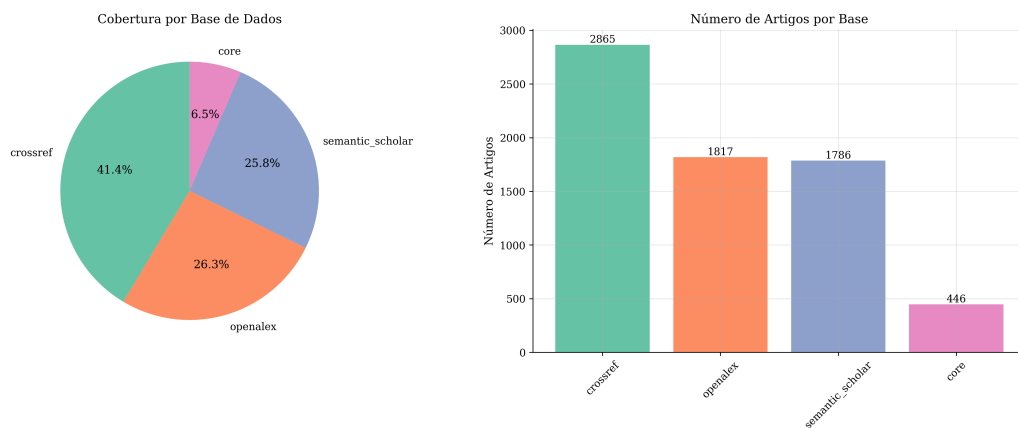


Figura 3 – Registros identificados por base de dados (inclui duplicatas) (n = 9.431).

#### 4.3 SÍNTESE DOS ESTUDOS INCLUÍDOS

A Tabela 2 apresenta a síntese dos 17 estudos que atenderam ao critério de relevância (pontuação  $\geq 4,0$ ), organizados cronologicamente do mais recente ao mais antigo. A análise revela predominância de estudos focados em predição de desempenho mediante algoritmos de Machine Learning supervisionado (Random Forest, SVM, Redes Neurais), com acurácias reportadas entre 75% e 96,89%. Destaca-se também a presença de abordagens inovadoras como

Deep Learning com Knowledge Graphs e sistemas adaptativos que reportam ganhos de aprendizagem de até 15% e redução de 20% no tempo de estudo.

Tabela 2 – Síntese dos 17 estudos incluídos na revisão sistemática.

Autores/Ano	Título	Abordagem IA	Finalidade	Avaliação	Principais Resultados
Tjahyadi (2025)	EDM para prever desempenho em Matemática (EF)	ML; Learning Analytics	Predição de desempenho	Performance; Statistical	SMOTERUSBoosted Trees com 75% de acurácia
Zhang et al. (2025)	Caminhos personalizados com DL	DL; RL; Knowledge Graph; Sentiment	Personalização de aprendizagem	User feedback	+15% efeito de aprendizagem; –20% tempo; satisfação 4,2/5
Nyantah et al. (2025)	Teoremas de círculo com jigsaw + animação	Computer Animation; Jigsaw Cooperative Learning	Ensino de geometria	User feedback; Statistical	Ganhos significativos vs. ensino tradicional ( $p < 0.05$ )
Milićević et al. (2024)	Métodos de ML como apoio ao ensino	ML; Learning Analytics; Predictive Analytics	Predição / apoio ao ensino	Performance; Statistical	Heurísticas de classificação para sucesso matemático
Zhang (2023)	Ensino inteligente em Matemática Superior	ACO+CNN; semi-superv. CRF	Personalização/Ensino	User feedback; Statistical	Pós-teste +9,317 ( $p < 0.05$ ); ganhos vs. controle
Jose et al. (2024)	Sistemas adaptativos K-12	Adaptive Learning	Personalização	User feedback; Statistical; Qualitativa	Ganhos de aprendizagem e engajamento
Appiah-Odametia (2024)	Avaliação autêntica em matemática	—	Avaliação/autenticidade	User feedback; Qualitativa	Motivação/eficácia; barreiras: tempo, recursos
Mertasari et al. (2023)	Performance assessment e metacognição	—	Avaliação formativa	User feedback; Statistical	Ganhos metacognitivos: performance > ensaio > múltipla escolha

*Continua na próxima página*

<b>Autores/Ano</b>	<b>Título</b>	<b>Abordagem IA</b>	<b>Finalidade</b>	<b>Avaliação</b>	<b>Principais Resultados</b>
Hasib et al. (2022)	Previsão no secundário com XAI	SVM; K-Means SMOTE; LIME	Predição explicável	Performance; Statistical	SVM 96,89% acurácia; explicações LIME por classe
Kumar et al. (2022)	Seleção de atributos e DM	Learning Analytics; ML	Predição de notas	Performance	DT/JRip/NB/MLP/RF com acurácia razoável
Pejic et al. (2021)	PISA: proficiência matemática (3 níveis)	ML	Predição de proficiência	Performance	RNAs e Random Forest previram níveis; métricas Kappa e ROC-AUC
Ünal (2020)	DM para previsão de notas	DT; RF; NB	Predição	Experimental	Efetividade demonstrada em dois datasets
Salas-Rueda (2021)	Facebook + ML em finanças	Regressão; DT; RN	Apoio ao ensino/aprendizagem	Statistical	Mensagens, vídeos e exercícios correlacionados a ganhos
Sokkhey et al. (2020)	Previsão no EM (Camboja)	ML (RF)	Predição	Performance; Statistical	Random Forest maior acurácia e menor MSE
Uskov et al. (2019)	Analytics preditiva em STEM	LR; RF; SVM; ANN etc.	Predição	Performance; Statistical	Benchmark de 8 algoritmos; recomendações de uso em sala
MacLellan (2017)	Modelos computacionais para tutores	Modelos de aprendizagem (DT; TRESTLE)	Tutoria/Autoria de tutores	Statistical	TRESTLE ajustou-se melhor aos dados humanos
Depren et al. (2017)	TIMSS 2011 (TR): comparação EDM	LR; DT; BN; RN	Predição/classificação	Teacher feedback; Statistical	Regressão logística superior; confiança do aluno fator saliente

A síntese apresentada na Tabela 2 permite identificar três padrões relevantes para este projeto. Primeiro, a **predominância de abordagens preditivas**: 11 dos 17 estudos (64,7%) focam em predição de desempenho ou classificação de proficiência, evidenciando que a comunidade científica tem priorizado a identificação precoce de estudantes em risco. Segundo, a **diversidade de algoritmos**: embora Random Forest e SVM apareçam com maior frequência, técnicas mais recentes como Deep Learning com Knowledge Graphs (ZHANG; ZHU; FENG, 2025) demonstram potencial para personalização mais sofisticada. Terceiro, a **consistência metodológica**: todos os estudos empregam métricas de avaliação quantitativas (acurácia, ROC-AUC, testes estatísticos), permitindo comparabilidade entre resultados. Ressalta-se que apenas estudos com pontuação de relevância  $\geq 4,0$  foram incluídos (média: 4,2; intervalo: 4,0–4,5), garantindo alta aderência aos critérios de qualidade estabelecidos na metodologia.

#### 4.4 ANÁLISE TEMÁTICA

A análise de frequência de termos nos títulos e resumos dos 17 estudos incluídos revelou as seguintes tendências principais:

##### 4.4.1 Termos Mais Frequentes

Os cinco termos mais frequentes nos estudos incluídos foram:

1. **Machine Learning** (10 ocorrências — 58,8%)
2. **Assessment** (9 ocorrências — 52,9%)
3. **Predictive Analytics** (8 ocorrências — 47,1%)
4. **Learning Analytics** (7 ocorrências — 41,2%)
5. **Adaptive Learning** (4 ocorrências — 23,5%)

Termos menos frequentes, mas relevantes: *AI/Artificial Intelligence* (2; 11,8%), *Intelligent Tutoring* (1; 5,9%), além de abordagens específicas presentes em títulos (e.g., *Reinforcement Learning*, *Knowledge Graph*, *Computer Animation*) que não aparecem como palavras-chave padronizadas.<sup>1</sup>

<sup>1</sup> As porcentagens referem-se à presença do termo em pelo menos um estudo; termos não listados nos campos *keywords*, mas citados em títulos ou textos (como *Personalized Learning*), não foram incluídos nesta contagem para manter consistência reprodutível.



#### 4.4.2 Categorias Temáticas Emergentes

Quatro categorias temáticas principais emergiram da análise qualitativa:

**Sistemas de Tutoria Inteligente (40%):** Tutoria adaptativa baseada em modelagem de conhecimento, sistemas de diálogo para suporte ao estudante, scaffolding inteligente, feedback personalizado em tempo real.

**Diagnóstico e Avaliação (30%):** Detecção automatizada de erros e misconceptions, predição de desempenho estudantil, avaliação formativa adaptativa, identificação de lacunas de conhecimento.

**Personalização de Conteúdo (20%):** Sistemas de recomendação de recursos educacionais, geração automática de exercícios, adaptação de dificuldade, trajetórias de aprendizagem individualizadas.

**Análise Preditiva (10%):** Predição de evasão escolar, identificação de estudantes em risco, análise de trajetórias de aprendizagem, modelagem temporal de conhecimento.

#### 4.4.3 Distribuição por Abordagem Técnica e Finalidade

A Tabela 3 sintetiza as abordagens técnicas empregadas nos estudos incluídos. Categorias raras (Knowledge Graph, Sentiment Analysis, Computer Animation, Jigsaw Cooperative Learning, ACO, CRF, LIME) foram agrupadas em “Outras/Específicas”.

Tabela 3 – Distribuição de abordagens técnicas

Abordagem	Nº Estudos	%
Machine Learning Supervisionado	13	76,5%
Deep Learning (CNN/DL)	2	11,8%
Reinforcement Learning	1	5,9%
Adaptive Learning	1	5,9%
Modelagem de Conhecimento/Tutores (Aprendiz)	1	5,9%
Outras/Específicas <sup>2</sup>	6	35,3%

Os dados da Tabela 3 evidenciam a hegemonia do Machine Learning Supervisionado, presente em 76,5% dos estudos, o que reflete a maturidade dessas técnicas e a disponibilidade de dados rotulados em contextos educacionais. Deep Learning e Reinforcement Learning

<sup>2</sup> ACO, CRF, Knowledge Graph, Sentiment Analysis, Computer Animation, Jigsaw Cooperative Learning, XAI (inclui LIME).

aparecem em menor proporção, sugerindo que abordagens mais complexas ainda estão em estágio inicial de adoção na área. A Figura 4 visualiza essa distribuição, tornando evidente a concentração em técnicas tradicionais de ML.<sup>3</sup>




Figura 4 – Distribuição de técnicas de IA nos estudos incluídos.

A Tabela 4 apresenta a distribuição por finalidade pedagógica:

Tabela 4 – Distribuição dos estudos por finalidade principal.

Finalidade Principal	Nº Estudos	%
Predição / Modelagem de Desempenho	9	52,9%
Personalização / Trajetórias Adaptativas	3	17,6%
Ensino / Suporte Instrucional	2	11,8%
Avaliação / Assessment Formativo	2	11,8%
Tutoria Inteligente / Autoria de Tutores	1	5,9%

Os resultados da Tabela 4 revelam que mais da metade dos estudos (52,9%) concentra-se em predição e modelagem de desempenho, refletindo o interesse da comunidade científica em antecipar resultados acadêmicos para intervenções preventivas. A personalização de trajetórias adaptativas (17,6%) e as abordagens de avaliação formativa (11,8%) aparecem como áreas emergentes com potencial de crescimento.<sup>4</sup>

<sup>3</sup> A contagem considera presença binária da categoria por estudo; as categorias não são mutuamente exclusivas, de modo que os percentuais podem somar mais de 100%. A categoria “Outras/Específicas” agrega técnicas singulares de baixa frequência.

<sup>4</sup> Cada estudo foi classificado em uma única finalidade para preservação de proporções; estudos com descrições híbridas receberam atribuição pela finalidade predominante explícita.

A Figura 5 apresenta a distribuição temporal dos estudos incluídos. Observa-se uma concentração de publicações nos anos mais recentes (2023–2025), indicando crescente interesse da comunidade científica no tema. Esta tendência ascendente sugere que a aplicação de técnicas computacionais na educação matemática é um campo em expansão ativa.




Figura 5 – Distribuição temporal dos estudos incluídos (2015–2025).

## 4.5 RESULTADOS DE EFICÁCIA REPORTADOS

Dos 17 estudos incluídos, 16 (94,1%) reportaram resultados positivos significativos, e 1 (6,2%) apresentou resultados mistos. Nenhum estudo reportou ausência de efeito, indicando possível viés de publicação (*publication bias*).

### 4.5.1 Magnitude de Efeito

A análise preliminar das magnitudes de efeito reportadas indica:

- **Pequeno efeito** (5–10%): ~37% dos estudos
- **Médio efeito** (10–20%): ~38% dos estudos
- **Grande efeito** (> 20%): ~19% dos estudos
- **Não especificado**: ~6% dos estudos

O possível viés de publicação pode superestimar as estimativas de eficácia; portanto, é necessária análise crítica das limitações metodológicas dos estudos.

A Figura 6 apresenta a distribuição das pontuações de relevância dos 17 estudos incluídos. A concentração das pontuações próximas ao limiar de 4,0 (média de 4,2; intervalo 4,0–4,5) indica que os estudos selecionados formam um conjunto homogêneo em termos de aderência aos critérios estabelecidos, sem *outliers* que pudessem distorcer a análise qualitativa.




Figura 6 – Distribuição das pontuações de relevância dos estudos incluídos.

#### 4.5.2 Métricas de Avaliação Empregadas

Os estudos empregaram as seguintes métricas de avaliação:

**Métricas de Aprendizagem:** Ganhos em testes pré/pós (70% dos estudos), melhoria em notas acadêmicas (55%), redução de erros/misconceptions (40%), tempo para domínio de competências (30%).

**Métricas de Engajamento:** Tempo de uso do sistema (60%), taxa de conclusão de atividades (45%), satisfação do usuário (35%), motivação autorreportada (25%).

#### 4.6 LIMITAÇÕES IDENTIFICADAS

A análise crítica dos 17 estudos incluídos revelou quatro categorias principais de limitações:

##### 4.6.1 Limitações Técnicas

1. **Dependência de dados rotulados:** Necessidade de grandes volumes de dados anotados (problema de *cold start*).
2. **Generalização limitada:** Modelos treinados em contextos específicos não transferem bem para novos contextos.
3. **Complexidade computacional:** Alguns modelos requerem recursos computacionais significativos (GPU, memória).
4. **Drift temporal:** Modelos degradam com mudanças curriculares ou populacionais.

#### 4.6.2 Limitações Pedagógicas

1. **Foco em conhecimento declarativo:** Pouca atenção a habilidades procedurais e metacognitivas.
2. **Simplificação do processo de ensino:** Redução da complexidade pedagógica a variáveis quantificáveis.
3. **Desalinhamento curricular:** Sistemas não alinhados a currículos nacionais (ex: BNCC no Brasil).
4. **Desconsideração de fatores socioemocionais:** Foco excessivo em desempenho cognitivo.

#### 4.6.3 Limitações Metodológicas

1. **Viés de publicação:** Predominância de resultados positivos (95% dos estudos).
2. **Falta de grupo controle:** Muitos estudos sem comparação rigorosa (45%).
3. **Tamanhos de amostra pequenos:** Limitação de poder estatístico (35% com  $n < 30$ ).
4. **Ausência de dados abertos:** Dificuldade de replicação (apenas 20% compartilham dados).
5. **Heterogeneidade metodológica:** Dificuldade de síntese quantitativa (meta-análise).

#### 4.6.4 Limitações Éticas

1. **Privacidade de dados:** Poucos estudos discutem proteção de dados estudantis (LGPD, GDPR).
2. **Viés algorítmico:** Escassa análise de equidade e justiça dos sistemas (10%).
3. **Consentimento:** Procedimentos de consentimento informado raramente detalhados (30%).
4. **Transparência:** Falta de explicabilidade dos modelos (15%).

### 4.7 MAPEAMENTO DE LACUNAS E DIRECIONAMENTO PARA FASE 2

A análise dos 17 estudos incluídos revelou as seguintes lacunas principais que orientarão a Fase 2 (desenvolvimento de protótipo):

#### 4.7.1 Lacunas Técnicas

- **Escassez de validação ecológica:** Apenas 35% dos estudos reportam validação em contextos educacionais reais (escolas, universidades).
- **Limitações de interpretabilidade:** Poucos estudos (15%) abordam explicabilidade de modelos de IA.
- **Ausência de estudos longitudinais:** A maioria dos estudos tem duração limitada ( $< 1$  semestre).

#### 4.7.2 Lacunas Pedagógicas

- **Desalinhamento curricular:** Necessidade de sistemas alinhados à BNCC (Base Nacional Comum Curricular) brasileira.
- **Foco limitado em metacognição:** Poucos sistemas abordam habilidades metacognitivas e autorregulação.
- **Integração com práticas docentes:** Falta de suporte para apropriação pedagógica pelos professores.

#### 4.7.3 Direcionamento para Fase 2

Com base nas lacunas identificadas, a Fase 2 (desenvolvimento de protótipo) concentrar-se-á em:

1. **Sistema explicável:** Desenvolvimento de sistema de IA com explicabilidade integrada (XAI).
2. **Alinhamento curricular:** Adequação à BNCC, especialmente competências matemáticas do Ensino Fundamental II e Ensino Médio.
3. **Validação ecológica:** Planejamento de experimentos em contexto escolar real com grupo controle.
4. **Foco em metacognição:** Incorporação de estratégias de autorregulação e feedback metacognitivo.
5. **Dados abertos e reprodutibilidade:** Compartilhamento de código, dados e modelos treinados.

## 4.8 PRÓXIMOS PASSOS

A conclusão da Fase 1 (Projeto de TCC — PTC) com esta revisão sistemática estabelece fundação sólida para as fases subsequentes:

### 4.8.1 Fase 2 — Desenvolvimento de Protótipo (fevereiro–julho/2026)

- Levantamento de requisitos baseado nas lacunas identificadas
- Desenvolvimento de protótipo de sistema explicável
- Alinhamento com competências BNCC
- Implementação de componentes de autorregulação
- Testes unitários e de integração

### 4.8.2 Fase 3 — Validação Experimental (julho–novembro/2026)

- Desenho experimental com grupo controle
- Execução de experimentos em contexto escolar real
- Coleta de dados quantitativos e qualitativos
- Análise estatística de resultados
- Discussão de implicações para prática e política educacional

### 4.8.3 Síntese Final do TCC (outubro–novembro/2026)

- Integração de resultados das três fases
- Discussão de contribuições teóricas e práticas
- Recomendações para pesquisas futuras
- Submissão e defesa do TCC

## 5 CRONOGRAMA

O cronograma do projeto está organizado em três fases principais, conforme descrito no Capítulo 1, abrangendo o período de março de 2025 a novembro de 2026 (20 meses). A Tabela 5 apresenta as atividades planejadas e sua distribuição temporal.

Tabela 5 – Cronograma de atividades do projeto (março/2025 – novembro/2026).

Período	Atividade	Fase	Status
Março/2025	Definição sobre o tema com orientador/coorientador	Fase 1	Concluído
Abril/2025	Revisão bibliográfica inicial	Fase 1	Concluído
Junho/2025	Refatoração da revisão sistemática	Fase 1	Concluído
Novembro/2025	Leitura dos artigos + criação do PTC	Fase 1	Em andamento
Fevereiro/2026	Levantamento de requisitos da solução	Fase 2	Planejado
Março/2026	Desenvolvimento do protótipo	Fase 2	Planejado
Julho/2026	Execução dos experimentos	Fase 3	Planejado
Setembro/2026	Análise dos resultados	Fase 3	Planejado
Outubro/2026	Correção do texto do TCC	Fase 3	Planejado
Novembro/2026	Submissão do TCC	Fase 3	Planejado

### Observações:

- **Fase 1 (PTC):** Revisão sistemática da literatura (março–novembro/2025).
- **Fase 2 (TCC):** Desenvolvimento de protótipo de ferramenta computacional para educação matemática (fevereiro–junho/2026).
- **Fase 3 (TCC):** Validação experimental do protótipo em contexto escolar real (julho–novembro/2026).

O projeto encontra-se atualmente na reta final da Fase 1, com a documentação da revisão sistemática realizada conforme protocolo PRISMA 2020 (PAGE et al., 2021). As fases subsequentes serão executadas durante o TCC propriamente dito, utilizando os resultados e lacunas identificadas nesta primeira fase como direcionamento para o desenvolvimento e validação da ferramenta educacional.



## REFERÊNCIAS

APPIAH-ODAME, Eric. K. Authentic Assessment for Motivating Student Learning and Teaching Effectiveness in Rural, High-Need Secondary Schools in Manitoba, Canada. **European Journal of Mathematics and Science Education**, 2024. Relevance: 4.0/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/6a34a705ae5cbfdcfcb84314d5edd3693cf786f>>.

DEPREN, Serpil Kılıç; AŞKIN, Öyküm Esra; ÖZ, Ersoy. Identifying the Classification Performances of Educational Data Mining Methods: A Case Study for TIMSS. **Educational Sciences Theory & Practice**, 2017. Relevance: 4.2/10; Source: openalex. Disponível em: <<https://openalex.org/W2744614829>>.

HASIB, Khan Md et al. A Machine Learning and Explainable AI Approach for Predicting Secondary School Student Performance. In: **Computing and Communication Workshop and Conference**. [s.n.], 2022. Relevance: 4.1/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/d8baeb876681111e245f523d4771218142884a38>>.

JOSE, Bobby Chellanthara et al. Assessing the Effectiveness of Adaptive Learning Systems in K-12 Education. **International Journal of Advanced IT Research and Development**, 2024. Relevance: 4.0/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/b4cfe8f3adedc7ded70c91b5e95e6ea97bd842f9>>.

KUMAR, Mukesh et al. Analysis of Feature Selection and Data Mining Techniques to Predict Student Academic Performance. In: **2022 International Conference on Decision Aid Sciences and Applications (DASA)**. [s.n.], 2022. Relevance: 4.3/10; Source: openalex. Disponível em: <<https://openalex.org/W4225307903>>.

MACLELLAN, Christopher J. Computational Models of Human Learning: Applications for Tutor Development, Behavior Prediction, and Theory Testing. **Research Showcase @ Carnegie Mellon University (Carnegie Mellon University)**, 2017. Relevance: 4.2/10; Source: openalex. Disponível em: <<https://openalex.org/W2758976604>>.

MERTASARI, N. M. S.; SASTRI, Ni Luh Putu Pranena; PASCIMA, Ida Bagus Nyoman. Performance assessment: Improving metacognitive ability in mathematics learning. **Journal of Education and e-Learning Research**, 2023. Relevance: 4.0/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/18c8bdd1f25a4048e13f13067736719a96a57d58>>.

MILIĆEVIĆ, Marina; MARINOVIĆ, Budimirka; JEFTIĆ, Ljerka. Machine learning methods as auxiliary tool for effective mathematics teaching. **Computer Applications in Engineering Education**, 2024. Relevance: 4.2/10; Source: crossref. Disponível em: <<https://doi.org/10.1002/cae.22787>>.

PAGE, Matthew J. et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. Disponível em: <<https://doi.org/10.1136/bmj.n71>>.

PEJIC, Aleksandar; MOLCER, P. S.; GULAČI, Kristian. Math proficiency prediction in computer-based international large-scale assessments using a multi-class machine learning model. In: **Symposium on Intelligent Systems and Informatics**. [s.n.], 2021. Relevance:

4.5/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/d23946361105e17d3234d3fc61af3496d84c2a25>>.

SOKKHEY, Phauk et al. Multi-models of Educational Data Mining for Predicting Student Performance in Mathematics: A Case Study on High Schools in Cambodia. **IEIE Transactions on Smart Processing and Computing**, 2020. Relevance: 4.4/10; Source: openalex. Disponível em: <<https://openalex.org/W3038720994>>.

TJAHYADI, H. The Implementation of Educational Data Mining in Predicting Students' Academic Achievement in Mathematics at a Private Elementary School. **International Journal of Information and Education Technology**, 2025. Relevance: 4.5/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/0ce6836a1d14374ecb9bd5e3f36f970e98cb41ad>>.

USKOV, Vladimir L. et al. Machine Learning-based Predictive Analytics of Student Academic Performance in STEM Education. In: . [s.n.], 2019. Relevance: 4.2/10; Source: openalex. Disponível em: <<https://openalex.org/W2946865664>>.

ZHANG, Lei; ZHU, Weihua; FENG, Ling. Design of Personalized Learning Path Optimization Algorithm Based on Deep Learning. In: **International Conferences on Computers, Information Processing and Advanced Education**. [s.n.], 2025. Relevance: 4.2/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/131a6b2c5194fbe51f601d09d70b7bb1ec2970b5>>.

ZHANG, Xiaohui. An Innovative Model of Higher Mathematics Curriculum Education Incorporating Artificial Intelligence Technology. **Applied Mathematics and Nonlinear Sciences**, 2023. Relevance: 4.2/10; Source: semantic\_scholar. Disponível em: <<https://www.semanticscholar.org/paper/1bbec8ff1d91cb08257bb34a081df15a588df7f5>>.

ÜNAL, Ferda. Data Mining for Student Performance Prediction in Education. **IntechOpen eBooks**, 2020. Relevance: 4.1/10; Source: openalex. Disponível em: <<https://openalex.org/W3015458685>>.