



Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal Catarinense
Campus Videira

THALES FERREIRA BATISTA

**ENSINO PERSONALIZADO DE MATEMÁTICA:
OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS**

Videira
2026

THALES FERREIRA BATISTA

**ENSINO PERSONALIZADO DE MATEMÁTICA:
OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS**

Trabalho de Conclusão de Curso apresentado ao
Curso de graduação em Ciência da Computação
do Instituto Federal Catarinense – Campus Vi-
deira para obtenção do título de bacharel em Ci-
ência da Computação.

Orientador: Prof. Dr. Rafael Zanin (IFC)

Coorientador: Prof. Dr. Manassés Ribeiro (IFC)

Videira

2026

THALES FERREIRA BATISTA

**ENSINO PERSONALIZADO DE MATEMÁTICA:
OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS**

Este Trabalho de Curso foi julgado adequado para a obtenção do título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira.

Videira (SC), ____ de _____ de 2026

Prof. Dr. Rafael Zanin
Orientador
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Manassés Ribeiro
Coorientador
Instituto Federal Catarinense – Campus Videira

BANCA EXAMINADORA

Prof. Me. Fábio José Rodrigues Pinheiro
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Dani Prestini
Instituto Federal Catarinense – Campus Videira

Dedico este trabalho a...

AGRADECIMENTOS

Agradeço primeiramente...

*“A educação é a arma mais poderosa
que você pode usar para mudar o mundo.”*
(Nelson Mandela)

RESUMO

Este trabalho propôs uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada no mapeamento e na análise da literatura científica. O relato da revisão foi estruturado com apoio do PRISMA 2020. Foram identificados 11.904 registros em quatro fontes científicas; após a remoção determinística de 27 identidades DOI/URL, 11.877 seguiram para a triagem, 2.486 para a priorização operacional baseada em metadados e resumos e 18 foram retidos operacionalmente. O conjunto retido compreende 17 candidatos empíricos provisórios e 1 protocolo ou proposta contextual, não incluído na síntese de evidências. Dos candidatos empíricos, 12 tiveram textos primários consultados e cinco foram apreciados com base em resumos e metadados. A apreciação metodológica preliminar pelo MMAT 2018 manteve separadas as respostas a cada critério, sem cálculo de pontuação geral ou ranking de qualidade. A síntese identificou exemplos localizados de limitações no relato de denominadores e alocação, duração reportada, combinação de componentes de intervenção e independência entre itens de escala e preditores; a cobertura não permite estimar a frequência desses problemas. Explicabilidade, integração curricular, participação docente, equidade e reprodutibilidade foram tratadas como requisitos de projeto ou questões para investigação, não como ausências comprovadas em toda a literatura. Com base nessa análise e na fundamentação pedagógica, foram definidos requisitos funcionais e não funcionais, critérios para seleção de fontes de dados e modelos, um protocolo de avaliação e uma arquitetura de referência. Os resultados reforçaram que desempenho observado, probabilidade preditiva, proficiência estimada, competência e aprendizagem não são conceitos equivalentes. Uma probabilidade preditiva não demonstra, isoladamente, eficácia pedagógica, e as saídas computacionais devem apoiar, e não substituir, a interpretação docente. O protocolo foi proposto, sem execução empírica própria. Como contribuições, o trabalho produziu uma síntese estruturada com artefatos versionados para reprodução do snapshot, um *pipeline* automatizado de revisão e uma especificação técnica e pedagógica auditável.

Palavras-chave: ensino de matemática; aprendizado de máquina; revisão sistemática; avaliação de competências; especificação de protótipo.

ABSTRACT

This work proposed a technical and pedagogical prototype specification to support teachers' interpretation of students' learning of mathematics, grounded in the mapping and analysis of the scientific literature. The review was reported with support from PRISMA 2020. A total of 11,904 records were identified across four scientific sources; after the deterministic removal of 27 DOI/URL identity duplicates, 11,877 proceeded to screening, 2,486 entered operational prioritization based on metadata and abstracts, and 18 were operationally retained. The retained set comprises 17 provisional empirical candidates and one contextual protocol or proposal, excluded from the evidence synthesis. Of the empirical candidates, 12 primary texts were consulted and five were assessed from abstracts and metadata. The preliminary MMAT 2018 appraisal preserved criterion-level responses without an overall score or quality ranking. The synthesis identified source-specific examples of limitations in reporting denominators and allocation, reported duration, combined intervention components, and independence between scale items and predictors; the available coverage does not support prevalence estimates. Explainability, curriculum integration, teacher participation, equity, and reproducibility were treated as design requirements or research questions, not as demonstrated absences across the literature. The study defined functional and non-functional requirements, data and model selection criteria, an evaluation protocol, and a reference architecture. The results reinforced that observed performance, predictive probability, estimated proficiency, competence, and learning are not equivalent concepts. Predictive probability alone does not demonstrate pedagogical effectiveness, and computational outputs should support, rather than replace, teacher interpretation. The proposed evaluation protocol was not empirically executed. Contributions include a structured literature synthesis with versioned snapshot artifacts, an automated review pipeline, and an auditable technical and pedagogical specification.

Keywords: mathematics education; machine learning; systematic review; competency assessment; prototype specification.

LISTA DE ILUSTRAÇÕES

Fluxograma 1 – Fluxo de seleção da revisão sistemática.	35
Gráfico 1 – Registros do snapshot após deduplicação, por fonte científica.	37

LISTA DE QUADROS

Quadro 1 – Camadas da estratégia de busca bilíngue.	26
Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão.	27
Quadro 3 – Síntese dos candidatos empíricos provisórios retidos.	38
Quadro 4 – Reavaliação documental preliminar dos estudos atuais com o MMAT 2018.	43
Quadro 5 – Mapeamento do relato aos itens do PRISMA 2020.	64

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da revisão sistemática.	36
---	----

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
ACO	<i>Ant Colony Optimization</i> (Otimização por Colônia de Formigas)
ANN	<i>Artificial Neural Networks</i> (Redes Neurais Artificiais)
API	<i>Application Programming Interface</i> (Interface de Programação de Aplicações)
BNCC	Base Nacional Comum Curricular
CNN	<i>Convolutional Neural Networks</i> (Redes Neurais Convolucionais)
DL	<i>Deep Learning</i> (Aprendizado Profundo)
DOI	<i>Digital Object Identifier</i>
DT	<i>Decision Trees</i> (Árvores de Decisão)
EDM	<i>Educational Data Mining</i> (Mineração de Dados Educacionais)
IA	Inteligência Artificial
IFC	Instituto Federal Catarinense
IOM	<i>Institute of Medicine</i>
KNN	<i>K-Nearest Neighbors</i> (K-Vizinhos Mais Próximos)
LA	<i>Learning Analytics</i> (Analítica da Aprendizagem)
LIME	<i>Local Interpretable Model-agnostic Explanations</i>
LR	<i>Logistic Regression</i> (Regressão Logística)
ML	<i>Machine Learning</i> (Aprendizado de Máquina)
MMAT	<i>Mixed Methods Appraisal Tool</i>
NB	<i>Naive Bayes</i>
NLP	<i>Natural Language Processing</i> (Processamento de Linguagem Natural)
PICOS	<i>Population, Intervention, Comparison, Outcomes, Study Design</i>
PISA	<i>Programme for International Student Assessment</i>
PRISMA	<i>Preferred Reporting Items for Systematic Reviews and Meta-Analyses</i>

PRISMA-P	<i>Preferred Reporting Items for Systematic Review and Meta-Analysis Protocols</i>
RF	<i>Random Forest</i> (Floresta Aleatória)
RL	<i>Reinforcement Learning</i> (Aprendizado por Reforço)
SAEB	Sistema de Avaliação da Educação Básica
SHAP	<i>SHapley Additive exPlanations</i>
SMOTE	<i>Synthetic Minority Over-sampling Technique</i>
STEM	<i>Science, Technology, Engineering, Mathematics</i>
STI	Sistemas Tutores Inteligentes
SVM	<i>Support Vector Machines</i> (Máquinas de Vetores de Suporte)
TCC	Trabalho de Conclusão de Curso
XAI	<i>eXplainable Artificial Intelligence</i> (Inteligência Artificial Explicável)

SUMÁRIO

1	INTRODUÇÃO	15
1.1	Justificativa	15
1.2	Problema de Pesquisa	16
1.3	Objetivos	16
1.3.1	Objetivo Geral	16
1.3.2	Objetivos Específicos	16
1.4	Estrutura do Trabalho	17
2	FUNDAMENTAÇÃO TEÓRICA	18
2.1	Aprendizagem Matemática e Evidências de Desempenho	18
2.2	Contribuições Pedagógicas para a Especificação	19
2.3	Tecnologia como Apoio à Decisão Pedagógica	20
2.4	Técnicas Computacionais na Educação	20
2.5	Avaliação Automatizada e Métricas	22
2.6	Requisitos Derivados da Fundamentação	23
3	METODOLOGIA	25
3.1	Protocolo e Relato da Revisão Sistemática	25
3.2	Estratégia de Busca	26
3.3	Critérios de Seleção	27
3.4	Processo de Seleção	28
3.4.1	Identificação	28
3.4.2	Deduplicação e Triagem	29
3.4.3	Priorização operacional e verificação de escopo	29
3.5	Infraestrutura Tecnológica da Revisão	30
3.6	Avaliação da Qualidade Metodológica	31
3.7	Derivação da Especificação do Protótipo	32
3.8	Apoio à Pesquisa	33
4	REVISÃO SISTEMÁTICA DA LITERATURA	34
4.1	Fluxo de Seleção	34
4.2	Estatísticas Descritivas	35
4.3	Síntese dos Estudos Incluídos	37

4.4	Avaliação Metodológica com o MMAT	42
4.5	Tendências e Lacunas	44
4.6	Limitações e Contribuições da Revisão	45
5	ESPECIFICAÇÃO DO PROTÓTIPO	47
5.1	Princípios e Requisitos	47
5.2	Dados, Modelagem e Avaliação	50
5.3	Arquitetura de Referência	52
6	RESULTADOS E DISCUSSÃO	53
6.1	Resultados da Revisão Sistemática	53
6.2	Resultados da Avaliação Metodológica	53
6.3	Resultados da Fundamentação Pedagógica	54
6.4	Resultados da Especificação do Protótipo	55
6.5	Atendimento aos Objetivos	55
6.6	Discussão Integrada	56
7	CONCLUSÃO	57
7.1	Contribuições do Trabalho	57
7.2	Limitações	58
7.3	Continuidade da Pesquisa	58
	REFERÊNCIAS	60
APÊNDICE A	MAPEAMENTO DO RELATO AO PRISMA 2020	64

1 INTRODUÇÃO

O ensino de matemática enfrenta o desafio de atender estudantes com conhecimentos prévios, ritmos e dificuldades diferentes. Em turmas numerosas, o acompanhamento individual exige tempo, instrumentos adequados e interpretação pedagógica dos dados produzidos nas atividades. Técnicas computacionais podem apoiar esse processo ao organizar evidências de desempenho e tornar padrões mais visíveis, mas suas respostas não substituem a avaliação do professor nem representam, isoladamente, a aprendizagem do estudante.

Nesse contexto, recursos como aprendizado de máquina (*machine learning*), analítica da aprendizagem (*learning analytics*) e sistemas tutores inteligentes têm sido investigados para apoiar avaliações diagnósticas, estimar níveis de proficiência e orientar intervenções pedagógicas (Uskov et al., 2019; Tjahyadi; Tude, 2025; Pejic; Molcer; Gulači, 2021). O uso responsável dessas técnicas requer clareza sobre os dados empregados, os limites das inferências e a relação entre as saídas computacionais e os objetivos educacionais.

1.1 JUSTIFICATIVA

A relevância deste trabalho decorreu de duas necessidades complementares. A primeira consistiu em organizar a literatura, dispersa entre diferentes bases e áreas de pesquisa, sobre técnicas computacionais aplicadas ao ensino de matemática. A segunda consistiu em transformar as evidências encontradas em requisitos técnicos e pedagógicos para uma especificação de protótipo voltada ao apoio do professor.

Para professores, uma síntese crítica auxilia na compreensão das abordagens investigadas, dos resultados reportados e das limitações metodológicas recorrentes. Para estudantes e instituições, a pesquisa contribui ao explicitar que desempenho observado, proficiência estimada, competência e aprendizagem são conceitos relacionados, porém não equivalentes. Na especificação, também foi prevista a distinção entre a probabilidade preditiva de um alvo definido — uma saída condicionada ao modelo e aos dados disponíveis — e o indicador de desempenho observado. Nenhuma dessas saídas, isoladamente, equivale a proficiência, competência, aprendizagem ou eficácia pedagógica.

1.2 PROBLEMA DE PESQUISA

Diante desse contexto, o trabalho respondeu ao seguinte problema de pesquisa: como estruturar uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática a partir das evidências e técnicas computacionais identificadas na literatura?

Essa finalidade pressupõe articular os registros de desempenho ao contexto pedagógico e à interpretação do professor. Não significa inferir aprendizagem diretamente de notas ou de probabilidades preditivas, nem demonstrar que a especificação proposta já avalia ou melhora. O alcance desta pesquisa permanece documental, sem validação educacional própria.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

Propor uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada no mapeamento e na análise da literatura científica.

1.3.2 Objetivos Específicos

O **OE1** consiste em categorizar as abordagens e técnicas computacionais e as finalidades pedagógicas descritas na literatura mapeada. O **OE2** consiste em identificar limitações e lacunas técnicas, pedagógicas, metodológicas e éticas no material examinado. O **OE3** consiste em formular a especificação técnica e pedagógica do protótipo, incluindo requisitos, critérios para seleção de fontes de dados e modelos e uma arquitetura de referência. O **OE4** consiste em propor um protocolo para orientar a avaliação futura do protótipo, contemplando aspectos técnicos e de adequação pedagógica, sem antecipar resultados experimentais.

A revisão sistemática, com relato apoiado pelo PRISMA 2020, a apreciação preliminar pelo MMAT e o *pipeline*, entendido como a sequência automatizada de etapas de processamento, constituíram os meios metodológicos para atender a esses objetivos. Sua descrição e seus artefatos foram preservados, assim como o recorte de publicações de 2015 a 2026.

O produto do trabalho é documental: uma revisão da literatura e uma especificação de protótipo. A delimitação dos procedimentos executados e das atividades empíricas não realizadas é apresentada no Capítulo 3.

1.4 ESTRUTURA DO TRABALHO

O documento está organizado em sete capítulos. O Capítulo 1 apresenta o contexto, a justificativa, o problema e os objetivos. O Capítulo 2 discute aprendizagem matemática, avaliação, técnicas computacionais e limites das inferências baseadas em dados. O Capítulo 3 delimita o escopo executado e descreve a revisão sistemática, a estratégia de busca, os critérios de seleção, o processo de deduplicação, o PRISMA, o MMAT e o procedimento de derivação da especificação. O Capítulo 4 apresenta o fluxo de seleção, a síntese dos estudos, a avaliação por critérios e as lacunas identificadas. O Capítulo 5 consolida os princípios, requisitos, critérios de dados e modelagem, protocolo de avaliação e arquitetura de referência do protótipo. O Capítulo 6 integra os resultados da revisão, da apreciação metodológica, da fundamentação e da especificação. Por fim, o Capítulo 7 sintetiza as contribuições, as limitações e as possibilidades de continuidade da pesquisa.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 APRENDIZAGEM MATEMÁTICA E EVIDÊNCIAS DE DESEMPENHO

No referencial curricular adotado, os saberes matemáticos envolvem mais do que a execução de procedimentos. A Base Nacional Comum Curricular (BNCC) associa o letramento matemático às capacidades de raciocinar, representar, comunicar e argumentar matematicamente, além de formular e resolver problemas em contextos variados (Brasil, 2018).

A BNCC define competência pela mobilização de conhecimentos, habilidades, atitudes e valores para resolver demandas complexas (Brasil, 2018). Neste trabalho, esse referencial orienta o cuidado de não reduzir competência matemática ao resultado observado em uma única atividade.

Para evitar que medidas distintas fossem tratadas como equivalentes, este trabalho adotou definições operacionais. A avaliação educacional parte de observações produzidas por tarefas e respostas para realizar inferências sobre conhecimentos e habilidades; essas inferências dependem do modelo de cognição, dos instrumentos e dos procedimentos de mensuração empregados (National Research Council, 2001). Em avaliações como o PISA, a proficiência é estimada em uma escala e interpretada por níveis que descrevem o que os estudantes tipicamente conseguem realizar (OECD, 2023).

Desempenho observado corresponde ao registro diretamente obtido em uma tarefa, como acerto, nota, número de tentativas, estratégia apresentada ou tempo de resolução (National Research Council, 2001). **Proficiência estimada** corresponde a uma inferência sobre a posição do estudante em uma escala de conhecimentos e habilidades, calculada a partir de um conjunto de evidências e de um modelo de mensuração (National Research Council, 2001; OECD, 2023). **Competência** refere-se à mobilização de conhecimentos, habilidades, atitudes e valores para enfrentar situações e resolver problemas (Brasil, 2018). Por sua vez, **aprendizagem** designa, operacionalmente neste trabalho, mudanças no que o estudante sabe e consegue fazer ao longo do tempo. Essa delimitação orienta a exigência de acompanhamento e interpretação contextualizada, sem pressupor que um indicador isolado demonstre tais mudanças. A distinção entre o conhecimento do estudante e a observação de sua atuação se apoia no caráter inferencial da avaliação discutido por National Research Council (2001, pp. 42–44).

Essas definições são relacionadas, mas não intercambiáveis. Um modelo computacional pode reconhecer padrões nos dados de desempenho e produzir estimativas para um alvo

definido; sua interpretação como proficiência requer um modelo de mensuração e evidências de validade para essa finalidade. Entretanto, o modelo não observa diretamente todos os processos cognitivos, sociais e afetivos envolvidos na aprendizagem. Suas saídas devem ser interpretadas como apoio à análise docente, e não como diagnóstico definitivo do estudante.

2.2 CONTRIBUIÇÕES PEDAGÓGICAS PARA A ESPECIFICAÇÃO

Os referenciais a seguir foram mobilizados para orientar aspectos distintos da especificação: mediação, conhecimento prévio e uso formativo de evidências. Essa articulação constitui uma escolha de projeto do trabalho, não uma afirmação de equivalência entre as teorias nem uma demonstração de eficácia do protótipo.

Vygotsky definiu a Zona de Desenvolvimento Proximal como a distância entre aquilo que o estudante realiza de forma autônoma e aquilo que consegue realizar com mediação (Vygotsky, 1978). O conceito de *scaffolding* foi formulado posteriormente por Wood, Bruner e Ross para descrever um suporte temporário oferecido durante a resolução de problemas e retirado gradualmente conforme aumenta a autonomia do aprendiz (Wood; Bruner; Ross, 1976). Na especificação proposta, a apresentação das evidências ao professor deve permitir que ele avalie a necessidade de apoio, sem tratar a saída computacional como medida da Zona de Desenvolvimento Proximal.

Ausubel destacou que novas informações são aprendidas de forma significativa quando se relacionam a conhecimentos relevantes já existentes na estrutura cognitiva do estudante (Ausubel, 1968). A partir desse referencial, o trabalho propõe organizar registros de atividades anteriores e relações curriculares como contexto para a interpretação docente. Esse requisito não autoriza inferir ausência de compreensão apenas pela ausência de acerto, sem considerar a natureza da tarefa e a estratégia utilizada.

A avaliação formativa utiliza evidências produzidas durante o processo de aprendizagem para orientar decisões sobre as próximas ações de ensino e estudo (Black; Wiliam, 1998). A efetividade do *feedback* depende de seu foco, de sua clareza e da forma como ajuda o estudante a compreender os objetivos, avaliar seu estado atual e identificar ações para avançar (Hattie; Timperley, 2007). Na síntese desta revisão, os resultados de avaliação reportados pelos estudos empíricos não foram interpretados por este trabalho como equivalentes a uma teoria de aprendizagem ou como prova geral de eficácia pedagógica.

Uma previsão algorítmica, por si só, não constitui *feedback* formativo. Para cum-

prir essa função, a saída precisa ser traduzida em informação compreensível, contextualizada e pedagogicamente acionável, preservando a possibilidade de interpretação e intervenção do professor.

2.3 TECNOLOGIA COMO APOIO À DECISÃO PEDAGÓGICA

As tecnologias computacionais podem processar grandes volumes de registros, identificar regularidades e apresentar visualizações que auxiliem o acompanhamento de turmas. Seu valor educacional não decorre apenas da acurácia de um modelo, mas da qualidade dos dados, da interpretação das saídas e da forma como a informação é incorporada à prática docente.

A adoção dessas tecnologias deve preservar a responsabilidade do professor pela interpretação das evidências e pela decisão de intervenções. As previsões precisam apresentar incertezas e limitações, e dados socioeconômicos ou comportamentais não devem ser usados para naturalizar desigualdades ou reduzir estudantes a categorias fixas. As recomendações devem estar alinhadas ao currículo e aos objetivos da atividade, considerando privacidade, consentimento e finalidade de uso dos dados desde o planejamento.

2.4 TÉCNICAS COMPUTACIONAIS NA EDUCAÇÃO

O aprendizado de máquina, ou *machine learning* (ML), é uma área da Inteligência Artificial que desenvolve modelos capazes de identificar padrões a partir de dados. Em educação matemática, suas aplicações incluem a predição de desempenho acadêmico (Sokkhey et al., 2020) e a classificação de níveis de proficiência em avaliações educacionais (Pejic; Molcer; Gulači, 2021). Outra finalidade investigada é a otimização de trajetórias personalizadas de aprendizagem (Zhang; Zhu; Feng, 2025).

Uma tarefa distinta foi investigada por He et al. (2025): a modelagem preditiva de tamanhos de efeito de tecnologias educacionais para matemática, a partir de dados extraídos de publicações. Nesse componente do estudo, a unidade de análise é a evidência sobre intervenções, e não a proficiência de um estudante. Essa distinção entre alvo e unidade de análise deve orientar a interpretação das aplicações de ML e a escolha de dados para um sistema de apoio docente.

A definição do alvo e da unidade de análise antecede a escolha do algoritmo: estimar categorias de desempenho de estudantes e prever resultados agregados de intervenções são

problemas distintos. Árvores de decisão organizam previsões por divisões sucessivas dos atributos dos dados. O *Random Forest* combina previsões de várias árvores, treinadas com amostragem de registros e seleção aleatória de atributos nas divisões (Breiman, 2001). As máquinas de vetores de suporte (SVM) procuram separar classes por uma fronteira com margem ampla; funções de *kernel* permitem representar separações não lineares (Cortes; Vapnik, 1995). Redes neurais combinam unidades parametrizadas em camadas, cujos pesos são ajustados a partir dos dados (James et al., 2021, cap. 8–10). Essas definições identificam famílias de modelos e não demonstram que alguma delas seja superior para todos os contextos educacionais.

A comparação deve incluir um modelo simples de referência, ou *baseline*, como a predição pela classe majoritária em classificação ou pela média do conjunto de treinamento em regressão. O desbalanceamento de classes ocorre quando suas frequências diferem substancialmente. Nesse caso, a acurácia, definida como a proporção de classificações corretas, pode esconder erros nas classes menos frequentes. Por isso, as métricas devem ser escolhidas conforme o alvo, a distribuição dos dados e os tipos de erro relevantes, com avaliação em dados não utilizados no ajuste do modelo (James et al., 2021, cap. 2 e 4). O termo *benchmarking* designa essa comparação de modelos sob condições e métricas definidas, não uma certificação de superioridade geral.

Na síntese dos estudos, DT e RF designam árvores de decisão e *Random Forest*; RN indica redes neurais e MLP, redes neurais multicamadas. NB indica o classificador probabilístico *Naive Bayes*, baseado na hipótese de independência condicional dos atributos (James et al., 2021, cap. 4 e 10). JRip é uma implementação que aprende regras de classificação.¹ CRF designa campos aleatórios condicionais, modelos probabilísticos para rotular dados em sequência (Lafferty; McCallum; Pereira, 2001). DL designa aprendizado profundo; RL, aprendizado por reforço; CNN, redes neurais convolucionais; e ACO, otimização por colônia de formigas. Esses nomes identificam métodos reportados, não alternativas equivalentes nem escolhas já validadas para o protótipo.

A *Learning Analytics* (LA), ou analítica da aprendizagem, envolve medir, coletar, analisar e apresentar dados sobre estudantes e seus contextos para compreender e apoiar a aprendizagem. A *Educational Data Mining* (EDM), ou mineração de dados educacionais, concentra-se no desenvolvimento e na aplicação de métodos de análise a dados educacionais (Romero; Ventura, 2020).

¹ A documentação oficial do Weka identifica JRip como implementação do algoritmo RIPPER: <<https://weka.sourceforge.io/doc.dev/weka/classifiers/rules/JRip.html>>. Acesso em: 7 out. 2026.

ML, LA e EDM não são sinônimos. ML designa uma família de métodos de aprendizado a partir de dados, enquanto LA e EDM delimitam campos de investigação e aplicação na educação. Ambos podem empregar ML, estatística e visualização, com sobreposição de métodos e finalidades; a distinção não constitui uma separação rígida entre ferramentas. Neste trabalho, essa relação organiza a leitura das técnicas e de seus usos pedagógicos (Romero; Ventura, 2020).

Essas áreas podem produzir painéis, alertas e modelos de conhecimento, mas a existência de uma correlação não prova uma relação causal. Um padrão de acesso ou tempo de resposta pode refletir diferentes condições, como conhecimento prévio, familiaridade com a interface, acessibilidade ou disponibilidade de conexão.

Sistemas Tutores Inteligentes procuram adaptar a interação ao estado estimado do estudante. A literatura descreve esses sistemas por características como representação do estudante, mecanismos de adaptação, estratégias de orientação e formas de interação (Mousavinasab et al., 2021). Sistemas adaptativos também podem selecionar conteúdos ou ajustar a dificuldade conforme os registros de interação (Xie et al., 2019).

A adaptação é pedagogicamente relevante quando os critérios de decisão são compreensíveis e quando o estudante continua exposto a desafios que promovam autonomia. Uma personalização excessiva ou baseada em dados incompletos pode limitar oportunidades de aprendizagem e reforçar classificações anteriores.

Os métodos computacionais devem ser distinguidos das estratégias didáticas que podem acompanhar seu uso. O termo *jigsaw*, empregado na síntese do estudo sobre geometria, identifica uma modalidade de aprendizagem cooperativa: participantes estudam partes do conteúdo em grupos de especialistas e compartilham essa aprendizagem com seu grupo de origem.² Essa explicação esclarece o termo, sem afirmar que todas as condições do procedimento foram verificadas no estudo retido.

2.5 AVALIAÇÃO AUTOMATIZADA E MÉTRICAS

Sistemas automatizados podem organizar respostas, calcular indicadores e aplicar regras previamente definidas. Em tarefas de classificação, podem ser empregadas acurácia, precisão, revocação (*recall*), medida F1 e área sob a curva ROC (Romero; Ventura, 2020). A escolha depende do alvo e da distribuição das classes; essas métricas não se aplicam indistintamente

² Descrição do procedimento no site oficial *The Jigsaw Classroom*, etapas 3–8: <<https://www.jigsaw.org/>>. Acesso em: 7 out. 2026.

à predição de valores contínuos. Elas avaliam o comportamento do modelo e não medem diretamente a qualidade pedagógica da intervenção.

A matriz de confusão organiza as contagens de classes observadas e previstas. Para uma classe examinada, precisão indica a proporção de previsões dessa classe que estão corretas, enquanto revocação indica a proporção de seus casos observados que foi reconhecida. F1 é a média harmônica dessas duas medidas; em problemas multiclasse, sua agregação também precisa ser especificada. Kappa quantifica a concordância entre duas categorizações, descontando o acordo esperado ao acaso. A interpretação desses indicadores exige preservar a tarefa e a forma de cálculo utilizada pelo estudo, sem adotá-los como medidas de aprendizagem.³

A curva ROC relaciona a taxa de casos positivos corretamente reconhecidos à taxa de falsos positivos, variando o limiar de decisão; sua área resume a capacidade de discriminação sob essa análise (Fawcett, 2006). A calibração, por sua vez, examina a correspondência entre probabilidades estimadas e frequências observadas dos eventos. Discriminar classes e estimar probabilidades confiáveis são propriedades distintas: uma área ROC elevada não garante, por si só, probabilidades calibradas (Niculescu-Mizil; Caruana, 2005).

No domínio educacional, também podem ser observados acertos e erros por habilidade, tempo e número de tentativas, progressão entre avaliações, participação e conclusão de atividades e explicações ou estratégias registradas pelo estudante.

A interpretação deve considerar o instrumento, a população e a finalidade. Um modelo com bom desempenho médio pode apresentar erros sistemáticos para determinados grupos. Por isso, a avaliação técnica deve incluir análise por classe, validação em dados não utilizados no treinamento e investigação de possíveis vieses.

2.6 REQUISITOS DERIVADOS DA FUNDAMENTAÇÃO

A fundamentação teórica sustentou requisitos para a especificação do protótipo: apresentar evidências de desempenho sem tratá-las como medida completa de aprendizagem; relacionar indicadores aos descritores e objetivos curriculares; oferecer explicações compreensíveis ao professor; registrar incertezas e limitações do modelo; permitir revisão humana das recomendações; proteger os dados educacionais; e exigir avaliação técnica antes de qualquer afirmação de eficácia pedagógica.

³ Definições e convenções de cálculo: documentação oficial do scikit-learn 1.6, seção 3.4, disponível em <https://scikit-learn.org/1.6/modules/model_evaluation.html>. Acesso em: 7 out. 2026.

Esses requisitos foram incorporados à especificação apresentada no Capítulo 5. Dessa forma, a fundamentação não permaneceu apenas como discussão conceitual, mas orientou diretamente as decisões técnicas e pedagógicas consolidadas pelo trabalho.

3 METODOLOGIA

3.1 PROTOCOLO E RELATO DA REVISÃO SISTEMÁTICA

Este trabalho empregou uma Revisão Sistemática da Literatura para identificar e analisar técnicas computacionais aplicadas ao ensino de matemática. O *Cochrane Handbook for Systematic Reviews of Interventions* (Higgins et al., 2023) e referências do *Institute of Medicine* (IOM) foram consultados como referências gerais de transparência e sistematicidade. Essa consulta não implica adoção integral de um protocolo Cochrane ou de um modelo formal do IOM.

O escopo executado compreendeu a revisão sistemática da literatura, a apreciação metodológica preliminar dos candidatos empíricos retidos e a elaboração de uma especificação conceitual de protótipo. Essa especificação consolidou princípios pedagógicos, requisitos, critérios para seleção de fontes de dados e modelos, procedimentos de avaliação e uma arquitetura de referência.

O desenvolvimento de uma aplicação funcional, o treinamento de modelos com uma base definitiva e a validação com participantes não integraram o escopo empírico desta pesquisa. Por essa razão, o trabalho não atribuiu ao protótipo métricas próprias de acurácia nem alegou eficácia pedagógica. Essa delimitação preservou a correspondência entre as afirmações apresentadas e os artefatos efetivamente produzidos.

O PRISMA 2020 (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) foi utilizado como diretriz de relato da revisão (Page et al., 2021). Sua função neste trabalho foi orientar a comunicação transparente da pergunta de pesquisa, das fontes consultadas, dos critérios de elegibilidade, do processo de seleção e dos resultados. Portanto, o PRISMA 2020 foi tratado como uma diretriz para relatar a revisão, e não como um método de busca, um instrumento de avaliação da qualidade ou uma garantia automática de ausência de viés.

O PRISMA-P 2015 (*Preferred Reporting Items for Systematic Review and Meta-Analysis Protocols*) possui finalidade distinta: orientar o desenvolvimento e o relato de protocolos de revisões sistemáticas (Moher et al., 2015). A revisão não foi registrada prospectivamente e, por isso, não se afirma conformidade integral com o PRISMA-P. Antes da execução, foram definidos a questão de pesquisa, os critérios de elegibilidade, a estratégia de busca, o processo de seleção e a forma de síntese. Esses elementos correspondem a princípios presentes no PRISMA-P, mas seu uso foi parcial e deve ser interpretado considerando a ausência de registro

prospectivo. O checklist de relato PRISMA 2020 encontra-se no Apêndice A.

O checklist PRISMA 2020 foi preenchido retrospectivamente, depois da consolidação do snapshot e da conferência dos artefatos versionados. Neste trabalho, snapshot designa a versão congelada dos registros e das decisões utilizada na análise, distinguindo-a de uma nova coleta. O checklist documenta como a revisão foi relatada; não constitui registro prospectivo do protocolo nem substitui a descrição das decisões efetivamente tomadas durante a execução.

3.2 ESTRATÉGIA DE BUSCA

A coleta de dados foi realizada por meio de interfaces de programação de aplicações (APIs), que permitem consultar serviços externos de forma automatizada. Foram utilizadas quatro fontes científicas complementares: Semantic Scholar, fonte multidisciplinar; OpenAlex, catálogo acadêmico aberto; Crossref, fonte de metadados bibliográficos e identificadores DOI; e CORE, agregador de publicações disponibilizadas em acesso aberto.

O uso de múltiplas fontes foi adotado para ampliar a cobertura da busca e reduzir a dependência de uma única base. Essa escolha não demonstra exaustividade da recuperação. Também exigiu uma etapa de normalização, pois o mesmo estudo poderia ser recuperado com diferenças de título, autores ou demais metadados.

A estratégia de busca combinou três camadas de termos: domínio matemático, técnica computacional e contexto educacional, sintetizadas no Quadro 1. O operador booleano AND foi utilizado para exigir a presença conjunta dessas dimensões. As grafias dos termos foram preservadas conforme a configuração executada, inclusive as formas sem acentuação.

Quadro 1 – Camadas da estratégia de busca bilíngue.

Dimensão	Inglês	Português
Domínio matemático	mathematics; math	matemática
Técnicas computacionais	adaptive; personalized; tutoring; analytics; mining; machine learning; ai; assessment; student modeling; predictive; intelligent tutor; artificial intelligence	adaptivo; personalizado; tutor; analítica; mineração; aprendizado de máquina; ia; avaliação; modelagem do aluno; preditivo; tutor inteligente; inteligência artificial
Contexto educacional	education; learning	educacao; ensino

Fonte: Elaborado pelo autor (2026).

A estratégia canônica foi composta por 72 consultas: 48 em inglês e 24 em português. O conjunto dessas consultas está versionado nos artefatos do estudo; como não foi

preservado um log histórico completo das requisições, esse número descreve a composição da estratégia, e não uma contagem retrospectiva de chamadas HTTP concluídas em cada API. Em cada consulta, um termo do domínio matemático foi combinado, pelo operador AND, com um termo computacional e um termo educacional. Por exemplo, a combinação em inglês foi `mathematics AND machine learning AND education`; em português, `matemática AND aprendizado de máquina AND educacao`. Esses exemplos ilustram a composição dos termos e não substituem as consultas versionadas.

3.3 CRITÉRIOS DE SELEÇÃO

Os critérios de inclusão e exclusão foram organizados com apoio do PICOS, apresentado no Quadro 2. Trata-se de uma adaptação ao mapeamento de técnicas computacionais na educação matemática: o capítulo 3 do *Cochrane Handbook*, seções 3.2 e 3.3, articula população, intervenção, comparação e resultados (PICO) à especificação dos desenhos de estudo (McKenzie et al., 2024). Neste trabalho, a letra S explicita essa última dimensão. A adaptação não implica execução de uma revisão Cochrane de efeitos de intervenções nem torna obrigatório um comparador para todos os estudos computacionais.

Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão.

Dimensão	Aplicação ao trabalho
P – População	Estudantes de matemática em qualquer nível educacional.
I – Intervenção	Aplicação de técnicas computacionais, como aprendizado de máquina, inteligência artificial, analítica da aprendizagem e sistemas tutores inteligentes.
C – Comparação	Abordagens pedagógicas alternativas ou tradicionais, quando disponíveis.
O – Resultados	Desempenho acadêmico, diagnóstico de competências, avaliação ou personalização do ensino, conforme a finalidade declarada no estudo.
S – Desenho de estudo	Estudos empíricos com descrição metodológica e evidências aplicadas.

Fonte: Elaborado pelo autor (2026).

O período de 2015 a 2026 foi definido para abranger a produção científica considerada no snapshot da revisão, com data de corte em 31 de agosto de 2026. O recorte concentrou a análise em abordagens compatíveis com a especificação desenvolvida no trabalho.

Os critérios de inclusão abrangeram artigos completos revisados por pares, teses de doutorado ou dissertações de mestrado, publicados nesse período, com foco explícito em técnicas computacionais aplicadas ao ensino de matemática. Exigiu-se a apresentação de dados empíricos, metodologia ou evidência de desenvolvimento e avaliação de sistemas, em texto redi-

gido em inglês ou português. Teses e dissertações foram consideradas como literatura cinzenta, sob os mesmos critérios de elegibilidade.

Os critérios de exclusão compreenderam metodologia insuficientemente descrita para responder à questão da revisão, foco apenas indireto no ensino ou na aprendizagem de matemática e publicações teóricas sem evidências empíricas compatíveis com o escopo. Também foram considerados inelegíveis editoriais, comentários, erratas e relatórios internos que não correspondessem aos tipos documentais elegíveis, além de textos em idiomas diferentes de inglês e português.

3.4 PROCESSO DE SELEÇÃO

O relato do processo considera os itens aplicáveis do PRISMA 2020, mas o fluxograma desta revisão é uma representação operacional própria, não o diagrama PRISMA completo. Após a triagem, o pipeline aplicou uma priorização heurística baseada em metadados e resumos. Essa etapa não corresponde à avaliação de elegibilidade de relatórios recuperados; por isso, seus resultados são descritos como priorização operacional e retenção provisória, sem afirmar inclusão final universal.

3.4.1 Identificação

O snapshot versionado preserva 11.904 registros identificados. A configuração canônica da busca contém 72 consultas para as quatro APIs; entretanto, a ausência de um log histórico completo impede reconstruir quantas requisições HTTP foram concluídas por consulta ou por API. O pipeline foi configurado com limite de até 50 resultados por consulta e por API, parâmetro operacional que deve ser considerado na interpretação da cobertura. Cada registro armazenou, quando disponível, título, autores, ano, veículo de publicação, DOI ou endereço eletrônico e resumo.

O corte temporal declarado da busca foi 31 de agosto de 2026. A adjudicação de escopo da população foi concluída em 3 de setembro de 2026; o manifesto de reprodutibilidade registra a geração dos artefatos em 4 de setembro de 2026, às 02:45:33 UTC. As datas correspondem, respectivamente, ao limite temporal da busca, à consolidação de escopo e à geração do snapshot. Como não foram preservados logs por consulta e por API, não é possível reconstruir o instante de cada requisição nem afirmar que todas as fontes foram consultadas exatamente na data de corte; essa limitação restringe o detalhamento da data de última busca por fonte.

3.4.2 Deduplicação e Triagem

A deduplicação utilizada no fluxo PRISMA foi determinística e baseada na identidade bibliográfica normalizada. Registros com o mesmo DOI normalizado ou com a mesma URL exata foram reunidos, preservando-se a representação escolhida para o fluxo; essa etapa removeu 27 linhas excedentes, sendo 25 identificadas por DOI e 2 por URL. A auditoria também calculou repetições de títulos normalizados. Contudo, os 232 excedentes restantes após a remoção por DOI/URL foram mantidos como candidatos à revisão semântica, pois títulos semelhantes ou idênticos podem corresponder a versões, erratas ou obras distintas. Portanto, não foram removidos automaticamente por título e não entram como duplicatas confirmadas no fluxo vigente.

Após a deduplicação determinística, 11.877 registros foram submetidos à triagem. Desses, 9.391 foram excluídos e 2.486 avançaram para a priorização operacional. Essa etapa não equivale à avaliação de elegibilidade de relatórios em texto completo.

3.4.3 Priorização operacional e verificação de escopo

A etapa de priorização operacional utilizou uma pontuação de relevância temática, distinta da avaliação de qualidade metodológica. A heurística considerou a presença e a relevância de técnicas computacionais, a aderência explícita ao ensino de matemática, a completude dos metadados e do resumo e a disponibilidade de identificadores e informações bibliográficas.

A pontuação foi um indicador operacional de relevância temática, calculado por uma heurística multicritério aplicada aos metadados e aos resumos disponíveis. No snapshot vigente, os valores observados variaram de 0,0 a 4,5 e o limiar operacional foi 4,0. O limiar apoiou a priorização e a seleção operacional, mas não constituiu medida de qualidade científica nem substituiu a verificação de escopo, tipo documental e pertinência. A apreciação metodológica foi conduzida separadamente com o MMAT 2018.

O valor 4,0 deve ser interpretado como um parâmetro de triagem do pipeline, e não como um ponto de corte validado para relevância científica. A retenção operacional também dependeu dos critérios documentais de decisão registrados em <research/data/current_eligibility_protocol.csv>. Como a confirmação em texto completo não foi concluída para todos os registros, o conjunto retido deve ser descrito como provisório. O snapshot vigente não inclui uma análise de sensibilidade do conjunto retido a diferentes limiares; portanto, não se atribui ao valor 4,0 estabilidade estatística ou capacidade de representar sozinho o universo da literatura.

Dos 2.486 registros submetidos a essa etapa, 2.468 foram excluídos pela heurística de priorização e pelas regras operacionais de escopo. Foram retidos 18 registros para adjudicação de escopo; 17 correspondem a candidatos empíricos provisórios e 1 corresponde a um protocolo ou proposta contextual. Apenas os 17 candidatos empíricos integram a síntese de evidências e a apreciação MMAT aplicável.

3.5 INFRAESTRUTURA TECNOLÓGICA DA REVISÃO

O fluxo automatizado da revisão foi implementado em Python. O SQLite foi utilizado para o armazenamento estruturado dos registros e das etapas de seleção; Requests, para comunicação com as APIs; Pandas, para manipulação e exportação de dados tabulares; e scikit-learn, como apoio às análises computacionais auxiliares do fluxo.

Foi utilizado um *cache* local, isto é, um armazenamento temporário de respostas previamente obtidas. Um acerto de cache ocorre quando uma nova solicitação pode ser atendida com um resultado já armazenado, sem consultar novamente a API externa. Como os contadores dependem do histórico e do momento de execução, a taxa de acertos não foi utilizada como indicador fixo do *pipeline*; sua interpretação permaneceu vinculada às estatísticas da execução analisada.

O código, os parâmetros de busca, os critérios de seleção e os artefatos derivados foram versionados no repositório. A reprodução do snapshot não depende da distribuição do banco SQLite: os registros, as decisões e as contagens podem ser verificados nos arquivos CSV, JSON e BibTeX versionados. Os principais comandos de verificação são:

```
python -m research.src.validation.versioned_snapshot
python -m research.src.processing.adjudicated_snapshot --check
python -m research.src.validation.bibliography_audit
```

A disponibilização do código e dos artefatos favorece a auditoria do processo. Entretanto, a reprodução exata dos resultados também depende da disponibilidade das APIs e das alterações realizadas por cada fonte ao longo do tempo.

O arquivo <research/exports/reports/reproducibility_manifest.json> funciona como índice de proveniência do snapshot: registra a data de geração, os hashes SHA-256 dos exports, o ledger corrente do MMAT, o manifesto de fontes primárias e os comandos de reconstrução.

Essa estrutura permite verificar a versão publicada sem distribuir o banco SQLite operacional e torna explícita a diferença entre uma reprodução do snapshot e uma nova coleta nas APIs.

3.6 AVALIAÇÃO DA QUALIDADE METODOLÓGICA

Os 17 candidatos empíricos provisórios foram submetidos a uma apreciação documental por critérios com o *Mixed Methods Appraisal Tool* (MMAT), versão 2018 (Hong et al., 2018). O protocolo ou proposta contextual retido não é uma evidência empírica e não se aplica à apreciação MMAT. O instrumento foi escolhido por oferecer conjuntos de critérios específicos para estudos qualitativos, quantitativos randomizados, quantitativos não randomizados, quantitativos descritivos e de métodos mistos; sua aplicação nesta versão é preliminar e limitada pela disponibilidade desigual dos textos primários.

Antes da apreciação específica, foram registradas as duas perguntas de triagem do instrumento: S1, “Há perguntas de pesquisa claras?”, e S2, “Os dados coletados permitem responder às perguntas de pesquisa?”. Em seguida, o processo compreendeu a classificação do desenho metodológico de cada estudo, o registro das respostas S1 e S2, a aplicação dos cinco critérios Q1–Q5 correspondentes ao desenho, o registro de cada célula como Y (“Sim”), N (“Não”) ou CT (“Não é possível concluir com a evidência disponível”) e a descrição das limitações identificadas em cada estudo.

As respostas não foram convertidas em pontuação geral, média, ranking ou categoria de qualidade. A apresentação por critério preserva quais aspectos metodológicos foram atendidos e quais permaneceram problemáticos ou insuficientemente descritos. Os estudos não foram excluídos em razão do MMAT; suas limitações foram consideradas na interpretação da síntese.

A avaliação foi realizada por um único revisor, embora o guia do MMAT recomende a participação independente de pelo menos dois avaliadores. Doze registros empíricos tiveram o texto primário consultado externamente, cinco foram apreciados com base em resumos e metadados e o registro contextual foi marcado como não aplicável. Nove textos estão arquivados; três foram consultados externamente, sem cópia no repositório: dois em páginas editoriais e um em cópia pública do texto integral, com identidade bibliográfica conferida pelo DOI. O ledger registra as fontes e os localizadores examinados. A verificação independente dos julgamentos e a adjudicação pelo supervisor ainda não estão completas; por isso, as respostas permanecem preliminares e não constituem uma síntese final de qualidade. A aplicação das perguntas de

triagem e dos critérios aos estudos, com seus resultados por célula, é apresentada na Seção 4.4.

Para Nyantah, Frempong e Larbi (2025, pp. 101–105), o texto primário apresenta afirmações incompatíveis sobre a alocação das escolas: uma seção descreve distribuição aleatória, enquanto outra caracteriza o estudo como quase-experimental sem alocação aleatória. Como a definição da categoria MMAT altera quais critérios Q1–Q5 são aplicáveis, a categoria desse estudo permanece pendente e essas cinco respostas foram mantidas como CT, sem inferir falha metodológica a partir da inconsistência documental.

O ledger de fontes primárias preserva, para cada registro, o identificador da fonte, a data de acesso, o tipo de fonte, a situação de recuperação e a base documental da apreciação. Quando apenas resumo e metadados estavam disponíveis, a insuficiência de acesso foi tratada como limitação da evidência e não como uma resposta negativa automática aos critérios. Essa distinção impede que a ausência do texto completo seja confundida com demonstração de falha metodológica do estudo.

3.7 DERIVAÇÃO DA ESPECIFICAÇÃO DO PROTÓTIPO

A especificação do protótipo foi elaborada a partir da integração entre os resultados da revisão sistemática e os princípios pedagógicos discutidos na fundamentação teórica. O procedimento consolidou as finalidades, técnicas e limitações identificadas nos 17 candidatos empíricos; agrupou as lacunas em dimensões técnicas, pedagógicas, metodológicas e éticas; traduziu essas dimensões em requisitos funcionais e não funcionais; definiu critérios para fontes de dados, alternativas de modelagem, explicabilidade e avaliação; e organizou os requisitos em uma arquitetura conceitual de referência.

As decisões foram registradas como especificação, e não como evidência de uma implementação funcional. Esse procedimento permitiu transformar os achados da literatura em um artefato técnico e pedagógico coerente com o escopo executado e com as limitações explicitadas no trabalho.

Na versão vigente, a rastreabilidade entre a revisão e a especificação está consolidada no nível das dimensões e dos requisitos descritos no capítulo. Uma matriz completa que associe cada requisito aos identificadores dos estudos que o sustentam ainda não foi concluída. Por isso, a especificação deve ser interpretada como uma derivação temática documentada, e não como uma atribuição exaustiva de cada requisito a uma fonte individual.

3.8 APOIO À PESQUISA

A pesquisa foi conduzida pelo autor com recursos próprios, sem financiamento externo. Não houve entidade financiadora externa com participação no delineamento, na seleção dos estudos, na análise ou na decisão de disponibilização dos resultados.


4 REVISÃO SISTEMÁTICA DA LITERATURA

Este capítulo apresenta os resultados da revisão sistemática desenvolvida no trabalho. O processo identificou 11.904 registros nas quatro fontes consultadas. Após a deduplicação determinística por identidade DOI/URL, 11.877 registros foram submetidos à triagem; 2.486 avançaram para a priorização operacional e 18 foram retidos provisoriamente. O corpus retido compreende 17 candidatos empíricos provisórios e 1 protocolo ou proposta contextual, que não integra a síntese de evidências. A pontuação operacional representou aderência temática ao problema de pesquisa; ela não foi interpretada como medida de qualidade científica.

4.1 FLUXO DE SELEÇÃO

O Fluxograma 1 apresenta uma representação operacional do processo de seleção, elaborada com referência ao PRISMA 2020. Ele não reproduz todas as etapas do diagrama padrão do PRISMA 2020: a priorização heurística dos 2.486 registros não equivale à avaliação de elegibilidade de relatórios recuperados. Após a identificação, 27 linhas excedentes foram removidas por identidade bibliográfica determinística: 25 por DOI normalizado e 2 por URL exata. Restaram 11.877 registros para a triagem. A triagem excluiu 9.391 registros e encaminhou 2.486 para a priorização operacional; nessa etapa, 2.468 foram excluídos e 18 foram retidos provisoriamente para adjudicação de escopo. A recuperação e a apreciação de textos primários foram desiguais entre os candidatos empíricos, conforme detalhado na Metodologia; portanto, a retenção não representa inclusão final universal.

Fluxograma 1 – Fluxo de seleção da revisão sistemática.



Auditoria de identidade: 25 excedentes DOI + 2 excedentes URL.
Repetições apenas por título permanecem para revisão.

Fonte: Elaborado pelo autor (2026).

4.2 ESTATÍSTICAS DESCRITIVAS

A Tabela 1 reúne os principais números da revisão. A auditoria de identidade registra as remoções determinísticas que entram no fluxo PRISMA e mantém separadas as repetições observadas apenas por título. Depois da remoção por DOI/URL, permaneceram 232 excedentes em grupos de título normalizado, tratados como candidatos à revisão semântica e não como duplicatas confirmadas. A pequena proporção de registros retidos decorreu do escopo específico e da aplicação do filtro operacional de relevância temática, seguida da verificação de escopo.

A taxa de acertos do *cache* não foi apresentada como métrica fixa. Um acerto ocorreu quando uma consulta foi atendida com uma resposta previamente armazenada, sem nova requisição à API. Como essa proporção dependeu do histórico de execução, sua interpretação permaneceu vinculada aos contadores registrados em cada execução do sistema.

Tabela 1 – Estatísticas descritivas da revisão sistemática.


Métrica	Valor
Registros identificados	11.904
Remoções determinísticas por DOI/URL	27 (0,23%)
Registros na triagem	11.877
Excluídos na triagem	9.391 (78,89%)
Registros submetidos à priorização operacional	2.486
Excluídos na priorização operacional	2.468 (99,28%)
Registros retidos operacionalmente	18
Candidatos empíricos provisórios	17
Protocolo/proposta contextual	1
Bases consultadas	4
Consultas bilíngues	72 (48 EN + 24 PT)
Período de cobertura	2015–2026

Fonte: Elaborado pelo autor (2026).

Os percentuais da tabela usam denominadores explicitados para evitar a leitura de taxas de etapas diferentes como se fossem equivalentes: 27 remoções correspondem a 0,23% dos 11.904 registros identificados; 9.391 exclusões na triagem correspondem a 78,89% dos mesmos 11.904 registros identificados; e 2.468 exclusões correspondem a 99,28% dos 2.486 registros submetidos à priorização operacional. Assim, o percentual da triagem descreve a parcela da população inicialmente identificada, não a proporção excluída apenas entre os registros efetivamente triados.

A distribuição por fonte é apresentada no Gráfico 1. O universo representado corresponde aos 11.877 registros do snapshot após a remoção determinística por DOI/URL, e não aos 11.904 registros brutos identificados. A fonte indica a procedência registrada para a representação preservada no snapshot; não mede a cobertura exclusiva de cada base nem a qualidade dos estudos. As quantidades e proporções foram calculadas a partir do export versionado, sem nova coleta.

Gráfico 1 – Registros do snapshot após deduplicação, por fonte científica.



Snapshot após deduplicação DOI/URL: n=11.877

Fonte: Elaborado pelo autor (2026).

4.3 SÍNTESE DOS ESTUDOS INCLUÍDOS

Entre os candidatos analisados, foram identificadas tarefas de predição de desempenho e de classificação ou estimativa de proficiência. Os estudos empregaram métodos diversos, incluindo *Random Forest*, SVM, árvores de decisão e redes neurais. Seus resultados não são diretamente comparáveis em todos os casos, pois foram produzidos com populações, instrumentos, variáveis e desenhos metodológicos distintos.

Os trabalhos preditivos utilizaram combinações de notas, respostas a itens, características contextuais e registros de interação para estimar categorias ou escores. Outros estudos investigaram personalização, avaliação formativa, recursos pedagógicos ou modelos computacionais de aprendizagem. Essa diversidade ampliou o panorama da revisão, mas também impediu tratar todos os resultados como se medissem o mesmo fenômeno educacional.

Acurácia elevada em uma base específica não demonstra automaticamente que a técnica produzirá o mesmo resultado em outra escola ou população. Da mesma forma, predição de desempenho não equivale a explicar como o estudante aprende matemática. Essas restrições foram incorporadas aos requisitos e aos critérios de avaliação da especificação apresentada no Capítulo 5.

No Quadro 3, a coluna de resultado preserva o sentido do achado reportado por cada artigo, sem formar um ranking entre estudos. A leitura deve considerar conjuntamente o desenho, a finalidade, a população analisada e as limitações metodológicas apresentadas posteriormente pelo MMAT. O protocolo contextual de Imperatrice et al. (2025) foi mantido para rastreabilidade, mas não integra o quadro por não apresentar resultado empírico concluído.

O estudo de Xia et al. (2026, pp. 8–9, 13–14, 18, 24) é evidência empírica adjacente: descreve uma reforma de matemática universitária aplicada à metrologia de carbetto de silício e um questionário adaptativo que os autores denominam baseado em IA. A comparação usa uma coorte de controle de 2021 (n=94) e uma coorte pós-reforma de 2025 (n=89), separadas por quatro anos. Embora os autores relatem indicadores de linha de base sem diferenças estatisticamente significativas, o desenho não contemporâneo não elimina confundimento temporal, e o artigo reconhece possíveis mudanças de equipe e contexto. Assim, os resultados não isolam o efeito do questionário ou da IA, nem demonstram eficácia generalizável de tutoria personalizada. O texto consultado não especifica um algoritmo de aprendizado de máquina; por isso, o estudo não é classificado como evidência de ML.

Quadro 3 – Síntese dos candidatos empíricos provisórios retidos.

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Resultado reportado
Tjahyadi e Tude (2025)	Predição de desempenho acadêmico em matemática. Finalidade: Predição	EDM; ML; classificadores	Acurácia	75% no conjunto de teste reportado
Pejic, Molcer e Gulači (2021)	Proficiência matemática no PISA. Finalidade: Predição de proficiência	ML multiclasse; RN; RF	Kappa; ROC-AUC	Comparação entre modelos de três classes
He et al. (2025)	Tecnologia educacional para matemática. Finalidade: Otimização e decisão	EDM; IA; modelos preditivos	Meta-análise; modelagem; comparação escolar	Predição de tamanhos de efeito e aplicação em oito turmas
Villegas-Ch et al. (2025)	Tutoria inteligente em STEM. Finalidade: Feedback personalizado	IA; aprendizagem adaptativa	Desempenho; análise estatística	Sistema adaptativo avaliado no contexto descrito pelo estudo

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Resultado reportado
Sokkhey et al. (2020)	Desempenho em matemática no ensino médio. Finalidade: Predição	EDM; ML; métodos estatísticos	Comparação de modelos	Estudo compara classes de métodos em dados escolares
Kumar et al. (2022)	Seleção de atributos e mineração de dados. Finalidade: Predição de desempenho	DT; JRip; NB; MLP; RF	Acurácia; comparação	Comparação de abordagens em conjuntos educacionais
Özseven e Özseven (2026)	Desempenho em matemática on-line. Finalidade: Predição	ML; modelo neurofuzzy	Desempenho preditivo	Estrutura híbrida para lidar com incerteza e generalização
Zhang, Zhu e Feng (2025)	Trajetórias personalizadas de aprendizagem. Finalidade: Personalização	DL; grafos de conhecimento; RL	Dados de desempenho; experimento	Algoritmo ajusta trajetórias com estado do estudante e análise de sentimentos
Zhang (2023)	Currículo de matemática superior apoiado por IA. Finalidade: Personalização	ACO; CNN; CRF; grafo de conhecimento	Análise estatística; feedback	Modelo de trajetória personalizada descrito e avaliado no estudo
Depren, Aşkın e Öz (2017)	Classificação no TIMSS. Finalidade: Predição	DT; rede bayesiana; regressão logística; RN	Classificação; desempenho	Comparação de métodos de mineração em dados do TIMSS
Uskov et al. (2019)	Analítica preditiva em STEM. Finalidade: Predição de desempenho	Oito algoritmos de ML	Benchmarking	Benchmark de algoritmos para desempenho acadêmico
MacLellan (2017)	Modelagem computacional da aprendizagem em frações e equações. Finalidade: Simulação e predição qualitativa	Modelos comparados com registros de tutoria	Ajuste de modelos; AIC; BIC	Efeitos instrucionais previstos qualitativamente, sem escores absolutos de desempenho

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Resultado reportado
Milićević, Marinović e Jeftić (2024)	Apoio ao ensino de matemática. Finalidade: Classificação de estudantes	ML; árvore de decisão	Predição de desempenho	Heurística de classificação do sucesso matemático
Xia et al. (2026)	Matemática universitária e desenvolvimento sustentável. Finalidade: Integração curricular	Questionário adaptativo descrito como IA; Fourier; PCA	Desempenho, questionário e entrevistas	Reforma curricular com aplicação industrial; coortes históricas sem isolamento do efeito computacional
Echeveria, Bajao e Godinez (2025)	Mentalidade matemática e intervenção precoce. Finalidade: Classificação de mentalidade	EDM; NB; SVM; MLP	Acurácia	Modelo de classificação com questionários e dados acadêmicos
Nyantah, Frempong e Larbi (2025)	Teoremas de círculo. Finalidade: Ensino de geometria	Animação computacional; aprendizagem cooperativa	Quase- experimento	Comparação entre animação com jigsaw e ensino convencional
Zeng (2025)	Carga cognitiva na resolução de problemas matemáticos. Finalidade: Reconhecimento de estados cognitivos	EEG; rastreamento ocular; ML	Experimento intraindiví- duos	Sinais multimodais e classificadores para reconhecer carga cognitiva

Fonte: Elaborado pelo autor (2026).

Os resultados quantitativos requerem leitura junto aos seus denominadores e às métricas por classe. Em Tjahyadi e Tude (2025, pp. 155–156, 160), o alvo é a categoria da nota escolar de matemática, em uma amostra de 280 estudantes de uma escola privada. Os autores descrevem uma divisão de 70% para treinamento e 30% para teste e reportam 75% de acurácia de teste para a combinação de SMOTE e RUSBoost. Na mesma comparação, a revocação da classe de baixo desempenho é de 43%. Portanto, a acurácia agregada não caracteriza uniformemente a identificação das três classes, nem demonstra ganho de aprendizagem decorrente de

uma intervenção.

Em He et al. (2025, pp. 1, 16, 31–35), devem ser distinguidos três componentes: a síntese meta-analítica de 423 publicações, a predição de tamanhos de efeito e a aplicação escolar em oito turmas. As publicações utilizadas pelos autores não foram incorporadas como novos registros desta revisão. O alvo da modelagem é o tamanho de efeito de uma intervenção, não a proficiência individual. Na comparação escolar, os autores descrevem quatro professores, com um deles responsável pelas duas turmas de controle e os demais pelas turmas experimentais; a análise não apresenta ajuste identificado para esse possível confundimento entre docente e condição. Há ainda uma inconsistência interna que afeta a interpretação dos resultados: a seção de aplicação informa 45 estudantes por turma nas oito turmas, mas declara amostra total de 90. Como o artigo não resolve essa divergência, o denominador do experimento não deve ser corrigido por inferência. Esses limites impedem tratar o experimento como demonstração causal robusta, eficácia universal ou regra geral de personalização.

Também foram identificados limites de relato e de comparação. Villegas-Ch et al. (2025, pp. 14, 22) descrevem um período experimental de seis semanas, mas apresentam resultados até a oitava semana, sem conciliar essas durações nos trechos examinados. Essa inconsistência impede adotar um cronograma único na síntese. Em Nyantah, Frempong e Larbi (2025, pp. 101–105), a seleção das duas escolas é descrita como intencional; o texto, porém, apresenta versões incompatíveis sobre a alocação: um trecho afirma que as escolas foram distribuídas aleatoriamente, enquanto outro caracteriza o estudo como quase-experimental sem alocação aleatória. Além disso, o próprio artigo relata diferença entre os grupos no pré-teste ($U=6714$; $p<0,001$; tamanho de efeito=0,346). A comparação pós-teste não permite, portanto, atribuir isoladamente o resultado à animação: a intervenção combina animação e aprendizagem cooperativa, e a alocação e a diferença inicial requerem cautela. Esses limites devem acompanhar a discussão das contribuições, em vez de serem ocultados pela apresentação de resultados favoráveis.

A definição do alvo também restringe o uso dos resultados. Em Echeveria, Bajao e Godinez (2025, pp. 66, 69–70), as categorias de mentalidade matemática são construídas com dados de questionários, e oito itens da escala de mentalidade permanecem entre os preditores selecionados. Essa sobreposição exige cautela ao interpretar a classificação como diagnóstico independente: o modelo pode reproduzir categorias derivadas dos próprios indicadores de entrada. O artigo contribui para discutir definição de rótulos e seleção de atributos, mas não de-

monstra, por esse resultado, mudança na aprendizagem ou efeito de uma intervenção precoce.

A tese de MacLellan (2017, pp. 44–48, 56) contribui como referência conceitual e metodológica para a modelagem computacional da aprendizagem. Nas tarefas de frações, compara simulações com registros de tutoria previamente coletados no DataShop para 79 estudantes e prevê qualitativamente efeitos de sequenciamentos instrucionais, não escores absolutos de desempenho no tutor ou em pós-teste. Em análise distinta sobre resolução de equações, descreve dados de 71 estudantes e 10.052 passos; a análise utiliza 4.568 passos nos quais os estudantes executaram as próprias ações, enquanto tarefas de estratégia em que o tutor realizava as transformações ficam fora desse recorte. Portanto, sua contribuição está delimitada às tarefas examinadas e não constitui avaliação prospectiva nem evidência de eficácia do protótipo deste TCC.

4.4 AVALIAÇÃO METODOLÓGICA COM O MMAT

O MMAT 2018 foi utilizado conforme o desenho metodológico de cada estudo empírico (Hong et al., 2018). O ledger registra primeiro as perguntas de triagem S1 (“Há perguntas de pesquisa claras?”) e S2 (“Os dados coletados permitem responder às perguntas de pesquisa?”) e, em seguida, os critérios Q1–Q5 do delineamento identificado. As respostas são codificadas como Y (“Sim”), N (“Não”) ou CT (“Não é possível concluir com a evidência disponível”), sem média, ranking ou categoria geral. A apreciação foi realizada por um único revisor e permanece preliminar: parte dos registros foi examinada com base em resumo e metadados, e a adjudicação pelo supervisor e os localizadores dos critérios ainda precisam ser consolidados. Assim, os julgamentos constituem uma apreciação estruturada e passível de revisão, não uma classificação definitiva dos artigos.

O Quadro 4 foi gerado automaticamente a partir do arquivo versionado <research/data/mmat_reassessment_current.csv>. Dessa forma, os critérios apresentados no TCC e no ledger atual possuem uma fonte única e verificável, separada da avaliação histórica.

Quadro 4 – Reavaliação documental preliminar dos estudos atuais com o MMAT 2018.

Estudo	Desenho	S1 S2 Q1 Q2 Q3 Q4 Q5	Base
Pejic et al. (2021)	Quant. descritivo	Y Y Y CT Y CT CT	Abstract/metadados
Tjahyadi (2025)	Quant. descritivo	Y Y Y N Y CT Y	Texto primário externo
Sokkhey et al. (2020)	Quant. descritivo	Y Y Y CT Y CT Y	Texto primário externo
Kumar et al. (2022)	Quant. descritivo	Y Y Y CT Y CT CT	Texto primário externo
Zhang et al. (2025)	Quant. não rand.	Y Y CT CT CT CT CT	Abstract/metadados
Depren et al. (2017)	Quant. descritivo	Y Y Y CT Y CT Y	Texto primário externo
Zhang (2023)	Quant. não rand.	Y Y CT CT Y CT Y	Texto primário externo
MacLellan (2017)	Quant. não rand.	Y Y CT CT CT CT CT	Texto primário externo
Uskov et al. (2019)	Quant. descritivo	Y Y Y CT Y CT Y	Abstract/metadados
Milićević et al. (2024)	Quant. descritivo	Y Y Y CT Y CT CT	Abstract/metadados
Nyantah et al. (2025)	Pendente	Y Y CT CT CT CT CT	Texto primário externo
He et al. (2025)	Quant. não rand.	Y Y N Y CT N Y	Texto primário externo
Villegas-Ch et al. (2025)	Quant. não rand.	Y Y CT CT CT N CT	Texto primário externo
Özseven et al. (2026)	Quant. descritivo	Y Y Y N Y CT Y	Texto primário externo
Xia et al. (2026)	Métodos mistos	Y Y CT CT CT CT CT	Texto primário externo
Echeveria et al. (2025)	Quant. descritivo	Y Y Y N Y N CT	Texto primário externo
Imperatrice et al. (2025)	Não aplicável	CT CT CT CT CT CT CT	Protocolo/proposta
Zeng (2025)	Quant. não rand.	Y Y CT Y CT CT CT	Abstract/metadados

Nota: Y = sim; N = não; CT = não é possível concluir com a evidência disponível. Todos os julgamentos empíricos são preliminares e aguardam adjudicação. O registro de protocolo ou proposta é contextual e não recebe apreciação MMAT empírica.

Fonte: Elaborado pelo autor (2026).

Os julgamentos preliminares por critério registraram limitações relativas à descrição dos dados, ao controle de variáveis de confusão e à representatividade. Como a avaliação foi conduzida por um único revisor e a disponibilidade de textos primários foi desigual, esses registros não foram convertidos em uma estimativa de frequência nem em classificação agregada de qualidade.

A recuperação adicional de fontes não implica aprovação dos julgamentos anteriores. No caso de He et al. (2025), a combinação de componentes meta-analítico, preditivo e escolar exige delimitar a unidade de apreciação antes de consolidar os critérios do MMAT.

O ledger mantém uma classificação provisória como quantitativo descritivo, enquanto parte de suas justificativas menciona confundimento e implementação da intervenção, próprios de outra categoria do instrumento. Essa divergência não foi resolvida por uma reclassificação automática: os julgamentos desse registro permanecem pendentes de revisão do delineamento e adjudicação.

4.5 TENDÊNCIAS E LACUNAS

As observações desta seção consideram somente os 17 candidatos empíricos provisórios; o protocolo ou proposta contextual foi mantido para rastreabilidade e não integra a síntese de evidências. A leitura é descritiva e foi limitada pela disponibilidade desigual das fontes: doze registros tiveram o texto primário consultado e cinco foram apreciados com base em resumo e metadados. Os exemplos a seguir localizam limitações em estudos específicos; essa cobertura não permite estimar a frequência das limitações na literatura, comparar a eficácia das intervenções ou afirmar que o conjunto apresenta evidência homogênea.

Em He et al. (2025, pp. 1, 16, 31–35), a descrição da aplicação escolar informa oito turmas com 45 estudantes por turma, enquanto o artigo declara amostra total de 90. O texto consultado não reconcilia esses denominadores. Os autores também descrevem quatro professores, com um responsável pelas duas turmas de controle e os demais pelas turmas experimentais; não foi identificado ajuste para esse possível confundimento entre docente e condição nas páginas examinadas. Essas inconsistências dificultam reconstituir a unidade de análise e exigem cautela na interpretação dos resultados, sem que o denominador possa ser corrigido por inferência.

Em Villegas-Ch et al. (2025, pp. 14, 22), a seção de métodos descreve seis semanas de experimento, enquanto os resultados se estendem até a oitava semana, sem conciliação nos trechos consultados. Essa diferença impede adotar um cronograma único para comparar ou sintetizar o estudo. Já Nyantah, Frempong e Larbi (2025, pp. 101–105) apresenta descrições incompatíveis sobre a alocação das escolas: um trecho informa distribuição aleatória, e outro caracteriza o desenho como quase-experimental sem alocação aleatória. O artigo também relata diferença entre os grupos no pré-teste ($U=6714$; $p<0,001$; tamanho de efeito=0,346), e a intervenção combina animação computacional e aprendizagem cooperativa. Em conjunto, esses elementos limitam a atribuição do resultado a um componente isolado e recomendam que a comparação seja interpretada considerando a diferença inicial e a intervenção combinada.

Em Echeveria, Bajao e Godinez (2025, pp. 66, 69–70), oito itens da escala de menta-

lidade matemática utilizados para formar as categorias também permanecem entre os preditores selecionados. O relato não estabelece, por si só, validade diagnóstica independente da classificação; por isso, o resultado não sustenta inferência de mudança na aprendizagem nem de efeito de uma intervenção precoce.

Esses casos sugerem requisitos de relato e avaliação para a especificação: explicitar denominadores, unidades de análise, alocação, medidas iniciais, duração e relação entre rótulos e preditores. Eles são exemplos localizados, não uma estimativa de prevalência nem uma avaliação definitiva dos estudos. Temas mais amplos — como equidade, participação docente, integração curricular e reprodutibilidade — não foram codificados de modo comparável para todos os registros; neste trabalho, permanecem questões e requisitos propostos para investigação, e não ausências demonstradas em toda a literatura ou em cada estudo retido.

4.6 LIMITAÇÕES E CONTRIBUIÇÕES DA REVISÃO

A revisão foi realizada por um único pesquisador, com suporte automatizado para deduplicação, triagem e organização dos registros. Não houve dupla revisão independente. A priorização operacional de grande parte dos registros foi avaliada a partir de títulos, resumos e metadados, pois nem todos os textos completos estavam disponíveis; por isso, a retenção não deve ser apresentada como elegibilidade final universal.

O protocolo não foi registrado prospectivamente. Foram adotados princípios de planejamento compatíveis com o PRISMA-P, mas não se afirmou conformidade integral. O PRISMA 2020 foi utilizado para orientar o relato do processo.

As fontes consultadas possuem cobertura predominantemente anglófona, e a busca foi limitada a português e inglês. A heterogeneidade dos desenhos, populações e métricas impediu uma síntese quantitativa conjunta. Não foi aplicado um teste formal de viés de publicação; a cobertura das fontes e a disponibilidade desigual dos textos completos podem ter influenciado o conjunto recuperado. Além disso, a apreciação MMAT por revisor único permanece preliminar e está sujeita a divergências interpretativas.

Considerados esses limites, a revisão forneceu a base documental disponível para a especificação do protótipo. A presença de tarefas preditivas entre os candidatos analisados justificou considerar modelos supervisionados como alternativas, enquanto a heterogeneidade das bases fundamentou critérios de seleção e validação. Requisitos de explicabilidade, integração curricular, participação docente e reprodutibilidade foram propostos a partir da leitura temática

e da fundamentação pedagógica; como esses aspectos não foram codificados de modo comparável em todos os registros, não são apresentados como lacunas comprovadas em cada estudo ou em toda a literatura.

Dessa forma, os resultados da revisão não foram tratados apenas como levantamento bibliográfico. Eles sustentaram as decisões consolidadas no Capítulo 5, preservando a distinção entre evidências reportadas na literatura e resultados produzidos pelo próprio trabalho.

5 ESPECIFICAÇÃO DO PROTÓTIPO

Este capítulo apresenta a especificação conceitual do protótipo elaborada a partir dos resultados da revisão sistemática e da fundamentação pedagógica. O artefato produzido consolidou princípios de projeto, requisitos funcionais e não funcionais, critérios para fontes de dados e modelos, um protocolo de avaliação e uma arquitetura de referência.

A especificação não foi tratada como evidência de uma aplicação funcional. Seu resultado consistiu em transformar as evidências da literatura em decisões técnicas e pedagógicas documentadas, auditáveis e coerentes com o escopo do trabalho.

O repositório também contém uma implementação técnica do pipeline do protótipo, acompanhada por testes sintéticos automatizados. Essa implementação demonstra propriedades de processamento e de proteção contra falhas previstas no código, mas não equivale a uma execução com dados educacionais reais, a uma validação de eficácia preditiva ou a uma avaliação de aprendizagem. O capítulo, portanto, descreve a especificação que orienta uma futura execução e mantém essa implementação técnica separada de qualquer alegação de resultado educacional.

5.1 PRINCÍPIOS E REQUISITOS

A especificação estabelece que o protótipo deverá apoiar a decisão pedagógica sem substituir o professor. Essa decisão de projeto implica distinguir, na representação e na interpretação dos resultados, o desempenho observado em uma atividade, a proficiência estimada por um modelo, a competência mobilizada em um contexto mais amplo e a aprendizagem como possível mudança ao longo do tempo. Esses conceitos não são intercambiáveis, e a passagem de um para outro não poderá ser presumida apenas pela produção de um indicador computacional.

As estimativas deverão ser acompanhadas de explicações, limitações e condições de validade compreensíveis para seus destinatários. A revisão humana deverá permanecer integrada ao uso das recomendações, de modo que o professor possa confrontar as evidências com o contexto da turma e decidir se há fundamento para uma intervenção. Nesse sentido, a saída do protótipo será tratada como apoio à análise, e não como classificação definitiva ou prescrição pedagógica.

A proteção dos dados educacionais constitui outro princípio da especificação. O uso deverá estar associado a uma finalidade explícita, com minimização dos dados pessoais e controle de acesso compatível com essa finalidade. Também deverá ser possível reproduzir

e auditar os procedimentos de preparação, treinamento e avaliação por meio do registro das versões, dos parâmetros e das dependências relevantes. Por fim, a especificação rejeita rótulos permanentes ou deterministas sobre os estudantes, pois uma estimativa situada não deve ser convertida em atributo fixo da pessoa.

No plano funcional, a futura implementação deverá importar dados documentados e relacionados a objetivos curriculares, preservando os metadados necessários à leitura de sua procedência. A partir desses dados, deverá organizar evidências de desempenho por habilidade ou descritor, de modo que a análise mantenha relação explícita com o contexto curricular em que os registros foram produzidos.

Na etapa de análise, o protótipo deverá produzir estimativas para um alvo educacional explicitamente definido, acompanhadas de incertezas e limitações, e apresentar resultados individuais e agregados ao professor. Uma probabilidade preditiva de acerto ou de pertencimento a uma classe de desempenho não será denominada proficiência apenas por resultar de um modelo computacional. A interpretação como proficiência exigirá um modelo de mensuração, uma escala e evidências de validade para o uso pretendido, em consonância com a distinção entre observação e inferência discutida por National Research Council (2001, pp. 42–44). Essas saídas deverão ser acompanhadas de uma explicação das variáveis relacionadas a cada estimativa, sem serem apresentadas como diagnósticos completos de aprendizagem. O fluxo também deverá permitir revisão humana das recomendações produzidas, para que o professor possa confrontar as evidências computacionais com a situação da turma e decidir sobre sua pertinência pedagógica. Por fim, deverá exportar dados, parâmetros e resultados para auditoria, assegurando que as decisões de processamento e as saídas apresentadas possam ser examinadas posteriormente.

A especificação também estabeleceu que indicadores computacionais não representam, isoladamente, diagnósticos de aprendizagem. Sua interpretação depende da natureza da atividade, da qualidade dos dados e do contexto pedagógico.

No plano não funcional, as condições de qualidade e de governança deverão ser satisfeitas por uma futura implementação; sua especificação não constitui evidência de que tais propriedades já tenham sido alcançadas. A reprodutibilidade deverá ser assegurada pelo registro das versões dos dados, dos parâmetros, dos modelos e das dependências. Complementarmente, a rastreabilidade deverá permitir associar cada resultado à fonte de dados utilizada e à versão do experimento que o produziu. Essa associação é necessária para que uma conclusão possa ser

examinada sem perder sua procedência.

A testabilidade deverá ser favorecida pela separação entre ingestão, preparação, modelagem, avaliação e apresentação. A portabilidade, por sua vez, exigirá um ambiente de execução documentado e passível de reprodução. Essas duas condições dizem respeito à possibilidade de verificar e repetir os procedimentos, e não à escolha de uma tecnologia ou de uma interface específica.

Os requisitos também abrangem a relação do protótipo com seus usuários e com os dados tratados. A apresentação deverá ser acessível, compreensível e compatível com diferentes perfis de usuário. A privacidade deverá orientar a minimização de dados pessoais e o controle de finalidade e de acesso. Por fim, a transparência deverá exigir que as limitações dos modelos e as condições de validade das estimativas sejam comunicadas junto aos resultados, evitando que a forma de apresentação atribua uma certeza que o procedimento não sustenta.

A escolha de fontes de dados permanece condicionada à documentação disponível, ao problema de pesquisa e às condições de execução que vierem a ser definidas. A especificação considera a possibilidade de trabalhar com microdados de avaliações educacionais, como SAEB e PISA, e com dados sintéticos destinados à verificação do *pipeline*; essa possibilidade não representa a seleção de uma base definitiva.

A seleção de uma fonte deverá considerar, inicialmente, sua licença e suas condições de uso, bem como a existência de dicionário de dados e de documentação metodológica. Também deverá examinar a unidade de análise e sua relação com o problema de pesquisa, a qualidade dos metadados e o tratamento previsto para valores ausentes. A representatividade da população deverá ser analisada em relação ao contexto para o qual se pretende interpretar os resultados, sem ser presumida a partir da simples disponibilidade da base. Do mesmo modo, a presença de variáveis relacionadas ao desempenho e ao contexto educacional será relevante, mas não garantirá, por si só, que seja possível associá-las a competências ou descritores curriculares. Essa associação deverá ser demonstrada e delimitada pela documentação e pelo desenho da avaliação.

Por fim, a análise da fonte deverá incluir os riscos de identificação, discriminação e uso indevido. Esses riscos são condições de governança da execução, e não apenas atributos técnicos do arquivo de dados. Dados sintéticos poderão ser usados para testar fluxos de processamento, interfaces e regras de validação. Entretanto, não constituirão evidência de desempenho educacional, de validade preditiva ou de eficácia pedagógica, nem substituirão uma

base empírica quando a investigação exigir inferências sobre estudantes ou contextos reais.

Quanto à modelagem, a revisão identificou uso de *Random Forest*, máquinas de vetores de suporte (SVM), árvores de decisão, regressão logística e redes neurais. Na especificação, *Random Forest* e SVM também foram ancoradas em suas fontes metodológicas primárias (Breiman, 2001; Cortes; Vapnik, 1995). Modelos supervisionados simples e interpretáveis foram mantidos como referências iniciais de comparação, condicionando o uso de modelos mais complexos à demonstração de ganho e à possibilidade de interpretação adequada.

Random Forest e SVM foram registrados como alternativas de modelagem, não como algoritmos definitivamente implementados. A escolha entre eles depende da base selecionada, da distribuição das classes, do tipo de variável, do custo computacional e dos requisitos de explicabilidade.

Em uma implementação com scikit-learn, identificadores longos devem ser documentados sem comprometer a legibilidade do texto ou a reprodução do código. O nome `RandomForestClassifier`, por exemplo, identifica uma classe de implementação, não uma técnica adicional.

5.2 DADOS, MODELAGEM E AVALIAÇÃO

O protocolo de avaliação constitui uma condição para a execução futura da modelagem e para a interpretação dos seus resultados. Ele deverá separar o que será observado no comportamento técnico dos modelos daquilo que exigiria evidência educacional adicional. Essa separação começa pela definição explícita dos conjuntos de treino, validação e teste e pela prevenção de vazamento de informação entre preparação, modelagem e avaliação. Os modelos candidatos deverão ser comparados com referências simples, para que qualquer ganho seja interpretado em relação a uma base de comparação, e as métricas deverão ser analisadas por classe, além das medidas agregadas, quando a tarefa permitir essa decomposição.

Como descrição complementar dos erros e acertos, o protocolo prevê o uso de matriz de confusão, precisão, revocação e medida F1. A área sob a curva ROC e a calibração somente deverão ser calculadas quando forem compatíveis com a tarefa e com o tipo de saída produzido (Fawcett, 2006; Niculescu-Mizil; Caruana, 2005). Também deverão ser examinadas a estabilidade das explicações e possíveis diferenças entre grupos, sem converter essas análises em conclusões causais não sustentadas pelo desenho do estudo. Por fim, a execução deverá registrar as limitações de generalização relacionadas à fonte de dados, à população observada e

às condições de aplicação.

O protocolo distingue desempenho observado, saída preditiva, proficiência estimada, competência e aprendizagem. O desempenho observado corresponde aos registros produzidos nas atividades ou avaliações consideradas. A saída preditiva estima um alvo definido, sob as condições dos dados e do modelo; não demonstra, por si só, a posição do estudante em uma escala de proficiência. Esta última interpretação depende do modelo de mensuração e da validade das inferências pretendidas (National Research Council, 2001, pp. 42–44). Competência e aprendizagem, contudo, não serão tratadas como equivalentes automáticos dessas grandezas: sua análise depende do contexto educacional, do construto adotado e, no caso da aprendizagem, de evidência de mudança ao longo do tempo. A implementação técnica atualmente disponível produz saídas preditivas em testes sintéticos, não uma escala de proficiência validada.

Essa distinção também separa a avaliação técnica da eficácia pedagógica. As métricas preditivas descrevem o comportamento do modelo em uma base e sob determinadas condições de avaliação. Elas não demonstram, por si só, melhoria da aprendizagem, adequação de uma intervenção escolar ou alinhamento curricular validado. Tais conclusões exigiriam um desenho empírico próprio, com condições de comparação e observação educacional compatíveis com a pergunta investigada.

Para examinar a adequação pedagógica da especificação, o protocolo prevê uma revisão documental por docentes da área de matemática. Essa revisão deverá considerar a correspondência dos requisitos com o referencial curricular pertinente ao nível de ensino, a clareza das explicações e das incertezas apresentadas, a possibilidade de interpretação contextualizada e a preservação da decisão docente. Cada julgamento deverá registrar o requisito examinado, a evidência documental, a justificativa, as limitações e os ajustes necessários. Trata-se de um procedimento proposto, que não foi executado neste trabalho; mesmo sua execução não substituiria um estudo empírico de eficácia educacional.

Como parte da avaliação e da revisão humana, SHAP e LIME foram incluídos como alternativas para explicar modelos, com referência às formulações originais de Lundberg e Lee e de Ribeiro, Singh e Guestrin (Lundberg; Lee, 2017; Ribeiro; Singh; Guestrin, 2016). Seu uso deverá considerar a estabilidade das explicações, o custo computacional e a possibilidade de tradução dos resultados para uma linguagem curricular compreensível. O professor permanece responsável por interpretar as evidências, relacioná-las ao contexto da turma e decidir intervenções; o protótipo é instrumento de apoio, não mecanismo autônomo de classificação ou

prescrição pedagógica.

5.3 ARQUITETURA DE REFERÊNCIA

A ingestão corresponde à leitura das fontes, à validação inicial de seus formatos e à preservação das informações de procedência. Em seguida, a etapa de preparação deverá tratar valores ausentes, codificar e transformar variáveis e documentar as decisões tomadas sobre esses dados. A modelagem abrangerá o treinamento e a comparação dos modelos candidatos de acordo com a base selecionada e com o protocolo de avaliação.

A etapa de avaliação e explicabilidade deverá calcular as métricas, analisar os erros e gerar explicações cuja estabilidade e limitações serão examinadas. Por fim, a apresentação deverá disponibilizar indicadores, incertezas e limitações de modo compreensível para a análise docente. Essa arquitetura de referência organiza responsabilidades e pontos de verificação; não descreve um sistema funcional já disponível, nem fixa a tecnologia ou a forma de implantação.

A separação dos componentes deverá favorecer a testabilidade, a rastreabilidade e a substituição controlada de técnicas. Ela também permite localizar em qual etapa uma decisão, uma transformação ou uma limitação foi introduzida. A arquitetura não impõe uma interface específica e poderá ser materializada como *notebook*, aplicação local, API ou sistema web. Qualquer dessas formas de execução deverá, entretanto, preservar os requisitos de auditoria, interpretação, privacidade e participação docente estabelecidos neste capítulo.

Em síntese, este capítulo consolida uma especificação técnica e pedagógica que conecta as evidências da revisão às decisões de projeto, abrangendo propósito, limites, requisitos, critérios para dados e modelos, protocolo de avaliação e arquitetura de referência. Essa entrega é fundamentada no material examinado, mas não se confunde com uma especificação submetida à revisão docente prevista no protocolo, com uma aplicação educacional validada ou com evidência de eficácia em sala de aula.

6 RESULTADOS E DISCUSSÃO

Os resultados do trabalho foram organizados em quatro entregas complementares: a revisão sistemática da literatura, a apreciação metodológica preliminar dos candidatos empíricos retidos, a consolidação dos fundamentos pedagógicos e a especificação conceitual do protótipo. Esta seção integra essas entregas e discute como elas responderam ao problema de pesquisa e aos objetivos definidos.

6.1 RESULTADOS DA REVISÃO SISTEMÁTICA

A revisão identificou 11.904 registros em quatro fontes científicas. Após a remoção determinística de identidades DOI/URL e a triagem, 2.486 registros foram submetidos à priorização operacional baseada em metadados e resumos; essa etapa não corresponde à avaliação de elegibilidade de relatórios em texto completo. Dezoito registros foram retidos provisoriamente para adjudicação de escopo: 17 candidatos empíricos e 1 protocolo ou proposta contextual. A síntese empírica preliminar considerou apenas os candidatos empíricos e identificou aplicações voltadas à predição de desempenho e à estimativa de proficiência, incluindo modelos supervisionados como *Random Forest*, SVM, árvores de decisão e redes neurais.

A heterogeneidade entre populações, instrumentos, variáveis e métricas impediu a comparação direta de todos os resultados. Acurácias reportadas em bases específicas foram interpretadas como evidências contextuais dos artigos, e não como garantias de desempenho em outros ambientes educacionais. Essa distinção evitou transferir resultados da literatura para o protótipo especificado sem validação empírica própria.

Os exemplos documentados na Seção 4.5 incluem limitações de alocação e controle de confundimento, divergência entre duração prevista e período reportado, combinação de componentes de intervenção e sobreposição entre instrumento e variáveis preditoras. Eles ilustram problemas localizados em estudos consultados; a cobertura de textos primários e a ausência de uma matriz de codificação não permitem estimar a frequência dessas limitações na área.

6.2 RESULTADOS DA AVALIAÇÃO METODOLÓGICA

A apreciação documental preliminar com o MMAT 2018 manteve as respostas aos cinco critérios separadas por estudo empírico. Esse formato tornou visíveis limitações relativas a representatividade, completude dos dados, controle de confundidores, integração de métodos e

coerência entre desenho e análise, sem transformar os julgamentos em uma pontuação agregada.

A avaliação não produziu nota geral, média ou ranking de qualidade. Essa decisão preservou a interpretação de cada critério e impediu que uma pontuação agregada ocultasse fragilidades metodológicas relevantes. Como os julgamentos foram realizados por um único revisor e parte deles se baseou em resumos e metadados, seus resultados foram tratados como apreciação estruturada, auditável e preliminar, não como classificação definitiva dos artigos.

O fortalecimento da rastreabilidade também constituiu um resultado técnico. Os julgamentos foram registrados em arquivo canônico versionado e passaram a alimentar os artefatos CSV, HTML e LaTeX utilizados no trabalho. A correspondência entre avaliação e estudo considerou título normalizado, ano e primeiro autor, reduzindo o risco de associações incorretas ou ambíguas.

6.3 RESULTADOS DA FUNDAMENTAÇÃO PEDAGÓGICA

A fundamentação permitiu distinguir desempenho observado, proficiência estimada, competência e aprendizagem. Notas, acertos, tentativas e tempos de resposta representam evidências dependentes da tarefa e do contexto; a interpretação de conhecimentos e habilidades requer relacionar essas observações ao construto e ao instrumento de avaliação (National Research Council, 2001). Na especificação, o acompanhamento de mudanças ao longo do tempo foi tratado como condição para investigar aprendizagem, e não como resultado já demonstrado. Essa distinção também alcançou a probabilidade preditiva de um alvo definido: uma saída condicionada aos dados e ao modelo, distinta do indicador de desempenho observado e não equivalente, por si só, a proficiência, competência, aprendizagem ou eficácia pedagógica.

Os referenciais sobre conhecimento prévio, mediação, resolução de problemas, avaliação formativa e *feedback* reforçaram que a utilidade de uma ferramenta computacional depende da forma como seus resultados são interpretados e incorporados à prática docente. A tecnologia foi posicionada como apoio à decisão, mantendo o professor responsável por considerar fatores pedagógicos, sociais e contextuais que não são observados diretamente pelo modelo.

Esses resultados fundamentaram requisitos de explicabilidade, revisão humana, associação curricular, proteção de dados e comunicação de incertezas. Assim, a dimensão pedagógica não foi adicionada apenas como justificativa; ela orientou diretamente a especificação técnica.

6.4 RESULTADOS DA ESPECIFICAÇÃO DO PROTÓTIPO

A integração entre revisão e fundamentação resultou em uma especificação conceitual composta por princípios de projeto, requisitos funcionais e não funcionais, critérios de seleção de fontes de dados, alternativas de modelagem, protocolo de avaliação e arquitetura de referência.

Entre os resultados consolidados destacaram-se a definição do protótipo como instrumento de apoio, sem substituição da interpretação docente, e a exigência de rastreabilidade entre dados, modelos, parâmetros e resultados. Também foram especificados modelos supervisionados simples e interpretáveis como alternativas iniciais de comparação, mantendo-se a separação entre avaliação técnica e alegações de eficácia pedagógica.

A especificação incorporou explicabilidade e análise de limitações ao fluxo de avaliação e organizou a arquitetura em componentes de ingestão, preparação, modelagem, avaliação, explicabilidade e apresentação. O uso de dados sintéticos foi delimitado a testes de fluxo, sem interpretação educacional.

A especificação constituiu um resultado final do trabalho porque transformou as evidências analisadas em decisões documentadas e verificáveis. Ao mesmo tempo, ela não foi apresentada como aplicação funcional nem recebeu métricas próprias de desempenho, preservando a correspondência entre o texto e os artefatos efetivamente produzidos.

6.5 ATENDIMENTO AOS OBJETIVOS

No escopo executado, o primeiro objetivo específico foi atendido pela categorização das técnicas e finalidades pedagógicas dos candidatos empíricos na síntese preliminar apresentada no Capítulo 4. O segundo foi atendido pela identificação de limitações e lacunas no material examinado, considerando a apreciação preliminar por critérios do MMAT e as restrições de acesso às fontes. O terceiro foi atendido pela formulação dos requisitos, critérios de dados e modelos e arquitetura de referência no Capítulo 5. O quarto foi atendido pela proposição do protocolo de avaliação nesse mesmo capítulo; seu atendimento corresponde à definição dos procedimentos, não à execução de experimentos ou à demonstração de eficácia pedagógica.

O objetivo geral foi alcançado no escopo documental ao propor uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática. A revisão e o *pipeline* forneceram os meios e a rastreabilidade dessa elaboração. A especificação não foi validada empiricamente como solução educacional, e sua fundamentação permanece

condicionada às limitações da síntese e da apreciação metodológica preliminares.

6.6 DISCUSSÃO INTEGRADA

A discussão da literatura e de suas limitações orientou a decisão de não selecionar uma técnica apenas pela frequência de uso ou pela maior acurácia reportada em um artigo. Na especificação proposta, a seleção deve considerar a qualidade e a representatividade dos dados, a finalidade pedagógica, a possibilidade de interpretação e as condições de aplicação.

A presença de modelos preditivos na síntese preliminar indicou tarefas de classificação e estimativa entre os candidatos analisados. Neste trabalho, essas tarefas não foram tratadas como mensuração completa de fenômenos educacionais. A especificação separou explicitamente desempenho, proficiência, competência e aprendizagem e previu participação docente na interpretação das saídas, sem atribuir aos autores dos estudos uma posição teórica uniforme.

A principal contribuição do trabalho esteve, portanto, na articulação entre revisão sistemática, avaliação metodológica, fundamentação pedagógica e engenharia de requisitos. Essa articulação ofereceu uma base estruturada para decisões futuras sobre soluções educacionais, mantendo a seleção de algoritmos subordinada ao contexto, à avaliação e aos limites da evidência.

7 CONCLUSÃO

Este trabalho investigou técnicas computacionais aplicadas ao ensino de matemática por meio de uma revisão sistemática da literatura e da elaboração de uma especificação conceitual de protótipo. O processo organizou registros provenientes de quatro fontes científicas e reteve operacionalmente 18 registros: 17 candidatos empíricos provisórios e 1 protocolo ou proposta contextual. Entre os candidatos empíricos analisados, a síntese preliminar identificou estudos voltados à predição de desempenho e à estimativa de proficiência.

A análise evidenciou que resultados obtidos em bases específicas não podem ser generalizados automaticamente e que indicadores de desempenho não equivalem, isoladamente, à aprendizagem. A especificação também distinguiu a probabilidade preditiva de um alvo definido, entendida como saída condicionada aos dados e ao modelo, do indicador de desempenho observado; essa probabilidade não equivale, isoladamente, à proficiência, à competência, à aprendizagem ou à eficácia pedagógica. A apreciação metodológica preliminar pelo MMAT foi organizada por critérios, sem pontuação geral, preservando a visibilidade das limitações de cada estudo e a rastreabilidade dos julgamentos realizados.

A fundamentação pedagógica permitiu distinguir desempenho observado, proficiência estimada, competência e aprendizagem. Essa diferenciação orientou a especificação do protótipo e reforçou que modelos computacionais devem apoiar a interpretação docente, sem produzir diagnósticos definitivos ou substituir decisões pedagógicas contextualizadas.

No escopo documental, o objetivo geral foi alcançado pela proposição de uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática, fundamentada na revisão e nos limites identificados. A categorização das técnicas e finalidades, a identificação de limitações e lacunas, a formulação dos requisitos, critérios e arquitetura e a proposição do protocolo de avaliação técnica e de adequação pedagógica corresponderam aos quatro objetivos específicos. Foram definidos princípios de projeto, requisitos funcionais e não funcionais e critérios para fontes de dados e modelos. O protocolo orienta uma avaliação futura; sua elaboração não demonstra a viabilidade empírica nem a eficácia pedagógica do protótipo.

7.1 CONTRIBUIÇÕES DO TRABALHO

Entre as contribuições, destaca-se a síntese estruturada da literatura, apoiada por artefatos versionados para reprodução do snapshot e por um *pipeline* automatizado para coleta,

deduplicação, triagem e exportação dos registros. O trabalho também separou explicitamente relevância temática e avaliação metodológica, preservando a apreciação preliminar dos estudos empíricos pelo MMAT em respostas organizadas por critério.

A fundamentação sobre aprendizagem matemática e os limites das inferências computacionais orientou uma especificação técnica e pedagógica de protótipo baseada nas evidências da revisão. Essa especificação definiu critérios de rastreabilidade, explicabilidade, avaliação e participação docente, sem transformar uma proposta conceitual em evidência de eficácia pedagógica.

7.2 LIMITAÇÕES

A revisão foi conduzida por um único pesquisador, sem dupla seleção e dupla avaliação independentes. Parte dos julgamentos dependeu de resumos, metadados e descrições metodológicas disponíveis, o que restringiu a profundidade da apreciação de alguns estudos. A recuperação de fontes, os localizadores dos critérios e a adjudicação do MMAT ainda precisam ser concluídos antes de qualquer síntese final de qualidade. As fontes consultadas e os idiomas selecionados também limitaram a cobertura da literatura.

A especificação do protótipo não incluiu uma aplicação educacional funcional, o treinamento de modelos com uma base definitiva ou validação com participantes. Consequentemente, o trabalho não produziu métricas próprias de acurácia nem evidências de eficácia pedagógica. Essa limitação foi assumida como delimitação do escopo executado. A implementação técnica adicional disponível no repositório e seus testes sintéticos não substituem essas validações; devem ser distinguidos da especificação e da aplicação educacional futura.

7.3 CONTINUIDADE DA PESQUISA

Como continuidade, recomenda-se desenvolver a aplicação educacional a partir da especificação e da implementação técnica disponível, em um ambiente reproduzível, selecionar uma base de dados compatível com os critérios definidos e comparar modelos de referência sob o protocolo de avaliação proposto. Estudos com participantes devem observar autorização institucional, proteção dos dados e participação de profissionais da educação na interpretação dos resultados.

A continuidade também deve investigar estabilidade das explicações, diferenças de desempenho entre grupos, alinhamento com descritores curriculares e utilidade das informações

para o planejamento docente. Essas atividades ampliam os resultados obtidos, mas não alteram a conclusão de que a revisão e a especificação responderam ao escopo definido para este trabalho.

REFERÊNCIAS

- AUSUBEL, David P. **Educational Psychology: A Cognitive View**. New York: Holt, Rinehart and Winston, 1968.
- BLACK, Paul; WILIAM, Dylan. Assessment and classroom learning. **Assessment in Education: Principles, Policy & Practice**, v. 5, n. 1, p. 7–74, 1998. DOI: <<https://doi.org/10.1080/0969595980050102>>.
- Brasil. **Base Nacional Comum Curricular: Educação é a Base**. 2018. Documento normativo que define o conjunto de aprendizagens essenciais para a Educação Básica. Disponível em: <<https://basenacionalcomum.mec.gov.br/>>. Acesso em: 15 set. 2026.
- BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, p. 5–32, 2001. DOI: <<https://doi.org/10.1023/A:1010933404324>>.
- CORTES, Corinna; VAPNIK, Vladimir. Support-vector networks. **Machine Learning**, v. 20, p. 273–297, 1995. DOI: <<https://doi.org/10.1007/BF00994018>>.
- DEPREN, Serpil Kılıç; AŞKIN, Öyküm Esra; ÖZ, Ersoy. Identifying the Classification Performances of Educational Data Mining Methods: A Case Study for TIMSS. **Educational Sciences: Theory & Practice**, v. 17, n. 5, p. 1605–1623, 2017. DOI: <<https://doi.org/10.12738/estp.2017.5.0634>>.
- ECHEVERIA, Joshua M.; BAJAO, Christal Joy; GODINEZ, C. Modeling Students' Mindset in Mathematics: A Data Mining Approach for Early Intervention. **European Journal of Education and Pedagogy**, v. 6, n. 6, 2025. DOI: <<https://doi.org/10.24018/ejedu.2025.6.6.934>>.
- FAWCETT, Tom. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006. DOI: <<https://doi.org/10.1016/j.patrec.2005.10.010>>.
- HATTIE, John; TIMPERLEY, Helen. The power of feedback. **Review of Educational Research**, v. 77, n. 1, p. 81–112, 2007. DOI: <<https://doi.org/10.3102/003465430298487>>.
- HE, Aneng et al. AI-driven predictive models for optimizing mathematics education technology: Enhancing decision-making through educational data mining and meta-analysis. **Smart Learning Environments**, 2025. DOI: <<https://doi.org/10.1186/s40561-025-00415-z>>.
- HIGGINS, Julian P. T. et al. **Cochrane Handbook for Systematic Reviews of Interventions**. Cochrane, 2023. Version 6.4; versão historicamente registrada no trabalho. Disponível em: <<https://www.training.cochrane.org/handbook>>. Acesso em: 15 set. 2026.
- HONG, Quan Nha et al. The mixed methods appraisal tool (MMAT) version 2018 for information professionals and researchers. **Education for Information**, v. 34, n. 4, p. 285–291, 2018. DOI: <<https://doi.org/10.3233/EFI-180221>>.
- IMPERATRICE, R. C. Fabiola et al. **Beyond the traditional classroom: innovation and inclusion in math teaching with AI**. 2025.
- JAMES, Gareth et al. **An Introduction to Statistical Learning: with Applications in R**. 2. ed. New York: Springer, 2021. DOI: <<https://doi.org/10.1007/978-1-0716-1418-1>>.

KUMAR, Mukesh et al. Analysis of Feature Selection and Data Mining Techniques to Predict Student Academic Performance. In: **2022 International Conference on Decision Aid Sciences and Applications (DASA)**. [s.n.], 2022. p. 1013–1017. DOI: <<https://doi.org/10.1109/DASA54658.2022.9765236>>.

LAFFERTY, John D.; MCCALLUM, Andrew; PEREIRA, Fernando C. N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In: **International Conference on Machine Learning**. [s.n.], 2001. p. 282–289. Disponível em: <<https://www.cis.upenn.edu/~danroth/Teaching/CS598-05/Papers/crf.pdf>>. Acesso em: 7 out. 2026.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. [s.n.], 2017. Disponível em: <<https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>>. Acesso em: 15 set. 2026.

MACLELLAN, Christopher J. **Computational Models of Human Learning: Applications for Tutor Development, Behavior Prediction, and Theory Testing**. Tese (Doutorado) — Carnegie Mellon University, 2017. DOI: <<https://doi.org/10.1184/R1/6715271>>.

MCKENZIE, Joanne E. et al. Defining the criteria for including studies and how they will be grouped for the synthesis. In: HIGGINS, Julian P. T. et al. (Ed.). **Cochrane Handbook for Systematic Reviews of Interventions**. Cochrane, 2024. cap. 3. Version 6.5; chapter updated August 2023; sections 3.2 and 3.3. Disponível em: <<https://www.cochrane.org/authors/handbooks-and-manuals/handbook/current/chapter-03>>. Acesso em: 7 out. 2026.

MILIĆEVIĆ, Marina; MARINOVIĆ, Budimirka; JEFTIĆ, Ljerka. Machine learning methods as auxiliary tool for effective mathematics teaching. **Computer Applications in Engineering Education**, v. 32, n. 6, p. e22787, 2024. DOI: <<https://doi.org/10.1002/cae.22787>>.

MOHER, David et al. Preferred reporting items for systematic review and meta-analysis protocols (PRISMA-P) 2015 statement. **Systematic Reviews**, v. 4, n. 1, p. 1, 2015. DOI: <<https://doi.org/10.1186/2046-4053-4-1>>.

MOUSAVINASAB, Elham et al. Intelligent tutoring systems: a systematic review of characteristics, applications, and evaluation methods. **Interactive Learning Environments**, v. 29, n. 1, p. 142–163, 2021. DOI: <<https://doi.org/10.1080/10494820.2018.1558257>>.

National Research Council. **Knowing What Students Know: The Science and Design of Educational Assessment**. Washington, DC: The National Academies Press, 2001. DOI: <<https://doi.org/10.17226/10019>>.

NICULESCU-MIZIL, Alexandru; CARUANA, Rich. Predicting good probabilities with supervised learning. In: **Proceedings of the 22nd International Conference on Machine Learning**. ACM, 2005. p. 625–632. DOI: <<https://doi.org/10.1145/1102351.1102430>>.

NYANTAH, Rahmat Opoku; FREMPONG, Nana Kena; LARBI, Ernest. Enhancing Student Achievement in Circle Theorems: Integrating Computer Animation with the Jigsaw Cooperative Learning Model. **International Journal of Mathematics and Mathematics Education**, v. 3, n. 2, p. 91–112, 2025. DOI: <<https://doi.org/10.56855/ijmme.v3i2.1299>>.

OECD. **PISA 2022 Assessment and Analytical Framework**. Paris: OECD Publishing, 2023. DOI: <<https://doi.org/10.1787/dfe0bf9c-en>>.

PAGE, Matthew J. et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: <<https://doi.org/10.1136/bmj.n71>>.

PEJIC, Aleksandar; MOLCER, Piroška Stanic; GULAČI, Kristian. Math proficiency prediction in computer-based international large-scale assessments using a multi-class machine learning model. In: **2021 IEEE 19th International Symposium on Intelligent Systems and Informatics (SISY)**. [s.n.], 2021. p. 49–54. DOI: <<https://doi.org/10.1109/SISY52375.2021.9582522>>.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. ACM, 2016. p. 1135–1144. DOI: <<https://doi.org/10.1145/2939672.2939778>>.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining and learning analytics: An updated survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, p. e1355, 2020. DOI: <<https://doi.org/10.1002/widm.1355>>.

SOKKHEY, Phauk et al. Multi-models of Educational Data Mining for Predicting Student Performance in Mathematics: A Case Study on High Schools in Cambodia. **IEIE Transactions on Smart Processing and Computing**, v. 9, n. 3, p. 217–229, 2020. DOI: <<https://doi.org/10.5573/IEIESPC.2020.9.3.217>>.

TJAHYADI, Hendra; TUDE, Krismon N. L. The Implementation of Educational Data Mining in Predicting Students’ Academic Achievement in Mathematics at a Private Elementary School. **International Journal of Information and Education Technology**, v. 15, n. 1, p. 154–163, 2025. DOI: <<https://doi.org/10.18178/ijiet.2025.15.1.2228>>.

USKOV, Vladimir L. et al. Machine Learning-based Predictive Analytics of Student Academic Performance in STEM Education. In: **2019 IEEE Global Engineering Education Conference (EDUCON)**. [s.n.], 2019. p. 1370–1376. DOI: <<https://doi.org/10.1109/EDUCON.2019.8725237>>.

VILLEGAS-CH, William et al. Adaptive intelligent tutoring systems for STEM education: analysis of the learning impact and effectiveness of personalized feedback. **Smart Learning Environments**, 2025. DOI: <<https://doi.org/10.1186/s40561-025-00389-y>>.

VYGOTSKY, Lev S. **Mind in Society: The Development of Higher Psychological Processes**. Cambridge, MA: Harvard University Press, 1978.

WOOD, David; BRUNER, Jerome S.; ROSS, Gail. The role of tutoring in problem solving. **Journal of Child Psychology and Psychiatry**, v. 17, n. 2, p. 89–100, 1976. DOI: <<https://doi.org/10.1111/j.1469-7610.1976.tb00381.x>>.

XIA, Chenxi et al. Exploring the Integration of Education for Sustainable Development into University Mathematics: Insights from SiC Thickness Measurement in Advanced Industrial Applications. **Sustainability**, v. 18, n. 4, 2026. DOI: <<https://doi.org/10.3390/su18041900>>.

XIE, Haoran et al. Trends and development in technology-enhanced adaptive/personalized learning: A systematic review of journal publications from 2007 to 2017. **Computers & Education**, v. 140, p. 103599, 2019. DOI: <<https://doi.org/10.1016/j.compedu.2019.103599>>.

ZENG, Jialing. **Multimodal neurophysiological measurement of cognitive load during math problem solving in 4th graders**. 2025. DOI: <<https://doi.org/10.7916/2q6y-bm58>>.

ZHANG, Lei; ZHU, Weihua; FENG, Ling. Design of Personalized Learning Path Optimization Algorithm Based on Deep Learning. In: **2025 International Conference on Computers, Information Processing and Advanced Education (CIPAE)**. [s.n.], 2025. p. 650–655. DOI: <<https://doi.org/10.1109/CIPAE66821.2025.00116>>.

ZHANG, Xiaohui. An Innovative Model of Higher Mathematics Curriculum Education Incorporating Artificial Intelligence Technology. **Applied Mathematics and Nonlinear Sciences**, 2023. DOI: <<https://doi.org/10.2478/amns.2023.2.01524>>.

ÖZSEVEN, Beyza Esin; ÖZSEVEN, Turgut. A Hybrid Neuro-Fuzzy and Machine Learning Model for Student Performance Prediction in Online Mathematics Education. **International Journal of Advanced Computer Science and Applications**, 2026. DOI: <<https://doi.org/10.14569/ijacsa.2026.0170516>>.

APÊNDICE A – MAPEAMENTO DO RELATO AO PRISMA 2020

Este apêndice apresenta um mapeamento do relato deste manuscrito com base no PRISMA 2020 (Page et al., 2021). O quadro desdobra os 27 itens do checklist em suas alíneas aplicáveis e utiliza tópicos abreviados; os requisitos completos estão no checklist oficial. O mapeamento avalia o que foi apresentado no texto, não certifica a execução do procedimento, o rigor metodológico, a ausência de viés ou a certeza da evidência. São registradas as informações localizadas e as limitações do manuscrito, sem atribuir pontuação ou declarar conformidade global ou integral.

A indicação *Localizado* identifica uma passagem pertinente, mas não certifica sua suficiência. *Parcial* indica informação disponível com limitações explicitadas. *Não apresentado* registra informação ou resultado não encontrado no manuscrito examinado, sem afirmar que o procedimento jamais ocorreu; quando a atividade não foi realizada, isso é indicado na justificativa. *Não aplicável* é empregado somente com justificativa específica; a ausência de meta-análise não dispensa o relato dos métodos de síntese narrativa.

Quadro 5 – Mapeamento do relato aos itens do PRISMA 2020.

Item	Tópico abreviado	Localização e estado do relato
1	Título	Parcial: capa e folha de rosto identificam o tema, mas o título não explicita revisão sistemática.
2	Resumo	Parcial: Resumo e Abstract apresentam método e resultados; não foi concluída a conferência específica do PRISMA para resumos.
3	Justificativa	Localizado: Cap. 1, Justificativa.
4	Objetivos	Localizado: Cap. 1, Problema de Pesquisa e Objetivos.
5	Elegibilidade	Parcial: Cap. 3, Critérios de Seleção. Os critérios estão descritos, mas os 18 registros retidos operacionalmente ainda são provisórios: 17 são candidatos empíricos e 1 é protocolo/proposta contextual, fora da síntese de evidências.
6	Fontes	Parcial: Cap. 3, Estratégia de Busca. Não estão discriminadas as datas da última consulta de cada fonte.

Continua na próxima página

Quadro 5 – Continuação

Item	Tópico abreviado	Localização e estado do relato
7	Buscas	Parcial: Cap. 3, Estratégia de Busca e Quadro 1. Há composição canônica e exemplos; o relato por fonte, com filtros e limites, não está completo.
8	Seleção	Parcial: Cap. 3, Processo de Seleção, e Cap. 4, Limitações e Contribuições da Revisão. São descritos automação e revisor único; a verificação documental permanece incompleta.
9	Coleta de dados	Parcial: Cap. 3, Identificação e Avaliação da Qualidade Metodológica. A obtenção de metadados está descrita; a extração dos textos e sua confirmação não estão integralmente documentadas.
10a	Desfechos	Parcial: Cap. 3, Critérios de Seleção, e Quadro 3. Faltam regras completas para seleção de resultados por desfecho.
10b	Outras variáveis	Parcial: Cap. 3, Identificação. Não há definição completa das variáveis extraídas e do tratamento de informação ausente.
11	Viés nos estudos	Parcial: Cap. 3, Avaliação da Qualidade Metodológica. O MMAT está documentado como apreciação preliminar por revisor único, com fontes e julgamentos ainda incompletos.
12	Medidas de efeito	Parcial: Quadro 3. As métricas reportadas são heterogêneas; não foi definida medida comum para combinação quantitativa.
13a	Composição das sínteses	Parcial: Cap. 3, Critérios de Seleção, e Cap. 4, Síntese dos Estudos Incluídos. A separação entre os 17 candidatos empíricos provisórios e o protocolo contextual está relatada; o procedimento para formar cada síntese e a confirmação científica final dos candidatos não estão completamente detalhados.
13b	Preparação dos dados	Não apresentado: não foi localizado procedimento específico para preparar os resultados extraídos, incluindo estatísticas ausentes ou conversões.

Continua na próxima página

Quadro 5 – Continuação

Item	Tópico abreviado	Localização e estado do relato
13c	Apresentação	Localizado: Cap. 4, Fluxo de Seleção, Estatísticas Descritivas, Síntese dos Estudos Incluídos e Avaliação Metodológica com o MMAT. A apresentação não substitui a validação dos dados.
13d	Síntese	Parcial: Cap. 4, Síntese dos Estudos Incluídos e Limitações e Contribuições da Revisão. A heterogeneidade é discutida; a codificação e o procedimento da síntese narrativa não estão inteiramente explicitados.
13e	Heterogeneidade	Não apresentado: não foi realizado método formal para investigar possíveis causas de heterogeneidade; diferenças entre populações, desenhos e métricas são discutidas qualitativamente.
13f	Sensibilidade	Não apresentado: não foi realizada análise de sensibilidade da síntese.
14	Viés de relato	Não apresentado: não foi realizada avaliação formal. Cap. 4, Limitações e Contribuições da Revisão, registra a ausência de teste de viés de publicação.
15	Certeza	Não apresentado: não foi apresentada avaliação formal da certeza do conjunto de evidências; o MMAT individual não a substitui.
16a	Fluxo	Parcial: Figura 1 e Tabela 1. Há contagens operacionais, mas não a discriminação completa de relatórios procurados, não recuperados e examinados.
16b	Exclusões justificadas	Não apresentado: o manuscrito não traz uma relação de estudos aparentemente elegíveis excluídos, com respectivas citações e razões. O ledger de adjudicação versionado registra decisões de escopo, mas não substitui essa apresentação no TCC.
17	Características	Parcial: Quadro 3. Os candidatos são citados, mas características de amostra e desenho não estão uniformemente detalhadas.
18	Apreciação individual	Parcial: Seção 4.4 e Quadro 4. Julgamentos preliminares, com limitações de fontes e localizadores.

Continua na próxima página

Quadro 5 – Continuação

Item	Tópico abreviado	Localização e estado do relato
19	Resultados individuais	Parcial: Quadro 3. Diversas entradas descrevem a abordagem; estimativas e precisão não são apresentadas uniformemente.
20a	Síntese e limitações	Parcial: Cap. 4, Síntese dos Estudos Incluídos e Avaliação Metodológica com o MMAT. Não está completa a ligação entre os estudos de cada síntese e seus julgamentos metodológicos.
20b	Sínteses estatísticas	Não aplicável aos resultados de combinação estatística: nenhuma síntese estatística conjunta foi realizada.
20c	Heterogeneidade	Não apresentado: não foram apresentados resultados de investigação formal das causas de heterogeneidade.
20d	Sensibilidade	Não apresentado: não foram apresentados resultados de análises de sensibilidade.
21	Viés de relato	Não apresentado: não foram apresentados resultados de avaliação formal de viés decorrente de resultados ausentes.
22	Certeza	Não apresentado: não foi apresentada classificação formal de certeza por desfecho.
23a	Interpretação	Parcial: Cap. 6, Discussão Integrada. As interpretações dependem da consolidação da extração e da apreciação metodológica.
23b	Limites da evidência	Localizado: Cap. 4, Avaliação Metodológica com o MMAT e Limitações e Contribuições da Revisão; Cap. 7, Limitações.
23c	Limites do processo	Localizado: Cap. 3, Avaliação da Qualidade Metodológica, e Cap. 4, Limitações e Contribuições da Revisão, incluindo revisor único e acesso desigual aos textos.
23d	Implicações	Localizado: Cap. 6, Discussão Integrada, e Cap. 7, Continuidade da Pesquisa.
24a	Registro	Localizado: Cap. 3, Protocolo e Relato, declara ausência de registro prospectivo.

Continua na próxima página

Quadro 5 – Continuação

Item	Tópico abreviado	Localização e estado do relato
24b	Protocolo	Parcial: Cap. 3 descreve o planejamento; não identifica endereço de acesso a uma versão completa do protocolo anterior à execução.
24c	Alterações	Não apresentado: não foi localizada uma declaração metodológica completa de alterações do protocolo, com justificativas. A ausência de registro prospectivo não responde, por si só, a este item.
25	Apoio	Localizado: Seção 3.8, Apoio à Pesquisa. A pesquisa foi conduzida com recursos próprios, sem financiamento externo ou participação de financiador nas decisões da revisão.
26	Interesses	Não apresentado: não foi localizada declaração específica de conflitos de interesse; não se presume sua ausência.
27	Materiais	Parcial: Cap. 3, Reprodutibilidade, descreve código e exports. A relação de materiais públicos e respectivos endereços precisa ser explicitada.

A apreciação MMAT corresponde aos itens 11 e 18 deste mapeamento e permanece preliminar. Ela não constitui avaliação formal da certeza do conjunto de evidências (itens 15 e 22), não é avaliação de viés de relato (itens 14 e 21) e não permite inferir ausência de viés ou conformidade global. As pendências indicadas restringem o alcance das conclusões e devem ser consideradas juntamente com as limitações apresentadas no Capítulo 4.