Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal Catarinense
Campus Videira

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Videira
2026

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Trabalho de Conclusão de Curso apresentado ao Curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira para obtenção do título de bacharel em Ciência da Computação.
Orientador: Prof. Dr. Rafael Zanin (IFC)
Coorientador: Prof. Dr. Manassés Ribeiro (IFC)

Videira
2026

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Este Trabalho de Curso foi julgado adequado para a obtenção do título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira.

Videira (SC), ____ de _____ de 2026

Prof. Dr. Rafael Zanin
Orientador
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Manassés Ribeiro
Coorientador
Instituto Federal Catarinense – Campus Videira

BANCA EXAMINADORA

Prof. Me. Fábio José Rodrigues Pinheiro
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Dani Prestini
Instituto Federal Catarinense – Campus Videira

RESUMO

Este trabalho elaborou uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada em uma revisão sistemática da literatura sobre técnicas computacionais aplicadas ao ensino de matemática. Os objetivos específicos consistiram em categorizar as abordagens, as técnicas computacionais e as finalidades pedagógicas descritas na literatura; identificar limitações e lacunas técnicas, pedagógicas, metodológicas e éticas no material examinado; formular a especificação do protótipo; e propor um protocolo para avaliar sua viabilidade e coerência. O relato da revisão foi estruturado com referência ao PRISMA 2020. Foram identificados 11.904 registros em quatro fontes científicas; após a remoção determinística de 27 identidades DOI/URL, 11.877 seguiram para a triagem e 2.486 para priorização operacional, da qual resultaram 18 registros selecionados preliminarmente. Após uma exclusão na triagem do resumo, um texto integral não recuperado e a exclusão de um protocolo sem resultados concluídos, 15 registros empíricos mantidos provisoriamente compuseram o núcleo da síntese. A apreciação metodológica foi registrada preliminarmente com o MMAT 2018, por critério e sem pontuação geral ou ranking de qualidade. A revisão foi conduzida por um único pesquisador, e a adjudicação humana independente permanece pendente. A síntese preliminar identificou tarefas de predição de desempenho e de classificação ou estimativa de proficiência, com métodos como *Random Forest*, máquinas de vetores de suporte, árvores de decisão e redes neurais, cujos resultados não são diretamente comparáveis por envolverem populações, instrumentos e desenhos distintos. Também foram identificadas limitações localizadas relativas à representatividade, à descrição dos dados e ao controle de variáveis de confusão, que motivaram cautela quanto à generalização dos resultados. Com base nesses achados e na fundamentação pedagógica, foram definidos requisitos funcionais e não funcionais, critérios para seleção de fontes de dados e modelos, um protocolo de avaliação e uma arquitetura de referência; requisitos de explicabilidade, integração curricular, participação docente e reprodutibilidade foram propostos sem serem apresentados como lacunas comprovadas em toda a literatura. O protocolo não foi executado empiricamente. Os resultados e a especificação reforçaram que indicador de desempenho observado, probabilidade preditiva condicionada ao modelo e aos dados, proficiência estimada, competência e aprendizagem não são conceitos equivalentes. A probabilidade preditiva não demonstra, isoladamente, eficácia pedagógica, e as saídas computacionais devem apoiar, e não substituir, a interpretação do professor. Como contribuições, o trabalho produziu uma síntese estruturada do recorte versionado, com artefatos para sua inspeção e reprodução, um *pipeline* automatizado para a revisão e uma especificação técnica e pedagógica com requisitos rastreáveis às fontes ou a decisões autorais.

Palavras-chave: ensino de matemática; aprendizado de máquina; revisão sistemática; avaliação de competências; especificação de protótipo.

ABSTRACT

This work developed a technical and pedagogical prototype specification to support teachers' interpretation of mathematics learning, grounded in a systematic literature review of computational techniques applied to mathematics education. The specific objectives were to categorize the computational approaches, techniques, and pedagogical purposes described in the literature; to identify technical, pedagogical, methodological, and ethical limitations and gaps in the examined material; to formulate the prototype specification; and to propose a protocol for assessing its feasibility and coherence. Reporting of the review was structured with reference to PRISMA 2020. Across four scientific sources, 11,904 records were identified; after deterministic removal of 27 DOI/URL identities, 11,877 entered screening and 2,486 entered operational prioritization, which yielded 18 preliminarily selected records. After one exclusion at abstract screening, one full text that was not retrieved, and the exclusion of one protocol without completed results, 15 provisionally retained empirical records formed the core of the synthesis. Methodological appraisal was recorded preliminarily with MMAT 2018, criterion by criterion and without an overall score or quality ranking. One researcher conducted the review, and independent human adjudication remains pending. The preliminary synthesis identified tasks of performance prediction and of proficiency classification or estimation, using methods such as Random Forest, support vector machines, decision trees, and neural networks, whose results are not directly comparable because they involve different populations, instruments, and designs. Localized limitations related to representativeness, data description, and control of confounding variables were also identified, prompting caution about generalizing the results. Based on these findings and on the pedagogical foundations, the work defined functional and non-functional requirements, criteria for selecting data sources and models, an evaluation protocol, and a reference architecture; requirements for explainability, curriculum integration, teacher participation, and reproducibility were proposed without being presented as gaps demonstrated across the literature. The protocol was not empirically executed. The results and the specification reinforced that an observed performance indicator, a predictive probability conditioned on the model and data, estimated proficiency, competence, and learning are not equivalent concepts. Predictive probability does not, by itself, demonstrate pedagogical effectiveness, and computational outputs should support, not replace, teachers' interpretation. As contributions, the work produced a structured synthesis of the versioned data set, with artifacts for its inspection and reproduction, an automated pipeline for the review, and a technical and pedagogical specification whose requirements are traceable to sources or authorial decisions.

Keywords: mathematics education; machine learning; systematic review; competency assessment; prototype specification.

LISTA DE ILUSTRAÇÕES

Fluxograma 1 – Fluxo de seleção da revisão sistemática. 35
Gráfico 1 – Registros do recorte versionado após deduplicação, por fonte científica. . . 37

LISTA DE QUADROS

Quadro 1 – Camadas da estratégia de busca bilíngue. 23
Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão. 24
Quadro 3 – Caracterização e situação dos 18 registros selecionados preliminarmente. . 39
Quadro 4 – Triagem e respostas documentais preliminares ao MMAT 2018 de 14 registros do corpus. 45
Quadro 5 – Apreciação preliminar dos componentes qualitativos e quantitativos em estudos de métodos mistos. 46
Quadro 6 – Origem, derivação e limites dos requisitos da especificação conceitual. . . . 59
Quadro 7 – Mapeamento do relato aos itens do PRISMA 2020. 76

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da revisão sistemática. 36

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
ACO	*Ant Colony Optimization* (Otimização por Colônia de Formigas)
ANN	*Artificial Neural Networks* (Redes Neurais Artificiais)
API	*Application Programming Interface* (Interface de Programação de Aplicações)
BNCC	Base Nacional Comum Curricular
CNN	*Convolutional Neural Networks* (Redes Neurais Convolucionais)
DL	*Deep Learning* (Aprendizado Profundo)
DOI	*Digital Object Identifier*
DT	*Decision Trees* (Árvores de Decisão)
EDM	*Educational Data Mining* (Mineração de Dados Educacionais)
IA	Inteligência Artificial
IFC	Instituto Federal Catarinense
LGPD	Lei Geral de Proteção de Dados Pessoais
KNN	*K-Nearest Neighbors* (K-Vizinhos Mais Próximos)
LA	*Learning Analytics* (Analítica da Aprendizagem)
LIME	*Local Interpretable Model-agnostic Explanations*
LR	*Logistic Regression* (Regressão Logística)
ML	*Machine Learning* (Aprendizado de Máquina)
MMAT	*Mixed Methods Appraisal Tool*
NB	*Naive Bayes*
NLP	*Natural Language Processing* (Processamento de Linguagem Natural)
PICOS	*Population, Intervention, Comparison, Outcomes, Study Design*
PISA	*Programme for International Student Assessment*
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*

PRISMA-P	*Preferred Reporting Items for Systematic Review and Meta-Analysis Protocols*
RF	*Random Forest* (Floresta Aleatória)
RL	*Reinforcement Learning* (Aprendizado por Reforço)
SAEB	Sistema de Avaliação da Educação Básica
SHAP	*SHapley Additive exPlanations*
SMOTE	*Synthetic Minority Over-sampling Technique*
STEM	*Science, Technology, Engineering, Mathematics*
STI	Sistemas Tutores Inteligentes
SVM	*Support Vector Machines* (Máquinas de Vetores de Suporte)
TCC	Trabalho de Conclusão de Curso
XAI	*eXplainable Artificial Intelligence* (Inteligência Artificial Explicável)

SUMÁRIO

1 INTRODUÇÃO 12
1.1 Justificativa 12
1.2 Problema de Pesquisa 13
1.3 Objetivos 13
1.3.1 Objetivo Geral 13
1.3.2 Objetivos Específicos 13
1.4 Estrutura do Trabalho 14
2 FUNDAMENTAÇÃO TEÓRICA 15
2.1 Aprendizagem Matemática e Evidências de Desempenho 15
2.2 Contribuições Pedagógicas para a Especificação 16
2.3 Tecnologia como Apoio à Decisão Pedagógica 17
2.4 Técnicas Computacionais na Educação 17
2.5 Avaliação Automatizada e Métricas 20
2.6 Requisitos Derivados da Fundamentação 21
3 METODOLOGIA 22
3.1 Protocolo e Relato da Revisão Sistemática 22
3.2 Estratégia de Busca 23
3.3 Critérios de Seleção 24
3.4 Processo de Seleção 25
3.4.1 Identificação 25
3.4.2 Deduplicação e Triagem 26
3.4.3 Priorização operacional e verificação de escopo 27
3.5 Infraestrutura Tecnológica da Revisão 28
3.6 Avaliação da Qualidade Metodológica 29
3.7 Derivação da Especificação do Protótipo 33
3.8 Apoio à Pesquisa 33
4 REVISÃO SISTEMÁTICA DA LITERATURA 34
4.1 Fluxo de Seleção 34
4.2 Estatísticas Descritivas 35
4.3 Caracterização dos Registros Selecionados Preliminarmente 37

4.4 Avaliação Metodológica com o MMAT 44
4.5 Tendências e Lacunas 49
4.6 Limitações e Contribuições da Revisão 50
5 ESPECIFICAÇÃO DO PROTÓTIPO 52
5.1 Princípios e Requisitos 52
5.2 Protocolo de Avaliação da Especificação Conceitual 56
5.3 Arquitetura de Referência 58
5.4 Fundamentação e Rastreabilidade dos Requisitos 59
6 RESULTADOS E DISCUSSÃO 64
6.1 Resultados da Revisão Sistemática 64
6.2 Resultados da Avaliação Metodológica 65
6.3 Resultados da Fundamentação Pedagógica 66
6.4 Resultados da Especificação do Protótipo 66
6.5 Atendimento aos Objetivos 67
6.6 Discussão Integrada 68
7 CONCLUSÃO 69
7.1 Contribuições do Trabalho 70
7.2 Limitações 70
7.3 Continuidade da Pesquisa 71
REFERÊNCIAS 72
APÊNDICE A MAPEAMENTO DO RELATO AO PRISMA 2020 76

1 INTRODUÇÃO

Este trabalho parte da necessidade de interpretar evidências de desempenho de estudantes com conhecimentos prévios, ritmos e dificuldades distintos. A mineração de dados educacionais e a analítica da aprendizagem reúnem métodos para analisar registros educacionais e identificar padrões, podendo apoiar a organização de informações usadas no acompanhamento de turmas (Romero; Ventura, 2020). Esse apoio não torna a saída computacional uma medida direta de aprendizagem: a validade da inferência depende do alvo definido, dos dados e do contexto de uso (National Research Council, 2001).

O resumo indexado de (Uskov et al., 2019) descreve modelos preditivos de aprendizado de máquina aplicados ao desempenho em cursos de Ciência da Computação e Sistemas de Informação. Como o registro foi excluído na triagem do resumo por não apresentar resultado específico de aprendizagem matemática, ele é mencionado somente como contexto bibliográfico, não como evidência incluída na síntese. Na educação matemática, estudos consultados em texto integral incluem a predição de desempenho escolar por (Tjahyadi; Tude, 2025), a classificação em categorias operacionais de desempenho com itens de Matemática do PISA computadorizado por (Pejić; Molcer; Gulači, 2021) e a classificação de resultados em uma disciplina de Matemática por (Milićević; Marinović; Jeftić, 2024). Esses trabalhos exemplificam tarefas de predição e avaliação, mas não demonstram que uma intervenção pedagógica personalizada tenha melhorado a aprendizagem. A interpretação dessas saídas requer explicitar os dados, os alvos e as limitações de amostragem e validação; elas não substituem a avaliação do professor.

1.1 JUSTIFICATIVA

A relevância deste trabalho decorreu de duas necessidades complementares. A primeira consistiu em organizar a literatura, dispersa entre diferentes bases e áreas de pesquisa, sobre técnicas computacionais aplicadas ao ensino de matemática. A segunda consistiu em transformar as evidências encontradas em requisitos técnicos e pedagógicos para uma especificação de protótipo voltada ao apoio do professor.

Para professores, uma síntese crítica auxilia na compreensão das abordagens investigadas, dos resultados reportados e das limitações metodológicas recorrentes. Para estudantes e instituições, a pesquisa contribui ao explicitar que desempenho observado, proficiência estimada, competência e aprendizagem são conceitos relacionados, porém não equivalentes. Na

especificação, também foi prevista a distinção entre a probabilidade preditiva de um alvo definido — uma saída condicionada ao modelo e aos dados disponíveis — e o indicador de desempenho observado. Nenhuma dessas saídas, isoladamente, equivale a proficiência, competência, aprendizagem ou eficácia pedagógica.

1.2 PROBLEMA DE PESQUISA

Diante desse contexto, o trabalho respondeu ao seguinte problema de pesquisa: como estruturar uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática a partir das evidências e técnicas computacionais identificadas na literatura?

Essa finalidade pressupõe articular os registros de desempenho ao contexto pedagógico e à interpretação do professor. Não significa inferir aprendizagem diretamente de notas ou de probabilidades preditivas, nem demonstrar que a especificação proposta já a avalia ou melhora. O alcance desta pesquisa permanece documental, sem validação educacional própria.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

Propor uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada no mapeamento e na análise da literatura científica.

1.3.2 Objetivos Específicos

O **OE1** consiste em categorizar as abordagens e técnicas computacionais e as finalidades pedagógicas descritas na literatura mapeada. O **OE2** consiste em identificar limitações e lacunas técnicas, pedagógicas, metodológicas e éticas no material examinado. O **OE3** consiste em formular a especificação técnica e pedagógica do protótipo, incluindo requisitos, critérios para seleção de fontes de dados e modelos e uma arquitetura de referência. O **OE4** consiste em propor um protocolo para avaliar a viabilidade e a coerência da especificação conceitual, considerando sua fundamentação, a consistência dos requisitos e as condições técnicas e pedagógicas de uma eventual execução. A proposição desse protocolo não equivale à realização da avaliação nem exige desenvolver o protótipo nesta versão.

A revisão sistemática, com relato apoiado pelo PRISMA 2020 (Page et al., 2021), a apreciação metodológica preliminar com o MMAT 2018 (Hong et al., 2018a) e o *pipeline* — sequência automatizada de etapas de processamento — constituíram os meios metodológicos para atender a esses objetivos. Sua descrição e seus artefatos foram preservados, assim como o recorte de publicações de 2015 a 2026.

O produto do trabalho é documental: uma revisão da literatura e uma especificação de protótipo. A delimitação dos procedimentos executados e das atividades empíricas não realizadas é apresentada no Capítulo 3.

1.4 ESTRUTURA DO TRABALHO

O documento está organizado em sete capítulos. O Capítulo 1 apresenta o contexto, a justificativa, o problema e os objetivos. O Capítulo 2 discute aprendizagem matemática, avaliação, técnicas computacionais e limites das inferências baseadas em dados. O Capítulo 3 delimita o escopo executado e descreve a revisão sistemática, a estratégia de busca, os critérios de seleção, o processo de deduplicação, o PRISMA, o MMAT e o procedimento de derivação da especificação. O Capítulo 4 apresenta o fluxo de seleção, a síntese dos estudos, a avaliação por critérios e as lacunas identificadas. O Capítulo 5 consolida os princípios, requisitos, critérios de dados e modelagem, protocolo de avaliação e arquitetura de referência do protótipo. O Capítulo 6 integra os resultados da revisão, da apreciação metodológica, da fundamentação e da especificação. Por fim, o Capítulo 7 sintetiza as contribuições, as limitações e as possibilidades de continuidade da pesquisa.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 APRENDIZAGEM MATEMÁTICA E EVIDÊNCIAS DE DESEMPENHO

No referencial curricular adotado, os saberes matemáticos envolvem mais do que a execução de procedimentos. A Base Nacional Comum Curricular (BNCC) associa o letramento matemático às capacidades de raciocinar, representar, comunicar e argumentar matematicamente, além de formular e resolver problemas em contextos variados (Brasil, 2018a).

A BNCC define competência pela mobilização de conhecimentos, habilidades, atitudes e valores para resolver demandas complexas (Brasil, 2018a). Neste trabalho, esse referencial orienta o cuidado de não reduzir competência matemática ao resultado observado em uma única atividade.

Para evitar que medidas distintas fossem tratadas como equivalentes, este trabalho adotou definições operacionais. A avaliação educacional parte de observações produzidas por tarefas e respostas para realizar inferências sobre conhecimentos e habilidades; essas inferências dependem do modelo de cognição, dos instrumentos e dos procedimentos de mensuração empregados (National Research Council, 2001). Em avaliações como o PISA, a proficiência é estimada em uma escala e interpretada por níveis que descrevem o que os estudantes tipicamente conseguem realizar (OECD, 2023a).

Desempenho observado corresponde ao registro diretamente obtido em uma tarefa, como acerto, nota, número de tentativas, estratégia apresentada ou tempo de resolução (National Research Council, 2001). **Proficiência estimada** corresponde a uma inferência sobre a posição do estudante em uma escala de conhecimentos e habilidades, calculada a partir de um conjunto de evidências e de um modelo de mensuração (National Research Council, 2001; OECD, 2023a). **Competência** refere-se à mobilização de conhecimentos, habilidades, atitudes e valores para enfrentar situações e resolver problemas (Brasil, 2018a). Por sua vez, **aprendizagem** designa, operacionalmente neste trabalho, mudanças no que o estudante sabe e consegue fazer ao longo do tempo. Essa delimitação orienta a exigência de acompanhamento e interpretação contextualizada, sem pressupor que um indicador isolado demonstre tais mudanças. A distinção entre o conhecimento do estudante e a observação de sua atuação se apoia no caráter inferencial da avaliação discutido por National Research Council (2001, pp. 42–44).

Essas definições são relacionadas, mas não intercambiáveis. Um modelo computacional pode reconhecer padrões nos dados de desempenho e produzir estimativas para um alvo

definido; sua interpretação como proficiência requer um modelo de mensuração e evidências de validade para essa finalidade. Entretanto, o modelo não observa diretamente todos os processos cognitivos, sociais e afetivos envolvidos na aprendizagem. Suas saídas devem ser interpretadas como apoio à análise docente, e não como diagnóstico definitivo do estudante.

2.2 CONTRIBUIÇÕES PEDAGÓGICAS PARA A ESPECIFICAÇÃO

Os referenciais a seguir foram mobilizados para orientar aspectos distintos da especificação: mediação, conhecimento prévio e uso formativo de evidências. Essa articulação constitui uma escolha de projeto do trabalho, não uma afirmação de equivalência entre as teorias nem uma demonstração de eficácia do protótipo.

Vygotsky definiu a Zona de Desenvolvimento Proximal como a distância entre aquilo que o estudante realiza de forma autônoma e aquilo que consegue realizar com mediação (Vygotsky, 1978). Em sua pesquisa sobre tutoria na resolução de problemas, Wood, Bruner e Ross analisaram formas de apoio pedagógico temporário oferecidas ao aprendiz durante a realização de tarefas (Wood; Bruner; Ross, 1976). Neste trabalho, essa contribuição fundamenta a apresentação de evidências ao professor como apoio à interpretação, sem equiparar tutoria à Zona de Desenvolvimento Proximal nem tratar uma saída computacional como medida desse conceito.

Ausubel destacou que novas informações são aprendidas de forma significativa quando se relacionam a conhecimentos relevantes já existentes na estrutura cognitiva do estudante (Ausubel, 1968). A partir desse referencial, o trabalho propõe organizar registros de atividades anteriores e relações curriculares como contexto para a interpretação docente. Esse requisito não autoriza inferir ausência de compreensão apenas pela ausência de acerto, sem considerar a natureza da tarefa e a estratégia utilizada.

A avaliação formativa utiliza evidências produzidas durante o processo de aprendizagem para orientar decisões sobre as próximas ações de ensino e estudo (Black; Wiliam, 1998). A efetividade do *feedback* depende de seu foco, de sua clareza e da forma como ajuda o estudante a compreender os objetivos, avaliar seu estado atual e identificar ações para avançar (Hattie; Timperley, 2007). Na síntese desta revisão, os resultados de avaliação reportados pelos estudos empíricos não foram interpretados por este trabalho como equivalentes a uma teoria de aprendizagem ou como prova geral de eficácia pedagógica.

Como critério conceitual deste trabalho, uma previsão algorítmica, por si só, não

é tratada como *feedback* formativo: para exercer essa função, ela precisa ser convertida em informação compreensível e útil para decidir os próximos passos de aprendizagem, de modo que professor e estudante possam interpretar o retorno e agir sobre ele (Hattie; Timperley, 2007). Esse critério orienta a discussão do protótipo e não constitui resultado empírico desta revisão.

2.3 TECNOLOGIA COMO APOIO À DECISÃO PEDAGÓGICA

As tecnologias computacionais podem analisar registros educacionais, identificar padrões e apresentar informações para apoiar o acompanhamento de turmas (Romero; Ventura, 2020). Seu valor para a avaliação depende também da qualidade das evidências, da validade das inferências e do contexto de uso; por isso, os resultados não devem ser estendidos além do que os dados sustentam (National Research Council, 2001).

Nesta especificação, as tecnologias são propostas como apoio à decisão, preservando a responsabilidade do professor pela interpretação pedagógica; as previsões devem explicitar suas incertezas e limitações. Também são princípios de projeto o alinhamento das recomendações ao currículo e a prevenção de interpretações que naturalizem desigualdades ou convertam estudantes em categorias fixas, em consonância com a exigência de validade e equidade das inferências educacionais (National Research Council, 2001). Para eventual uso de dados pessoais, a especificação prevê finalidade explícita, minimização e análise da base legal aplicável, sem presumir que o consentimento seja sempre a base adequada (Brasil, 2018b). Esses pontos são requisitos propostos para uma implementação futura, não resultados empíricos desta revisão.

2.4 TÉCNICAS COMPUTACIONAIS NA EDUCAÇÃO

O aprendizado de máquina, ou ***machine learning*** (ML), é uma área da Inteligência Artificial que desenvolve modelos capazes de identificar padrões a partir de dados. Na educação matemática, estudos consultados em texto integral ilustram tarefas distintas: Pejić, Molcer e Gulači (2021) classifica estudantes em três categorias operacionais de desempenho, denominadas pelos autores níveis de proficiência e construídas a partir das respostas a itens do PISA computadorizado de 2012, sem equivalência demonstrada com os níveis oficiais da avaliação; Milićević, Marinović e Jeftić (2024) utiliza uma árvore de decisão para classificar resultados em uma disciplina de Matemática de 50 estudantes do primeiro ano de Engenharia Industrial, observados entre 2017 e 2021; e Zhang, Zhu e Feng (2025) propõe trajetórias de aprendizagem

personalizadas que incluem cursos de Matemática. Esses trabalhos contribuem para caracterizar alvos, dados e técnicas computacionais, mas não constituem, em conjunto, evidência de eficácia de ensino personalizado. No estudo de Pejić, Molcer e Gulači (2021), a seleção do subconjunto analítico e a descrição contraditória da separação entre treino, validação e teste limitam a interpretação das métricas; o relato não permite determinar se houve uso efetivo do conjunto de teste no ajuste; em Milićević, Marinović e Jeftić (2024), não foi localizada validação independente do classificador; e Zhang, Zhu e Feng (2025) não informa amostra, alocação nem análise inferencial suficientes para sustentar os efeitos que reporta. Essas limitações orientam a síntese e impedem extrapolar os resultados para o protótipo proposto.

Uma tarefa distinta foi investigada por He et al. (2025): a modelagem preditiva de tamanhos de efeito de tecnologias educacionais para matemática, a partir de dados extraídos de publicações. Nesse componente do estudo, a unidade de análise é a evidência sobre intervenções, e não a proficiência de um estudante. Essa distinção entre alvo e unidade de análise deve orientar a interpretação das aplicações de ML e a escolha de dados para um sistema de apoio docente.

A definição do alvo e da unidade de análise antecede a escolha do algoritmo: estimar categorias de desempenho de estudantes e prever resultados agregados de intervenções são problemas distintos. Árvores de decisão organizam previsões por divisões sucessivas dos atributos dos dados. O *Random Forest* combina previsões de várias árvores, treinadas com amostragem de registros e seleção aleatória de atributos nas divisões (Breiman, 2001). As máquinas de vetores de suporte (SVM) procuram separar classes por uma fronteira com margem ampla; funções de *kernel* permitem representar separações não lineares (Cortes; Vapnik, 1995). Redes neurais combinam unidades parametrizadas em camadas, cujos pesos são ajustados a partir dos dados (James et al., 2021, cap. 8–10). Essas definições identificam famílias de modelos e não demonstram que alguma delas seja superior para todos os contextos educacionais.

A comparação deve incluir um modelo simples de referência, ou *baseline*, como a predição pela classe majoritária em classificação ou pela média do conjunto de treinamento em regressão. O desbalanceamento de classes ocorre quando suas frequências diferem substancialmente. Nesse caso, a acurácia, definida como a proporção de classificações corretas, pode esconder erros nas classes menos frequentes. Por isso, as métricas devem ser escolhidas conforme o alvo, a distribuição dos dados e os tipos de erro relevantes, com avaliação em dados não utilizados no ajuste do modelo (James et al., 2021, cap. 2 e 4). O termo *benchmarking* de-

signa essa comparação de modelos sob condições e métricas definidas, não uma certificação de superioridade geral.

Na síntese dos estudos, DT e RF designam árvores de decisão e *Random Forest*; RN indica redes neurais e MLP, redes neurais multicamadas. NB indica o classificador probabilístico *Naive Bayes*, baseado na hipótese de independência condicional dos atributos (James et al., 2021, cap. 4 e 10). JRip é uma implementação que aprende regras de classificação.[1] CRF designa campos aleatórios condicionais, modelos probabilísticos para rotular dados em sequência (Lafferty; McCallum; Pereira, 2001). DL designa aprendizado profundo; RL, aprendizado por reforço; CNN, redes neurais convolucionais; e ACO, otimização por colônia de formigas. Esses nomes identificam métodos reportados, não alternativas equivalentes nem escolhas já validadas para o protótipo.

A ***Learning Analytics*** (LA), ou analítica da aprendizagem, envolve medir, coletar, analisar e apresentar dados sobre estudantes e seus contextos para compreender e apoiar a aprendizagem. A ***Educational Data Mining*** (EDM), ou mineração de dados educacionais, concentra-se no desenvolvimento e na aplicação de métodos de análise a dados educacionais (Romero; Ventura, 2020).

ML, LA e EDM não são sinônimos. ML designa uma família de métodos de aprendizado a partir de dados, enquanto LA e EDM delimitam campos de investigação e aplicação na educação. Ambos podem empregar ML, estatística e visualização, com sobreposição de métodos e finalidades; a distinção não constitui uma separação rígida entre ferramentas. Neste trabalho, essa relação organiza a leitura das técnicas e de seus usos pedagógicos (Romero; Ventura, 2020).

No escopo desta especificação, associações entre acesso, tempo de resposta e desempenho serão tratadas como padrões observados, não como explicações causais. Conhecimento prévio, familiaridade com a interface, acessibilidade e disponibilidade de conexão são hipóteses contextuais que poderão orientar análises futuras; seus efeitos não foram estimados neste trabalho (National Research Council, 2001).

Sistemas Tutores Inteligentes procuram adaptar a interação ao estado estimado do estudante. A literatura descreve esses sistemas por características como representação do estudante, mecanismos de adaptação, estratégias de orientação e formas de interação (Mousavinasab et al., 2021). Sistemas adaptativos também podem selecionar conteúdos ou ajustar a dificuldade

[1] A documentação oficial do Weka identifica JRip como implementação do algoritmo RIPPER: <https://weka.sourceforge.io/doc.dev/weka/classifiers/rules/JRip.html>. Acesso em: 7 out. 2026.

conforme os registros de interação (Xie et al., 2019).

Como princípio de projeto, uma regra adaptativa deverá ser compreensível ao professor e preservar oportunidades de exploração e autonomia. A possibilidade de que uma personalização excessiva ou baseada em dados incompletos limite essas oportunidades é tratada aqui como risco a avaliar, e não como efeito demonstrado pelos estudos reunidos.

Os métodos computacionais devem ser distinguidos das estratégias didáticas que podem acompanhar seu uso. O termo *jigsaw*, empregado na síntese do estudo sobre geometria, identifica uma modalidade de aprendizagem cooperativa: participantes estudam partes do conteúdo em grupos de especialistas e compartilham essa aprendizagem com seu grupo de origem.[2] Essa explicação esclarece o termo, sem afirmar que todas as condições do procedimento foram verificadas no estudo retido.

2.5 AVALIAÇÃO AUTOMATIZADA E MÉTRICAS

Sistemas automatizados podem organizar respostas, calcular indicadores e aplicar regras previamente definidas. Em tarefas de classificação, podem ser empregadas acurácia, precisão, revocação (*recall*), medida F1 e área sob a curva ROC (Romero; Ventura, 2020). A escolha depende do alvo e da distribuição das classes; essas métricas não se aplicam indistintamente à predição de valores contínuos. Elas avaliam o comportamento do modelo e não medem diretamente a qualidade pedagógica da intervenção.

A matriz de confusão organiza as contagens de classes observadas e previstas. Para uma classe examinada, precisão indica a proporção de previsões dessa classe que estão corretas, enquanto revocação indica a proporção de seus casos observados que foi reconhecida. F1 é a média harmônica dessas duas medidas; em problemas multiclasse, sua agregação também precisa ser especificada. Kappa quantifica a concordância entre duas categorizações, descontando o acordo esperado ao acaso. A interpretação desses indicadores exige preservar a tarefa e a forma de cálculo utilizada pelo estudo, sem adotá-los como medidas de aprendizagem.[3]

A curva ROC relaciona a taxa de casos positivos corretamente reconhecidos à taxa de falsos positivos, variando o limiar de decisão; sua área resume a capacidade de discriminação sob essa análise (Fawcett, 2006). A calibração, por sua vez, examina a correspondência entre probabilidades estimadas e frequências observadas dos eventos. Discriminar classes e estimar

[2] Descrição do procedimento no site oficial *The Jigsaw Classroom*, etapas 3–8: <https://www.jigsaw.org/>. Acesso em: 7 out. 2026.

[3] Definições e convenções de cálculo: documentação oficial do scikit-learn 1.6, seção 3.4, disponível em <https://scikit-learn.org/1.6/modules/model_evaluation.html>. Acesso em: 7 out. 2026.

probabilidades confiáveis são propriedades distintas: uma área ROC elevada não garante, por si só, probabilidades calibradas (Niculescu-Mizil; Caruana, 2005).

No domínio educacional, também podem ser observados acertos e erros por habilidade, tempo e número de tentativas, progressão entre avaliações, participação e conclusão de atividades e explicações ou estratégias registradas pelo estudante.

A interpretação deve considerar o instrumento, a população e a finalidade. Um bom desempenho médio não demonstra, por si só, validade equivalente das inferências entre grupos; por isso, a avaliação proposta inclui análise por classe, validação em dados não utilizados no treinamento e investigação de possíveis diferenças de erro, quando os dados permitirem (National Research Council, 2001). Esse procedimento é uma salvaguarda planejada, não um resultado medido nesta pesquisa.

2.6 REQUISITOS DERIVADOS DA FUNDAMENTAÇÃO

A fundamentação teórica sustentou requisitos para a especificação do protótipo: apresentar evidências de desempenho sem tratá-las como medida completa de aprendizagem; relacionar indicadores aos descritores e objetivos curriculares; oferecer explicações compreensíveis ao professor; registrar incertezas e limitações do modelo; permitir revisão humana das recomendações; proteger os dados educacionais; e exigir avaliação técnica antes de qualquer afirmação de eficácia pedagógica.

Esses requisitos foram incorporados à especificação apresentada no Capítulo 5. Dessa forma, a fundamentação não permaneceu apenas como discussão conceitual, mas orientou diretamente as decisões técnicas e pedagógicas consolidadas pelo trabalho.

3 METODOLOGIA

3.1 PROTOCOLO E RELATO DA REVISÃO SISTEMÁTICA

Este trabalho empregou uma Revisão Sistemática da Literatura para identificar e analisar técnicas computacionais aplicadas ao ensino de matemática. O *Cochrane Handbook for Systematic Reviews of Interventions* (Higgins et al., 2023) foi consultado como orientação metodológica geral. Essa consulta não implica adoção integral de um protocolo Cochrane.

O escopo executado compreendeu a revisão sistemática da literatura, a apreciação metodológica preliminar dos candidatos empíricos retidos e a elaboração de uma especificação conceitual de protótipo. Essa especificação consolidou princípios pedagógicos, requisitos, critérios para seleção de fontes de dados e modelos, procedimentos de avaliação e uma arquitetura de referência.

O desenvolvimento de uma aplicação funcional, o treinamento de modelos com uma base definitiva e a validação com participantes não integraram o escopo empírico desta pesquisa. Por essa razão, o trabalho não atribuiu ao protótipo métricas próprias de acurácia nem alegou eficácia pedagógica. Essa delimitação preservou a correspondência entre as afirmações apresentadas e os artefatos efetivamente produzidos.

O PRISMA 2020 (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) foi utilizado como diretriz de relato da revisão (Page et al., 2021). Sua função neste trabalho foi orientar a comunicação transparente da pergunta de pesquisa, das fontes consultadas, dos critérios de elegibilidade, do processo de seleção e dos resultados. Portanto, o PRISMA 2020 foi tratado como uma diretriz para relatar a revisão, e não como um método de busca, um instrumento de avaliação da qualidade ou uma garantia automática de ausência de viés.

O PRISMA-P 2015 (*Preferred Reporting Items for Systematic Review and Meta-Analysis Protocols*) possui finalidade distinta: orientar o desenvolvimento e o relato de protocolos de revisões sistemáticas (Moher et al., 2015). A revisão não foi registrada prospectivamente e, por isso, não se afirma conformidade integral com o PRISMA-P. Antes da execução, foram definidos a questão de pesquisa, os critérios de elegibilidade, a estratégia de busca, o processo de seleção e a forma de síntese. Esses elementos correspondem a princípios presentes no PRISMA-P, mas seu uso foi parcial e deve ser interpretado considerando a ausência de registro prospectivo. O checklist de relato PRISMA 2020 encontra-se no Apêndice A.

O checklist PRISMA 2020 foi preenchido retrospectivamente, depois da consoli-

dação do recorte versionado e da conferência dos artefatos. Neste trabalho, recorte versionado designa a versão congelada dos registros e das decisões utilizada na análise, distinguindo-a de uma nova coleta. O checklist documenta como a revisão foi relatada; não constitui registro prospectivo do protocolo nem substitui a descrição das decisões efetivamente tomadas durante a execução.

3.2 ESTRATÉGIA DE BUSCA

A coleta de dados foi realizada por meio de interfaces de programação de aplicações (APIs), que permitem consultar serviços externos de forma automatizada. Foram utilizadas quatro fontes científicas complementares: Semantic Scholar, fonte multidisciplinar; OpenAlex, catálogo acadêmico aberto; Crossref, fonte de metadados bibliográficos e identificadores DOI; e CORE, agregador de publicações disponibilizadas em acesso aberto.

O uso de múltiplas fontes foi adotado para ampliar a cobertura da busca e reduzir a dependência de uma única base. Essa escolha não demonstra exaustividade da recuperação. Também exigiu uma etapa de normalização, pois o mesmo estudo poderia ser recuperado com diferenças de título, autores ou demais metadados.

A estratégia de busca combinou três camadas de termos: domínio matemático, técnica computacional e contexto educacional, sintetizadas no Quadro 1. O operador booleano `AND` foi utilizado para exigir a presença conjunta dessas dimensões. As grafias dos termos foram preservadas conforme a configuração executada, inclusive as formas sem acentuação.

Quadro 1 – Camadas da estratégia de busca bilíngue.

Dimensão	**Inglês**	**Português**
Domínio matemático	mathematics; math	matemática
Técnicas computacionais	adaptive; personalized; tutoring; analytics; mining; machine learning; ai; assessment; student modeling; predictive; intelligent tutor; artificial intelligence	adaptivo; personalizado; tutor; analitica; mineração; aprendizado de máquina; ia; avaliação; modelagem do aluno; preditivo; tutor inteligente; inteligência artificial
Contexto educacional	education; learning	educacao; ensino

Fonte: Elaborado pelo autor (2026).

A estratégia canônica foi composta por 72 consultas: 48 em inglês e 24 em português. O conjunto dessas consultas está versionado nos artefatos do estudo; como não foi preservado um log histórico completo das requisições, esse número descreve a composição

da estratégia, e não uma contagem retrospectiva de chamadas HTTP concluídas em cada API. Em cada consulta, um termo do domínio matemático foi combinado, pelo operador `AND`, com um termo computacional e um termo educacional. Por exemplo, a combinação em inglês foi `mathematics AND machine learning AND education`; em português, `matemática AND aprendizado de máquina AND educacao`. Esses exemplos ilustram a composição dos termos e não substituem as consultas versionadas.

3.3 CRITÉRIOS DE SELEÇÃO

Os critérios de inclusão e exclusão foram organizados com apoio do PICOS, apresentado no Quadro 2. Trata-se de uma adaptação ao mapeamento de técnicas computacionais na educação matemática: o capítulo 3 do *Cochrane Handbook*, seções 3.2 e 3.3, articula população, intervenção, comparação e resultados (PICO) à especificação dos desenhos de estudo (McKenzie et al., 2024). Neste trabalho, a letra S explicita essa última dimensão. A adaptação não implica execução de uma revisão Cochrane de efeitos de intervenções nem torna obrigatório um comparador para todos os estudos computacionais.

Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão.

Dimensão	**Aplicação ao trabalho**
P – População	Estudantes de matemática em qualquer nível educacional.
I – Intervenção	Aplicação de técnicas computacionais, como aprendizado de máquina, inteligência artificial, analítica da aprendizagem e sistemas tutores inteligentes.
C – Comparação	Abordagens pedagógicas alternativas ou tradicionais, quando disponíveis.
O – Resultados	Desempenho acadêmico, diagnóstico de competências, avaliação ou personalização do ensino, conforme a finalidade declarada no estudo.
S – Desenho de estudo	Estudos empíricos com descrição metodológica e evidências aplicadas.

Fonte: Elaborado pelo autor (2026).

O período de 2015 a 2026 foi definido para abranger a produção científica considerada no recorte versionado da revisão, com data de corte em 31 de agosto de 2026. O recorte concentrou a análise em abordagens compatíveis com a especificação desenvolvida no trabalho.

Foram elegíveis artigos completos revisados por pares, teses de doutorado e dissertações de mestrado publicados nesse período, com foco explícito em técnicas computacionais aplicadas ao ensino de matemática. A inclusão de teses e dissertações, como literatura cinzenta, permitiu considerar estudos empíricos pertinentes independentemente do tipo de veículo de publicação, sem flexibilizar os critérios de elegibilidade. Para todas as modalidades, exigiu-se a

apresentação de dados empíricos ou de relato metodológico sobre desenvolvimento e avaliação de sistemas, em texto redigido em inglês ou português.

Os critérios de exclusão compreenderam metodologia insuficientemente descrita para responder à questão da revisão, foco apenas indireto no ensino ou na aprendizagem de matemática e publicações teóricas sem evidências empíricas compatíveis com o escopo. Também foram considerados inelegíveis editoriais, comentários, erratas e relatórios internos que não correspondessem aos tipos documentais elegíveis, além de textos em idiomas diferentes de inglês e português.

3.4 PROCESSO DE SELEÇÃO

O relato do processo considera os itens aplicáveis do PRISMA 2020, mas o fluxograma desta revisão é uma representação operacional própria, não o diagrama PRISMA completo. Após a triagem, o pipeline aplicou uma priorização heurística baseada em metadados e resumos. Essa etapa não corresponde à avaliação de elegibilidade de relatórios recuperados; por isso, seus resultados são descritos como priorização operacional e retenção provisória, sem afirmar inclusão final universal.

3.4.1 Identificação

O recorte versionado preserva 11.904 registros identificados. A configuração da busca contém 72 consultas para as quatro APIs; entretanto, como não foi preservado um histórico completo das requisições, não é possível reconstruir quantas solicitações HTTP foram concluídas por consulta ou por API. O fluxo automatizado foi configurado com limite de até 50 resultados por consulta e por API, parâmetro operacional que deve ser considerado na interpretação da cobertura. Cada registro armazenou, quando disponível, título, autores, ano, veículo de publicação, DOI ou endereço eletrônico e resumo.

O corte temporal declarado da busca foi 31 de agosto de 2026. A adjudicação inicial do escopo da população foi concluída em 3 de setembro de 2026. Em 14 de outubro de 2026, uma reconciliação atualizada confrontou os 18 registros da lista preliminar com o protocolo escrito e com a situação de recuperação dos textos integrais, incluindo três artigos recém-recuperados e verificados. Essa atualização corrigiu a classificação das etapas de seleção, sem nova consulta às bases e sem alterar o corte temporal da busca. Em 20 de outubro de 2026, a recuperação suplementar do texto integral do registro excluído originalmente após a triagem

do resumo confirmou que o estudo descreve cursos de Ciência da Computação e Sistemas de Informação e reserva a Matemática a trabalho futuro; essa conferência confirmou a decisão de escopo, sem criar uma nova etapa de exclusão nem alterar as contagens PRISMA. O fluxo vigente distingue um registro excluído após resumo, 17 relatórios procurados, um texto não recuperado, 16 relatórios avaliados em texto completo, um protocolo excluído e 15 estudos empíricos mantidos provisoriamente. A triagem S1/S2 do MMAT foi registrada para 14 desses estudos e os critérios específicos de categoria para 11; o estudo 8 segue sem respostas até adjudicação humana da elegibilidade e da unidade de apreciação. Como não foram preservados registros completos das requisições por consulta e por API, não é possível reconstruir o instante de cada solicitação nem afirmar que todas as fontes foram consultadas exatamente na data de corte; essa limitação restringe o detalhamento da data de última busca por fonte.

3.4.2 Deduplicação e Triagem

A deduplicação utilizada no fluxo PRISMA foi determinística e baseada na identidade bibliográfica normalizada. Registros com o mesmo DOI normalizado ou com a mesma URL exata foram reunidos, preservando-se a representação escolhida para o fluxo; essa etapa removeu 27 linhas excedentes, sendo 25 identificadas por DOI e 2 por URL. A auditoria também calculou repetições de títulos normalizados. Contudo, os 232 excedentes restantes após a remoção por DOI/URL foram mantidos como candidatos à revisão semântica, pois títulos semelhantes ou idênticos podem corresponder a versões, erratas ou obras distintas. Portanto, não foram removidos automaticamente por título e não entram como duplicatas confirmadas no fluxo vigente.

Após a deduplicação determinística, 11.877 registros foram submetidos à triagem. Desses, 9.391 foram excluídos e 2.486 avançaram para a priorização operacional. Essa etapa não equivale à avaliação de elegibilidade de relatórios em texto completo.

A triagem automatizada utilizou regras sobre os metadados e o resumo disponível. No arquivo versionado, 4.314 exclusões receberam o motivo operacional `abstract_too_short`, aplicado a resumos com menos de 50 palavras; em 4.093 desses registros, o campo continha a indicação “Abstract não disponível”. Outras 2.076 exclusões receberam o motivo `no_methodology`, acionado pela ausência, no resumo, dos termos em inglês `method`, `approach`, `experiment`, `study`, `analysis`, `evaluation`, `test` ou `assess`, com exceções para termos de revisão. Os demais motivos registrados nessa etapa foram não atendi-

mento aos critérios de inclusão, com 2.856 registros; conteúdo não classificado como pesquisa, com 103; e conteúdo fora do tema, com 42. Esses valores totalizam as 9.391 exclusões de triagem e não incluem as 2.468 exclusões posteriores na priorização operacional.

Esses rótulos descrevem o funcionamento do código, não uma apreciação da qualidade metodológica dos trabalhos excluídos. Resumo ausente ou curto não demonstra ausência de método, e a falta dos termos procurados em inglês pode decorrer do idioma, da redação ou da cobertura dos metadados. Assim, as regras podem produzir falsos negativos e restringir a cobertura da revisão. Não foi realizada uma verificação independente de todos os registros excluídos nem uma estimativa da sensibilidade desses filtros. A reprodução das contagens comprova consistência do registro disponível, não completude da recuperação científica; por isso, o recorte não foi apresentado como levantamento exaustivo da área.

3.4.3 Priorização operacional e verificação de escopo

A etapa de priorização operacional utilizou uma pontuação de relevância temática, distinta da avaliação de qualidade metodológica. A heurística considerou a presença e a relevância de técnicas computacionais, a aderência explícita ao ensino de matemática, a completude dos metadados e do resumo e a disponibilidade de identificadores e informações bibliográficas.

A pontuação foi um indicador operacional de relevância temática, calculado por uma heurística multicritério aplicada aos metadados e aos resumos disponíveis. No recorte vigente, os valores observados variaram de 0,0 a 4,5 e o limiar operacional foi 4,0. O limiar apoiou a priorização e a seleção operacional, mas não constituiu medida de qualidade científica nem substituiu a verificação de escopo, tipo documental e pertinência. A apreciação metodológica foi conduzida separadamente com o MMAT 2018.

O valor 4,0 deve ser interpretado como parâmetro de triagem do fluxo automatizado, e não como ponto de corte validado para relevância científica. A retenção também dependeu dos critérios documentais registrados em <research/data/current_eligibility_protocol.csv>. Como a confirmação em texto completo não foi concluída para todos os registros, o conjunto retido deve ser descrito como provisório. O recorte vigente não inclui uma análise de sensibilidade a diferentes limiares; portanto, não se atribui ao valor 4,0 estabilidade estatística ou capacidade de representar sozinho o universo da literatura.

Dos 2.486 registros submetidos à priorização operacional, 2.468 foram excluídos por essa heurística e pelas regras operacionais de escopo, restando 18 registros na lista prelimi-

nar para adjudicação. Um registro foi excluído após a triagem do resumo por tratar de cursos de Ciência da Computação e Sistemas de Informação sem resultado empírico de aprendizagem matemática. Entre os 17 relatórios procurados, um texto integral não foi recuperado: o da dissertação de Zeng (2025). Conforme consulta registrada no manifesto de fontes em 13 de outubro de 2026, o repositório Academic Commons informava que os arquivos estariam disponíveis a partir de 16 de maio de 2027. Até essa data, o resumo institucional pode ser usado apenas como informação contextual; a elegibilidade por texto completo e a apreciação MMAT permanecem pendentes.

Os outros 16 relatórios foram examinados em texto completo. Após a aplicação dos critérios escritos, um protocolo sem resultados concluídos foi excluído da síntese empírica (Imperatrice et al. (2025)) e 15 registros empíricos permaneceram provisoriamente no núcleo. Entre os textos consultados, Pejić, Molcer e Gulači (2021) e Milićević, Marinović e Jeftić (2024) tratam de predição ou classificação de resultados matemáticos, enquanto Zhang, Zhu e Feng (2025) propõe trajetórias personalizadas; essas contribuições não equivalem, por si, a evidência de eficácia pedagógica. O estudo de Xia et al. (2026) também foi mantido porque o protocolo não exige personalização como condição: ele descreve ensino universitário de matemática que integra Transformada de Fourier e avaliação mediada por recursos computacionais. Seus resultados, contudo, não isolam o efeito da IA e comparam coortes separadas por quatro anos.

O estudo 8 permanece provisoriamente no fluxo e no núcleo, mas sua elegibilidade e unidade de apreciação ainda aguardam adjudicação humana. Assim, os 18 registros da lista preliminar distribuem-se em 15 estudos empíricos provisórios, um registro excluído após resumo, um texto integral não recuperado e um protocolo excluído após texto completo; essa contagem não representa 18 estudos empíricos incluídos.

3.5 INFRAESTRUTURA TECNOLÓGICA DA REVISÃO

O fluxo automatizado da revisão foi implementado em Python. O SQLite foi utilizado para o armazenamento estruturado dos registros e das etapas de seleção; Requests, para comunicação com as APIs; Pandas, para manipulação e exportação de dados tabulares; e scikit-learn, como apoio às análises computacionais auxiliares do fluxo.

Foi utilizado um *cache* local, isto é, um armazenamento temporário de respostas previamente obtidas. Um acerto de cache ocorre quando uma nova solicitação pode ser atendida com um resultado já armazenado, sem consultar novamente a API externa. Como os contadores

dependem do histórico e do momento de execução, a taxa de acertos não foi utilizada como indicador fixo do *pipeline*; sua interpretação permaneceu vinculada às estatísticas da execução analisada.

Consultas, critérios e código estão versionados; os arquivos CSV, JSON e BibTeX permitem auditar o recorte atual sem o banco SQLite. A verificação pode ser feita com:

```
python -m research.src.validation.versioned_snapshot
python -m research.src.processing.adjudicated_snapshot --check
python -m research.src.validation.bibliography_audit
```

A disponibilização do código e dos artefatos favorece a auditoria do processo. Entretanto, a reprodução exata dos resultados também depende da disponibilidade das APIs e das alterações realizadas por cada fonte ao longo do tempo.

O arquivo <research/exports/reports/reproducibility_manifest.json> funciona como índice de proveniência do recorte versionado: registra a data de geração, os hashes SHA-256 dos arquivos exportados, o registro corrente de avaliação MMAT, as fontes primárias consultadas e os comandos de reconstrução. Essa estrutura permite verificar a versão publicada sem distribuir o banco SQLite operacional e torna explícita a diferença entre reproduzir o recorte e iniciar uma nova coleta nas APIs.

3.6 AVALIAÇÃO DA QUALIDADE METODOLÓGICA

Os 15 registros empíricos mantidos provisoriamente foram considerados na apreciação documental por critérios com o *Mixed Methods Appraisal Tool* (MMAT), versão 2018 (Hong et al., 2018a). Quatorze possuem respostas preliminares S1/S2; em 11, também foram apreciados os critérios específicos da categoria. Nos estudos 5 (Zhang, Zhu e Feng (2025)), 7 (Zhang (2024)) e 14 (Nyantah, Frempong e Larbi (2025)), Q1–Q5 permanecem sem resposta até a definição do delineamento; o estudo 8 permanece sem respostas até a adjudicação de sua elegibilidade e unidade de apreciação. A dissertação de Zeng (2025), único relatório não recuperado, também não recebeu apreciação: seus itens permanecem sem resposta e não devem ser interpretados como CT, N ou N/A. O registro excluído após resumo fica fora do denominador empírico; o protocolo sem resultados concluídos não integra esse denominador e recebe N/A nas células empíricas. O instrumento foi escolhido por oferecer conjuntos de critérios específicos para estudos qualitativos, quantitativos randomizados, quantitativos não randomizados,

quantitativos descritivos e de métodos mistos; sua aplicação nesta versão é preliminar e limitada pela adjudicação humana pendente.

Antes da apreciação específica, foram registradas as duas perguntas de triagem do instrumento: S1, “Há perguntas de pesquisa claras?”, e S2, “Os dados coletados permitem responder às perguntas de pesquisa?”. Em seguida, o processo compreendeu a classificação do desenho metodológico de cada estudo, o registro das respostas S1 e S2, a aplicação dos cinco critérios Q1–Q5 correspondentes ao desenho, o registro de cada célula como Y (“Sim”), N (“Não”) ou CT (“Não é possível concluir com a evidência disponível”) e a descrição das limitações identificadas em cada estudo.

Os critérios Q1–Q5 variam conforme a categoria do MMAT e, por isso, foram interpretados somente após a classificação do desenho. Em estudos quantitativos descritivos, Q1 avalia a pertinência da estratégia de amostragem; em estudos quantitativos não randomizados, Q1 avalia a representatividade dos participantes em relação à população-alvo; na categoria de métodos mistos, os cinco critérios avaliam a justificativa, a integração e a interpretação dos componentes, o tratamento de divergências e a qualidade de cada tradição metodológica. O guia também recomenda apreciar cada componente com a categoria qualitativa ou quantitativa apropriada. Os registros 6916, 6919 e 6920 foram reclassificados como estudos de métodos mistos após consulta aos respectivos textos primários; seus componentes qualitativos e quantitativos são apreciados separadamente no quadro complementar de avaliação. Essa ampliação não encerra a avaliação: os julgamentos são de revisor único, permanecem preliminares e aguardam conferência independente e adjudicação. A pertinência temática de um estudo não substitui nenhum critério metodológico. De modo análogo, em estudos descritivos, a simples menção à comparação entre modelos não demonstra que a análise estatística seja apropriada sem a descrição do procedimento. Nesses casos, CT indica insuficiência documental, não uma conclusão negativa sobre a qualidade do estudo, conforme as orientações de aplicação do instrumento (Hong et al., 2018b).

As respostas não foram convertidas em pontuação geral, média, ranking ou categoria de qualidade. A apresentação por critério preserva quais aspectos metodológicos foram atendidos e quais permaneceram problemáticos ou insuficientemente descritos. Os estudos não foram excluídos em razão do MMAT; suas limitações foram consideradas na interpretação da síntese.

Os julgamentos apresentados são registros documentais provisórios, produzidos

com apoio de IA generativa e ainda sujeitos à conferência humana por fonte e critério. O rótulo histórico de revisor único no registro de avaliação não comprova, por si, identidade do avaliador nem leitura humana integral; por isso, esta versão não apresenta uma apreciação humana concluída. O guia do MMAT recomenda a participação independente de pelo menos dois avaliadores (Hong et al., 2018b); consultas a agentes automatizados não constituem essa avaliação independente nem substituem a adjudicação humana. O fluxo registra 15 candidatos empíricos provisórios após a avaliação documental de elegibilidade, mas essa contagem não demonstra cobertura integral de leitura dos textos, figuras e apêndices. O estudo 8 permanece sem respostas enquanto se adjudicam sua elegibilidade e unidade de apreciação. A dissertação de Zeng (2025), registrada como relatório não recuperado, também não recebeu apreciação; um registro foi excluído após o resumo e um protocolo após a avaliação em texto completo. As cópias dos textos primários não são distribuídas no repositório público. O manifesto e os localizadores preservam a proveniência declarada das consultas, não certificam sua extensão. A confirmação das fontes e rendições, a leitura crítica humana e a adjudicação dos julgamentos permanecem pendentes; as respostas não constituem uma síntese final de qualidade.

Na revisão de consistência, a simples identificação de variáveis ou desfechos nos resumos não foi considerada evidência suficiente para apreciar critérios do MMAT. Para o único relatório não recuperado, o da dissertação de Zeng (2025), nenhum item foi avaliado: S1, S2 e Q1–Q5 permanecem sem resposta. Não houve classificação do delineamento nem juízo metodológico, e essa ausência não representa uma conclusão negativa sobre o estudo. Os textos integrais de Pejić, Molcer e Gulači (2021), Zhang, Zhu e Feng (2025) e Milićević, Marinović e Jeftić (2024) foram incorporados com limitações explícitas: suas contribuições sustentam exemplos de predição/avaliação matemática ou uma proposta de personalização, não afirmações de eficácia causal ou generalizável. O estudo 8 também permanece sem respostas até a adjudicação de escopo e unidade. A triagem S1/S2 dos 14 estudos e a apreciação por categoria de 11, com seus resultados por célula e as pendências dos outros três, são apresentadas na Seção 4.4.

Para Nyantah, Frempong e Larbi (2025, pp. 101–105), o texto primário apresenta afirmações incompatíveis sobre a alocação das escolas: uma seção descreve distribuição aleatória, enquanto outra caracteriza o estudo como quase-experimental sem alocação aleatória. Como a definição da categoria MMAT altera quais critérios Q1–Q5 são aplicáveis, a categoria desse estudo permanece pendente e esses cinco critérios não foram apreciados e permanecem sem resposta, em vez de CT, sem inferir falha metodológica a partir da inconsistência documental.

O registro de fontes primárias preserva, para cada estudo, a identificação da fonte, a data de consulta, o tipo de fonte, a situação de recuperação e a base documental da apreciação. Quando apenas resumo e metadados estavam disponíveis, essa limitação de acesso foi tratada como insuficiência de evidência, não como resposta negativa automática aos critérios. Essa distinção impede que a ausência do texto completo seja confundida com demonstração de falha metodológica do estudo.

Na atualização documental de 20 de outubro de 2026, 16 dos 18 registros candidatos dispunham de cópias locais identificadas por hash. A matriz complementar distingue páginas de texto examinadas, imagens inspecionadas, contribuição delimitada de cada fonte e conferência humana pendente. Os textos dos registros 4 e 9 foram incorporados nessa atualização; os registros 7 e 6919 já haviam sido recuperados em 17 de outubro. No registro 9, a codificação do texto embutido estava corrompida, exigindo reconhecimento óptico de caracteres e inspeção visual seletiva; essa extração não certifica a leitura de todas as figuras e tabelas. A conferência do texto integral confirmou a decisão de escopo originalmente registrada após o resumo, sem transformar a recuperação suplementar em novo evento de seleção.

Permaneceram sem cópia verificável os registros 3 e 6923. Para o registro 3, foi relatado acesso por compra, sem obtenção do original; a inclusão provisória e as respostas MMAT anteriores são preservadas como histórico, não como apreciação revalidada nesta auditoria. Para o registro 6923, o manifesto documenta embargo informado pelo repositório institucional na consulta de 13 de outubro de 2026, com liberação prevista para 2027; nenhum critério MMAT foi aplicado. A indisponibilidade dos originais limita a verificação, mas não demonstra falha metodológica ou irrelevância temática. O trabalho prossegue com essas restrições explícitas, sem substituir os textos por inferências a partir de metadados.

Essa disponibilidade local não recalcula o fluxo histórico de 17 relatórios procurados e 16 declarados avaliados, nem ratifica consultas anteriores sem rendição verificável. A tese do registro 8 recebeu leitura parcial de 38 das 108 páginas na auditoria de cobertura, sem conferir integralmente seus demais capítulos, figuras e apêndices. As consultas suplementares têm cobertura própria registrada na matriz; a reprodução congelada do índice de recuperação textual continua limitada às 12 fontes originalmente indexadas. Extração automática e leitura de texto extraível não foram equiparadas à leitura humana ou multimodal integral.

3.7 DERIVAÇÃO DA ESPECIFICAÇÃO DO PROTÓTIPO

A especificação do protótipo foi elaborada a partir da integração entre os resultados da revisão sistemática e os princípios pedagógicos discutidos na fundamentação teórica. O procedimento articulou limitações localizadas nos 15 estudos mantidos provisoriamente no núcleo, fundamentos teóricos ou normativos e decisões de projeto do autor, sem atribuir todas as dimensões ao corpus. Essa articulação orientou requisitos funcionais e não funcionais e critérios para fontes de dados, alternativas de modelagem, explicabilidade e avaliação; e organizou os requisitos em uma arquitetura conceitual de referência.

As decisões foram registradas como especificação, e não como evidência de uma implementação funcional. Esse procedimento permitiu transformar os achados da literatura em um artefato técnico e pedagógico coerente com o escopo executado e com as limitações explicitadas no trabalho.

Na versão vigente, a rastreabilidade entre a revisão e a especificação está consolidada no nível das dimensões e dos requisitos descritos no capítulo. O Quadro 6 explicita a origem dos grupos de requisitos: observações localizadas dos estudos, fundamentos teóricos ou normativos e decisões de projeto do autor. Essa distinção evita atribuir ao corpus requisitos que não foram avaliados empiricamente por seus estudos. O quadro constitui rastreabilidade documental da derivação, não validação pedagógica da especificação nem auditoria independente integral das fontes.

3.8 APOIO À PESQUISA

A pesquisa foi conduzida pelo autor com recursos próprios, sem financiamento externo. Não houve entidade financiadora externa com participação no delineamento, na seleção dos estudos, na análise ou na decisão de disponibilização dos resultados. O autor declara não haver conflitos de interesse relacionados a esta pesquisa.

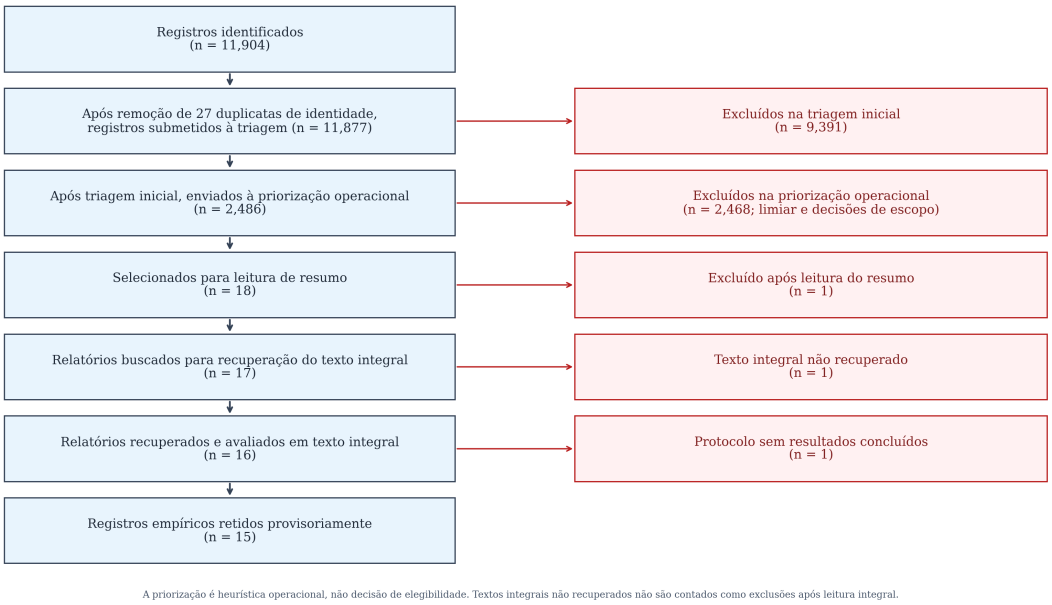
4 REVISÃO SISTEMÁTICA DA LITERATURA

Este capítulo apresenta os resultados da revisão sistemática desenvolvida no trabalho. O processo identificou 11.904 registros nas quatro fontes consultadas. Após a deduplicação determinística por identidade DOI/URL, 11.877 registros foram submetidos à triagem; 9.391 foram excluídos e 2.486 avançaram para priorização operacional. Dos 18 registros selecionados preliminarmente, um foi excluído após a triagem do resumo; 17 relatórios foram procurados, um não foi recuperado e 16 foram avaliados em texto completo. Um protocolo sem resultados concluídos foi excluído, e 15 estudos compõem provisoriamente o núcleo empírico incluído. A pontuação operacional representou aderência temática ao problema de pesquisa; ela não foi interpretada como medida de qualidade científica.

4.1 FLUXO DE SELEÇÃO

O Fluxograma 1 apresenta uma representação operacional do processo de seleção, elaborada com referência ao PRISMA 2020. Ele distingue a priorização heurística da avaliação de elegibilidade em texto completo: a priorização não equivale a essa avaliação. Após a identificação, 27 linhas excedentes foram removidas por identidade bibliográfica determinística, 25 por DOI normalizado e 2 por URL exata. Dos 11.877 registros triados, 9.391 foram excluídos e 2.486 passaram à priorização; 2.468 foram excluídos nessa etapa e 18 formaram a lista preliminar. Um registro foi excluído após resumo. Dos 17 relatórios procurados, um não foi recuperado e 16 foram avaliados em texto completo; o protocolo sem resultados concluídos foi excluído. Os 15 restantes compõem provisoriamente o núcleo empírico incluído. Portanto, os 18 registros pré-selecionados não equivalem a 18 artigos incluídos.

Fluxograma 1 – Fluxo de seleção da revisão sistemática.



Fonte: Elaborado pelo autor (2026).

4.2 ESTATÍSTICAS DESCRITIVAS

A Tabela 1 reúne os principais números da revisão. A auditoria de identidade registra as remoções determinísticas que entram no fluxo PRISMA e mantém separadas as repetições observadas apenas por título. Depois da remoção por DOI/URL, permaneceram 232 excedentes em grupos de título normalizado, tratados como candidatos à revisão semântica e não como duplicatas confirmadas. A pequena proporção de registros retidos decorreu do escopo específico e da aplicação do filtro operacional de relevância temática, seguida da verificação de escopo.

A taxa de acertos do *cache* não foi apresentada como métrica fixa. Um acerto ocorreu quando uma consulta foi atendida com uma resposta previamente armazenada, sem nova requisição à API. Como essa proporção dependeu do histórico de execução, sua interpretação permaneceu vinculada aos contadores registrados em cada execução do sistema.

Tabela 1 – Estatísticas descritivas da revisão sistemática.

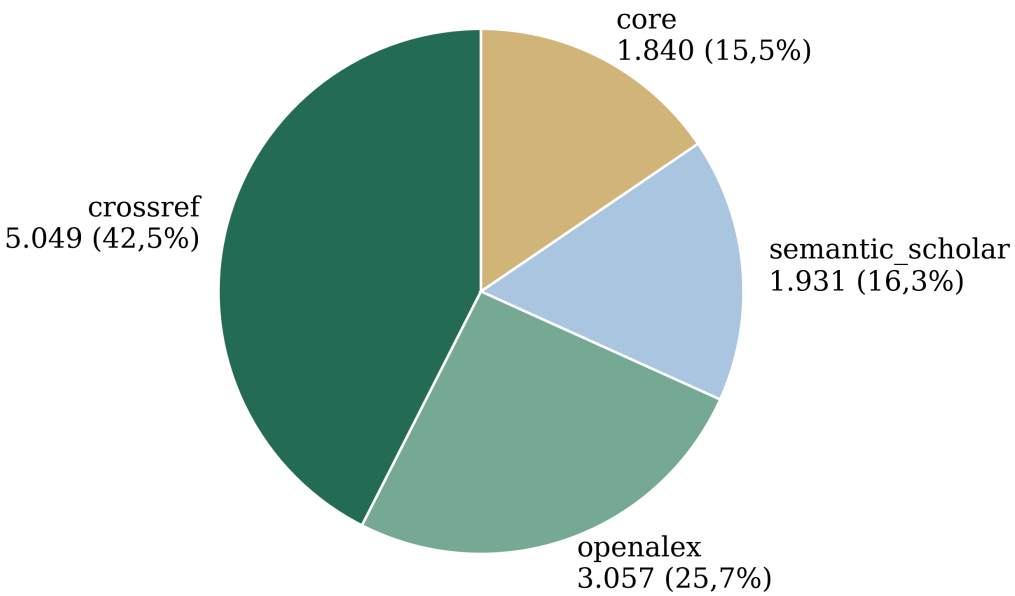
Métrica	**Valor**
Registros identificados	11.904
Remoções determinísticas por DOI/URL	27 (0,23%)
Registros na triagem	11.877
Excluídos na triagem	9.391 (78,89%)
Registros submetidos à priorização operacional	2.486
Excluídos na priorização operacional	2.468 (99,28%)
Registros na lista preliminar	18
Excluídos após triagem do resumo	1
Relatórios procurados após triagem do resumo	17
Relatórios não recuperados	1
Relatórios avaliados em texto completo	16
Protocolos excluídos após texto completo	1
Estudos empíricos mantidos provisoriamente	15
Bases consultadas	4
Consultas bilíngues	72 (48 EN + 24 PT)
Período de cobertura	2015–2026

Fonte: Elaborado pelo autor (2026).

Os percentuais da tabela usam denominadores explicitados para evitar a leitura de taxas de etapas diferentes como se fossem equivalentes: 27 remoções correspondem a 0,23% dos 11.904 registros identificados; 9.391 exclusões na triagem correspondem a 78,89% dos mesmos 11.904 registros identificados; e 2.468 exclusões correspondem a 99,28% dos 2.486 registros submetidos à priorização operacional. Assim, o percentual da triagem descreve a parcela dos registros inicialmente identificados, não a proporção excluída apenas entre os registros efetivamente triados.

A distribuição por fonte é apresentada no Gráfico 1. O universo representado corresponde aos 11.877 registros do recorte versionado após a remoção determinística por DOI/URL, e não aos 11.904 registros brutos identificados. A fonte indica a procedência registrada para a representação preservada nesse recorte; não mede a cobertura exclusiva de cada base nem a qualidade dos estudos. As quantidades e proporções foram calculadas a partir dos arquivos exportados, sem nova coleta.

Gráfico 1 – Registros do recorte versionado após deduplicação, por fonte científica.



Snapshot após deduplicação DOI/URL: n=11.877

Fonte: Elaborado pelo autor (2026).

4.3 CARACTERIZAÇÃO DOS REGISTROS SELECIONADOS PRELIMINARMENTE

Nos 15 estudos empíricos mantidos provisoriamente, foram identificadas tarefas de predição de desempenho e de classificação ou estimativa de proficiência. Entre os métodos descritos estão *Random Forest*, SVM, árvores de decisão e redes neurais. Seus resultados não são diretamente comparáveis em todos os casos, pois foram produzidos com populações, instrumentos, variáveis e desenhos metodológicos distintos.

Os estudos preditivos utilizaram combinações de notas, respostas a itens, características contextuais e registros de interação para estimar categorias ou escores. Outros trabalhos incluídos investigaram personalização, avaliação formativa, recursos pedagógicos ou modelos computacionais de aprendizagem. Essa diversidade ampliou o panorama da revisão, mas também impediu tratar todos os resultados como se medissem o mesmo fenômeno educacional.

Acurácia elevada em uma base específica não demonstra automaticamente que a técnica produzirá o mesmo resultado em outra escola ou população. Da mesma forma, predição de desempenho não equivale a explicar como o estudante aprende matemática. Essas restrições foram incorporadas aos requisitos e aos critérios de avaliação da especificação apresentada no Capítulo 5.

O Quadro 3 caracteriza os 18 registros selecionados preliminarmente e explicita a situação de cada um no fluxo. A leitura deve considerar conjuntamente o desenho, a população, os desfechos e a situação de cada registro: para o texto integral não recuperado, as informações provêm somente dos registros bibliográficos e resumos indexados e não constituem apreciação empírica nem MMAT. O estudo de Xia et al. (2026) integra provisoriamente o núcleo empírico segundo os critérios escritos do protocolo; o protocolo de Imperatrice et al. (2025) permanece fora dele por não apresentar resultados concluídos. O quadro não apresenta medida harmonizada de efeito nem permite comparar eficácia entre estudos.

A consulta de Xia et al. (2026, pp. 8–9, 13–14, 18, 24–25), complementada pela recuperação do PDF em 17 de outubro de 2026 e pela conferência de seções selecionadas, descreve integração computacional ao ensino universitário de matemática: uma reforma aplicada à metrologia de carbeto de silício, o uso da Transformada de Fourier e um questionário adaptativo que os autores denominam baseado em IA. Para análise estrutural dos dados do questionário, a seção 4.3.2 relata o uso de análise de componentes principais (PCA); esse procedimento não deve ser confundido com o mecanismo de personalização Xia et al. (2026, seção 4.3.2). A comparação usa uma coorte de controle de 2021 (n=94) e uma coorte pós-reforma de 2025 (n=89), separadas por quatro anos. Na seção 6, os autores afirmam que os testes de equivalência da linha de base não identificaram diferenças estatisticamente significativas ($p > 0{,}05$), sem apresentar ali estatísticas detalhadas Xia et al. (2026, seção 6). Esse resultado de não significância não demonstra equivalência entre as coortes. O desenho não contemporâneo também não elimina confundimento temporal, e o artigo reconhece possíveis mudanças de equipe e contexto. Assim, os resultados não isolam o efeito do questionário ou da IA, nem demonstram eficácia generalizável de tutoria personalizada. Não foi identificado algoritmo de aprendizado de máquina nas passagens examinadas; isso não demonstra sua ausência em todo o artigo, nem permite classificar o estudo como evidência de ML. A cobertura de leitura permanece parcial e os julgamentos MMAT continuam provisórios, sem confirmação de elegibilidade definitiva ou de apreciação humana integral.

Quadro 3 – Caracterização e situação dos 18 registros selecionados preliminarmente.

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
Tjahyadi e Tude (2025)	Predição de desempenho acadêmico em matemática. Finalidade: Predição	EDM; ML; classificadores	Acurácia	Incluído no núcleo empírico. O estudo reporta 75% de acurácia de teste; a interpretação é delimitada na discussão subsequente
Pejić, Molcer e Gulači (2021)	Classificação em três categorias operacionais de desempenho, denominadas pelos autores níveis de proficiência e construídas a partir das respostas ao PISA 2012 computadorizado. Finalidade: Predição e avaliação	Rede neural; Random Forest; seleção de atributos	Kappa; recall; ROC-AUC	Incluído provisoriamente como estudo de avaliação, não de intervenção. O artigo relata 58.753 registros após seleção e resultados de classificação; a descrição diverge sobre o uso do conjunto de teste no early stopping, impedindo confirmar a independência da avaliação de teste
He et al. (2025)	Tecnologia educacional para matemática. Finalidade: Otimização e decisão	EDM; IA; modelos preditivos	Meta-análise; modelagem; comparação escolar	Incluído no núcleo empírico. O texto distingue síntese de literatura, predição de tamanhos de efeito e aplicação escolar
Villegas-Ch et al. (2025)	Tutoria inteligente em STEM. Finalidade: Feedback personalizado	IA; aprendizagem adaptativa	Desempenho; análise estatística	Incluído no núcleo empírico. A interpretação permanece restrita ao contexto e às janelas temporais relatadas
Sokkhey et al. (2020)	Desempenho em matemática no ensino médio, conforme registro histórico. Finalidade: Predição	EDM; ML; métodos estatísticos, conforme registro anterior	Comparação de modelos não revalidada nesta auditoria	Mantido provisoriamente; original indisponível para conferência atual. As respostas MMAT anteriores não foram ratificadas nesta rodada
Kumar et al. (2022)	Notas de Matemática e Língua Portuguesa analisadas separadamente. Finalidade: Predição	DT; JRip; NB; MLP; RF; seleção wrapper	Acurácia em classificações binária e de cinco classes	Incluído provisoriamente, com PDF conferido. Há resultados de matemática separáveis, mas faltam detalhes de amostragem e validação; tabelas e narrativa apresentam inconsistências

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
Özseven e Özseven (2026)	Desempenho em matemática on-line. Finalidade: Predição	ML; modelo neurofuzzy	Desempenho preditivo	Incluído no núcleo empírico. A transferência do modelo para o protótipo não foi demonstrada
Zhang, Zhu e Feng (2025)	Trajetórias personalizadas em cursos de Matemática, Chinês e Inglês. Finalidade: Personalização	Aprendizagem profunda; grafo de conhecimento; aprendizagem por reforço; análise de sentimento	Taxa de melhoria do efeito de aprendizagem de 15%; redução do tempo de 20%; satisfação de 4,2/5, conforme os autores	Incluído provisoriamente como proposta de personalização. A taxa é definida pelos autores pela diferença relativa entre ganhos médios dos grupos; faltam amostra, alocação, análise inferencial e incerteza. As reduções de tempo variam entre comparações; os valores não sustentam efeito causal ou generalizável
Zhang (2024)	Currículo de matemática superior apoiado por IA. Finalidade: Personalização	ACO; CNN; CRF; grafo de conhecimento	Análise estatística; feedback	Incluído no núcleo empírico. O relato é usado para caracterizar personalização curricular, não eficácia transferível
Depren, Aşkın e Öz (2017)	Classificação de desempenho no TIMSS 2011. Finalidade: Classificação	RF; J48; Naive Bayes; MLP; regressão logística	Classificação	Incluído no núcleo empírico. A descrição textual da validação em 10 dobras inverte treino e teste; limitação discutida adiante
Uskov et al. (2019)	Analítica preditiva em cursos de Ciência da Computação e Sistemas de Informação, conforme texto integral.	Modelos preditivos de nota final; percepções dos estudantes	Sem desfecho matemático separadamente avaliado; matemática aparece em trabalho futuro	Exclusão por escopo registrada após resumo e confirmada no texto integral recuperado em 20/10/2026. Sem MMAT; a conferência suplementar não recalcula o PRISMA

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
MacLellan (2017)	Modelagem computacional da aprendizagem em frações e equações. Finalidade: Simulação e predição qualitativa	Modelos comparados com registros de tutoria	Ajuste de modelos; AIC; BIC	Mantido provisoriamente no fluxo de síntese; elegibilidade como estudo empírico e a unidade de apreciação MMAT aguardam adjudicação humana. A contribuição é delimitada às tarefas examinadas e não demonstra eficácia do protótipo
Milićević, Marinović e Jeftić (2024)	Classificação de aprovação, reprovação ou resultado condicional em Matemática para 50 estudantes do primeiro ano de Engenharia Industrial, observados entre 2017 e 2021.	Árvore de decisão	Acurácia reportada de 72%	Incluído provisoriamente como exemplo de predição/avaliação, não de intervenção. O artigo não descreve validação treino/teste ou cruzada para este modelo; a passagem sobre k-fold refere-se a outro estudo citado
Xia et al. (2026)	Matemática universitária e desenvolvimento sustentável. Finalidade: Integração curricular	Questionário adaptativo descrito como IA; Fourier; PCA aplicada ao questionário	Desempenho, questionário e entrevistas	Incluído sob os critérios amplos do protocolo; resultados não isolam o efeito da IA e coortes não contemporâneas limitam inferência causal
Echeveria, Bajao e Godinez (2025)	Mentalidade matemática e intervenção precoce. Finalidade: Classificação de mentalidade	EDM; NB; SVM; MLP	Acurácia	Incluído no núcleo empírico. O conflito de coortes e a sobreposição entre itens do desfecho e preditores limitam a interpretação
Nyantah, Frempong e Larbi (2025)	Teoremas de círculo. Finalidade: Ensino de geometria	Animação computacional; aprendizagem cooperativa	Delineamento experimental descrito de modo inconsistente	Incluído no núcleo empírico. O relato diverge sobre alocação aleatória; a intervenção combina componentes

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
Imperatrice et al. (2025)	Ensino inclusivo de matemática. Finalidade: Protocolo de estudo	Protocolo/ proposta	Não aplicável: sem resultados concluídos	Excluído da síntese empírica após texto completo por não apresentar resultados empíricos concluídos; não recebe apreciação MMAT de estudo concluído
Zeng (2025)	Carga cognitiva durante resolução de problemas matemáticos, conforme o resumo institucional.	EEG e rastreamento ocular; regressão logística e SVM, conforme o resumo	Delineamento intrassujeitos em duas fases, conforme o resumo	Pendente: texto integral da dissertação não recuperado; MMAT não aplicado. Desenho, algoritmos e resultados são atribuídos ao resumo, não tratados como verificados no texto integral

Fonte: Elaborado pelo autor (2026).

Em Depren, Aşkın e Öz (2017, p. 1613), a descrição da validação cruzada de dez dobras afirma que uma dobra é usada no treinamento e nove no teste, invertendo a partição usual de uma dobra de teste e nove de treinamento. Sem o código ou os dados processados, não é possível determinar se a inversão está apenas no relato ou também na execução; por isso, Q5 permanece como Não é possível concluir. O resumo apresenta famílias gerais de classificadores, enquanto a configuração experimental nomeia algoritmos específicos; essa diferença de granularidade, por si só, não comprova uma divergência entre os modelos.

A conferência integral de Kumar et al. (2022, pp. 1014–1017) permite separar predição de notas e eficácia pedagógica. O artigo define classificações binária e de cinco classes e apresenta resultados distintos para matemática e português, mas não explicita suficientemente a dimensão das amostras, os atributos selecionados nem o protocolo de validação dos experimentos. Além disso, os valores de acurácia atribuídos a Naive Bayes na conclusão correspondem a Random Forest na Tabela 8; a Tabela 7 contém reduções para alguns classificadores, contrariando a afirmação de melhoria em todos os casos. Essas inconsistências limitam a interpretação das comparações, mas não comprovam vazamento de dados ou falha efetivamente executada. A contribuição ao TCC é exigir definição dos desfechos, rastreabilidade da seleção de atributos e avaliação independente; não demonstrar melhora de aprendizagem ou generalização dos resultados.

Os resultados quantitativos requerem leitura junto aos seus denominadores e às métricas por classe. Em Tjahyadi e Tude (2025, pp. 155–156, 160), o alvo é a categoria da nota escolar de matemática, em uma amostra de 280 estudantes de uma escola privada. Os registros correspondem à quarta série em 2017/2018, enquanto o desfecho é a nota de Matemática na conclusão do ensino primário em 2020/2021; portanto, a interpretação depende desse horizonte temporal, e não de uma medida contemporânea de competência. Os autores descrevem uma divisão de 70% para treinamento e 30% para teste e reportam 75% de acurácia de teste para a combinação de SMOTE e RUSBoost. Na mesma comparação, a revocação da classe de baixo desempenho é de 43%. Portanto, a acurácia agregada não caracteriza uniformemente a identificação das três classes, nem demonstra ganho de aprendizagem decorrente de uma intervenção.

Em He et al. (2025, pp. 1, 16, 31–35), convém distinguir três componentes do artigo: a síntese meta-analítica de 423 publicações, a predição de tamanhos de efeito e a aplicação escolar em oito turmas. As publicações examinadas pelos autores não foram adicionadas como registros da presente revisão, e o alvo da modelagem foi o tamanho de efeito de uma intervenção, não a proficiência individual. As inconsistências de denominador e de unidade analítica da aplicação escolar são examinadas na Seção 4.5.

A tese de MacLellan (2017, pp. 44–48, 56) contribui como referência conceitual e metodológica para a modelagem computacional da aprendizagem. Nas tarefas de frações, compara simulações com registros de tutoria previamente coletados no DataShop para 79 estudantes e prevê qualitativamente efeitos de sequenciamentos instrucionais, não escores absolutos de desempenho no tutor ou em pós-teste. Em análise distinta sobre resolução de equações, descreve dados de 71 estudantes e 10.052 passos; a análise utiliza 4.568 passos nos quais os estudantes executaram as próprias ações. A nota 5 esclarece que o subconjunto inclui os passos de estratégia em que o estudante escolhe a transformação; ficam fora somente os passos em que o tutor executa os cálculos MacLellan (2017, p. 56). Portanto, sua contribuição está delimitada às tarefas examinadas e não constitui avaliação prospectiva nem evidência de eficácia do protótipo deste TCC.

Os três estudos recuperados para esta síntese ilustram contribuições distintas. Pejić, Molcer e Gulači (2021, pp. 50–53) classifica estudantes em três categorias operacionais de desempenho com dados do PISA 2012 computadorizado, denominadas pelos autores níveis de proficiência, sem equivalência demonstrada com os níveis oficiais do PISA; a redução de 271.323 registros iniciais para 58.753 após seleção não é suficientemente explicada, e o relato

diverge sobre o uso do conjunto de teste no treinamento. Milićević, Marinović e Jeftić (2024, pp. 4–5) apresenta uma árvore de decisão para resultados em Matemática de estudantes de um único curso e instituição e reporta 72% de acurácia, sem descrever validação independente. Já Zhang, Zhu e Feng (2025, pp. 650, 653–654) propõe trajetórias personalizadas e reporta uma taxa de melhoria do efeito de aprendizagem de 15%, calculada pela diferença relativa entre ganhos médios dos grupos. Como não informa adequadamente a amostra, a alocação, a análise inferencial ou a incerteza, esse indicador — assim como a redução de tempo e a satisfação reportadas — deve ser tratado como resultado atribuído aos autores, não como efeito causal ou generalizável.

4.4 AVALIAÇÃO METODOLÓGICA COM O MMAT

O registro MMAT 2018 contém respostas S1/S2 para 14 e critérios específicos para 11 dos 15 registros empíricos mantidos provisoriamente no núcleo. A estrutura segue o artigo de apresentação e o guia oficial (Hong et al., 2018a; Hong et al., 2018b), mas o preenchimento documental não comprova apreciação humana concluída nem correção dos julgamentos. O estudo 8 permanece no fluxo e no núcleo sem respostas, até adjudicação de sua elegibilidade e unidade de apreciação; suas bases distintas não devem ser somadas. S1 e S2 são perguntas de triagem; Q1–Q5 são critérios específicos, sem média, ranking ou categoria geral. Y significa “Sim”, N significa “Não” e CT significa “Não é possível concluir” para um critério efetivamente examinado. Quando a fonte ou o delineamento impedem a apreciação, as células permanecem sem resposta, não como CT. O protocolo 6921 não integra o núcleo empírico por não apresentar resultados concluídos. As 14 triagens e os 11 conjuntos de critérios são registros provisórios, com apoio automatizado e conferência humana por fonte e localizador ainda pendente. Os estudos 6916, 6919 e 6920 têm componentes qualitativos e quantitativos registrados separadamente, sem serem contados como estudos adicionais. Nenhum julgamento constitui classificação definitiva dos artigos.

Os Quadros 4 e 5 são gerados dos arquivos versionados <research/data/mmat_reassessment_current.csv> e <research/data/mmat_component_reassessment_current.csv>. Eles mantêm os critérios da categoria mista separados das apreciações dos componentes e da avaliação histórica.

Quadro 4 – Triagem e respostas documentais preliminares ao MMAT 2018 de 14 registros do corpus.

Estudo	Desenho	S1	S2	Q1	Q2	Q3	Q4	Q5	Base
Pejic et al. (2021)	Quant. descritivo	Y	Y	Y	CT	CT	CT	CT	Texto primário externo
Tjahyadi (2025)	Quant. descritivo	Y	Y	Y	CT	CT	CT	Y	Texto primário externo
Sokkhey et al. (2020)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT	Texto primário externo
Kumar et al. (2022)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT	Texto primário externo
Zhang et al. (2025)	Pendente	Y	Y	—	—	—	—	—	Texto primário externo
Depren et al. (2017)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT	Texto primário externo
Zhang (2023)	Pendente	Y	Y	—	—	—	—	—	Texto primário externo
Milićević et al. (2024)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT	Texto primário externo
Nyantah et al. (2025)	Pendente	Y	Y	—	—	—	—	—	Texto primário externo
He et al. (2025)	Quant. não rand. (componente escolar)	Y	Y	CT	Y	CT	N	Y	Texto primário externo
Villegas-Ch et al. (2025)	Métodos mistos	Y	Y	Y	Y	CT	CT	CT	Texto primário externo
Özseven et al. (2026)	Quant. descritivo	Y	Y	CT	CT	CT	CT	Y	Texto primário externo
Xia et al. (2026)	Métodos mistos	Y	Y	Y	Y	N	CT	N	Texto primário externo
Echeveria et al. (2025)	Métodos mistos	Y	Y	Y	Y	CT	CT	N	Texto primário externo

Fonte: Elaborado pelo autor (2026).

Cobertura: S1/S2 respondidas para 14 registros; Q1–Q5 apreciados para 11. Nos três registros com categoria pendente, — significa não avaliado, não CT. *Nota:* Registros provisórios, conferência humana pendente, sem escore agregado. S1 e S2 são perguntas de triagem. Q1–Q5 correspondem aos critérios MMAT da categoria; Y/N/CT/N/A = sim/não/não é possível concluir/não aplicável. Quant. = quantitativo; rand. = randomizado. Base = fonte consultada. Ver Seção 4.4. Denominador: 14 registros.

Quadro 5 – Apreciação preliminar dos componentes qualitativos e quantitativos em estudos de métodos mistos.

Estudo	Componente	C1	C2	C3	C4	C5	Síntese dos julgamentos e localizador
Villegas-Ch et al. (2025)	Quant. não rand.	CT	CT	CT	CT	CT	3.1 (CT): Recruitment frame and sampling strategy are not established in the reviewed sections. 3.2 (CT): The outcome measures are described but the available report does not establish their appropriateness sufficiently. 3.3 (CT): Completeness of outcome data and attrition are not established. 3.4 (CT): Group allocation and baseline confounder control are not sufficiently documented. 3.5 (CT): The article's introduction refers to one academic semester, methods report six weeks, and the results show week-eight progress for high-interaction programming students; this reporting conflict does not establish adherence or chronology for the mathematics component. Localizador: Introduction; Experimental Design; Data Acquisition and Evaluation; Results; Limitations
Villegas-Ch et al. (2025)	Qualitativo	Y	CT	CT	CT	CT	1.1 (Y): A qualitative approach is relevant to examining student and educator perceptions of the tutoring system. 1.2 (CT): Surveys and structured interviews are reported but participant selection and collection procedures need fuller support. 1.3 (CT): Thematic analysis is named but the derivation of themes is not described in enough detail. 1.4 (CT): Interpretation is not sufficiently substantiated by the qualitative material reported. 1.5 (CT): Coherence between qualitative sources, collection, analysis, and interpretation remains unclear. Localizador: Qualitative Analysis; Methods; Results
Xia et al. (2026)	Quant. não rand.	CT	Y	CT	N	CT	3.1 (CT): The cohorts are from one course and separated by four years; the target population and selection process are not sufficiently described. 3.2 (Y): Questionnaire and course outcomes are described and analyzed; the appraisal remains provisional. 3.3 (CT): Completeness and disposition of outcome data are not sufficiently documented in the reviewed sections. 3.4 (N): The noncontemporaneous control and experimental cohorts create temporal confounding acknowledged by the authors. 3.5 (CT): Intervention implementation and adherence are not documented sufficiently for this criterion. Localizador: §4.1.1 pp. 8–9; §4.3 pp. 13–14; §6 pp. 24–25

Continua na próxima página

Quadro 5 – Continuação

Estudo	Componente	C1	C2	C3	C4	C5	Síntese dos julgamentos e localizador
Xia et al. (2026)	Qualitativo	Y	Y	CT	Y	CT	1.1 (Y): Interviews are appropriate to explore student perspectives on the course reform. 1.2 (Y): The article reports semi-structured interviews with 12 students from the experimental cohort. 1.3 (CT): The analytic steps used to derive themes are not sufficiently detailed. 1.4 (Y): The interpretation includes student accounts and is supported by reported quotations. 1.5 (CT): The relationship among qualitative sampling, collection, analysis, and integrated claims needs further verification. Localizador: §4.4.8 p. 18; §6 pp. 24–25
Echeveria et al. (2025)	Quant. descritivo	Y	CT	N	CT	CT	4.1 (Y): The one-school student records fit the local classification question described by the study. 4.2 (CT): A broader target population and sampling frame are not sufficiently defined. 4.3 (N): Eight scale items used to construct the mindset categories also remain among selected predictors, compromising independent measurement of the target. 4.4 (CT): The report gives 633 recruited and 428 complete cases and cites academic years 2023–2024 and 2022–2023 without clarifying cohort provenance or whether missing cases create nonresponse bias. 4.5 (CT): The split and validation descriptions conflict and do not permit a clear appraisal of analysis appropriateness. Localizador: §2.1 p. 65; §2.6 p. 68; §3.1 p. 69; Results pp. 69–70
Echeveria et al. (2025)	Qualitativo	Y	CT	CT	CT	CT	1.1 (Y): Teacher interviews are relevant to the study's stated contextual and triangulation aims. 1.2 (CT): The interview method is reported but selection and collection details are insufficiently documented. 1.3 (CT): The analytic procedure for the interview material is not adequately described. 1.4 (CT): Interpretation of the teacher interviews is not sufficiently substantiated in the reviewed report. 1.5 (CT): Coherence among the student-record analysis, teacher interviews, collection, and interpretation needs further verification. Localizador: §2.1 p. 65; §3.3.4 p. 73

Fonte: Elaborado pelo autor (2026).

Nota: C1–C5 correspondem aos cinco critérios da categoria indicada: 1.1–1.5 (qualitativo), 3.1–3.5 (quantitativo não randomizado) e 4.1–4.5 (quantitativo descritivo). Y = sim; N = não; CT = não é possível concluir. Os registros documentais são provisórios, sem pontuação global; a conferência humana permanece pendente.

Os julgamentos preliminares por critério registraram limitações relativas à descrição dos dados, ao controle de variáveis de confusão e à representatividade. Como a conferência humana dos julgamentos está pendente e a disponibilidade de textos primários foi desigual, esses registros não foram convertidos em uma estimativa de frequência nem em classificação agregada de qualidade.

No estudo de Zhang (2024, seção 4.1, pp. 9–11 e Tabela 2), o texto integral informa 120 estudantes e dados válidos de desfecho para 50 participantes no grupo experimental e 52 no grupo controle. O resultado basal reportado como $p = 0{,}583$ não demonstra equivalência entre os grupos; além disso, não foi localizado o procedimento de alocação nem uma explicação para os 18 casos sem desfecho válido. Por isso, a categoria de delineamento e os critérios Q1–Q5 permanecem pendentes de adjudicação, sem classificar o estudo como randomizado ou não randomizado e sem atribuir causalidade aos resultados.

A tese de MacLellan (2017, pp. 44–49, 52–56) reúne avaliações computacionais distintas com dados humanos preexistentes: uma análise de tarefas de frações com registros de 79 estudantes e outra de resolução de equações com dados de 71 estudantes, 10.052 passos disponíveis e 4.568 passos executados pelos estudantes. Esses componentes não formam uma única amostra. Como o protocolo escrito não define se a unidade elegível para apreciação é a simulação computacional ou o estudo humano de origem, S1, S2 e Q1–Q5 permanecem sem resposta; a ausência de apreciação não deve ser interpretada como CT. A elegibilidade e a unidade de avaliação aguardam adjudicação humana, sem inferir eficácia do protótipo deste TCC.

A recuperação adicional de fontes não implica aprovação dos julgamentos anteriores. Para He et al. (2025, pp. 1, 16, 31–35), o registro de avaliação delimita provisoriamente a apreciação ao componente escolar da aplicação, classificado como quantitativo não randomizado; os demais componentes do artigo não integram essa unidade de avaliação. Na categoria quantitativa não randomizada, o MMAT 2018 inclui critérios sobre controle de confundidores e administração da intervenção conforme planejada (Hong et al., 2018a). A classificação do delineamento e as respostas por critério permanecem preliminares e aguardam adjudicação independente; portanto, não representam uma apreciação definitiva do artigo como um todo.

4.5 TENDÊNCIAS E LACUNAS

As observações desta seção dizem respeito ao material documental associado aos 15 registros mantidos provisoriamente no núcleo empírico, sem pressupor leitura humana integral do conjunto. O registro contém S1/S2 para 14 e Q1–Q5 para 11; nos estudos 5, 7 e 14, os critérios específicos permanecem sem resposta até definir a categoria; o estudo 8 permanece sem respostas enquanto se adjudicam elegibilidade e unidade de análise. Um registro aguarda recuperação do texto e também não recebe apreciação MMAT; um registro foi excluído após resumo e um protocolo após texto completo. A conferência suplementar do texto integral do registro excluído confirmou a decisão de escopo já contabilizada na triagem do resumo, sem alterar a sequência ou as contagens PRISMA. Essas categorias permanecem distintas no fluxo de seleção. A análise é descritiva e não permite estimar a frequência das limitações na literatura, comparar a eficácia das intervenções ou afirmar que o conjunto apresenta evidência homogênea. Lacunas inferidas da comparação documental não são atribuídas automaticamente aos autores nem apresentadas como ausências em toda a área.

Em He et al. (2025, pp. 1, 16, 31–35), a descrição da aplicação escolar informa oito turmas com 45 estudantes cada, o que corresponde a 360 estudantes por cálculo aritmético, enquanto o artigo declara amostra total de 90. O texto consultado não reconcilia esses denominadores. Os autores também descrevem quatro professores, com um deles responsável pelas duas turmas de controle e os demais pelas turmas experimentais; não foi identificado ajuste para esse possível confundimento entre docente e condição nas páginas examinadas. Além disso, embora o artigo reporte testes *t* independentes para grupos de 45 estudantes, organiza as condições por turma e não informa se a análise considera esse agrupamento. Não é possível, portanto, reconstruir a unidade analítica nem a precisão das comparações. Esses limites do relato exigem cautela, sem autorizar corrigir o denominador por inferência ou declarar os resultados inválidos.

Em Villegas-Ch et al. (2025, pp. 2, 14, 22), a introdução descreve a avaliação em um semestre acadêmico, a seção de métodos informa período experimental de seis semanas e os resultados apresentam, na subanálise de programação, progresso até a oitava semana para estudantes com alta interação. O relato não reconcilia essas janelas temporais; portanto, o resultado de programação não deve ser transportado para matemática nem usado para fixar uma duração única do estudo. Já Nyantah, Frempong e Larbi (2025, pp. 101–105) apresenta descrições incompatíveis sobre a alocação das escolas: um trecho informa distribuição aleatória, e outro caracteriza o desenho como quase-experimental sem alocação aleatória. Na Tabela 3 (p. 105;

página física 15), os autores reportam diferença estatisticamente significativa entre os grupos já no pré-teste ($U = 6714$, $Z = 4{,}839$, $p < 0{,}001$, tamanho de efeito=0,346) Nyantah, Frempong e Larbi (2025, Tabela 3, p. 105). Esse desequilíbrio basal, somado à intervenção combinada de animação computacional e aprendizagem cooperativa, impede atribuir a diferença pós-teste exclusivamente à intervenção ou isolar a contribuição da animação.

Em Echeveria, Bajao e Godinez (2025, pp. 65, 69–70), a seção de métodos situa a matrícula no ano letivo de 2023–2024, enquanto a seção 3.1 associa os 633 estudantes ao ano letivo de 2022–2023, sem esclarecer se são coortes distintas. Esse conflito não deve ser conciliado por inferência. Além disso, oito itens da escala de mentalidade matemática utilizados para formar as categorias também permanecem entre os preditores selecionados. O relato não estabelece, por si só, validade diagnóstica independente da classificação; por isso, o resultado não sustenta inferência de mudança na aprendizagem nem de efeito de uma intervenção precoce. A seção 3.1 informa 428 casos completos entre os 633 estudantes inicialmente descritos. A Tabela IX, na página impressa 73 (física 11), apresenta outra incompatibilidade: os totais de coluna somam 86, enquanto o total impresso é 84 (Echeveria; Bajao; Godinez, 2025). Essa divergência impede reconstruir o denominador da matriz MLP sem esclarecimento, não autoriza escolher um total por inferência e não deve ser transportada automaticamente às métricas dos outros classificadores.

Esses casos sugerem requisitos de relato e avaliação para a especificação: explicitar denominadores, unidades de análise, alocação, medidas iniciais, duração e relação entre rótulos e preditores. Eles são exemplos localizados, não uma estimativa de prevalência nem uma avaliação definitiva dos estudos. Temas mais amplos — como equidade, participação docente, integração curricular e reprodutibilidade — não foram codificados de modo comparável para todos os registros; neste trabalho, permanecem questões e requisitos propostos para investigação, e não ausências demonstradas em toda a literatura ou em cada estudo retido.

4.6 LIMITAÇÕES E CONTRIBUIÇÕES DA REVISÃO

A revisão foi realizada por um único pesquisador, com suporte automatizado para deduplicação, triagem e organização dos registros. Não houve dupla revisão independente. A priorização operacional de grande parte dos registros foi avaliada a partir de títulos, resumos e metadados, pois nem todos os textos completos estavam disponíveis; por isso, a retenção não deve ser apresentada como elegibilidade final universal.

O protocolo não foi registrado prospectivamente. Foram adotados princípios de planejamento compatíveis com o PRISMA-P, mas não se afirmou conformidade integral. O PRISMA 2020 foi utilizado para orientar o relato do processo.

As fontes consultadas possuem cobertura predominantemente anglófona, e a busca foi limitada a português e inglês. A heterogeneidade dos desenhos, populações e métricas impediu uma síntese quantitativa conjunta. Não foi aplicado um teste formal de viés de publicação; a cobertura das fontes e a disponibilidade desigual dos textos completos podem ter influenciado o conjunto recuperado. Além disso, os julgamentos MMAT permanecem preliminares e sujeitos à conferência humana e a divergências interpretativas.

Considerados esses limites, a revisão forneceu a base documental disponível para a especificação do protótipo. A presença de tarefas preditivas entre os candidatos analisados justificou considerar modelos supervisionados como alternativas, enquanto a heterogeneidade das bases fundamentou critérios de seleção e validação. Requisitos de explicabilidade, integração curricular, participação docente e reprodutibilidade foram propostos a partir da leitura temática e da fundamentação pedagógica; como esses aspectos não foram codificados de modo comparável em todos os registros, não são apresentados como lacunas comprovadas em cada estudo ou em toda a literatura.

Dessa forma, os resultados da revisão não foram tratados apenas como levantamento bibliográfico. Eles sustentaram as decisões consolidadas no Capítulo 5, preservando a distinção entre evidências reportadas na literatura e resultados produzidos pelo próprio trabalho.

5 ESPECIFICAÇÃO DO PROTÓTIPO

Este capítulo apresenta a especificação conceitual do protótipo elaborada a partir dos resultados da revisão sistemática e da fundamentação pedagógica. O artefato produzido consolidou princípios de projeto, requisitos funcionais e não funcionais, critérios para fontes de dados e modelos, um protocolo de avaliação e uma arquitetura de referência.

A especificação não foi tratada como evidência de uma aplicação funcional. Seu resultado consistiu em transformar as evidências da literatura em decisões técnicas e pedagógicas documentadas, auditáveis e coerentes com o escopo do trabalho.

O repositório também contém uma implementação técnica do pipeline do protótipo, acompanhada por testes sintéticos automatizados. Essa implementação demonstra propriedades de processamento e de proteção contra falhas previstas no código, mas não equivale a uma execução com dados educacionais reais, a uma validação de eficácia preditiva ou a uma avaliação de aprendizagem. O capítulo, portanto, descreve a especificação que orienta uma futura execução e mantém essa implementação técnica separada de qualquer alegação de resultado educacional.

5.1 PRINCÍPIOS E REQUISITOS

A especificação estabelece que o protótipo deverá apoiar a decisão pedagógica sem substituir o professor. Essa decisão de projeto implica distinguir, na representação e na interpretação dos resultados, o desempenho observado em uma atividade, a proficiência estimada por um modelo, a competência mobilizada em um contexto mais amplo e a aprendizagem como possível mudança ao longo do tempo. Esses conceitos não são intercambiáveis, e a passagem de um para outro não poderá ser presumida apenas pela produção de um indicador computacional.

As estimativas deverão ser acompanhadas de explicações, limitações e condições de validade compreensíveis para seus destinatários. A revisão humana deverá permanecer integrada ao uso das recomendações, de modo que o professor possa confrontar as evidências com o contexto da turma e decidir se há fundamento para uma intervenção. Nesse sentido, a saída do protótipo será tratada como apoio à análise, e não como classificação definitiva ou prescrição pedagógica.

A proteção dos dados educacionais constitui outro princípio da especificação. O uso deverá estar associado a uma finalidade explícita, com minimização dos dados pessoais e controle de acesso compatível com essa finalidade. Também deverá ser possível reproduzir

e auditar os procedimentos de preparação, treinamento e avaliação por meio do registro das versões, dos parâmetros e das dependências relevantes. Por fim, a especificação rejeita rótulos permanentes ou deterministas sobre os estudantes, pois uma estimativa situada não deve ser convertida em atributo fixo da pessoa.

No plano funcional, a futura implementação deverá importar dados documentados e relacionados a objetivos curriculares, preservando os metadados necessários à leitura de sua procedência. A partir desses dados, deverá organizar evidências de desempenho por habilidade ou descritor, de modo que a análise mantenha relação explícita com o contexto curricular em que os registros foram produzidos.

Na etapa de análise, o protótipo deverá produzir estimativas para um alvo educacional explicitamente definido, acompanhadas de incertezas e limitações, e apresentar resultados individuais e agregados ao professor. Uma probabilidade preditiva de acerto ou de pertencimento a uma classe de desempenho não será denominada proficiência apenas por resultar de um modelo computacional. A interpretação como proficiência exigirá um modelo de mensuração, uma escala e evidências de validade para o uso pretendido, em consonância com a distinção entre observação e inferência discutida por National Research Council (2001, pp. 42–44). Essas saídas deverão ser acompanhadas de uma explicação das variáveis relacionadas a cada estimativa, sem serem apresentadas como diagnósticos completos de aprendizagem. O fluxo também deverá permitir revisão humana das recomendações produzidas, para que o professor possa confrontar as evidências computacionais com a situação da turma e decidir sobre sua pertinência pedagógica. Por fim, deverá exportar dados, parâmetros e resultados para auditoria, assegurando que as decisões de processamento e as saídas apresentadas possam ser examinadas posteriormente.

A especificação também estabeleceu que indicadores computacionais não representam, isoladamente, diagnósticos de aprendizagem. Sua interpretação depende da natureza da atividade, da qualidade dos dados e do contexto pedagógico.

No plano não funcional, as condições de qualidade e de governança deverão ser satisfeitas por uma futura implementação; sua especificação não constitui evidência de que tais propriedades já tenham sido alcançadas. A reprodutibilidade deverá ser assegurada pelo registro das versões dos dados, dos parâmetros, dos modelos e das dependências. Complementarmente, a rastreabilidade deverá permitir associar cada resultado à fonte de dados utilizada e à versão do experimento que o produziu. Essa associação é necessária para que uma conclusão possa ser

examinada sem perder sua procedência.

A testabilidade deverá ser favorecida pela separação entre ingestão, preparação, modelagem, avaliação e apresentação. A portabilidade, por sua vez, exigirá um ambiente de execução documentado e passível de reprodução. Essas duas condições dizem respeito à possibilidade de verificar e repetir os procedimentos, e não à escolha de uma tecnologia ou de uma interface específica.

Os requisitos também abrangem a relação do protótipo com seus usuários e com os dados tratados. A apresentação deverá ser acessível, compreensível e compatível com diferentes perfis de usuário. A privacidade deverá orientar a minimização de dados pessoais e o controle de finalidade e de acesso. Por fim, a transparência deverá exigir que as limitações dos modelos e as condições de validade das estimativas sejam comunicadas junto aos resultados, evitando que a forma de apresentação atribua uma certeza que o procedimento não sustenta.

A escolha de fontes de dados permanece condicionada à documentação disponível, ao problema de pesquisa e às condições de execução que vierem a ser definidas. A especificação considera a possibilidade de trabalhar com microdados de avaliações educacionais, como SAEB e PISA, e com dados sintéticos destinados à verificação do *pipeline*; essa possibilidade não representa a seleção de uma base definitiva.

A implementação técnica exploratória do repositório segue uma escolha distinta, de viabilidade, que não substitui esse critério. Seu adaptador aceita somente a versão corrigida do conjunto *Skill-builder data 2009-2010* do ASSISTments[1], que registra uma linha por par estudante–problema, com ordem das interações, indicador de acerto e habilidades associadas. O sistema que gerou esses registros é descrito por Feng, Heffernan e Koedinger (2009), referência indicada pelo próprio provedor, embora esse artigo não analise o conjunto de 2009–2010. A escolha atende a uma verificação técnica do fluxo de previsão da próxima resposta, que exige registros sequenciais por habilidade; os microdados de proficiência do SAEB e do PISA não têm essa estrutura. Ela não seleciona a base de uma investigação empírica, não representa estudantes brasileiros e não foi acompanhada do processamento de qualquer arquivo real nesta versão; as demais fontes aparecem na configuração apenas como candidatas, sem adaptador implementado. Os termos de uso publicados pelo provedor deverão ser registrados e respeitados antes de qualquer aquisição.

A seleção de uma fonte deverá considerar, inicialmente, sua licença e suas condi-

[1] Página do conjunto, cuja URL o provedor pede que seja citada: <https://sites.google.com/site/assistmentsdata/home/2009-2010-assistment-data/skill-builder-data-2009-2010>. Acesso em: 22 out. 2026.

ções de uso, bem como a existência de dicionário de dados e de documentação metodológica. Também deverá examinar a unidade de análise e sua relação com o problema de pesquisa, a qualidade dos metadados e o tratamento previsto para valores ausentes. A representatividade da população deverá ser analisada em relação ao contexto para o qual se pretende interpretar os resultados, sem ser presumida a partir da simples disponibilidade da base. Do mesmo modo, a presença de variáveis relacionadas ao desempenho e ao contexto educacional será relevante, mas não garantirá, por si só, que seja possível associá-las a competências ou descritores curriculares. Essa associação deverá ser demonstrada e delimitada pela documentação e pelo desenho da avaliação.

Por fim, a análise da fonte deverá incluir os riscos de identificação, discriminação e uso indevido. Esses riscos são condições de governança da execução, e não apenas atributos técnicos do arquivo de dados. Dados sintéticos poderão ser usados para testar fluxos de processamento, interfaces e regras de validação. Entretanto, não constituirão evidência de desempenho educacional, de validade preditiva ou de eficácia pedagógica, nem substituirão uma base empírica quando a investigação exigir inferências sobre estudantes ou contextos reais.

Quanto à modelagem, a revisão identificou uso de *Random Forest*, máquinas de vetores de suporte (SVM), árvores de decisão, regressão logística e redes neurais. Na especificação, *Random Forest* e SVM também foram ancoradas em suas fontes metodológicas primárias (Breiman, 2001; Cortes; Vapnik, 1995). Modelos supervisionados simples e interpretáveis foram mantidos como referências iniciais de comparação, condicionando o uso de modelos mais complexos à demonstração de ganho e à possibilidade de interpretação adequada.

Random Forest e SVM foram registrados como alternativas de modelagem, não como algoritmos definitivamente implementados. A escolha entre eles depende da base selecionada, da distribuição das classes, do tipo de variável, do custo computacional e dos requisitos de explicabilidade.

O código exploratório não implementa essas duas alternativas. Ele contém referências históricas simples, uma regressão logística regularizada (James et al., 2021) e, como candidato não linear exploratório, um classificador de *gradient boosting* (Friedman, 2001) em sua variante baseada em histogramas disponível na biblioteca scikit-learn (Pedregosa et al., 2011). Essa composição foi definida para testar o fluxo com um modelo interpretável e um candidato não linear; não resulta de uma comparação com *Random Forest* ou SVM nem indica superioridade de qualquer modelo. Nenhum desses modelos foi treinado com dados educacionais reais.

Em uma implementação com scikit-learn, identificadores longos devem ser documentados sem comprometer a legibilidade do texto ou a reprodução do código. O nome `RandomForestClassifier`, por exemplo, identifica uma classe de implementação, não uma técnica adicional.

5.2 PROTOCOLO DE AVALIAÇÃO DA ESPECIFICAÇÃO CONCEITUAL

O protocolo proposto para o OE4 tem como objeto a especificação conceitual, e não o desempenho de um sistema treinado. Sua aplicação deverá examinar a rastreabilidade dos requisitos até as fontes ou decisões autorais, a consistência entre entradas, saídas e responsabilidades da arquitetura e a correspondência entre as saídas previstas e os conceitos educacionais adotados. A viabilidade será examinada documentalmente pelas condições necessárias de acesso e uso dos dados, disponibilidade de variáveis, recursos computacionais e participação docente. Sem medições ou aplicação empírica, essa análise poderá identificar condições e impedimentos, mas não comprovar custo de execução, utilidade prática ou eficácia pedagógica.

Para cada requisito examinado, deverão ser registrados seu identificador, a versão da especificação, a fonte e o localizador, o critério utilizado, a justificativa e a necessidade de ajuste. O julgamento poderá indicar coerência documental, coerência condicionada a ressalvas ou necessidade de revisão; falta de evidência deverá permanecer explícita, sem ser convertida em aprovação. A revisão por docentes e a análise técnica deverão ser registradas separadamente, com discussão das divergências. O Quadro 6 oferece uma entrada para esse procedimento, mas não demonstra que ele tenha sido executado. Nesta versão, o resultado do OE4 é a proposição do protocolo; sua aplicação e a validação humana da especificação permanecem pendentes.

Se houver decisão posterior de implementar o protótipo, um protocolo experimental distinto deverá orientar a modelagem e a interpretação dos seus resultados. Ele deverá separar o que será observado no comportamento técnico dos modelos daquilo que exigiria evidência educacional adicional. Essa separação começa pela definição explícita dos conjuntos de treino, validação e teste e pela prevenção de vazamento de informação entre preparação, modelagem e avaliação. Os modelos candidatos deverão ser comparados com referências simples, para que diferenças de desempenho, inclusive resultados nulos ou desfavoráveis, sejam interpretadas em relação a uma base de comparação, e as métricas deverão ser analisadas por classe, além das medidas agregadas, quando a tarefa permitir essa decomposição.

Como descrição complementar dos erros e acertos, o protocolo prevê o uso de ma-

triz de confusão, precisão, revocação e medida F1. A área sob a curva ROC e a calibração somente deverão ser calculadas quando forem compatíveis com a tarefa e com o tipo de saída produzido (Fawcett, 2006; Niculescu-Mizil; Caruana, 2005). Também deverão ser examinadas a estabilidade das explicações e possíveis diferenças entre grupos, sem converter essas análises em conclusões causais não sustentadas pelo desenho do estudo. Por fim, a execução deverá registrar as limitações de generalização relacionadas à fonte de dados, à população observada e às condições de aplicação.

O protocolo distingue desempenho observado, saída preditiva, proficiência estimada, competência e aprendizagem. O desempenho observado corresponde aos registros produzidos nas atividades ou avaliações consideradas. A saída preditiva estima um alvo definido, sob as condições dos dados e do modelo; não demonstra, por si só, a posição do estudante em uma escala de proficiência. Esta última interpretação depende do modelo de mensuração e da validade das inferências pretendidas (National Research Council, 2001, pp. 42–44). Competência e aprendizagem, contudo, não serão tratadas como equivalentes automáticos dessas grandezas: sua análise depende do contexto educacional, do construto adotado e, no caso da aprendizagem, de evidência de mudança ao longo do tempo. A implementação técnica atualmente disponível produz saídas preditivas em testes sintéticos, não uma escala de proficiência validada.

Essa distinção também separa a avaliação técnica da eficácia pedagógica. As métricas preditivas descrevem o comportamento do modelo em uma base e sob determinadas condições de avaliação. Elas não demonstram, por si só, melhoria da aprendizagem, adequação de uma intervenção escolar ou alinhamento curricular validado. Tais conclusões exigiriam um desenho empírico próprio, com condições de comparação e observação educacional compatíveis com a pergunta investigada.

Para examinar a adequação pedagógica da especificação, o protocolo prevê uma revisão documental por docentes da área de matemática. Essa revisão deverá considerar a correspondência dos requisitos com o referencial curricular pertinente ao nível de ensino, a clareza das explicações e das incertezas apresentadas, a possibilidade de interpretação contextualizada e a preservação da decisão docente. Cada julgamento deverá registrar o requisito examinado, a evidência documental, a justificativa, as limitações e os ajustes necessários. Trata-se de um procedimento proposto, que não foi executado neste trabalho; mesmo sua execução não substituiria um estudo empírico de eficácia educacional.

Como parte da avaliação e da revisão humana, SHAP e LIME foram incluídos como

alternativas para explicar modelos, com referência às formulações originais de Lundberg e Lee e de Ribeiro, Singh e Guestrin (Lundberg; Lee, 2017; Ribeiro; Singh; Guestrin, 2016). Seu uso deverá considerar a estabilidade das explicações, o custo computacional e a possibilidade de tradução dos resultados para uma linguagem curricular compreensível. A implementação exploratória não inclui SHAP nem LIME, que permanecem alternativas especificadas. Para a regressão logística, ela decompõe o logaritmo da razão de chances de cada previsão em intercepto e produtos entre coeficientes e valores transformados dos atributos, decomposição exata para esse modelo linear, e calcula a importância por permutação no conjunto de teste, adaptação agnóstica ao modelo do procedimento de permutação proposto por Breiman (2001) para florestas aleatórias. O candidato de *gradient boosting* não possui explicação implementada. Essas saídas descrevem dependências do modelo ajustado e não identificam causas da dificuldade do estudante. O professor permanece responsável por interpretar as evidências, relacioná-las ao contexto da turma e decidir intervenções; o protótipo é instrumento de apoio, não mecanismo autônomo de classificação ou prescrição pedagógica.

5.3 ARQUITETURA DE REFERÊNCIA

A ingestão corresponde à leitura das fontes, à validação inicial de seus formatos e à preservação das informações de procedência. Em seguida, a etapa de preparação deverá tratar valores ausentes, codificar e transformar variáveis e documentar as decisões tomadas sobre esses dados. A modelagem abrangerá o treinamento e a comparação dos modelos candidatos de acordo com a base selecionada e com o protocolo de avaliação.

A etapa de avaliação e explicabilidade deverá calcular as métricas, analisar os erros e gerar explicações cuja estabilidade e limitações serão examinadas. Por fim, a apresentação deverá disponibilizar indicadores, incertezas e limitações de modo compreensível para a análise docente. Essa arquitetura de referência organiza responsabilidades e pontos de verificação; não descreve um sistema funcional já disponível, nem fixa a tecnologia ou a forma de implantação.

A separação dos componentes deverá favorecer a testabilidade, a rastreabilidade e a substituição controlada de técnicas. Ela também permite localizar em qual etapa uma decisão, uma transformação ou uma limitação foi introduzida. A arquitetura não impõe uma interface específica e poderá ser materializada como *notebook*, aplicação local, API ou sistema web. Qualquer dessas formas de execução deverá, entretanto, preservar os requisitos de auditoria, interpretação, privacidade e participação docente estabelecidos neste capítulo.

5.4 FUNDAMENTAÇÃO E RASTREABILIDADE DOS REQUISITOS

A especificação articula três origens que não devem ser confundidas: observações localizadas nos estudos do corpus, fundamentos teóricos ou normativos e decisões de projeto do autor. Um problema de relato identificado em um artigo pode motivar uma salvaguarda, mas não demonstra que a solução proposta seja eficaz. Da mesma forma, um referencial pedagógico orienta a interpretação das saídas sem validar uma interface ou um algoritmo específico.

O Quadro 6 organiza os requisitos das seções anteriores em 26 grupos identificáveis. A coluna de origem explicita a base da decisão e a última coluna delimita a inferência permitida. Requisitos de engenharia que não receberam sustentação externa específica são apresentados como escolhas autorais, e não como achados empíricos da revisão. As referências remetem aos trabalhos discutidos na fundamentação e na síntese; os localizadores das apreciações empíricas permanecem no registro de evidências dos estudos.

Os grupos R01–R19 remetem aos requisitos e critérios da Seção 5.1; R07, R10, R11 e R16 também explicitam condições da arquitetura na Seção 5.3. R20–R26 correspondem às condições do protocolo de avaliação da Seção 5.2. Esses vínculos identificam onde cada grupo foi especificado, sem transformar as decisões autorais em exigências extraídas de um artigo.

Quadro 6 – Origem, derivação e limites dos requisitos da especificação conceitual.

ID	**Requisito ou grupo**	**Origem e base documental**	**Derivação e limite da justificativa**
R01	Apoio docente e revisão humana, sem prescrição autônoma.	Fundamento teórico e decisão autoral: mediação em Vygotsky (1978) e Wood, Bruner e Ross (1976).	A mediação orienta a participação do professor; não demonstra utilidade do protótipo nem mensuração da zona de desenvolvimento proximal.
R02	Separar desempenho, previsão, proficiência, competência e aprendizagem.	Fundamento teórico e normativo: National Research Council (2001, pp. 42–44), OECD (2023a) e Brasil (2018a).	Exigir construto e validade para interpretar inferências. A definição operacional de aprendizagem adotada neste trabalho não foi testada pelo protótipo.
R03	Comunicar explicações, incertezas e condições de validade.	Fundamento teórico e decisão autoral: National Research Council (2001) e Hattie e Timperley (2007).	Informação interpretável é condição proposta de uso. Explicação algorítmica não equivale automaticamente a feedback formativo compreendido pelo docente.

Continua na próxima página

Quadro 6 – Continuação

ID	Requisito ou grupo	Origem e base documental	Derivação e limite da justificativa
R04	Finalidade, minimização, acesso e análise de riscos de identificação e uso indevido.	Fundamento normativo e decisão de governança: Brasil (2018b).	Orientar o planejamento do tratamento de dados pessoais; não declarar conformidade jurídica de uma implementação ainda não avaliada.
R05	Evitar rótulos permanentes e interpretações discriminatórias.	Fundamento teórico e salvaguarda autoral: limites de inferência em National Research Council (2001).	Restringir a interpretação à tarefa e ao contexto; não afirmar dano demonstrado no corpus nem equidade já alcançada.
R06	Registrar versões, parâmetros e dependências; exportar dados e resultados, vinculando cada saída à fonte e à versão do experimento.	Decisão de projeto do autor, explicitada nos princípios e requisitos deste capítulo.	Viabilizar inspeção documental e reprodução futura. O corpus não demonstra a eficácia desse conjunto operacional.
R07	Importar dados documentados e preservar procedência.	Decisão de projeto do autor, relativa à ingestão e à preparação.	Preservar contexto e registrar validações de formato; não presumir qualidade pelo simples sucesso da importação.
R08	Relacionar evidências a habilidades, descritores e objetivos curriculares.	Fundamento teórico e normativo: Brasil (2018a) e Ausubel (1968); aplicação operacional autoral.	Orientar o vínculo curricular e considerar conhecimentos anteriores. A associação concreta entre variáveis e habilidades ainda deverá ser demonstrada.
R09	Definir o alvo e distinguir saídas individuais de agregadas.	Observação do corpus: alvos e unidades distintos em He et al. (2025, pp. 11–12, seção de definição do resultado predito); fundamento em National Research Council (2001); decisão autoral de apresentação.	A predição de efeito de intervenções não equivale à proficiência individual. A forma de exibição ainda não foi avaliada com docentes.
R10	Separar componentes para favorecer testabilidade.	Decisão de arquitetura do autor: ingestão, preparação, modelagem, avaliação e apresentação.	Organizar responsabilidades e pontos de inspeção; não tratar modularidade como propriedade empiricamente comprovada da proposta.
R11	Documentar o ambiente e permitir substituição controlada de técnicas.	Decisão de projeto do autor sobre portabilidade e interfaces.	Condicionar execução à documentação de dependências e contratos; a especificação não demonstra portabilidade entre ambientes reais.

Continua na próxima página

Quadro 6 – Continuação

ID	Requisito ou grupo	Origem e base documental	Derivação e limite da justificativa
R12	Considerar acessibilidade e diferentes perfis de usuários.	Requisito autoral de apresentação, sem validação específica no corpus.	Registrar uma condição a operacionalizar em critérios de aceitação; não declarar acessibilidade alcançada ou avaliada.
R13	Examinar SAEB e PISA como fontes candidatas, não definitivas.	Exemplo do corpus em Pejić, Molcer e Gulači (2021); documentação contextual de Brasil. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (2024) e OECD (2023b); decisão autoral.	Uso de uma edição do PISA não valida outra base, outra edição ou sua transferência ao contexto brasileiro. O uso do ASSISTments no código exploratório é teste de viabilidade, não seleção da base.
R14	Verificar licença, condições de uso, dicionário e documentação metodológica.	Critério autoral para seleção das fontes.	Condicionar uso à documentação e às permissões pertinentes. Disponibilidade pública e proteção de dados não substituem licença de uso.
R15	Examinar unidade de análise e representatividade da população.	Observação do corpus: seleção e alvo em Pejić, Molcer e Gulači (2021, p. 50); distinção de unidades em He et al. (2025, pp. 11–12, seção de definição do resultado predito); decisão autoral.	Exigir compatibilidade entre pergunta, amostra e inferência. Casos localizados não estimam a frequência de problemas na literatura.
R16	Documentar metadados, transformações e valores ausentes.	Decisão de projeto do autor para seleção e preparação de dados.	Tornar as decisões examináveis; não fixar regra universal de imputação nem garantir validade das variáveis.
R17	Restringir dados sintéticos à verificação técnica.	Delimitação autoral do escopo e do protocolo proposto.	Verificar fluxos e regras sem inferir aprendizagem, validade preditiva em dados reais ou eficácia pedagógica.
R18	Considerar famílias supervisionadas como alternativas.	Exemplos do corpus em Depren, Aşkın e Öz (2017, p. 1609, algoritmos de classificação) e Tjahyadi e Tude (2025, p. 156, Tabela 2); fontes metodológicas (Breiman, 2001; Cortes; Vapnik, 1995).	Identificar candidatos, condicionando a escolha ao tipo de variável, à distribuição das classes, ao custo e à explicabilidade. A ocorrência em artigos não estabelece superioridade ou adequação.
R19	Comparar com referências simples e justificar complexidade.	Fundamento metodológico em James et al. (2021); regra de comparação autoral.	Interpretar ganhos sob condições explícitas; não antecipar algoritmo vencedor ou limiar universal de ganho aceitável.

Continua na próxima página

Quadro 6 – Continuação

ID	Requisito ou grupo	Origem e base documental	Derivação e limite da justificativa
R20	Separar treino, validação e teste e prevenir vazamento.	Fundamento metodológico em James et al. (2021); relato contraditório de Pejić, Molcer e Gulači (2021, pp. 50–51).	A ambiguidade documental motiva separação e relato inequívocos; não permite determinar qual procedimento foi efetivamente executado no artigo.
R21	Examinar confusão, precisão, revocação e F1 por classe.	Resultados por classe em Tjahyadi e Tude (2025, p. 160, Tabela 8); fundamento em James et al. (2021); decisão autoral de protocolo.	Examinar erros que a acurácia agregada pode ocultar; resultados de uma base não determinam o desempenho futuro do protótipo.
R22	Usar ROC-AUC e calibração quando compatíveis com a tarefa.	Fundamentos metodológicos em Fawcett (2006) e Niculescu-Mizil e Caruana (2005).	Distinguir discriminação e qualidade probabilística; nenhuma das métricas constitui medida de aprendizagem.
R23	Examinar estabilidade das explicações e diferenças entre grupos.	Decisão autoral de avaliação, orientada pelos limites de validade discutidos em National Research Council (2001).	Formular verificações futuras, cujo procedimento ainda deverá ser operacionalizado. Desempenho médio não demonstra estabilidade ou equidade.
R24	Delimitar generalização e evitar causalidade automática.	Observações localizadas em Pejić, Molcer e Gulači (2021, p. 50), Milićević, Marinović e Jeftić (2024, p. 5, seção 2.2) e Zhang, Zhu e Feng (2025, p. 654, conclusão); interpretação crítica autoral.	Restringir a conclusão à população, ao alvo e ao desenho examinados; não transformar associação ou ganho relatado em efeito causal.
R25	Prever revisão documental por docentes e registrar julgamentos.	Referencial curricular em Brasil (2018a) e avaliação formativa em Hattie e Timperley (2007); procedimento proposto pelo autor.	Examinar adequação curricular e interpretativa da especificação. O procedimento não foi executado e não substituiria avaliação de eficácia educacional.
R26	Examinar SHAP e LIME, sua estabilidade, custo e comunicação curricular.	Fontes metodológicas (Lundberg; Lee, 2017; Ribeiro; Singh; Guestrin, 2016); escolha autoral de alternativas.	Identificar métodos de explicação, sem atribuir às fontes prova de compreensão docente, estabilidade ou adequação curricular da aplicação proposta. O código exploratório implementa apenas a decomposição exata da regressão logística e a importância por permutação.

Fonte: Elaborado pelo autor (2026).

O quadro torna verificável a origem declarada de cada grupo, mas não encerra a apreciação científica das referências. Permanecem distintas a rastreabilidade documental, a conferência independente da interpretação de cada fonte e a avaliação futura do artefato. Os critérios operacionais de acessibilidade, estabilidade explicativa e revisão docente ainda deverão ser

detalhados antes de uma execução; essa pendência limita o protocolo proposto, sem constituir resultado experimental ausente do escopo desta entrega.

Em síntese, este capítulo consolida uma especificação técnica e pedagógica que conecta as evidências da revisão às decisões de projeto, abrangendo propósito, limites, requisitos, critérios para dados e modelos, protocolo de avaliação e arquitetura de referência. Essa entrega é fundamentada no material examinado, mas não se confunde com uma especificação submetida à revisão docente prevista no protocolo, com uma aplicação educacional validada ou com evidência de eficácia em sala de aula.

6 RESULTADOS E DISCUSSÃO

Os resultados do trabalho foram organizados em quatro entregas complementares: a revisão sistemática da literatura, a apreciação metodológica preliminar dos candidatos empíricos retidos, a consolidação dos fundamentos pedagógicos e a especificação conceitual do protótipo. Esta seção integra essas entregas e discute como elas responderam ao problema de pesquisa e aos objetivos definidos.

6.1 RESULTADOS DA REVISÃO SISTEMÁTICA

A revisão identificou 11.904 registros em quatro fontes científicas. Após a remoção determinística de 27 identidades DOI/URL, 11.877 registros seguiram para triagem; 9.391 foram excluídos nessa etapa e 2.486 avançaram para priorização operacional. Dos 18 registros selecionados preliminarmente, um foi excluído após a triagem do resumo. Dos 17 relatórios procurados, um não foi recuperado e 16 foram examinados em texto completo; um protocolo sem resultados concluídos foi excluído, resultando em 15 registros empíricos mantidos provisoriamente. A síntese distingue estudos de predição/avaliação de resultados matemáticos, como a classificação em categorias operacionais de desempenho com itens do PISA por Pejić, Molcer e Gulači (2021) e a previsão de aprovação, reprovação ou resultado condicional em Matemática por Milićević, Marinović e Jeftić (2024), de uma proposta de trajetórias personalizadas por Zhang, Zhu e Feng (2025). Os dois primeiros não testam intervenções pedagógicas; seus desempenhos reportados são limitados às amostras e aos procedimentos descritos. No terceiro, a falta de informação sobre participantes, alocação e análise inferencial impede interpretar os percentuais do artigo como efeitos causais ou generalizáveis. A experiência universitária de Xia et al. (2026), que integra Transformada de Fourier à medição industrial de SiC, também não isola o efeito dos recursos de IA e compara coortes separadas por quatro anos.

O fluxo documental mantém provisoriamente 15 registros empíricos, sem comprovar leitura humana integral de todos os textos. O registro MMAT contém respostas S1/S2 para 14 e critérios de categoria para 11; são julgamentos provisórios sujeitos à conferência das fontes e à validação humana, não apreciações concluídas. Os estudos 5, 7 e 14 aguardam definição do delineamento; o estudo 8 permanece sem respostas até adjudicação da elegibilidade e da unidade de apreciação. O relatório integral de Zeng (2025) não foi recuperado, e as informações desse registro permanecem atribuídas ao resumo, sem apreciação MMAT.

A heterogeneidade entre populações, instrumentos, variáveis e métricas impediu a comparação direta de todos os resultados. Acurácias reportadas em bases específicas foram interpretadas como evidências contextuais dos artigos, e não como garantias de desempenho em outros ambientes educacionais. Essa distinção evitou transferir resultados da literatura para o protótipo especificado sem validação empírica própria.

Os exemplos documentados na Seção 4.5 incluem limitações de alocação e controle de confundimento, divergência entre duração prevista e período reportado, combinação de componentes de intervenção e sobreposição entre instrumento e variáveis preditoras. Eles ilustram problemas localizados em estudos consultados; a cobertura de textos primários e a ausência de uma matriz de codificação não permitem estimar a frequência dessas limitações na área.

6.2 RESULTADOS DA AVALIAÇÃO METODOLÓGICA

Nos 11 estudos com categoria definida preliminarmente, a apreciação documental com o MMAT 2018 manteve as respostas aos cinco critérios separadas por estudo empírico. Outros três receberam apenas a triagem S1/S2, enquanto se define sua categoria. Esse formato tornou visíveis limitações relativas a representatividade, completude dos dados, controle de confundidores, integração de métodos e coerência entre desenho e análise, sem transformar os julgamentos em uma pontuação agregada.

A avaliação não produziu nota geral, média ou ranking de qualidade. Essa decisão preservou a interpretação de cada critério e impediu que uma pontuação agregada ocultasse fragilidades metodológicas relevantes. Dos 15 registros empíricos mantidos provisoriamente, 14 receberam respostas S1/S2 e 11 tiveram os critérios específicos da categoria apreciados; nos estudos 5, 7 e 14, Q1–Q5 permanecem sem resposta até definir o delineamento; o estudo 8 permanece sem respostas enquanto sua elegibilidade e unidade de apreciação aguardam adjudicação humana. O relatório não recuperado também não foi apreciado. A estruturação dos registros permite sua conferência, mas não comprova correção dos julgamentos nem apreciação humana concluída; leitura crítica, confirmação da proveniência e adjudicação independente continuam necessárias.

O fortalecimento da rastreabilidade também constituiu um resultado técnico. Os julgamentos foram registrados em arquivo canônico versionado e passaram a alimentar os artefatos CSV, HTML e LaTeX utilizados no trabalho. A correspondência entre avaliação e estudo considerou título normalizado, ano e primeiro autor, reduzindo o risco de associações incorretas

ou ambíguas.

6.3 RESULTADOS DA FUNDAMENTAÇÃO PEDAGÓGICA

A fundamentação permitiu distinguir desempenho observado, proficiência estimada, competência e aprendizagem. Notas, acertos, tentativas e tempos de resposta representam evidências dependentes da tarefa e do contexto; a interpretação de conhecimentos e habilidades requer relacionar essas observações ao construto e ao instrumento de avaliação (National Research Council, 2001). Na especificação, o acompanhamento de mudanças ao longo do tempo foi tratado como condição para investigar aprendizagem, e não como resultado já demonstrado. Essa distinção também alcançou a probabilidade preditiva de um alvo definido: uma saída condicionada aos dados e ao modelo, distinta do indicador de desempenho observado e não equivalente, por si só, a proficiência, competência, aprendizagem ou eficácia pedagógica.

Os referenciais sobre conhecimento prévio, mediação, resolução de problemas, avaliação formativa e *feedback* reforçaram que a utilidade de uma ferramenta computacional depende da forma como seus resultados são interpretados e incorporados à prática docente. A tecnologia foi posicionada como apoio à decisão, mantendo o professor responsável por considerar fatores pedagógicos, sociais e contextuais que não são observados diretamente pelo modelo.

Esses resultados fundamentaram requisitos de explicabilidade, revisão humana, associação curricular, proteção de dados e comunicação de incertezas. Assim, a dimensão pedagógica não foi adicionada apenas como justificativa; ela orientou diretamente a especificação técnica.

6.4 RESULTADOS DA ESPECIFICAÇÃO DO PROTÓTIPO

A integração entre revisão e fundamentação resultou em uma especificação conceitual composta por princípios de projeto, requisitos funcionais e não funcionais, critérios de seleção de fontes de dados, alternativas de modelagem, protocolo de avaliação e arquitetura de referência.

Entre os resultados consolidados destacaram-se a definição do protótipo como instrumento de apoio, sem substituição da interpretação docente, e a exigência de rastreabilidade entre dados, modelos, parâmetros e resultados. Também foram especificados modelos supervisionados simples e interpretáveis como alternativas iniciais de comparação, mantendo-se a separação entre avaliação técnica e alegações de eficácia pedagógica.

A especificação incorporou explicabilidade e análise de limitações ao fluxo de avaliação e organizou a arquitetura em componentes de ingestão, preparação, modelagem, avaliação, explicabilidade e apresentação. O uso de dados sintéticos foi delimitado a testes de fluxo, sem interpretação educacional.

A especificação constituiu a entrega documental do trabalho ao articular observações dos estudos, fundamentos teóricos e normativos e decisões de projeto explicitadas no Quadro 6. Ao mesmo tempo, ela não foi apresentada como aplicação funcional nem recebeu métricas próprias de desempenho, preservando a correspondência entre o texto e os artefatos efetivamente produzidos.

6.5 ATENDIMENTO AOS OBJETIVOS

No escopo executado, o primeiro objetivo específico foi desenvolvido por meio da categorização preliminar das técnicas e finalidades pedagógicas dos candidatos empíricos no Capítulo 4. O segundo foi desenvolvido pela identificação de limitações localizadas no material examinado, sem estimar sua frequência na literatura. O terceiro foi operacionalizado na formulação dos requisitos, critérios para dados e modelos e arquitetura de referência no Capítulo 5. O quarto resultou na proposição de um protocolo de avaliação da viabilidade e da coerência da especificação conceitual, descrito na Seção 5.2. Sua aplicação não foi realizada; o protocolo experimental de uma eventual implementação constitui contingência separada, não evidência de atendimento empírico do OE4. Como a elegibilidade de parte dos registros, a apreciação MMAT e a revisão independente permanecem pendentes, os resultados associados aos dois primeiros objetivos são preliminares e não equivalem a uma síntese final do corpus.

O componente propositivo do objetivo geral foi realizado no escopo documental pela elaboração de uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática. Sua fundamentação, contudo, permanece preliminar: a retenção é operacional, a extensão das consultas deve ser confirmada por fonte, um relatório procurado permanece não recuperado e a apreciação MMAT aguarda conferência e adjudicação humanas. Portanto, o resultado é uma especificação derivada tematicamente do recorte versionado analisado, não uma síntese conclusiva da literatura nem uma solução educacional validada.

6.6 DISCUSSÃO INTEGRADA

A discussão da literatura e de suas limitações orientou a decisão de não selecionar uma técnica apenas pela frequência de uso ou pela maior acurácia reportada em um artigo. Na especificação proposta, a seleção deve considerar a qualidade e a representatividade dos dados, a finalidade pedagógica, a possibilidade de interpretação e as condições de aplicação.

A presença de modelos preditivos na síntese preliminar indicou tarefas de classificação e estimativa entre os candidatos analisados. Neste trabalho, essas tarefas não foram tratadas como mensuração completa de fenômenos educacionais. A especificação separou explicitamente desempenho, proficiência, competência e aprendizagem e previu participação docente na interpretação das saídas, sem atribuir aos autores dos estudos uma posição teórica uniforme.

A principal contribuição do trabalho esteve, portanto, na articulação entre revisão sistemática, avaliação metodológica, fundamentação pedagógica e engenharia de requisitos. Essa articulação ofereceu uma base estruturada para decisões futuras sobre soluções educacionais, mantendo a seleção de algoritmos subordinada ao contexto, à avaliação e aos limites da evidência.

7 CONCLUSÃO

Este trabalho investigou técnicas computacionais aplicadas ao ensino de matemática por meio de uma revisão sistemática da literatura e da elaboração de uma especificação conceitual de protótipo. O fluxo partiu de 11.904 registros e terminou, entre os 18 registros selecionados preliminarmente para avaliação de escopo, com 15 estudos empíricos mantidos provisoriamente, um registro excluído após resumo, um relatório não recuperado e um protocolo sem resultados concluídos. A síntese preliminar identificou estudos de classificação ou predição de resultados em itens e disciplinas de Matemática, como os de Pejić, Molcer e Gulači (2021) e Milićević, Marinović e Jeftić (2024); uma proposta de trajetórias personalizadas descrita por Zhang, Zhu e Feng (2025), cuja avaliação não oferece informações suficientes para inferência causal; e uma aplicação de Transformada de Fourier articulada ao ensino universitário de matemática por Xia et al. (2026), cujos resultados não isolam a contribuição da IA.

A leitura crítica dos estudos de Pejić, Molcer e Gulači (2021), Milićević, Marinović e Jeftić (2024) e Zhang, Zhu e Feng (2025) motivou cautela quanto à generalização de seus resultados para outras populações. Na interpretação adotada pelo trabalho, indicadores isolados de desempenho não foram tratados como demonstração de aprendizagem, conforme a distinção conceitual da fundamentação educacional. A especificação também distinguiu a probabilidade preditiva de um alvo definido, entendida como saída condicionada aos dados e ao modelo, do indicador de desempenho observado; essa probabilidade não equivale, isoladamente, à proficiência, à competência, à aprendizagem ou à eficácia pedagógica. A apreciação metodológica preliminar pelo MMAT foi organizada por critérios, sem pontuação geral, preservando a visibilidade das limitações de cada estudo e a rastreabilidade dos julgamentos realizados.

A fundamentação pedagógica permitiu distinguir desempenho observado, proficiência estimada, competência e aprendizagem. Essa diferenciação orientou a especificação do protótipo e reforçou que modelos computacionais devem apoiar a interpretação docente, sem produzir diagnósticos definitivos ou substituir decisões pedagógicas contextualizadas.

O componente propositivo do objetivo geral foi realizado no escopo documental pela elaboração de uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática. A categorização, a identificação de limitações, a formulação dos requisitos e da arquitetura e a proposição do protocolo foram desenvolvidas, mas não devem ser interpretadas como conclusão definitiva da revisão: um relatório selecionado preliminarmente

segue sem texto integral e sem MMAT, e a triagem S1/S2 abrange 14 dos 15 registros empíricos mantidos provisoriamente, enquanto 11 têm apreciação por categoria. Nos estudos 5, 7 e 14, Q1–Q5 permanecem sem resposta até a definição do delineamento. O estudo 8 permanece sem respostas MMAT enquanto sua elegibilidade e unidade de apreciação aguardam adjudicação humana; suas bases distintas não devem ser somadas. A contribuição, portanto, é uma especificação conceitual derivada tematicamente do recorte versionado disponível, não uma síntese conclusiva da literatura nem uma solução educacional validada. O protocolo orienta uma avaliação futura; sua elaboração não demonstra viabilidade empírica ou eficácia pedagógica do protótipo.

7.1 CONTRIBUIÇÕES DO TRABALHO

Entre as contribuições, destaca-se a síntese estruturada do recorte versionado e os artefatos que permitem inspecionar e reproduzir esse conjunto. O fluxo automatizado reúne etapas de coleta, deduplicação, triagem e exportação, mas os registros disponíveis não permitem reconstruir integralmente as consultas históricas nem reproduzir toda a busca executada. O trabalho também separou relevância temática e apreciação metodológica preliminar dos estudos empíricos pelo MMAT, com respostas organizadas por critério.

A fundamentação sobre aprendizagem matemática e os limites das inferências computacionais orientou uma especificação técnica e pedagógica de protótipo baseada nas evidências da revisão. Essa especificação definiu critérios de rastreabilidade, explicabilidade, avaliação e participação docente, sem transformar uma proposta conceitual em evidência de eficácia pedagógica.

7.2 LIMITAÇÕES

A revisão foi conduzida por um único pesquisador, sem dupla seleção e dupla avaliação independentes. Um relatório selecionado preliminarmente não foi recuperado; por isso, não recebeu apreciação MMAT, e sua eventual elegibilidade permanece pendente. O estudo 8 permanece no fluxo PRISMA e no corpus empírico provisório, mas não recebeu respostas MMAT até adjudicação de sua elegibilidade e unidade de apreciação; suas bases distintas não devem ser somadas. Os localizadores dos critérios e a adjudicação independente das 14 triagens e dos 11 conjuntos de critérios MMAT também precisam ser concluídos antes de qualquer síntese final de qualidade. As fontes consultadas e os idiomas selecionados limitaram a cobertura

da literatura.

A especificação do protótipo não incluiu uma aplicação educacional funcional, o treinamento de modelos com uma base definitiva ou validação com participantes. Consequentemente, o trabalho não produziu métricas próprias de acurácia nem evidências de eficácia pedagógica. Essa limitação foi assumida como delimitação do escopo executado. A implementação técnica adicional disponível no repositório e seus testes sintéticos não substituem essas validações; devem ser distinguidos da especificação e da aplicação educacional futura.

7.3 CONTINUIDADE DA PESQUISA

Como continuidade prioritária, propõe-se concluir a conferência humana das fontes e dos julgamentos e aplicar o protocolo de avaliação da viabilidade e da coerência da especificação conceitual. O desenvolvimento de uma aplicação educacional é uma possibilidade condicionada a decisão posterior, não uma etapa presumida desta entrega. Se autorizado, deverá envolver seleção de dados compatíveis com os critérios definidos e comparação de modelos de referência em ambiente reproduzível. Estudos com participantes devem observar avaliação ética aplicável, autorização institucional, proteção dos dados e participação de profissionais da educação na interpretação dos resultados.

A continuidade também deve investigar estabilidade das explicações, diferenças de desempenho entre grupos, alinhamento com descritores curriculares e utilidade das informações para o planejamento docente. Essas atividades ampliam os resultados obtidos, mas não alteram a conclusão de que a revisão e a especificação responderam ao escopo definido para este trabalho.

REFERÊNCIAS

AUSUBEL, David P. **Educational Psychology: A Cognitive View**. New York: Holt, Rinehart and Winston, 1968.

BLACK, Paul; WILIAM, Dylan. Assessment and classroom learning. **Assessment in Education: Principles, Policy & Practice**, v. 5, n. 1, p. 7–74, 1998. DOI: <https://doi.org/10.1080/0969595980050102>.

Brasil. **Base Nacional Comum Curricular: Educação é a Base**. 2018. Documento normativo que define o conjunto de aprendizagens essenciais para a Educação Básica. Disponível em: <https://basenacionalcomum.mec.gov.br/>. Acesso em: 15 set. 2026.

____. **Lei nº 13.709, de 14 de agosto de 2018**: Lei geral de proteção de dados pessoais. 2018. Disponível em: <https://planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm>. Acesso em: 11 out. 2026.

Brasil. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Relatório de resultados do Saeb 2021: volume 1: contexto educacional e resultados em língua portuguesa e matemática para o 5º e 9º anos do ensino fundamental e séries finais do ensino médio**. Brasília, DF: Inep, 2024. 261 p. ISBN 978-65-5801-078-4. Disponível em: <https://download.inep.gov.br/educacao_basica/saeb/2021/resultados/relatorio_de_resultados_do_saeb_2021_volume_1.pdf>. Acesso em: 22 out. 2026.

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, p. 5–32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>.

CORTES, Corinna; VAPNIK, Vladimir. Support-vector networks. **Machine Learning**, v. 20, p. 273–297, 1995. DOI: <https://doi.org/10.1007/BF00994018>.

DEPREN, Serpil Kılıç; AŞKIN, Öyküm Esra; ÖZ, Ersoy. Identifying the Classification Performances of Educational Data Mining Methods: A Case Study for TIMSS. **Educational Sciences: Theory & Practice**, v. 17, n. 5, p. 1605–1623, 2017. DOI: <https://doi.org/10.12738/estp.2017.5.0634>.

ECHEVERIA, Joshua M.; BAJAO, Christal Joy; GODINEZ, C. Modeling Students' Mindset in Mathematics: A Data Mining Approach for Early Intervention. **European Journal of Education and Pedagogy**, v. 6, n. 6, 2025. DOI: <https://doi.org/10.24018/ejedu.2025.6.6.934>.

FAWCETT, Tom. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006. DOI: <https://doi.org/10.1016/j.patrec.2005.10.010>.

FENG, Mingyu; HEFFERNAN, Neil; KOEDINGER, Kenneth. Addressing the assessment challenge with an online system that tutors as it assesses. **User Modeling and User-Adapted Interaction**, v. 19, n. 3, p. 243–266, 2009. DOI: <https://doi.org/10.1007/s11257-009-9063-7>.

FRIEDMAN, Jerome H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. DOI: <https://doi.org/10.1214/aos/1013203451>.

HATTIE, John; TIMPERLEY, Helen. The power of feedback. **Review of Educational Research**, v. 77, n. 1, p. 81–112, 2007. DOI: <https://doi.org/10.3102/003465430298487>.

HE, Aneng et al. AI-driven predictive models for optimizing mathematics education technology: Enhancing decision-making through educational data mining and meta-analysis. **Smart Learning Environments**, 2025. DOI: <https://doi.org/10.1186/s40561-025-00415-z>.

HIGGINS, Julian P. T. et al. **Cochrane Handbook for Systematic Reviews of Interventions**. Cochrane, 2023. Version 6.4; versão historicamente registrada no trabalho. Disponível em: <https://www.training.cochrane.org/handbook>. Acesso em: 15 set. 2026.

HONG, Quan Nha et al. The mixed methods appraisal tool (MMAT) version 2018 for information professionals and researchers. **Education for Information**, v. 34, n. 4, p. 285–291, 2018. DOI: <https://doi.org/10.3233/EFI-180221>.

____. **Mixed Methods Appraisal Tool (MMAT), version 2018: User guide**. 2018. Disponível em: <https://mixedmethodsappraisaltoolpublic.pbworks.com/w/file/fetch/127916259/MMAT_2018_criteria-manual_2018-08-01_ENG.pdf>. Acesso em: 10 out. 2026.

IMPERATRICE, R. C. F. et al. Beyond the traditional classroom: innovation and inclusion in math teaching with AI. **Journal of Inclusive Methodology and Technology in Learning and Teaching**, v. 5, n. 3, 2025. Disponível em: <https://www.inclusiveteaching.it/index.php/inclusiveteaching/article/view/449>. Acesso em: 12 out. 2026.

JAMES, Gareth et al. **An Introduction to Statistical Learning: with Applications in R**. 2. ed. New York: Springer, 2021. DOI: <https://doi.org/10.1007/978-1-0716-1418-1>.

KUMAR, Mukesh et al. Analysis of Feature Selection and Data Mining Techniques to Predict Student Academic Performance. In: **2022 International Conference on Decision Aid Sciences and Applications (DASA)**. [s.n.], 2022. p. 1013–1017. DOI: <https://doi.org/10.1109/DASA54658.2022.9765236>.

LAFFERTY, John D.; MCCALLUM, Andrew; PEREIRA, Fernando C. N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data. In: **International Conference on Machine Learning**. [s.n.], 2001. p. 282–289. Disponível em: <https://www.cis.upenn.edu/~danroth/Teaching/CS598-05/Papers/crf.pdf>. Acesso em: 7 out. 2026.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. [s.n.], 2017. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Acesso em: 15 set. 2026.

MACLELLAN, Christopher J. **Computational Models of Human Learning: Applications for Tutor Development, Behavior Prediction, and Theory Testing**. Tese (Doutorado) — Carnegie Mellon University, 2017. DOI: <https://doi.org/10.1184/R1/6715271>.

MCKENZIE, Joanne E. et al. Defining the criteria for including studies and how they will be grouped for the synthesis. In: HIGGINS, Julian P. T. et al. (Ed.). **Cochrane Handbook for Systematic Reviews of Interventions**. Cochrane, 2024. cap. 3. Version 6.5; chapter updated August 2023; sections 3.2 and 3.3. Disponível em: <https://www.cochrane.org/authors/handbooks-and-manuals/handbook/current/chapter-03>. Acesso em: 7 out. 2026.

MILIĆEVIĆ, Marina; MARINOVIĆ, Budimirka; JEFTIĆ, Ljerka. Machine learning methods as auxiliary tool for effective mathematics teaching. **Computer Applications in Engineering Education**, v. 32, n. 6, p. e22787, 2024. DOI: <https://doi.org/10.1002/cae.22787>.

MOHER, David et al. Preferred reporting items for systematic review and meta-analysis protocols (PRISMA-P) 2015 statement. **Systematic Reviews**, v. 4, n. 1, p. 1, 2015. DOI: <https://doi.org/10.1186/2046-4053-4-1>.

MOUSAVINASAB, Elham et al. Intelligent tutoring systems: a systematic review of characteristics, applications, and evaluation methods. **Interactive Learning Environments**, v. 29, n. 1, p. 142–163, 2021. DOI: <https://doi.org/10.1080/10494820.2018.1558257>.

National Research Council. **Knowing What Students Know: The Science and Design of Educational Assessment**. Washington, DC: The National Academies Press, 2001. DOI: <https://doi.org/10.17226/10019>.

NICULESCU-MIZIL, Alexandru; CARUANA, Rich. Predicting good probabilities with supervised learning. In: **Proceedings of the 22nd International Conference on Machine Learning**. ACM, 2005. p. 625–632. DOI: <https://doi.org/10.1145/1102351.1102430>.

NYANTAH, Rahmat Opoku; FREMPONG, Nana Kena; LARBI, Ernest. Enhancing Student Achievement in Circle Theorems: Integrating Computer Animation with the Jigsaw Cooperative Learning Model. **International Journal of Mathematics and Mathematics Education**, v. 3, n. 2, p. 91–112, 2025. DOI: <https://doi.org/10.56855/ijmme.v3i2.1299>.

OECD. **PISA 2022 Assessment and Analytical Framework**. Paris: OECD Publishing, 2023. DOI: <https://doi.org/10.1787/dfe0bf9c-en>.

____. **PISA 2022 Results (Volume I): The State of Learning and Equity in Education**. OECD Publishing, 2023. DOI: <https://doi.org/10.1787/53f23881-en>.

PAGE, Matthew J. et al. The prisma 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: <https://doi.org/10.1136/bmj.n71>.

PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, n. 85, p. 2825–2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 22 out. 2026.

PEJIĆ, Aleksandar; MOLCER, Piroska Stanić; GULAČI, Kristian. Math proficiency prediction in computer-based international large-scale assessments using a multi-class machine learning model. In: **2021 IEEE 19th International Symposium on Intelligent Systems and Informatics (SISY)**. [s.n.], 2021. p. 49–54. DOI: <https://doi.org/10.1109/SISY52375.2021.9582522>.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. ACM, 2016. p. 1135–1144. DOI: <https://doi.org/10.1145/2939672.2939778>.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining and learning analytics: An updated survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, p. e1355, 2020. DOI: <https://doi.org/10.1002/widm.1355>.

SOKKHEY, Phauk et al. Multi-models of Educational Data Mining for Predicting Student Performance in Mathematics: A Case Study on High Schools in Cambodia. **IEIE Transactions on Smart Processing and Computing**, v. 9, n. 3, p. 217–229, 2020. DOI: <https://doi.org/10.5573/IEIESPC.2020.9.3.217>.

TJAHYADI, Hendra; TUDE, Krismon N. L. The Implementation of Educational Data Mining in Predicting Students' Academic Achievement in Mathematics at a Private Elementary School. **International Journal of Information and Education Technology**, v. 15, n. 1, p. 154–163, 2025. DOI: <https://doi.org/10.18178/ijiet.2025.15.1.2228>.

USKOV, Vladimir L. et al. Machine Learning-based Predictive Analytics of Student Academic Performance in STEM Education. In: **2019 IEEE Global Engineering Education Conference (EDUCON)**. [s.n.], 2019. p. 1370–1376. DOI: <https://doi.org/10.1109/EDUCON.2019.8725237>.

VILLEGAS-CH, William et al. Adaptive intelligent tutoring systems for STEM education: analysis of the learning impact and effectiveness of personalized feedback. **Smart Learning Environments**, v. 12, 2025. DOI: <https://doi.org/10.1186/s40561-025-00389-y>.

VYGOTSKY, Lev S. **Mind in Society: The Development of Higher Psychological Processes**. Cambridge, MA: Harvard University Press, 1978.

WOOD, David; BRUNER, Jerome S.; ROSS, Gail. The role of tutoring in problem solving. **Journal of Child Psychology and Psychiatry**, v. 17, n. 2, p. 89–100, 1976. DOI: <https://doi.org/10.1111/j.1469-7610.1976.tb00381.x>.

XIA, Chenxi et al. Exploring the Integration of Education for Sustainable Development into University Mathematics: Insights from SiC Thickness Measurement in Advanced Industrial Applications. **Sustainability**, v. 18, n. 4, 2026. DOI: <https://doi.org/10.3390/su18041900>.

XIE, Haoran et al. Trends and development in technology-enhanced adaptive/personalized learning: A systematic review of journal publications from 2007 to 2017. **Computers & Education**, v. 140, p. 103599, 2019. DOI: <https://doi.org/10.1016/j.compedu.2019.103599>.

ZENG, Jialing. **Multimodal neurophysiological measurement of cognitive load during math problem solving in 4th graders**. 2025. DOI: <https://doi.org/10.7916/2q6y-bm58>.

ZHANG, Lei; ZHU, Weihua; FENG, Ling. Design of Personalized Learning Path Optimization Algorithm Based on Deep Learning. In: **2025 International Conference on Computers, Information Processing and Advanced Education (CIPAE)**. [s.n.], 2025. p. 650–655. DOI: <https://doi.org/10.1109/CIPAE66821.2025.00116>.

ZHANG, Xiaohui. An Innovative Model of Higher Mathematics Curriculum Education Incorporating Artificial Intelligence Technology. **Applied Mathematics and Nonlinear Sciences**, v. 9, n. 1, p. 1–16, 2024. DOI: <https://doi.org/10.2478/amns.2023.2.01524>.

ÖZSEVEN, Beyza Esin; ÖZSEVEN, Turgut. A Hybrid Neuro-Fuzzy and Machine Learning Model for Student Performance Prediction in Online Mathematics Education. **International Journal of Advanced Computer Science and Applications**, v. 17, n. 5, 2026. DOI: <https://doi.org/10.14569/ijacsa.2026.0170516>.

APÊNDICE A – MAPEAMENTO DO RELATO AO PRISMA 2020

Este apêndice apresenta um mapeamento do relato deste manuscrito com base no PRISMA 2020 (Page et al., 2021). O quadro desdobra os 27 itens do checklist em suas alíneas aplicáveis e utiliza tópicos abreviados; os requisitos completos estão no checklist oficial. O mapeamento avalia o que foi apresentado no texto, não certifica a execução do procedimento, o rigor metodológico, a ausência de viés ou a certeza da evidência. São registradas as informações localizadas e as limitações do manuscrito, sem atribuir pontuação ou declarar conformidade global ou integral.

A indicação *Localizado* identifica uma passagem pertinente, mas não certifica sua suficiência. *Parcial* indica informação disponível com limitações explicitadas. *Não apresentado* registra informação ou resultado não encontrado no manuscrito examinado, sem afirmar que o procedimento jamais ocorreu; quando a atividade não foi realizada, isso é indicado na justificativa. *Não aplicável* é empregado somente com justificativa específica; a ausência de meta-análise não dispensa o relato dos métodos de síntese narrativa.

Quadro 7 – Mapeamento do relato aos itens do PRISMA 2020.

Item	**Tópico abreviado**	**Localização e estado do relato**
1	Título	Parcial: capa e folha de rosto identificam o tema, mas o título não explicita revisão sistemática.
2	Resumo	Parcial: Resumo e Abstract apresentam método e resultados; não foi concluída a conferência específica do PRISMA para resumos.
3	Justificativa	Localizado: Cap. 1, Justificativa.
4	Objetivos	Localizado: Cap. 1, Problema de Pesquisa e Objetivos.
5	Elegibilidade	Parcial: Cap. 3, Critérios de Seleção, e Quadro 3. Dos 18 registros selecionados preliminarmente, 1 foi excluído após resumo; 17 relatórios foram procurados, 1 não foi recuperado e 16 foram avaliados em texto completo. Um protocolo foi excluído após essa avaliação e 15 compõem provisoriamente o núcleo empírico. A priorização operacional não equivale à elegibilidade.

Continua na próxima página

Quadro 7 – Continuação

Item	**Tópico abreviado**	**Localização e estado do relato**
6	Fontes	Parcial: Cap. 3, Estratégia de Busca. Não estão discriminadas as datas da última consulta de cada fonte.
7	Buscas	Parcial: Cap. 3, Estratégia de Busca e Quadro 1. Há composição canônica e exemplos; o relato por fonte, com filtros e limites, não está completo.
8	Seleção	Parcial: Cap. 3, Processo de Seleção, e Cap. 4, Limitações e Contribuições da Revisão. São descritos automação e revisor único; a verificação documental permanece incompleta.
9	Coleta de dados	Parcial: Cap. 3, Identificação e Avaliação da Qualidade Metodológica. A obtenção de metadados está descrita; a extração dos textos e sua confirmação não estão integralmente documentadas.
10a	Desfechos	Parcial: Cap. 3, Critérios de Seleção, e Quadro 3. Faltam regras completas para seleção de resultados por desfecho.
10b	Outras variáveis	Parcial: Cap. 3, Identificação. Não há definição completa das variáveis extraídas e do tratamento de informação ausente.
11	Viés nos estudos	Parcial: Cap. 3, Avaliação da Qualidade Metodológica. O MMAT está documentado como apreciação preliminar por revisor único, com fontes e julgamentos ainda incompletos.
12	Medidas de efeito	Parcial: Quadro 3. As métricas reportadas são heterogêneas; não foi definida medida comum para combinação quantitativa.
13a	Composição das sínteses	Parcial: Cap. 3, Critérios de Seleção, e Cap. 4, Síntese dos Estudos Incluídos. A síntese empírica considera provisoriamente 15 estudos; o relatório não recuperado, a exclusão após resumo e o protocolo sem resultados concluídos estão discriminados no Quadro 3. O procedimento de codificação e a confirmação independente ainda não estão completos.

Continua na próxima página

Quadro 7 – Continuação

Item	Tópico abreviado	Localização e estado do relato
13b	Preparação dos dados	Não apresentado: não foi localizado procedimento específico para preparar os resultados extraídos, incluindo estatísticas ausentes ou conversões.
13c	Apresentação	Localizado: Cap. 4, Fluxo de Seleção, Estatísticas Descritivas, Síntese dos Estudos Incluídos e Avaliação Metodológica com o MMAT. A apresentação não substitui a validação dos dados.
13d	Síntese	Parcial: Cap. 4, Síntese dos Estudos Incluídos e Limitações e Contribuições da Revisão. A heterogeneidade é discutida; a codificação e o procedimento da síntese narrativa não estão inteiramente explicitados.
13e	Heterogeneidade	Não apresentado: não foi realizado método formal para investigar possíveis causas de heterogeneidade; diferenças entre populações, desenhos e métricas são discutidas qualitativamente.
13f	Sensibilidade	Não apresentado: não foi realizada análise de sensibilidade da síntese.
14	Viés de relato	Não apresentado: não foi realizada avaliação formal. Cap. 4, Limitações e Contribuições da Revisão, registra a ausência de teste de viés de publicação.
15	Certeza	Não apresentado: não foi apresentada avaliação formal da certeza do conjunto de evidências; o MMAT individual não a substitui.
16a	Fluxo	Parcial: Figura 1, Tabela 1 e Quadro 3. O relato discrimina 17 relatórios procurados, 1 não recuperado, 16 avaliados em texto completo, 1 protocolo excluído após essa avaliação e 15 estudos empíricos mantidos provisoriamente; 1 exclusão após resumo permanece em etapa distinta. A priorização operacional é explicitada como etapa heurística, não de elegibilidade.

Continua na próxima página

Quadro 7 – Continuação

Item	**Tópico abreviado**	**Localização e estado do relato**
16b	Exclusões justificadas	Parcial: Quadro 3 identifica o protocolo 6921 excluído após texto completo por não apresentar resultados empíricos concluídos. O registro excluído após resumo (9) e o texto não recuperado são distinguidos dessa exclusão; o estudo 6919 foi incluído conforme os critérios escritos do protocolo. A caracterização do relato pendente limita-se aos metadados e resumos disponíveis.
17	Características	Parcial: Quadro 3. Os 18 registros selecionados preliminarmente são identificados com sua situação no fluxo; características de amostra e desenho não estão uniformemente detalhadas. O único relatório não recuperado é descrito com base nos metadados e no resumo disponível; o registro excluído após resumo pertence a etapa distinta e não foi tratado como relatório procurado.
18	Apreciação individual	Parcial: Seção 4.4 e Quadro 4. Julgamentos preliminares, com limitações de fontes e localizadores.
19	Resultados individuais	Parcial: Quadro 3. Diversas entradas descrevem a abordagem; estimativas e precisão não são apresentadas uniformemente.
20a	Síntese e limitações	Parcial: Cap. 4, Síntese dos Estudos Incluídos e Avaliação Metodológica com o MMAT. Não está completa a ligação entre os estudos de cada síntese e seus julgamentos metodológicos.
20b	Sínteses estatísticas	Não aplicável aos resultados de combinação estatística: nenhuma síntese estatística conjunta foi realizada.
20c	Heterogeneidade	Não apresentado: não foram apresentados resultados de investigação formal das causas de heterogeneidade.
20d	Sensibilidade	Não apresentado: não foram apresentados resultados de análises de sensibilidade.
21	Viés de relato	Não apresentado: não foram apresentados resultados de avaliação formal de viés decorrente de resultados ausentes.
22	Certeza	Não apresentado: não foi apresentada classificação formal de certeza por desfecho.

Continua na próxima página

Quadro 7 – Continuação

Item	**Tópico abreviado**	**Localização e estado do relato**
23a	Interpretação	Parcial: Cap. 6, Discussão Integrada. As interpretações dependem da consolidação da extração e da apreciação metodológica.
23b	Limites da evidência	Localizado: Cap. 4, Avaliação Metodológica com o MMAT e Limitações e Contribuições da Revisão; Cap. 7, Limitações.
23c	Limites do processo	Localizado: Cap. 3, Avaliação da Qualidade Metodológica, e Cap. 4, Limitações e Contribuições da Revisão, incluindo revisor único e acesso desigual aos textos.
23d	Implicações	Localizado: Cap. 6, Discussão Integrada, e Cap. 7, Continuidade da Pesquisa.
24a	Registro	Localizado: Cap. 3, Protocolo e Relato, declara ausência de registro prospectivo.
24b	Protocolo	Parcial: Cap. 3 descreve o planejamento; não identifica endereço de acesso a uma versão completa do protocolo anterior à execução.
24c	Alterações	Não apresentado: não foi localizada uma declaração metodológica completa de alterações do protocolo, com justificativas. A ausência de registro prospectivo não responde, por si só, a este item.
25	Apoio	Localizado: Seção 3.8, Apoio à Pesquisa. A pesquisa foi conduzida com recursos próprios, sem financiamento externo ou participação de financiador nas decisões da revisão.
26	Interesses	Localizado: Seção 3.8, Apoio à Pesquisa. O autor declara não haver conflitos de interesse relacionados a esta pesquisa.
27	Materiais	Parcial: Cap. 3, Reprodutibilidade, descreve código e exports. A relação de materiais públicos e respectivos endereços precisa ser explicitada.

A apreciação MMAT corresponde aos itens 11 e 18 deste mapeamento e permanece preliminar. Ela não constitui avaliação formal da certeza do conjunto de evidências (itens 15 e 22), não é avaliação de viés de relato (itens 14 e 21) e não permite inferir ausência de viés ou

conformidade global. As pendências indicadas restringem o alcance das conclusões e devem ser consideradas juntamente com as limitações apresentadas no Capítulo 4.