Ministério da Educação
Secretaria de Educação Profissional e Tecnológica
Instituto Federal Catarinense
Campus Videira

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Videira
2026

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Trabalho de Conclusão de Curso apresentado ao Curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira para obtenção do título de bacharel em Ciência da Computação.
Orientador: Prof. Dr. Rafael Zanin (IFC)
Coorientador: Prof. Dr. Manassés Ribeiro (IFC)

Videira
2026

THALES FERREIRA BATISTA

ENSINO PERSONALIZADO DE MATEMÁTICA: OPORTUNIDADES E TÉCNICAS COMPUTACIONAIS

Este Trabalho de Curso foi julgado adequado para a obtenção do título de Bacharel em Ciência da Computação e aprovado em sua forma final pelo curso de graduação em Ciência da Computação do Instituto Federal Catarinense – Campus Videira.

Videira (SC), ____ de _____ de 2026

Prof. Dr. Rafael Zanin
Orientador
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Manassés Ribeiro
Coorientador
Instituto Federal Catarinense – Campus Videira

BANCA EXAMINADORA

Prof. Me. Fábio José Rodrigues Pinheiro
Instituto Federal Catarinense – Campus Videira

Prof. Dr. Dani Prestini
Instituto Federal Catarinense – Campus Videira

RESUMO

Este trabalho propôs uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada em revisão sistemática da literatura. Foram consideradas publicações em português ou inglês, de 2015 a 2026, com data de corte da busca em 31 de agosto de 2026, recuperadas em Semantic Scholar, OpenAlex, Crossref e *COnnecting REpositories* (CORE). O relato foi organizado com referência ao *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (PRISMA) 2020. O conjunto histórico reúne 15 estudos: 14 têm texto recuperado, e Sokkhey (2020) permanece com respostas anteriores do *Mixed Methods Appraisal Tool* (MMAT) 2018 não revalidadas por falta de cópia verificável. A apreciação é apresentada por critério, sem escore agregado. A análise distinguiu estudos de predição e classificação, personalização e sistemas tutores inteligentes, intervenção didática, modelagem cognitiva e integração curricular. A apreciação identificou limitações na evidência disponível ao revisor sobre amostragem, medidas, completude dos dados e procedimentos de avaliação, restringindo a interpretação dos achados. A seleção por relevância, a disponibilidade dos textos primários e a amostragem aleatória sem semente fixa na coleta via Crossref também limitaram a abrangência e a repetibilidade da revisão. Na exploração de sensibilidade abaixo de 4,0, foram classificados como elegíveis 13 de 45 registros examinados por censo na faixa 3,75–3,95, 29 de 54 examinados por seleção dirigida na faixa 3,50–3,74 e 5 de 30 em amostra aleatória estratificada na faixa 3,00–3,49, indicando possível perda de cobertura. A síntese dos estudos selecionados por triagem e priorização por relevância fundamentou uma especificação com 26 grupos de requisitos, critérios para dados e modelos, cenários de uso e arquitetura de referência. Também foi proposto um protocolo documental para avaliar a viabilidade e a coerência da especificação, acompanhado de formulário de revisão docente, ainda não aplicado. Conclui-se que a organização de evidências por finalidade e condições de validade permite estruturar uma base documental de apoio à interpretação docente, preservando as diferenças entre desempenho, previsão, proficiência, competência e aprendizagem. A contribuição obtida é documental e não demonstra eficácia educacional de uma implementação.

Palavras-chave: ensino de matemática; aprendizado de máquina; revisão sistemática; avaliação de competências; especificação de protótipo.

ABSTRACT

This study proposed a technical and pedagogical prototype specification to support teachers' interpretation of mathematics learning, grounded in a systematic literature review. Publications in Portuguese or English from 2015 to 2026 were considered, with a search cutoff of 31 August 2026, retrieved from Semantic Scholar, OpenAlex, Crossref, and *COnnecting REpositories* (CORE). Reporting was organized with reference to the *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (PRISMA) 2020. The historical set comprises 15 studies: full texts were recovered for 14, while Sokkhey (2020) retains earlier MMAT 2018 responses, not revalidated for lack of a verifiable copy. The appraisal is reported by criterion, without an aggregate score. The analysis distinguished studies of prediction and classification, personalization and intelligent tutoring systems, instructional interventions, cognitive modeling, and curricular integration. The appraisal identified limitations in the evidence available to the reviewer on sampling, measures, data completeness, and evaluation procedures, restricting the interpretation of the findings. Relevance-based selection, primary-text availability, and random sampling without a fixed seed during data collection via Crossref also limited the review's coverage and repeatability. The sensitivity exploration below 4.0 classified 13 of 45 records examined by census in the 3.75–3.95 band, 29 of 54 examined through directed selection in the 3.50–3.74 band, and 5 of 30 in a stratified random sample in the 3.00–3.49 band as eligible, indicating possible loss of coverage. The synthesis of studies selected through screening and relevance prioritization informed a specification comprising 26 requirement groups, criteria for data and models, use scenarios, and a reference architecture. A documentary protocol for assessing the specification's feasibility and coherence was also proposed, accompanied by a teacher-review form, and has not been applied. Organizing evidence by purpose and validity conditions provides a documentary basis for teachers' interpretation, preserving the differences among performance, prediction, proficiency, competence, and learning. The resulting contribution is documentary and does not demonstrate the educational effectiveness of an implementation.

Keywords: mathematics education; machine learning; systematic review; competency assessment; prototype specification.

LISTA DE ILUSTRAÇÕES

Fluxograma 1 – Fluxo de seleção da revisão sistemática. 34
Gráfico 1 – Registros após a remoção de duplicatas, por fonte científica. 35
Figura 1 – Componentes e fluxos da arquitetura conceitual. 68

LISTA DE QUADROS

Quadro 1 – Camadas da estratégia de busca bilíngue. 26
Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão. 27
Quadro 3 – Caracterização e situação dos 18 registros selecionados preliminarmente. . 36
Quadro 4 – Finalidade, técnica e população dos estudos incluídos. 41
Quadro 5 – Alvos, validação e métricas dos estudos incluídos. 43
Quadro 6 – Triagem e apreciação preliminar pelo MMAT 2018 de 15 estudos do corpus. 46
Quadro 7 – Componentes qualitativos e quantitativos dos estudos de métodos mistos. . 46
Quadro 8 – Respostas MMAT por critério e categoria de desenho. 48
Quadro 9 – Contagens separadas dos componentes dos três estudos mistos. 49
Quadro 10 – Critérios de aceitação dos requisitos funcionais. 62
Quadro 11 – Origem, derivação e limites dos requisitos da especificação conceitual. . . . 69
Quadro 12 – Observações dos estudos e sua relação com os requisitos. 72
Quadro 13 – Mapeamento do relato aos itens do PRISMA 2020. 86
Quadro 14 – Ficha individual de julgamento por requisito. 94
Quadro 15 – Modelo de ficha de aceitação documental por função. 95
Quadro 16 – Ferramentas de inteligência artificial e finalidades gerais. 99

LISTA DE TABELAS

Tabela 1 – Estatísticas descritivas da revisão sistemática. 35
Tabela 2 – Frequência da finalidade principal no corpus de 15 estudos. 45

LISTA DE ABREVIATURAS E SIGLAS

ACO	*Ant Colony Optimization* (Otimização por Colônia de Formigas)
AIC	*Akaike Information Criterion* (Critério de Informação de Akaike)
API	*Application Programming Interface* (Interface de Programação de Aplicações)
BIC	*Bayesian Information Criterion* (Critério de Informação Bayesiano)
BKT	*Bayesian Knowledge Tracing* (Acompanhamento Bayesiano do Conhecimento)
BNCC	Base Nacional Comum Curricular
CNN	*Convolutional Neural Networks* (Redes Neurais Convolucionais)
CORE	*COnnecting REpositories*
CRF	*Conditional Random Fields* (Campos Aleatórios Condicionais)
CSV	*Comma-Separated Values* (Valores Separados por Vírgulas)
CT	*Can't tell* (Não é possível concluir com a evidência disponível)
DKT	*Deep Knowledge Tracing* (Acompanhamento do Conhecimento com Aprendizado Profundo)
DL	*Deep Learning* (Aprendizado Profundo)
DOI	*Digital Object Identifier* (Identificador de Objeto Digital)
DT	*Decision Trees* (Árvores de Decisão)
ECE	*Expected Calibration Error* (Erro de Calibração Esperado)
EDM	*Educational Data Mining* (Mineração de Dados Educacionais)
EEG	*Electroencephalography* (Eletroencefalografia)
F1	Medida F1 (média harmônica entre precisão e revocação)
HTML	*HyperText Markup Language* (Linguagem de Marcação de Hipertexto)
IA	Inteligência Artificial
IFC	Instituto Federal Catarinense
JSON	*JavaScript Object Notation* (Notação de Objetos JavaScript)

LA	*Learning Analytics* (Analítica da Aprendizagem)
LGPD	Lei Geral de Proteção de Dados Pessoais
LIME	*Local Interpretable Model-agnostic Explanations*
ML	*Machine Learning* (Aprendizado de Máquina)
MLP	*Multilayer Perceptron* (Perceptron Multicamadas)
MMAT	*Mixed Methods Appraisal Tool* (Instrumento de Avaliação de Métodos Mistos)
NB	*Naive Bayes*
OE	Objetivo específico (OE1 a OE4)
PCA	*Principal Component Analysis* (Análise de Componentes Principais)
PDF	*Portable Document Format* (Formato de Documento Portátil)
PICOS	*Population, Intervention, Comparison, Outcomes, Study Design* (População, Intervenção, Comparação, Desfechos e Desenho de Estudo)
PISA	*Programme for International Student Assessment*
PRISMA	*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*
PRISMA-P	*Preferred Reporting Items for Systematic Review and Meta-Analysis Protocols*
RF	*Random Forest* (Floresta Aleatória)
RIPPER	*Repeated Incremental Pruning to Produce Error Reduction* (Poda Incremental Repetida para Redução de Erro)
RL	*Reinforcement Learning* (Aprendizado por Reforço)
RN	Redes Neurais
ROC	*Receiver Operating Characteristic* (Característica de Operação do Receptor)
ROC-AUC	Área sob a curva ROC (*Receiver Operating Characteristic – Area Under the Curve*)
RUSBoost	*Random Under-Sampling Boost* (Reforço de classificadores com subamostragem aleatória)

SAEB	Sistema de Avaliação da Educação Básica
SHA-256	*Secure Hash Algorithm* de 256 bits (Algoritmo de Hash Seguro)
SHAP	*SHapley Additive exPlanations*
SiC	Carbeto de silício
SMOTE	*Synthetic Minority Over-sampling Technique*
STEM	*Science, Technology, Engineering, and Mathematics* (Ciência, Tecnologia, Engenharia e Matemática)
STI	Sistemas Tutores Inteligentes
SVM	*Support Vector Machines* (Máquinas de Vetores de Suporte)
TCC	Trabalho de Conclusão de Curso
TIMSS	*Trends in International Mathematics and Science Study* (Estudo Internacional de Tendências em Matemática e Ciências)
TRI	Teoria de Resposta ao Item
URL	*Uniform Resource Locator* (Localizador Uniforme de Recursos)

SUMÁRIO

1 INTRODUÇÃO 13
1.1 Justificativa 13
1.2 Problema de Pesquisa 13
1.3 Objetivos 14
1.4 Estrutura do Trabalho 15
2 FUNDAMENTAÇÃO TEÓRICA 16
2.1 Aprendizagem Matemática e Evidências de Desempenho 16
2.2 Contribuições Pedagógicas para a Especificação 17
2.3 Tecnologia como Apoio à Decisão Pedagógica 18
2.3.1 Proteção de Dados de Crianças e Adolescentes 18
2.4 Técnicas Computacionais na Educação 18
2.4.1 Trabalhos Relacionados 21
2.5 Avaliação Automatizada e Métricas 21
3 METODOLOGIA 24
3.1 Protocolo e Relato da Revisão Sistemática 24
3.2 Estratégia de Busca 25
3.3 Critérios de Seleção 26
3.4 Processo de Seleção 27
3.5 Infraestrutura Tecnológica da Revisão 29
3.6 Avaliação da Qualidade Metodológica 29
3.7 Uso de Ferramentas de Inteligência Artificial 30
3.8 Derivação da Especificação do Protótipo 31
4 REVISÃO SISTEMÁTICA DA LITERATURA 33
4.1 Fluxo de Seleção 33
4.2 Estatísticas Descritivas 33
4.3 Caracterização dos Estudos Incluídos 36
4.3.1 Matriz de Categorização do OE1 40
4.4 Avaliação Metodológica com o MMAT 45
4.4.1 Síntese das Respostas por Critério 48
4.5 Tendências e Lacunas 50

4.6 Limitações e Contribuições da Revisão 50
5 ESPECIFICAÇÃO DO PROTÓTIPO 57
5.1 Princípios e Requisitos 57
5.1.1 Alternativas de Mensuração 61
5.1.2 Critérios de Aceitação das Funções 62
5.1.3 Cenários de Uso e Saídas Previstas 63
5.2 Protocolo de Avaliação da Especificação Conceitual 64
5.2.1 Revisão Documental por Docentes 64
5.3 Arquitetura de Referência 67
5.4 Fundamentação e Rastreabilidade dos Requisitos 68
5.5 Contribuição dos Estudos para os Requisitos 72
6 RESULTADOS E DISCUSSÃO 74
6.1 Síntese dos Resultados 74
6.2 Atendimento aos Objetivos 74
6.3 Discussão Integrada 75
7 CONCLUSÃO 77
REFERÊNCIAS 80
APÊNDICE A MAPEAMENTO DO RELATO AO PRISMA 2020 86
APÊNDICE B REGISTRO DE RECUPERAÇÃO DAS FONTES 90
B.1 Histórico de recuperação e leitura 90
B.2 Arquivos e reprodução 92
APÊNDICE C FORMULÁRIO DE REVISÃO DA ESPECIFICAÇÃO . . 94
APÊNDICE D JUSTIFICATIVAS DOS COMPONENTES MMAT 96
APÊNDICE E FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL . . 99

1 INTRODUÇÃO

Este trabalho parte da necessidade de interpretar evidências de desempenho de estudantes com conhecimentos prévios, ritmos e dificuldades distintos. A mineração de dados educacionais e a analítica da aprendizagem reúnem métodos para analisar registros educacionais e identificar padrões, podendo apoiar a organização de informações usadas no acompanhamento de turmas (Romero; Ventura, 2020). Esse apoio não torna a saída computacional uma medida direta de aprendizagem: a validade da inferência depende do alvo definido, dos dados e do contexto de uso (National Research Council, 2001).

Na educação matemática, os estudos consultados incluem a predição de desempenho escolar por Tjahyadi e Tude (2025), a classificação com itens de Matemática do Programa Internacional de Avaliação de Estudantes (PISA, na sigla em inglês) computadorizado por Pejić, Molcer e Gulači (2021) e a classificação de resultados em uma disciplina de Matemática por Milićević, Marinović e Jeftić (2024). Esses exemplos ilustram tarefas de predição e avaliação. O alcance de seus resultados é discutido no Capítulo 4.

1.1 JUSTIFICATIVA

A relevância deste trabalho decorreu de duas necessidades complementares. A primeira consistiu em organizar a literatura, dispersa entre diferentes bases e áreas de pesquisa, sobre técnicas computacionais aplicadas ao ensino de matemática. A segunda consistiu em transformar as evidências encontradas em requisitos técnicos e pedagógicos para uma especificação de protótipo voltada ao apoio do professor.

Para professores, uma síntese crítica auxilia na compreensão das abordagens investigadas, dos resultados reportados e de suas limitações metodológicas. Para estudantes e instituições, a pesquisa explicita as diferenças entre desempenho observado, proficiência estimada, competência e aprendizagem. A especificação também distingue a probabilidade preditiva de um alvo definido do indicador de desempenho observado.

1.2 PROBLEMA DE PESQUISA

Diante desse contexto, o trabalho respondeu ao seguinte problema de pesquisa: como estruturar uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática a partir das evidências e técnicas computacionais

identificadas na literatura? Essa finalidade articula registros de desempenho, contexto pedagógico e interpretação do professor, no escopo documental da revisão e da especificação.

1.3 OBJETIVOS

Para responder a esse problema, definiu-se como objetivo geral propor uma especificação técnica e pedagógica de protótipo para apoiar a interpretação docente da aprendizagem matemática, fundamentada no mapeamento e na análise da literatura científica.

Para alcançá-lo, foram definidos os seguintes objetivos específicos:

a) (OE1) categorizar as abordagens e técnicas computacionais e as finalidades pedagógicas descritas na literatura mapeada;

b) (OE2) identificar, por codificação sistemática, limitações metodológicas e de relato e discutir conceitualmente dimensões técnicas, pedagógicas e éticas no material examinado;

c) (OE3) formular a especificação técnica e pedagógica do protótipo, incluindo requisitos, critérios para seleção de fontes de dados e modelos e uma arquitetura de referência;

d) (OE4) propor um protocolo para avaliar a viabilidade e a coerência da especificação conceitual, considerando sua fundamentação, a consistência dos requisitos e as condições técnicas e pedagógicas de execução.

O OE2 foi delimitado à codificação sistemática das limitações metodológicas e de relato porque esses aspectos permitem análise comparável com base nos critérios MMAT nos textos recuperados; os eixos técnico, pedagógico e ético são discutidos conceitualmente.

A revisão sistemática e a apreciação metodológica dos estudos fundamentaram parcialmente a especificação, em conjunto com fundamentos teóricos e decisões de projeto. O Capítulo 3 apresenta os procedimentos empregados e o recorte de publicações de 2015 a 2026, com data de corte da busca em 31 de agosto de 2026 e inclusão de artigos de periódicos, trabalhos completos em anais revisados por pares, teses e dissertações.

O produto principal do trabalho é documental: uma revisão da literatura e uma especificação de protótipo. A implementação exploratória serviu como verificação técnica auxiliar, sem demonstrar eficácia pedagógica. A proposta de revisão docente e sua não aplicação são delimitadas nos Capítulos 5 e 6; os procedimentos da pesquisa estão descritos no Capítulo 3.

1.4 ESTRUTURA DO TRABALHO

Os capítulos seguintes apresentam a fundamentação teórica (Capítulo 2), a metodologia da revisão (Capítulo 3), a seleção e a apreciação dos estudos (Capítulo 4), a especificação conceitual e seu protocolo proposto de avaliação (Capítulo 5), a discussão integrada (Capítulo 6) e as conclusões (Capítulo 7).

2 FUNDAMENTAÇÃO TEÓRICA

2.1 APRENDIZAGEM MATEMÁTICA E EVIDÊNCIAS DE DESEMPENHO

No referencial curricular adotado, os saberes matemáticos envolvem mais do que a execução de procedimentos. A Base Nacional Comum Curricular (BNCC) associa o letramento matemático às capacidades de raciocinar, representar, comunicar e argumentar matematicamente, além de formular e resolver problemas em contextos variados (Brasil, 2018a).

A BNCC define competência pela mobilização de conhecimentos, habilidades, atitudes e valores para resolver demandas complexas (Brasil, 2018a). Neste trabalho, esse referencial orienta o cuidado de não reduzir competência matemática ao resultado observado em uma única atividade.

Para evitar que medidas distintas fossem tratadas como equivalentes, este trabalho adotou definições operacionais. A avaliação educacional parte de observações produzidas por tarefas e respostas para realizar inferências sobre conhecimentos e habilidades; essas inferências dependem do modelo de cognição, dos instrumentos e dos procedimentos de mensuração empregados (National Research Council, 2001). Em avaliações como o PISA, a proficiência é estimada em uma escala e interpretada por níveis que descrevem o que os estudantes tipicamente conseguem realizar (OECD, 2023a).

Desempenho observado corresponde ao registro diretamente obtido em uma tarefa, como acerto, nota, número de tentativas, estratégia apresentada ou tempo de resolução (National Research Council, 2001). Proficiência estimada corresponde a uma inferência sobre a posição do estudante em uma escala de conhecimentos e habilidades, calculada a partir de um conjunto de evidências e de um modelo de mensuração (National Research Council, 2001; OECD, 2023a). Competência refere-se à mobilização de conhecimentos, habilidades, atitudes e valores para enfrentar situações e resolver problemas (Brasil, 2018a). Por sua vez, aprendizagem designa, operacionalmente neste trabalho, mudanças no que o estudante sabe e consegue fazer ao longo do tempo. Essa delimitação orienta a exigência de acompanhamento e interpretação contextualizada, sem pressupor que um indicador isolado demonstre tais mudanças. A distinção entre o conhecimento do estudante e a observação de sua atuação se apoia no caráter inferencial da avaliação discutido por National Research Council (2001, p. 42–44).

Essas definições são relacionadas, mas não intercambiáveis. Um modelo computacional pode reconhecer padrões nos dados de desempenho e produzir estimativas para um alvo

definido; sua interpretação como proficiência requer um modelo de mensuração e evidências de validade para essa finalidade. Entretanto, o modelo não observa diretamente todos os processos cognitivos, sociais e afetivos envolvidos na aprendizagem. Suas saídas devem ser interpretadas como apoio à análise docente, e não como diagnóstico definitivo do estudante.

2.2 CONTRIBUIÇÕES PEDAGÓGICAS PARA A ESPECIFICAÇÃO

Os referenciais a seguir orientam aspectos distintos da especificação: mediação, conhecimento prévio e uso formativo de evidências.

Vygotsky definiu a Zona de Desenvolvimento Proximal como a distância entre aquilo que o estudante realiza de forma autônoma e aquilo que consegue realizar com mediação (Vygotsky, 1978). Em sua pesquisa sobre tutoria na resolução de problemas, Wood, Bruner e Ross analisaram formas de apoio pedagógico temporário oferecidas ao aprendiz durante a realização de tarefas (Wood; Bruner; Ross, 1976). Neste trabalho, essa contribuição fundamenta a apresentação de evidências ao professor como apoio à interpretação, sem equiparar tutoria à Zona de Desenvolvimento Proximal nem tratar uma saída computacional como medida desse conceito.

Ausubel destacou que novas informações são aprendidas de forma significativa quando se relacionam a conhecimentos relevantes já existentes na estrutura cognitiva do estudante (Ausubel, 1968). A partir desse referencial, o trabalho propõe organizar registros de atividades anteriores e relações curriculares como contexto para a interpretação docente.

A avaliação formativa utiliza evidências produzidas durante o processo de aprendizagem para orientar decisões sobre as próximas ações de ensino e estudo (Black; Wiliam, 1998). A efetividade do retorno pedagógico depende de seu foco, de sua clareza e da forma como ajuda o estudante a compreender os objetivos, avaliar seu estado atual e identificar ações para avançar (Hattie; Timperley, 2007).

Como critério conceitual deste trabalho, uma previsão algorítmica, por si só, não é tratada como retorno pedagógico formativo. Para exercer essa função, ela precisa ser convertida em informação compreensível e útil aos próximos passos de aprendizagem. Professor e estudante devem poder interpretar o retorno e agir sobre ele (Hattie; Timperley, 2007). Esses referenciais orientam decisões de projeto; sua articulação não afirma equivalência entre as teorias nem demonstra eficácia do protótipo.

2.3 TECNOLOGIA COMO APOIO À DECISÃO PEDAGÓGICA

As tecnologias computacionais podem analisar registros educacionais, identificar padrões e apresentar informações para apoiar o acompanhamento de turmas (Romero; Ventura, 2020). Seu valor para a avaliação depende também da qualidade das evidências, da validade das inferências e do contexto de uso; por isso, os resultados não devem ser estendidos além do que os dados sustentam (National Research Council, 2001).

Nesta especificação, as tecnologias são propostas como apoio à decisão, preservando a responsabilidade do professor pela interpretação pedagógica; as previsões devem explicitar suas incertezas e limitações. Também são princípios de projeto o alinhamento das recomendações ao currículo e a prevenção de interpretações que naturalizem desigualdades ou convertam estudantes em categorias fixas, em consonância com a exigência de validade e equidade das inferências educacionais (National Research Council, 2001). Para eventual uso de dados pessoais, a especificação prevê finalidade explícita, minimização e análise da base legal aplicável, conforme a Lei Geral de Proteção de Dados Pessoais (LGPD), sem presumir que o consentimento seja sempre a base adequada (Brasil, 2018b).

2.3.1 Proteção de Dados de Crianças e Adolescentes

Como o corpus inclui estudos do ensino médio, eventual aplicação poderá envolver dados pessoais de crianças e adolescentes. Antes de qualquer tratamento, a hipótese legal aplicável deverá ser definida para o contexto, observando-se o melhor interesse desses titulares previsto no art. 14 da LGPD (Brasil, 2018b). Os dados necessários, a minimização correspondente, os prazos de retenção e eliminação e a identificação do responsável pelo tratamento permanecem a definir. Esta diretriz de projeto não declara conformidade jurídica.

2.4 TÉCNICAS COMPUTACIONAIS NA EDUCAÇÃO

O aprendizado de máquina, ou *machine learning* (ML), é uma área da inteligência artificial (IA) que desenvolve modelos capazes de identificar padrões a partir de dados. Na educação matemática, o estudo de Pejić, Molcer e Gulači (2021) classifica estudantes em três categorias operacionais de desempenho com respostas a itens do PISA computadorizado de 2012. O estudo de Milićević, Marinović e Jeftić (2024) utiliza uma árvore de decisão para classificar resultados de 50 estudantes do primeiro ano de Engenharia Industrial, observados entre 2017 e 2021. Já o trabalho de Zhang, Zhu e Feng (2025) propõe trajetórias de aprendizagem per-

sonalizadas que incluem cursos de Matemática. Esses exemplos identificam alvos e aplicações distintos, examinados no Capítulo 4.

Uma tarefa distinta foi investigada por He et al. (2025): a modelagem preditiva de tamanhos de efeito de tecnologias educacionais para matemática, a partir de dados extraídos de publicações. Nesse componente do estudo, a unidade de análise é a evidência sobre intervenções, e não a proficiência de um estudante. Essa distinção entre alvo e unidade de análise deve orientar a interpretação das aplicações de ML e a escolha de dados para um sistema de apoio docente.

A definição do alvo e da unidade de análise antecede a escolha do algoritmo: estimar categorias de desempenho de estudantes e prever resultados agregados de intervenções são problemas distintos. Árvores de decisão organizam previsões por divisões sucessivas dos atributos dos dados. O *Random Forest* combina previsões de várias árvores, treinadas com amostragem de registros e seleção aleatória de atributos nas divisões (Breiman, 2001). As máquinas de vetores de suporte (SVM) procuram separar classes por uma fronteira com margem ampla; funções de *kernel* permitem representar separações não lineares (Cortes; Vapnik, 1995). Redes neurais combinam unidades parametrizadas em camadas, cujos pesos são ajustados a partir dos dados (James et al., 2021, cap. 10).

A comparação deve incluir um modelo simples de referência, como a predição pela classe majoritária em classificação ou pela média do conjunto de treinamento em regressão. O desbalanceamento de classes ocorre quando suas frequências diferem substancialmente. Nesse caso, a acurácia, definida como a proporção de classificações corretas, pode esconder erros nas classes menos frequentes. Por isso, as métricas devem ser escolhidas conforme o alvo, a distribuição dos dados e os tipos de erro relevantes, com avaliação em dados não utilizados no ajuste do modelo (James et al., 2021, cap. 2, 4 e 5).

Na síntese dos estudos, árvores de decisão (DT) e floresta aleatória (*Random Forest*, RF) são famílias de modelos distintas; redes neurais (RN) e redes neurais multicamadas (MLP, *Multilayer Perceptron*) também são reportadas. O classificador probabilístico *Naive Bayes* (NB) baseia-se na hipótese de independência condicional dos atributos (James et al., 2021, cap. 4). JRip é uma implementação do algoritmo *Repeated Incremental Pruning to Produce Error Reduction* (RIPPER), que aprende regras de classificação (Xu; Frank, s.d.). A sigla CRF designa campos aleatórios condicionais (*Conditional Random Fields*). Aprendizado profundo (DL, *Deep Learning*), aprendizado por reforço (RL, *Reinforcement Learning*), re-

des neurais convolucionais (CNN, *Convolutional Neural Networks*) e otimização por colônia de formigas (ACO, *Ant Colony Optimization*) também aparecem entre os métodos reportados. Esses métodos são examinados conforme o alvo e o contexto de cada estudo, sem pressupor superioridade geral de uma família.

A *Learning Analytics* (LA), ou analítica da aprendizagem, envolve medir, coletar, analisar e apresentar dados sobre estudantes e seus contextos para compreender e apoiar a aprendizagem. A *Educational Data Mining* (EDM), ou mineração de dados educacionais, concentra-se no desenvolvimento e na aplicação de métodos de análise a dados educacionais (Romero; Ventura, 2020).

ML, LA e EDM não são sinônimos. ML designa uma família de métodos de aprendizado a partir de dados, enquanto LA e EDM delimitam campos de investigação e aplicação na educação. Ambos podem empregar ML, estatística e visualização, com sobreposição de métodos e finalidades; a distinção não constitui uma separação rígida entre ferramentas. Neste trabalho, essa relação organiza a leitura das técnicas e de seus usos pedagógicos (Romero; Ventura, 2020).

No escopo desta especificação, associações entre acesso, tempo de resposta e desempenho serão tratadas como padrões observados, não como explicações causais. Conhecimento prévio, familiaridade com a interface, acessibilidade e disponibilidade de conexão são hipóteses contextuais que poderão orientar análises futuras; seus efeitos não foram estimados neste trabalho (National Research Council, 2001).

Sistemas Tutores Inteligentes procuram adaptar a interação ao estado estimado do estudante. A literatura descreve esses sistemas por características como representação do estudante, mecanismos de adaptação, estratégias de orientação e formas de interação (Mousavinasab et al., 2021). Sistemas adaptativos também podem selecionar conteúdos ou ajustar a dificuldade conforme os registros de interação (Xie et al., 2019).

Como princípio de projeto, uma regra adaptativa deverá ser compreensível ao professor e preservar oportunidades de exploração e autonomia. A possibilidade de que uma personalização excessiva ou baseada em dados incompletos limite essas oportunidades é tratada aqui como risco a avaliar, e não como efeito demonstrado pelos estudos reunidos.

Os métodos computacionais devem ser distinguidos das estratégias didáticas que podem acompanhar seu uso. O termo *jigsaw*, empregado na síntese do estudo sobre geometria, identifica uma modalidade de aprendizagem cooperativa: participantes estudam partes do con-

teúdo em grupos de especialistas e compartilham essa aprendizagem com seu grupo de origem (Social Psychology Network, s.d.).

2.4.1 Trabalhos Relacionados

Os trabalhos relacionados exigidos na organização do TCC são apresentados nesta subseção. Opesemowo e Adewuyi (2024) revisaram dez artigos de periódicos sobre IA em educação matemática, de 2015 a 2023, recuperados em Scopus e Google Scholar. A revisão descreve métodos, instrumentos, participantes e ferramentas, com predomínio qualitativo e uso de questionários. Seu foco em aplicações e no contexto da quarta revolução industrial difere da relação entre evidências e requisitos de apoio docente proposta aqui.

Yi et al. (2025) sintetizaram 21 estudos e 40 amostras sobre IA e desempenho matemático na educação básica, a partir de cinco bases e publicações de 2000 a dezembro de 2023. O resumo publicado informa uma metanálise, com efeito geral de 0,343. Aqui, a comparação se restringe ao escopo e ao tipo de síntese informados nesse resumo, sem exame do texto integral. Esta revisão abrange diferentes níveis, finalidades e unidades de análise; sua síntese descritiva não estima o efeito conjunto de uma intervenção. Os trabalhos de Opesemowo e Adewuyi (2024) e Yi et al. (2025) são revisões de outros estudos, utilizadas nesta fundamentação para comparar temas, recortes e formas de síntese. Não integram o corpus empírico de 15 estudos nem acrescentam a esse conjunto os artigos que analisaram.

2.5 AVALIAÇÃO AUTOMATIZADA E MÉTRICAS

Sistemas automatizados podem organizar respostas, calcular indicadores e aplicar regras previamente definidas. Em tarefas de classificação, podem ser empregadas acurácia, precisão, revocação (*recall*), medida F1 (média harmônica entre precisão e revocação) e área sob a curva característica de operação do receptor (ROC, *Receiver Operating Characteristic*) (Romero; Ventura, 2020). A escolha depende do alvo e da distribuição das classes; essas métricas não se aplicam indistintamente à predição de valores contínuos. Elas avaliam o comportamento do modelo e não medem diretamente a qualidade pedagógica da intervenção.

A matriz de confusão organiza as contagens de classes observadas e previstas. Para uma classe examinada, precisão indica a proporção de previsões dessa classe que estão corretas, enquanto revocação indica a proporção de seus casos observados que foi reconhecida. F1 é a média harmônica dessas duas medidas; em problemas multiclasse, sua agregação também pre-

cisa ser especificada. Kappa quantifica a concordância entre duas categorizações, descontando o acordo esperado ao acaso. A interpretação desses indicadores exige preservar a tarefa e a forma de cálculo utilizada pelo estudo, sem adotá-los como medidas de aprendizagem (Scikit-learn developers, 2025).

A curva ROC relaciona a taxa de casos positivos corretamente reconhecidos à taxa de falsos positivos, variando o limiar de decisão; sua área resume a capacidade de discriminação sob essa análise (Fawcett, 2006). A calibração, por sua vez, examina a correspondência entre probabilidades estimadas e frequências observadas dos eventos. Discriminar classes e estimar probabilidades confiáveis são propriedades distintas: uma área ROC elevada não garante, por si só, probabilidades calibradas (Niculescu-Mizil; Caruana, 2005).

No domínio educacional, também podem ser observados acertos e erros por habilidade, tempo e número de tentativas, progressão entre avaliações, participação e conclusão de atividades e explicações ou estratégias registradas pelo estudante.

A interpretação deve considerar o instrumento, a população e a finalidade. Um bom desempenho médio não demonstra, por si só, validade equivalente das inferências entre grupos; por isso, a avaliação proposta inclui análise por classe, validação em dados não utilizados no treinamento e investigação de possíveis diferenças de erro, quando os dados permitirem (National Research Council, 2001).

Como alternativa de mensuração, a Teoria de Resposta ao Item (TRI) relaciona respostas a características dos itens e a uma variável latente. A interpretação em uma escala exige calibração, ajuste do modelo e evidências de validade. O relatório técnico do PISA descreve esses procedimentos e o uso de valores plausíveis para inferências populacionais, que não devem ser transformados em diagnósticos individuais (OECD, 2024, cap. 11, p. 217–225).

O acompanhamento do conhecimento ao longo de interações, ou *knowledge tracing*, responde a outra pergunta. O *Bayesian Knowledge Tracing* (BKT) representa estados por habilidade e suas transições probabilísticas; o *Deep Knowledge Tracing* (DKT) usa redes recorrentes para prever respostas a partir de sequências. Sua saída usual é uma probabilidade condicionada ao histórico, e não automaticamente uma escala de proficiência (Abdelrahman; Wang; Nunes, 2023, seções 2.1.1 e 2.2.1). A escolha entre TRI, BKT e DKT depende de dados por item ou sequência, definição de habilidades, validação e finalidade de uso.

Dessas definições decorrem requisitos para a especificação: apresentar evidências de desempenho, relacioná-las a objetivos curriculares e oferecer explicações compreensíveis ao

professor. Também se exige comunicar incertezas, permitir revisão humana e proteger os dados educacionais. A avaliação técnica deve anteceder qualquer afirmação de eficácia pedagógica.

Esses requisitos foram incorporados à especificação apresentada no Capítulo 5. Dessa forma, a fundamentação não permaneceu apenas como discussão conceitual, mas orientou diretamente as decisões técnicas e pedagógicas consolidadas pelo trabalho.

3 METODOLOGIA

3.1 PROTOCOLO E RELATO DA REVISÃO SISTEMÁTICA

Este trabalho empregou uma Revisão Sistemática da Literatura para identificar e analisar técnicas computacionais aplicadas ao ensino de matemática. O planejamento e os procedimentos da revisão são descritos neste capítulo. O *Cochrane Handbook for Systematic Reviews of Interventions* (Higgins et al., 2024) foi utilizado como referência complementar para organizar a pergunta e os critérios de elegibilidade, com adaptações ao domínio educacional e aos estudos computacionais. O escopo compreendeu a revisão, a apreciação metodológica preliminar dos estudos empíricos incluídos e a elaboração de uma especificação conceitual de protótipo.

Neste relato, registro designa a referência recuperada nas bases durante a identificação e a triagem; relatório, o documento cujo texto completo foi procurado; estudo, a unidade empírica. Os componentes de um mesmo relatório são examinados sem duplicar o estudo ou os dados reutilizados. O corpus empírico apresentado reúne 15 estudos selecionados segundo o corte de relevância 4,0.

O PRISMA 2020 orientou o relato da pergunta, das fontes, dos critérios, do processo de seleção e dos resultados (Page et al., 2021). Trata-se de uma diretriz de relato, distinta de um método de busca ou de avaliação da qualidade. O PRISMA-P 2015 orienta o planejamento e o relato de protocolos (Moher et al., 2015). Seus princípios foram utilizados parcialmente na organização da questão, dos critérios, da estratégia de busca e da forma de síntese. O planejamento inicial está documentado no histórico do repositório, mas não houve registro em plataforma de pré-registro. A consulta complementar ao Handbook não corresponde à adoção integral dos procedimentos de uma revisão Cochrane.

O código e os registros da revisão foram mantidos sob controle de versão em repositório público (Batista, 2026).

A lista de verificação PRISMA 2020 foi preenchida retrospectivamente, após a consolidação do conjunto de dados e decisões analisados. Ela documenta o relato no Apêndice A. O registro de recuperação das fontes e os arquivos de conferência estão reunidos no Apêndice B; o histórico completo das requisições não foi preservado, como discutido na Seção 4.6.

A pesquisa foi conduzida pelo autor no Instituto Federal Catarinense – Campus Videira, com recursos próprios, sem financiamento externo. Não houve entidade financiadora

externa com participação no delineamento, na seleção dos estudos, na análise ou na decisão de disponibilização dos resultados. O autor declara não haver conflitos de interesse relacionados a esta pesquisa.

O planejamento inicial documentado no histórico do repositório considerava publicações de 2015 a 2025 e artigos revisados por pares. Na revisão executada, o período abrangeu 2015 a 2026, com corte em 31 de agosto de 2026, e os tipos documentais incluíram também teses e dissertações, conforme os critérios apresentados neste capítulo. O relato distinguiu a priorização por metadados e resumos da avaliação de elegibilidade em texto completo. A apreciação com o MMAT foi realizada na fase do TCC, por critério, sem escore agregado e sem utilização como regra de exclusão.

3.2 ESTRATÉGIA DE BUSCA

A coleta utilizou interfaces de programação de aplicações (APIs), que permitem consultar serviços externos de forma automatizada. Foram utilizadas Semantic Scholar, fonte multidisciplinar; OpenAlex, catálogo acadêmico aberto; Crossref, fonte de metadados e identificadores de objeto digital (DOI, do inglês *Digital Object Identifier*); e *COnnecting REpositories* (CORE), agregador de publicações em acesso aberto. A combinação buscou ampliar a cobertura e exigiu padronizar títulos, autores e outros metadados dos registros recuperados.

A estratégia combinou domínio matemático, técnica computacional e contexto educacional, conforme o Quadro 1. A expressão configurada conecta essas dimensões por `AND`, mas seu tratamento varia entre as APIs; não foi aplicada uma semântica booleana uniforme. As grafias foram preservadas conforme a configuração executada, inclusive as formas sem acentuação.

A estratégia canônica reuniu 72 consultas: 48 em inglês e 24 em português. Em cada consulta, um termo matemático foi combinado com um termo computacional e um termo educacional. São exemplos `mathematics AND machine learning AND education` e `matemática AND aprendizado de máquina AND educacao`. Esse total descreve a estratégia configurada; a ausência de histórico completo das requisições impede determinar quantas foram concluídas por consulta ou por API e suas datas exatas. O limite configurado foi de até 50 resultados por consulta e por API. Uma passagem pelas 72 consultas e quatro APIs teria, nominalmente, teto de $72 \times 4 \times 50 = 14.400$ resultados antes de deduplicar. Esse valor descreve a configuração, não um limite comprovado do histórico armazenado.

Quadro 1 – Camadas da estratégia de busca bilíngue.

Dimensão	**Inglês**	**Português**
Domínio matemático	mathematics; math	matemática
Técnicas computacionais	adaptive; personalized; tutoring; analytics; mining; machine learning; ai; assessment; student modeling; predictive; intelligent tutor; artificial intelligence	adaptivo; personalizado; tutor; analitica; mineração; aprendizado de máquina; ia; avaliação; modelagem do aluno; preditivo; tutor inteligente; inteligência artificial
Contexto educacional	education; learning	educacao; ensino

Fonte: Elaborado pelo autor (2026).

No Crossref, o coletor retira o texto `AND`, envia os termos à busca bibliográfica, solicita ordenação por relevância e chama uma amostragem de até 100 resultados para obter até 50 itens aceitos. A documentação do serviço define essa amostragem como aleatória; o código não fixa uma semente. Portanto, a resposta não é uma lista reproduzível dos 50 primeiros por relevância (Crossref, 2025). No Semantic Scholar, a expressão é enviada com `AND` literal no campo de consulta. O OpenAlex retira apenas as aspas, preservando `AND`; esses dois clientes não definem um parâmetro de ordenação. O CORE recebe a expressão e ordena os resultados por ano decrescente. O limite restringe os itens que avançam conforme a ordem retornada pelos serviços; no Crossref, atua sobre a amostra.

O cache pode devolver uma coleção anterior sem reaplicar o limite, e as tentativas do coletor Crossref podem acumular respostas. O conjunto preservado contém pares API/consulta com mais de 50 itens, inclusive mais registros Crossref que os 3.600 nominais de uma passagem. Por isso, não se infere do código atual quantas requisições históricas ocorreram nem quais páginas de resultados foram percorridas. Não houve reprocessamento da busca nesta revisão do relato.

3.3 CRITÉRIOS DE SELEÇÃO

Os critérios foram organizados pelas dimensões população, intervenção, comparação, desfechos e desenho de estudo (PICOS), apresentadas no Quadro 2. A organização adapta ao mapeamento educacional as seções 3.2 e 3.3 do capítulo 3 do *Cochrane Handbook*, que articulam PICO à especificação dos desenhos de estudo (McKenzie et al., 2024). A letra S explicita essa última dimensão. Um comparador não foi exigido para todos os estudos computacionais.

Quadro 2 – Dimensões PICOS adaptadas ao escopo da revisão.

Dimensão	**Aplicação ao trabalho**
P – População	Estudantes de matemática em qualquer nível educacional.
I – Intervenção	Aplicação de técnicas computacionais, como aprendizado de máquina, inteligência artificial, analítica da aprendizagem e sistemas tutores inteligentes.
C – Comparação	Abordagens pedagógicas alternativas ou tradicionais, quando disponíveis.
O – Resultados	Desempenho acadêmico, diagnóstico de competências, avaliação ou personalização do ensino, conforme a finalidade declarada no estudo.
S – Desenho de estudo	Estudos empíricos com descrição metodológica e evidências aplicadas.

Fonte: Elaborado pelo autor (2026).

Em relação ao planejamento inicial de 2015 a 2025, a revisão ampliou o intervalo até 2026, com data de corte da busca em 31 de agosto de 2026.

Foram elegíveis artigos de periódicos e trabalhos completos em anais revisados por pares, teses de doutorado e dissertações de mestrado publicados nesse período, com foco explícito em técnicas computacionais aplicadas ao ensino de matemática. A inclusão de teses e dissertações, como literatura cinzenta, permitiu considerar estudos empíricos pertinentes independentemente do tipo de veículo de publicação, sem flexibilizar os critérios de elegibilidade. Para todas as modalidades, exigiu-se a apresentação de dados empíricos ou de relato metodológico sobre desenvolvimento e avaliação de sistemas, em texto redigido em inglês ou português.

Os critérios de exclusão compreenderam metodologia insuficientemente descrita para responder à questão da revisão, foco apenas indireto no ensino ou na aprendizagem de matemática e publicações teóricas sem evidências empíricas compatíveis com o escopo. Também foram considerados inelegíveis editoriais, comentários, erratas e relatórios internos que não correspondessem aos tipos documentais elegíveis, além de textos em idiomas diferentes de inglês e português.

3.4 PROCESSO DE SELEÇÃO

O processo reuniu identificação, deduplicação, triagem, priorização por relevância e verificação de elegibilidade. O Fluxograma 1 apresenta as contagens e distingue essas etapas.

Na identificação, cada registro armazenou, quando disponíveis, título, autores, ano, veículo de publicação, DOI ou endereço eletrônico e resumo. Registros com o mesmo *Digital Object Identifier* (DOI, identificador de objeto digital), após padronização, ou o mesmo *Uniform Resource Locator* (URL, localizador uniforme de recursos) foram reunidos. Essa etapa removeu

27 duplicatas por DOI/URL. Uma reconciliação posterior confirmou manualmente mais dois relatórios já representados, totalizando 29 duplicatas removidas antes da triagem. A auditoria de títulos havia sinalizado 232 excedentes em grupos repetidos; sem evidência de identidade, os demais casos permanecem apenas como candidatos à conferência.

A triagem utilizou regras sobre os metadados e os resumos. Foram registradas 4.314 exclusões por resumo ausente ou com menos de 50 palavras; em 4.093 desses casos, o campo continha "Abstract não disponível". Outras 2.076 exclusões decorreram da ausência dos termos em inglês `method`, `approach`, `experiment`, `study`, `analysis`, `evaluation`, `test` ou `assess`, com exceções para termos de revisão. Esse filtro foi aplicado também aos registros recuperados por consultas em português. Os demais motivos foram não atendimento aos critérios de inclusão, com 2.856 registros; conteúdo não classificado como pesquisa, com 103; conteúdo fora do tema, com 42; e ano de publicação fora do intervalo temporal em dois registros, após conferência das datas descrita no Apêndice B. Esses valores totalizam as 9.393 exclusões de triagem, distintas das 2.464 exclusões na priorização por relevância. O apoio das regras automatizadas e da IA generativa nessas etapas é descrito na Seção 3.7.

A priorização por relevância foi aplicada aos registros que passaram pelas regras iniciais de triagem. A função de pontuação combinou indicadores obtidos do título, resumo e metadados: domínio matemático, com peso 0,3; técnicas computacionais, com peso 0,3; termos de delineamento e avaliação, com peso 0,2; ano de publicação, com peso 0,1; e completude do resumo, DOI e indicação de veículo, com peso 0,1. Esses componentes são sinais lexicais e bibliográficos, não verificações da qualidade metodológica (Batista, 2026).

A função executada limita a soma ponderada ao intervalo nominal de 0 a 10 e arredonda o resultado a duas casas decimais. Nos dados preservados, os escores variaram de 0,0 a 4,5, sem renormalização. O valor 4,0 representa o ponto de corte da soma ponderada: registros com escore igual ou superior a 4,0 permaneceram candidatos à leitura, sujeitos aos demais critérios; os inferiores ao corte foram sinalizados como baixa relevância. O número não representa uma porcentagem de aderência, probabilidade de elegibilidade ou nota de qualidade.

Foi mantido o limiar 4,0 para delimitar o conjunto de estudos analisado. O registro versionado documenta uma exploração de sensibilidade da seleção, apresentada na Seção 4.6. Essa exploração não valida a escolha exata de 4,0 nem substitui a validação do corte por leitura humana de uma amostra contra os critérios de elegibilidade, que não foi realizada. A apreciação metodológica ocorreu separadamente, com o MMAT 2018.

3.5 INFRAESTRUTURA TECNOLÓGICA DA REVISÃO

O fluxo foi implementado em Python. O SQLite armazenou registros e etapas de seleção; Requests realizou a comunicação com as APIs; Pandas apoiou a manipulação e a exportação tabular; e scikit-learn foi utilizada nas análises computacionais auxiliares.

Um *cache* local armazenou respostas obtidas anteriormente. Um acerto ocorre quando uma solicitação é atendida com uma resposta armazenada, sem nova consulta à API. A taxa de acertos depende do histórico de execução e foi interpretada pelos contadores de cada execução, sem ser utilizada como indicador fixo do fluxo.

Consultas, critérios e código foram mantidos sob controle de versão. Os julgamentos MMAT geraram arquivos *Comma-Separated Values* (CSV, valores separados por vírgulas), *HyperText Markup Language* (HTML, linguagem de marcação de hipertexto) e LaTeX. A associação entre avaliação e estudo utilizou título padronizado, ano e primeiro autor. Os arquivos exportados e os comandos permitem conferir o conjunto analisado sem distribuir o banco SQLite; uma nova coleta continua dependente das respostas das APIs.

3.6 AVALIAÇÃO DA QUALIDADE METODOLÓGICA

Os 15 estudos da seleção histórica têm registros de apreciação preliminar com o *Mixed Methods Appraisal Tool* (MMAT), versão 2018 (Hong et al., 2018a). Há texto recuperado para 14; Sokkhey et al. (2020) permanece com respostas MMAT históricas não revalidadas, sem cópia verificável. O instrumento oferece critérios para estudos qualitativos, quantitativos randomizados, quantitativos não randomizados, quantitativos descritivos e de métodos mistos. As adaptações de categoria e os julgamentos por estudo são apresentados na Seção 4.4.

Inicialmente foram registradas as perguntas S1, “Há perguntas de pesquisa claras?”, e S2, “Os dados coletados permitem responder às perguntas de pesquisa?”. Em seguida foram registrados o desenho, os cinco critérios Q1–Q5 correspondentes e as justificativas. Cada critério recebeu Y (“Sim”), N (“Não”) ou *Can’t tell* (CT, “Não é possível concluir com a evidência disponível”). A ausência de avaliação é distinta de CT e não constitui resposta adicional do instrumento.

Os critérios Q1–Q5 dependem da categoria. Em estudos quantitativos descritivos, Q1 examina a estratégia de amostragem; nos não randomizados, examina a representatividade dos participantes em relação à população-alvo. Nos métodos mistos, os critérios abrangem justificativa, integração e interpretação dos componentes, tratamento de divergências e qualidade de

cada tradição metodológica. Cada componente também foi apreciado pela categoria qualitativa ou quantitativa apropriada, conforme o guia (Hong et al., 2018b). Esse procedimento foi aplicado aos trabalhos de Villegas-Ch et al. (2025), Xia et al. (2026) e Echeveria, Bajao e Godinez (2025) sem acrescentá-los como estudos novos.

As respostas foram apresentadas por critério, sem pontuação geral, média, ranking ou categoria de qualidade. Os estudos não foram excluídos em razão do MMAT; as limitações identificadas orientaram a interpretação da síntese. A suficiência da evidência foi distinguida da cobertura da leitura e da disponibilidade do documento. O registro por fonte e critério no Apêndice B identifica informação insuficiente no material examinado, exame ainda incompleto e cópia indisponível; quando o registro público não permite distinguir essas origens, a incerteza é mantida. Esses estados documentais não acrescentam respostas ao MMAT nem alteram os julgamentos. As restrições de acesso, leitura e relato são explicitadas na Seção 4.6.

3.7 USO DE FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

Ferramentas de inteligência artificial generativa apoiaram a redação e a revisão ortográfica, gramatical e de clareza do texto. Também foram utilizadas no desenvolvimento e na revisão do código versionado: scripts de pontuação e processamento, validadores, geração de quadros, site e materiais de apresentação. Esses usos são distintos do emprego de técnicas computacionais nos estudos examinados na revisão.

Na seleção e na apreciação metodológica, o apoio incluiu leitura de títulos, resumos e textos disponíveis, localização de evidências, elaboração de propostas de respostas e justificativas do MMAT e conferência documental por agentes. A conferência incluiu inspeção visual de páginas selecionadas de arquivos em formato *Portable Document Format* (PDF).

Cabe ao autor conferir as fontes, aceitar ou rejeitar as sugestões, verificar o texto e o código incorporados e responder pelas análises, interpretações e argumentos apresentados. Testes, validadores e comparação com os documentos originais apoiam essa verificação, sem substituir o julgamento dos critérios de elegibilidade e do MMAT nem demonstrar eficácia educacional.

O Apêndice E resume as ferramentas, as famílias e versões registradas e as finalidades gerais do apoio. O histórico parcial das interações não permite atribuir cada trecho do texto ou do código a um modelo específico.

O repositório disponibiliza modelos de prompts em <.github/prompts/>, além dos

scripts e critérios versionados (Batista, 2026). Esses arquivos não constituem o histórico completo das conversas ou das instruções utilizadas na pesquisa. A disponibilidade parcial dos prompts e a dependência de versões dos serviços limitam a reprodução das interações com as ferramentas.

3.8 DERIVAÇÃO DA ESPECIFICAÇÃO DO PROTÓTIPO

A especificação do protótipo foi elaborada a partir da integração entre os resultados da revisão sistemática e os princípios pedagógicos discutidos na fundamentação teórica. O procedimento articulou limitações identificadas nos estudos selecionados pela triagem e priorização por relevância, fundamentos teóricos ou normativos e decisões de projeto do autor, sem atribuir todas as dimensões ao corpus. Essa articulação orientou requisitos funcionais e não funcionais e critérios para fontes de dados, alternativas de modelagem, explicabilidade e avaliação; e organizou os requisitos em uma arquitetura conceitual de referência.

Para o OE1, cada estudo foi classificado por uma finalidade principal, definida pelo alvo central do componente matemático: predição/classificação, personalização ou sistema tutor inteligente (STI), intervenção didática, modelagem cognitiva ou integração curricular. Atividades secundárias foram descritas sem duplicar o estudo nas frequências. A matriz registrou família de técnica, nível educacional, tamanho e unidade da amostra, alvo, validação e métrica, preservando informação não reportada e distinguindo métricas de modelo de resultados educacionais. As contagens MMAT foram calculadas por critério e por categoria, sem somar respostas como escore e sem misturar os componentes com os estudos principais.

As decisões foram reunidas em uma especificação técnica e pedagógica, conforme o escopo documental do trabalho.

Na versão vigente, a rastreabilidade entre a revisão e a especificação está consolidada no nível das dimensões e dos requisitos descritos no capítulo. O Quadro 11 explicita a origem dos grupos de requisitos: observações localizadas dos estudos, fundamentos teóricos ou normativos e decisões de projeto do autor. Essa distinção evita atribuir ao corpus requisitos que não foram avaliados empiricamente por seus estudos.

Complementarmente, a implementação exploratória foi utilizada como verificação técnica auxiliar da especificação. Seus testes trabalharam com arquivos temporários sintéticos para conferir contratos de entrada, procedência, construção de atributos históricos apenas com respostas anteriores, separação das partições, cálculos de avaliação e reconstrução das explica-

ções logísticas. O adaptador aceita a versão corrigida do ASSISTments 2009–2010; referências probabilísticas simples, regressão logística e *gradient boosting* permitem exercitar o fluxo de previsão da próxima resposta. Essas escolhas pertencem ao código auxiliar e não definem a base nem o modelo de uma futura aplicação educacional.

A versão examinada e a contagem dos testes estão identificadas no Capítulo 5. As execuções sintéticas não processaram dados educacionais reais nem produziram resultados preditivos ou educacionais sobre uma população. Elas verificam comportamentos técnicos nos casos construídos, preservando a distinção entre a implementação auxiliar e a avaliação da especificação pelo protocolo proposto no OE4.

4 REVISÃO SISTEMÁTICA DA LITERATURA

Este capítulo apresenta a seleção, a caracterização dos estudos e a apreciação metodológica. As limitações da revisão e dos resultados examinados estão reunidas ao final.

4.1 FLUXO DE SELEÇÃO

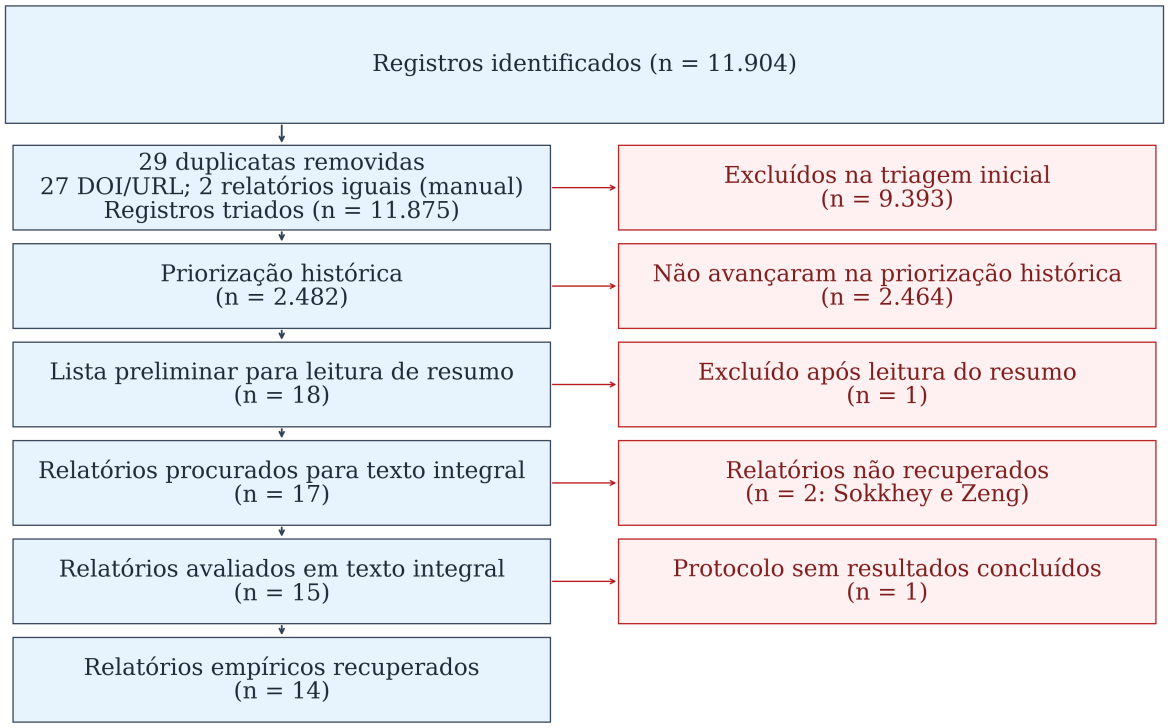
O Fluxograma 1 apresenta uma representação adaptada do processo de seleção, elaborada com referência ao PRISMA 2020. Ele distingue a priorização pelo corte de relevância da avaliação de elegibilidade em texto completo: a priorização não equivale a essa avaliação. Inicialmente foram identificados 11.904 registros. Na reconciliação de 31/10/2026, foram removidas 29 duplicatas: 27 por identidade DOI/URL e duas por confirmação manual de relatórios já representados. Dos 11.875 registros únicos triados, 9.393 foram excluídos e 2.482 avançaram à priorização. Na seleção pelo corte 4,0, 2.464 não avançaram: 2.459 por escore e cinco por critérios de escopo; 18 formaram a lista preliminar. Um registro foi excluído após resumo. Dos 17 relatórios procurados, dois não foram recuperados: Sokkhey et al. (2020) e Zeng (2025). Quinze foram avaliados em texto completo; o protocolo de Imperatrice et al. (2025) foi excluído por não apresentar resultados concluídos. A seleção histórica mantém 15 estudos empíricos, dos quais 14 têm texto recuperado; Sokkhey permanece apenas como inclusão histórica, sem cópia verificável.

4.2 ESTATÍSTICAS DESCRITIVAS

A Tabela 1 reúne os principais números da revisão. A deduplicação inicial retirou 27 registros por DOI/URL; a reconciliação posterior confirmou mais dois relatórios repetidos, chegando a 29 remoções antes da triagem. A auditoria por título havia sinalizado 232 excedentes em grupos repetidos; os casos sem confirmação de identidade permanecem sem remoção automática. A proporção dos 15 estudos selecionados em relação aos registros identificados descreve o processo realizado e não estima a prevalência de estudos elegíveis na literatura.

Os percentuais têm os seguintes denominadores: 29 remoções correspondem a 0,24% dos 11.904 registros identificados; 9.393 exclusões na triagem correspondem a 79,10% dos 11.875 registros únicos triados; e 2.464 exclusões na priorização por relevância correspondem a 99,27% dos 2.482 registros submetidos a essa etapa. Considerando o mesmo denominador de 2.482 registros, as 2.459 exclusões por escore correspondem a 99,07%; outras

Fluxograma 1 – Fluxo de seleção da revisão sistemática.



Fonte: Elaborado pelo autor (2026), com base em Page et al. (2021). Dois relatórios não foram recuperados; Sokkhey permanece na seleção histórica de 15 estudos, sem cópia verificável. Os 14 relatórios empíricos recuperados não incluem o protocolo excluído após avaliação.

cinco exclusões por critérios de escopo completam as 2.464 exclusões dessa etapa. Os dois filtros de resumo e de termos metodológicos respondem, respectivamente, por 36,33% (4.314) e 17,48% (2.076) dos registros triados, totalizando 53,81% (6.390). As categorias descrevem o primeiro motivo atribuído pelo processamento, sem dupla contagem.

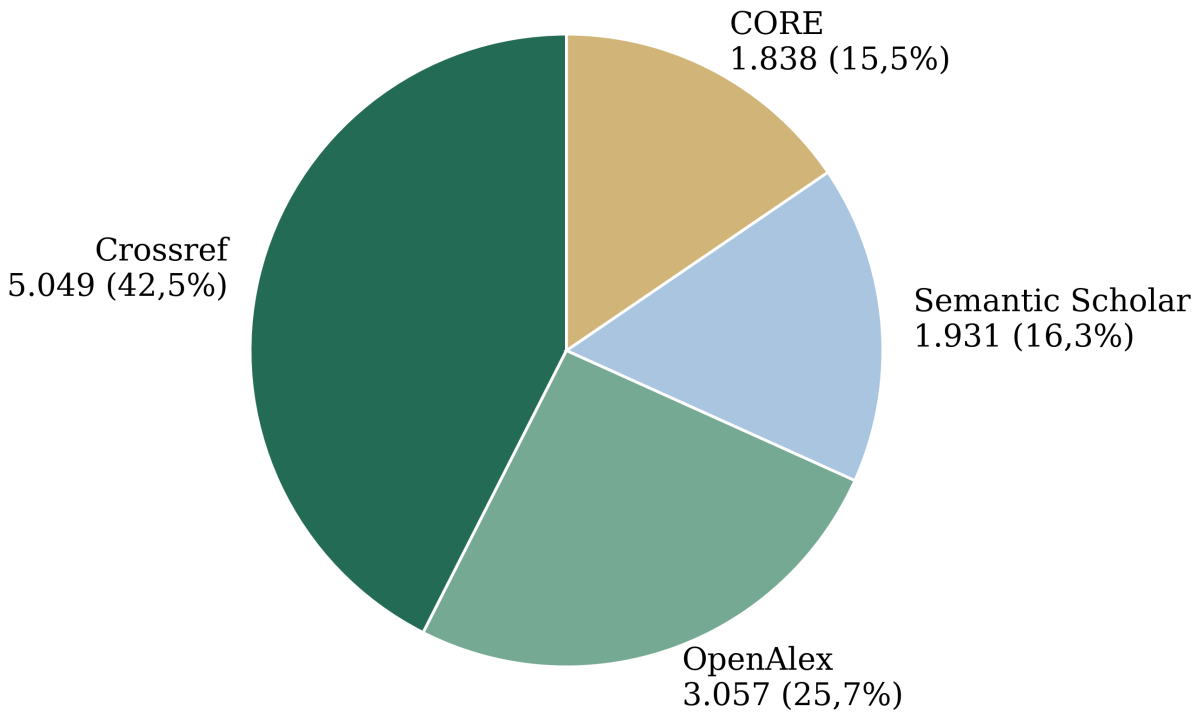
A distribuição por fonte é apresentada no Gráfico 1. O gráfico considera os 11.875 registros únicos após a reconciliação de 29 duplicatas, e não os 11.904 registros identificados. A fonte indicada é a origem da versão mantida de cada registro. A distribuição não mede a cobertura exclusiva de cada base nem a qualidade dos estudos. As quantidades e proporções foram calculadas a partir dos arquivos exportados, sem nova coleta.

Tabela 1 – Estatísticas descritivas da revisão sistemática.

Métrica	**Valor**
Registros identificados	11.904
Duplicatas removidas (27 DOI/URL; 2 revisadas manualmente)	29 (0,24%)
Registros únicos na triagem	11.875
Excluídos na triagem	9.393 (79,10%)
Registros submetidos à priorização por relevância	2.482
Não avançaram na priorização por relevância	2.464 (99,27%)
Dos quais, por escore abaixo de 4,0	2.459 (99,07%)
Registros na lista preliminar	18
Excluídos após triagem do resumo	1
Relatórios procurados após triagem do resumo	17
Relatórios não recuperados	2
Relatórios avaliados em texto completo	15
Protocolos excluídos após texto completo	1
Relatórios empíricos recuperados	14
Estudos empíricos mantidos na seleção histórica	15
Bases consultadas	4
Expressões de busca configuradas	72 (48 em inglês + 24 em português)
Período de cobertura	2015–2026

Fonte: Elaborado pelo autor (2026). A seleção histórica mantém 15 estudos empíricos; 14 têm texto recuperado e Sokkhey permanece sem cópia verificável. Zeng não integra os 15.

Gráfico 1 – Registros após a remoção de duplicatas, por fonte científica.



Fonte: Elaborado pelo autor (2026).

4.3 CARACTERIZAÇÃO DOS ESTUDOS INCLUÍDOS

O conjunto selecionado pelo corte 4,0 reúne 15 estudos empíricos de predição/classificação, personalização/STI, intervenção didática, modelagem cognitiva e integração curricular. Entre as técnicas descritas estão *Random Forest*, SVM, árvores de decisão e redes neurais. Os preditores incluem notas, respostas a itens, características contextuais e registros de interação. As frequências refletem a seleção histórica de 15 estudos: 14 têm texto recuperado, e Sokkhey et al. (2020) permanece como inclusão histórica sem cópia verificável do texto integral.

O Quadro 3 caracteriza esses estudos e apresenta também os outros três registros da lista preliminar, totalizando 18. Sua última coluna distingue inclusão, exclusão e texto não recuperado. Xia et al. (2026) foi incluído segundo os critérios escritos, que não exigem personalização como condição. O protocolo de Imperatrice et al. (2025) foi excluído por não apresentar resultados concluídos. As informações sobre Zeng (2025) provêm do resumo institucional.

As diferenças entre populações, instrumentos, variáveis e desenhos impedem tratar os resultados como medidas de um mesmo fenômeno ou transferi-los diretamente ao protótipo. Não há medida harmonizada de efeito. A Seção 4.6 detalha essas restrições.

O estudo de Xia et al. (2026, p. 7–8, 12–14, 18, 24–25) descreve uma reforma do ensino universitário de matemática aplicada à medição industrial de carbeto de silício (SiC). O estudo integra a Transformada de Fourier e um questionário adaptativo que os autores denominam baseado em IA. A análise de componentes principais (PCA), relatada na seção 4.3.2, examina a estrutura dos dados do questionário (Xia et al., 2026, seção 4.3.2).

Quadro 3 – Caracterização e situação dos 18 registros selecionados preliminarmente.

Autores/Ano	**Tema e finalidade**	**Abordagem**	**Avaliação**	**Situação no fluxo e síntese**
Tjahyadi e Tude (2025)	Predição de desempenho acadêmico em matemática. Finalidade: Predição	EDM; ML; classificadores	Acurácia	Incluído. O estudo reporta 75% de acurácia de teste; a interpretação é delimitada na discussão subsequente
Pejić, Molcer e Gulači (2021)	Classificação em três categorias operacionais de desempenho, denominadas pelos autores níveis de proficiência e construídas a partir das respostas ao PISA 2012 computadorizado. Finalidade: Predição e avaliação	Rede neural; *Random Forest*; seleção de atributos	Kappa; revocação (*recall*); área sob a curva ROC (ROC-AUC)	Incluído como estudo de avaliação, não de intervenção. O artigo relata 58.753 registros após seleção e resultados de classificação; a descrição diverge sobre o uso do conjunto de teste na interrupção antecipada (*early stopping*), impedindo confirmar a independência da avaliação de teste

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
He et al. (2025)	Tecnologia educacional para matemática. Finalidade: Otimização e decisão	EDM; IA; modelos preditivos	Meta-análise; modelagem; comparação escolar	Incluído. O texto distingue síntese de literatura, predição de tamanhos de efeito e aplicação escolar
Villegas-Ch et al. (2025)	Tutoria inteligente em ciência, tecnologia, engenharia e matemática (STEM). Finalidade: Retorno pedagógico personalizado	IA; aprendizagem adaptativa	Desempenho; análise estatística	Incluído. A interpretação permanece restrita ao contexto e às janelas temporais relatadas
Sokkhey et al. (2020)	Desempenho em matemática no ensino médio. Finalidade: Predição	EDM; ML; métodos estatísticos	Comparação entre modelos, sem conferência do artigo original	Inclusão histórica; relatório não recuperado. As respostas MMAT anteriores são preservadas sem revalidação; não se afirma conferência atual do texto integral
Kumar et al. (2022)	Notas de Matemática e Língua Portuguesa analisadas separadamente. Finalidade: Predição	DT; JRip; NB; MLP; RF; seleção de atributos pela avaliação de subconjuntos com um classificador	Acurácia em classificações binária e de cinco classes	Incluído, com PDF conferido. Há resultados de matemática separáveis, mas faltam detalhes de amostragem e validação; tabelas e narrativa apresentam inconsistências
Özseven e Özseven (2026)	Desempenho em matemática on-line. Finalidade: Predição	ML; modelo que combina redes neurais e lógica difusa	Desempenho preditivo	Incluído. A transferência do modelo para o protótipo não foi demonstrada
Zhang, Zhu e Feng (2025)	Trajetórias personalizadas em cursos de Matemática, Chinês e Inglês. Finalidade: Personalização	Aprendizagem profunda; grafo de conhecimento; aprendizagem por reforço; análise de sentimento	Taxa de melhoria do efeito de aprendizagem de 15%; redução do tempo de 20%; satisfação de 4,2/5, conforme os autores	Incluído como proposta de personalização. A taxa é definida pelos autores pela diferença relativa entre ganhos médios dos grupos; faltam amostra, alocação, análise inferencial e incerteza. As reduções de tempo variam entre comparações; os valores não sustentam efeito causal ou generalizável
Zhang (2024)	Currículo de matemática superior apoiado por IA. Finalidade: Personalização	ACO; CNN; CRF; grafo de conhecimento	Análise estatística; retorno pedagógico	Incluído. O relato é usado para caracterizar personalização curricular, não eficácia transferível
Depren, Aşkın e Öz (2017)	Classificação de desempenho no Estudo Internacional de Tendências em Matemática e Ciências (TIMSS, *Trends in International Mathematics and Science Study*) 2011. Finalidade: Classificação	RF; J48; *Naive Bayes*; MLP; regressão logística	Classificação	Incluído. A descrição textual da validação em 10 dobras inverte treino e teste; limitação discutida adiante

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
Uskov et al. (2019)	Analítica preditiva em cursos de Ciência da Computação e Sistemas de Informação, conforme texto integral.	Modelos preditivos de nota final; percepções dos estudantes	Sem desfecho matemático separada-mente avaliado; matemática aparece em trabalho futuro	Exclusão por escopo registrada após resumo e confirmada no texto integral recuperado em 20/10/2026. Sem MMAT; a conferência posterior não altera as contagens PRISMA
MacLellan (2017)	Modelagem computacional da aprendizagem em frações e equações. Finalidade: Simulação e predição qualitativa	Modelos comparados com registros de tutoria	Ajuste de modelos; critério de informação de Akaike (AIC); critério de informação Bayesiano (BIC)	Incluído como uma tese/um relatório de modelagem computacional, com categoria 4 adaptada e limitações explícitas. Frações reutilizadas entre capítulos não são contadas duas vezes; resultados de sete domínios não são exclusivamente matemáticos. A contribuição é delimitada às tarefas examinadas e não demonstra eficácia do protótipo
Milićević, Marinović e Jeftić (2024)	Classificação de aprovação, reprovação ou resultado condicional em Matemática para 50 estudantes do primeiro ano de Engenharia Industrial, observados entre 2017 e 2021.	Árvore de decisão	Acurácia reportada de 72%	Incluído como exemplo de predição/avaliação, não de intervenção. O artigo não descreve validação treino/teste ou cruzada para este modelo; a passagem sobre *k-fold* refere-se a outro estudo citado
Xia et al. (2026)	Matemática universitária e desenvolvimento sustentável. Finalidade: Integração curricular	Questionário adaptativo descrito como IA; Transformada de Fourier; análise de componentes principais (PCA) aplicada ao questionário	Desempenho, questionário e entrevistas	Incluído sob os critérios amplos do protocolo; resultados não isolam o efeito da IA e grupos de estudantes de anos diferentes limitam inferência causal
Echeveria, Bajao e Godinez (2025)	Mentalidade matemática e intervenção precoce. Finalidade: Classificação de mentalidade	EDM; NB; SVM; MLP	Acurácia	Incluído. A divergência sobre os grupos e anos letivos analisados e a sobreposição entre itens do desfecho e preditores limitam a interpretação
Nyantah, Frempong e Larbi (2025)	Teoremas de círculo. Finalidade: Ensino de geometria	Animação computacional; aprendizagem cooperativa	Delineamento experimental descrito de modo inconsistente	Incluído. O relato diverge sobre alocação aleatória; a intervenção combina componentes

Continua na próxima página

Quadro 3 – Continuação

Autores/Ano	Tema e finalidade	Abordagem	Avaliação	Situação no fluxo e síntese
Imperatrice et al. (2025)	Ensino inclusivo de matemática. Finalidade: Protocolo de estudo	Protocolo/ proposta	Não aplicável: sem resultados concluídos	Excluído da síntese empírica após texto completo por não apresentar resultados empíricos concluídos; não recebe apreciação MMAT de estudo concluído
Zeng (2025)	Carga cognitiva durante resolução de problemas matemáticos, conforme o resumo institucional.	Eletroencefalografia (EEG) e rastreamento ocular; regressão logística e SVM, conforme o resumo	Delineamento com comparação de condições nos mesmos participantes em duas fases, conforme o resumo	Pendente: texto integral da tese não recuperado; MMAT não aplicado. Desenho, algoritmos e resultados são atribuídos ao resumo, não tratados como verificados no texto integral

Fonte: Elaborado pelo autor (2026).

Em Tjahyadi e Tude (2025, p. 155–156, 160), o alvo é a categoria da nota escolar de matemática, em uma amostra de 280 estudantes de uma escola privada. Os registros correspondem à quarta série em 2017/2018, enquanto o desfecho é a nota de Matemática na conclusão do ensino primário em 2020/2021. Os autores descrevem uma divisão de 70% para treinamento e 30% para teste e reportam 75% de acurácia de teste para a combinação da técnica SMOTE (*Synthetic Minority Oversampling Technique*) e do algoritmo RUSBoost (*Random Under-Sampling Boost*). Na mesma comparação, a revocação da classe de baixo desempenho é de 43%. A primeira técnica gera exemplos sintéticos para classes menos frequentes; o segundo algoritmo combina redução aleatória das classes mais frequentes e treinamento sucessivo de classificadores.

Em He et al. (2025, p. 1, 16, 31–35), o artigo reúne três componentes: a síntese meta-analítica de 423 publicações, a predição de tamanhos de efeito e a aplicação escolar em oito turmas. As publicações examinadas pelos autores não foram adicionadas como registros da presente revisão, e o alvo da modelagem foi o tamanho de efeito de uma intervenção, não a proficiência individual. As inconsistências de denominador e de unidade de análise da aplicação escolar são examinadas na Seção 4.6.

A tese de MacLellan (2017, p. 44–48, 56) contribui como referência conceitual e metodológica para a modelagem computacional da aprendizagem. Nas tarefas de frações, compara simulações com registros de tutoria previamente coletados no DataShop para 79 estudantes e prevê qualitativamente efeitos de sequenciamentos instrucionais, não escores absolutos de de-

sempenho no tutor ou em pós-teste. Em análise distinta sobre resolução de equações, descreve dados de 71 estudantes e 10.052 passos; a análise utiliza 4.568 passos nos quais os estudantes executaram as próprias ações. A nota 5 esclarece que o subconjunto inclui os passos de estratégia em que o estudante escolhe a transformação; ficam fora somente os passos em que o tutor executa os cálculos (MacLellan, 2017, p. 56).

O estudo de Pejić, Molcer e Gulači (2021, p. 50–53) classifica estudantes em três categorias operacionais de desempenho com dados do PISA 2012 computadorizado. O estudo de Milićević, Marinović e Jeftić (2024, p. 4–5) utiliza uma árvore de decisão e reporta 72% de acurácia para estudantes de um único curso e instituição. Já o trabalho de Zhang, Zhu e Feng (2025, p. 650, 653–654) propõe trajetórias personalizadas e reporta melhoria de 15% no efeito de aprendizagem, definida pela diferença relativa entre ganhos médios dos grupos. O artigo também relata redução de tempo de 20% e satisfação de 4,2/5.

4.3.1 Matriz de Categorização do OE1

A finalidade principal foi atribuída ao componente matemático central de cada estudo. Predição/classificação reúne alvos como nota, classe de desempenho, acerto ou mentalidade; personalização/STI reúne seleção de trajetória, recurso e retorno adaptativo. Intervenção didática examina o uso de recursos em uma situação de ensino; modelagem cognitiva examina mecanismos computacionais relacionados a registros humanos; integração curricular articula conteúdo matemático e contexto de aplicação. A categorização não confirma o desenho nem o efeito da intervenção.

No estudo de He et al. (2025), a finalidade principal corresponde à aplicação escolar apreciada no MMAT; a predição de efeitos de tecnologias é registrada como finalidade secundária. A tese de MacLellan (2017) conta uma vez, sem duplicar frações reutilizadas entre capítulos. Sokkhey et al. (2020) mantém a finalidade histórica indicada pelo título e registro, com os demais campos não reconferidos. O nível e o tamanho amostral preservam as unidades informadas, sem total de participantes agregado.

Quadro 4 – Finalidade, técnica e população dos estudos incluídos.

Estudo	**Finalidade principal**	**Família de técnica**	**Nível e n (unidade)**
Pejić, Molcer e Gulači (2021)	Predição/classificação	Rede neural *feedforward*/ MLP e *Random Forest*; seleção manual/RF/ qui-quadrado/eliminação recursiva; SMOTE no treino.	Escolar, avaliação internacional PISA 2012 computadorizada; 271.323 registros CBA iniciais; 58.753 estudantes no conjunto analítico.
Tjahyadi e Tude (2025)	Predição/classificação	Dez classificadores (árvores, discriminante, SVM, regressão logística, KNN, redes e combinações de modelos); combinação SMOTE/RUSBoost destacada.	Ensino primário, escola privada; atributos da quarta série e nota de conclusão da sexta; 280 estudantes; 33 atributos originais, 48 colunas após codificação.
Sokkhey et al. (2020)	Predição/classificação	EDM, ML e métodos estatísticos, conforme registro histórico; algoritmos específicos não reconferidos.	Ensino médio, escolas do Camboja, conforme metadados/ histórico; Não reconferido; fonte primária indisponível.
Kumar et al. (2022)	Predição/classificação	DT, RF, *Naive Bayes*, MLP e JRip; seleção *wrapper* de atributos.	Ensino secundário, duas escolas portuguesas; Matemática e Português separados; Dimensão amostral não informada suficientemente; não importar n da UCI por suposição.
Zhang, Zhu e Feng (2025)	Personalização/STI	Grafo de conhecimento; perfis por redes profundas/ RNN; aprendizagem por reforço e análise de sentimento.	Não informado suficientemente; cursos de Matemática, Chinês e Inglês; Não informado; amostragem, alocação e origem humana/ simulada dos resultados incertas.
Depren, Aşkın e Öz (2017)	Predição/classificação	RF, J48, *Naive Bayes*, MLP e regressão logística.	Oitavo ano, Turquia, TIMSS 2011; atributo idade 13-16; 6.928 originais; 678 excluídos por dados ausentes/inexatos; 6.250 analíticos.
Zhang (2024)	Personalização/STI	Grafo/perfil; ACO e CNN para trajetórias; TransR e CRF semissupervisionado/ KNN para recursos.	Primeiro ano universitário, duas turmas de Gestão Financeira, Matemática Superior; 120 iniciais; 50 experimentais e 52 controles válidos; 18 casos sem explicação.
MacLellan (2017)	Modelagem cognitiva	Arquitetura Apprentice Learner; modelos DECISION TREE e TRESTLE; simulações e modelos mistos binomiais.	Frações e equações em dados educacionais secundários; tarefas de caixas e setas com participantes recrutados via Mechanical Turk. Níveis heterogêneos; Frações: 79; equações: 71 estudantes, 10.052 passos disponíveis e 4.568 analisados; caixas e setas: 202 participantes. Não somar bases nem frações reutilizadas.

Quadro 4 – Continuação

Estudo	Finalidade principal	Família de técnica	Nível e n (unidade)
Milićević, Marinović e Jeftić (2024)	Predição/classificação	Árvore de decisão podada, MATLAB.	Primeiro ano de Engenharia Industrial, Universidade de East Sarajevo; 50 estudantes; dados de 2017-2021.
Nyantah, Frempong e Larbi (2025)	Intervenção didática	Animação computacional e aprendizagem cooperativa *jigsaw*; não experimento de ML.	Segundo ano senior high school/Form2, Matemática eletiva, duas escolas públicas de Ghana; 196; 95 *jigsaw*/ animação, 101 tradicional; uma escola por condição.
He et al. (2025)	Intervenção didática	Escolar: GeoGebra e duração orientada por modelo. Outros componentes: meta-análise e regressão/EDM, incluindo XGBoost.	Escolar: ensino secundário/ geometria analítica, escola no sudeste da China; literatura: K-12; Literatura: 423 estudos/ efeitos, não participantes ou novas inclusões do TCC. Escolar: oito turmas de 45, mas total declarado90; não reconciliado.
Villegas-Ch et al. (2025)	Personalização/STI	STI; *deep learning*/NLP, *transformers*/RNN/BERT; modelos supervisionados DNN/SVM descritos; *feedback*/sequência adaptativos.	Universitário STEM: Matemática, Física e Programação; 450 no conjunto STEM; n específico de Matemática/grupos não estabelecido nas passagens. Entrevistas com estudantes/ educadores, n não suficientemente localizado.
Özseven e Özseven (2026)	Predição/classificação	ANFIS/neuro-fuzzy, RF e XGBoost; saídas contínuas, híbrido ponderado, *stacking*/ regressão logística e limiares binários.	ASSISTments descrito para middle/high school; recorte analítico não suficientemente delimitado; n final de estudantes/interações não localizado; filtros menos de5 e limite1000, perdas não quantificadas.
Xia et al. (2026)	Integração curricular	Fourier aplicado à metrologia SiC; questionário adaptativo denominado IA; PCA para estrutura do questionário. Algoritmo ML não identificado nas passagens.	Segundo ano universitário, Measurement and Control Technology/Advanced Mathematics; Controle2021 n94; pós-reforma2025 n89; 12 entrevistados do experimental, sem somá-los como novos participantes.
Echeveria, Bajao e Godinez (2025)	Predição/classificação	K-means para categorias; Boruta; SVM/NB/MLP; entrevistas docentes.	Junior high school, uma escola nas Filipinas; 633 recrutados,428 completos,5 docentes; métodos2023-2024 versus resultados2022-2023 não reconciliados.

Fonte: Elaborado pelo autor (2026).

Quadro 5 – Alvos, validação e métricas dos estudos incluídos.

Estudo	**Alvo**	**Validação e fonte**	**Métrica ou resultado reportado**
Pejić, Molcer e Gulači (2021)	Três classes operacionais derivadas da razão pontos obtidos/máximos nos itens matemáticos; não são níveis oficiais do PISA ou escala individual validada.	Partição 70/30; seleção de atributos declarada só no treino; subdivisão treino/ validação da RN. Outra passagem afirma monitorar teste no parada antecipada, impedindo confirmar independência (páginas físicas 2–5, Tabelas IV–VI).	RN/eliminação recursiva: acurácia denominada *macro-average* pelos autores 78,39% e F1 0,68 (Tabela IV). Kappa máximo 0,46 (Tabela VI); agregações distintas.
Tjahyadi e Tude (2025)	Low/Medium/High da nota matemática da sexta série; dados da quarta em 2017/2018 e desfecho em 2020/ 2021.	Partição 70/30; validação em cinco partes no treino; reamostragem declarada no treino (páginas físicas 2–3 e 7–8, Tabelas 8–9).	SMOTE+Ensemble RUSBoosted Trees: teste 75%; classe Low recall 43%, precisão 67%, F-measure 52% (Tabela 8). Validação 92% é outra etapa.
Sokkhey et al. (2020)	Desempenho matemático conforme título; operacionalização não reconferida.	Não reconferida (registro histórico; fonte primária não reconferida).	Não reconferida; nenhum valor ratificado nesta versão.
Kumar et al. (2022)	Nota final em aprovação/reprovação ou cinco classes.	Protocolo próprio de partição/validação não especificado suficientemente (páginas físicas 2–5, Tabelas 6 e 8).	Matemática: Tabela 6, DT multiclasses 85,62% antes e 88,75% após *wrapper*; Tabela 8, RF binária 93,49% antes e 94,10% após.
Zhang, Zhu e Feng (2025)	Selecionar próximo nó da trajetória segundo conhecimento, progresso e emoção; ganhos, tempo e satisfação.	Comparação com filtragem colaborativa e rede rasa; sem partição, alocação, análise inferencial ou incerteza suficientes (páginas físicas 1–5, Tabela I).	Ganhos relativos reportados: aprendizagem 15%, tempo 20%; satisfação 4,2/5. Sem incerteza suficiente.
Depren, Aşkın e Öz (2017)	MATHACH binário: primeira valor plausível acima de 500 ou não.	Dez dobras declaradas; texto diz uma dobra treino/nove teste. Não determina se erro de relato ou execução (páginas físicas 4–5, 9 e 11).	Regressão logística: kappa 0,4885; RMSE 0,3885 (Tabela 3); F-measure ponderada 0,779 e ROC-AUC 0,817 (Tabela 4).
Zhang (2024)	Trajetórias/recursos personalizados; pré/ pós de Matemática e percepções.	Comparação pré/pós entre turmas; alocação não localizada; p basal 0,583 não prova equivalência (páginas físicas 9–12, Tabelas 1–6).	Experimental 63,795 para 75,631; controle 62,865 para 66,314. Narrativa usa também 74,631; pré-teste com gl=80 não reconciliado com 50+52.
MacLellan (2017)	Comportamento/curvas humanos e efeitos qualitativos de sequenciamento; ajuste de mecanismos computacionais.	Agentes recebem problemas na ordem dos registros; curvas/resíduos e ajuste. Não é nova intervenção humana prospectiva; sete domínios não são todos matemáticos (páginas impressas 44–48 e 52–56).	Frações: AIC 9.512,8 (TRESTLE) e 9.521,3 (árvore); ajuste de curvas e predições instrucionais qualitativas, não escala de proficiência.

Quadro 5 – Continuação

Estudo	**Alvo**	**Validação e fonte**	**Métrica ou resultado reportado**
Milićević, Marinović e Jeftić (2024)	Resultado matemático anual fail/conditional/ pass; preditores incluem notas de outras disciplinas e atividades.	Não localizado protocolo próprio treino/teste ou validação cruzada; passagem k-fold descreve outro estudo (páginas físicas 4–7).	Acurácia reportada 72%, erro 28%; não apresentar como teste independente.
Nyantah, Frempong e Larbi (2025)	Pré/pós em teoremas de círculo.	Pré/pós e Mann-Whitney; §2.4 declara sorteio de escolas, §2.7 nega alocação aleatória. Comparações separadas não ajustam medida inicial/escola (páginas físicas 10–15, Tabela 3).	Pré-teste: U=6.714, p inferior a 0,001, efeito 0,346; pós: U=7.948,5, p inferior a 0,001, efeito 0,568. Comparações não ajustadas.
He et al. (2025)	Escolar: resultados após 18 períodos com GeoGebra. Modelagem: tamanho de efeito de tecnologia educacional, não proficiência individual.	Dois controles/seis experimentais, testes t pré/ pós; seis efeitos escolares revalidam modelo. Professor confundido com condição; agrupamento por turma não esclarecido (páginas físicas 11–16 e 31–35, Tabelas 11–13).	Aplicação: Hedges g entre 0,727 e 0,764 nos seis grupos (Tabela 13). Não contar como seis estudos novos.
Villegas-Ch et al. (2025)	Feedback, sequência, precisão, progresso, sucesso em problemas, tempo e percepções; construtos distintos.	Experimental/controle, t/ ANOVA e entrevistas temáticas; recrutamento/ alocação/completude insuficientes. Semestre na introdução, seis semanas métodos, semana8 somente Programação (páginas físicas 2, 13–16 e 19–26).	Tabela4 Matemática: precisão do feedback80,2% para88,7%, melhoria relativa10,6%. Tabela3 global STEM88,5% versus76,3%; não atribuir somente a Matemática.
Özseven e Özseven (2026)	correct de cada interação estudante-problema; não proficiência global ou classe validada de risco.	60/20/20 por estudante; cada estudante em único subconjunto declarado. Disponibilidade temporal dos atributos e validade dos construtos exigem esclarecimento (páginas físicas 3–4, 7 e 10–12).	ANFIS: acurácia 0,922063, revocação de acerto 0,9962. Híbrido ponderado: RMSE 0,2414. Tarefas e agregações distintas.
Xia et al. (2026)	Integração matemática/ indústria/ sustentabilidade; experiência de aula, apoio, ativação cognitiva e estrutura disciplinar; entrevistas.	Coortes não contemporâneas; testes t; alfa/KMO/Bartlett/PCA do questionário não validam mecanismo de personalização. Não significância basal não prova equivalência (páginas físicas 7–8, 12–14 e 18–19; leitura parcial).	Questionário: tamanhos de efeito de -0,38 a 0,67 nas quatro dimensões. Alfa 0,906; KMO 0,643. Não mede efeito isolado da IA.

Quadro 5 – Continuação

Estudo	Alvo	Validação e fonte	Métrica ou resultado reportado
Echeveria, Bajao e Godinez (2025)	Quatro categorias de mentalidade derivadas de questionário; não domínio matemático ou resposta à intervenção.	Relato menciona dois terços,80/20 e dez dobras; execução final incerta. Oito itens do alvo permanecem nos preditores (páginas físicas 3 e 6–12).	SVM: 83/84=98,8%, Kappa 0,98. Matriz MLP tem total impresso 84 e colunas somando 86; não harmonizada.

Fonte: Elaborado pelo autor (2026).

Tabela 2 – Frequência da finalidade principal no corpus de 15 estudos.

Finalidade	Estudos (n)
Predição/classificação	8
Personalização/STI	3
Modelagem cognitiva	1
Intervenção didática	2
Integração curricular	1
Total	15

Fonte: Elaborado pelo autor (2026).

4.4 AVALIAÇÃO METODOLÓGICA COM O MMAT

Os Quadros 6 e 7 apresentam respostas preliminares S1/S2 e critérios específicos para os 15 estudos empíricos. A organização segue o artigo e o guia do instrumento (Hong et al., 2018a, 2018b). Os critérios são apresentados separadamente, sem média, ranking ou categoria geral de qualidade.

S1 e S2 são perguntas de triagem; Q1–Q5 são critérios da categoria utilizada. Y significa “Sim”, N significa “Não” e CT significa “Não é possível concluir” para um critério examinado. O travessão indica ausência de avaliação, distinta de CT. A tese de Zeng (2025) não foi apreciada por falta do texto integral. Imperatrice et al. (2025) permanece fora do corpus por apresentar um protocolo sem resultados concluídos.

A categoria 3 foi utilizada para examinar as comparações quantitativas de Zhang, Zhu e Feng (2025) e Zhang (2024), com alocação desconhecida. Em Zhang, Zhu e Feng (2025), S2 ficou CT porque a origem humana ou simulada dos resultados não foi confirmada; Q1–Q5

permanecem CT. Para Nyantah, Frempong e Larbi (2025), a categoria 2 segue a declaração de sorteio das escolas, embora contraditória no artigo. A categoria 4 foi adaptada à modelagem computacional da tese de MacLellan (2017).

Os componentes qualitativos e quantitativos de Villegas-Ch et al. (2025), Xia et al. (2026) e Echeveria, Bajao e Godinez (2025) foram apreciados separadamente, sem contar estudos adicionais. Os quadros são gerados pelos arquivos descritos no Apêndice B. As restrições de acesso, leitura e relato são discutidas na Seção 4.6.

Quadro 6 – Triagem e apreciação preliminar pelo MMAT 2018 de 15 estudos do corpus.

Estudo	Desenho	S1	S2	Q1	Q2	Q3	Q4	Q5
Pejić, Molcer e Gulači (2021)	Quant. descritivo	Y	Y	Y	CT	CT	CT	CT
Tjahyadi e Tude (2025)	Quant. descritivo	Y	Y	Y	CT	CT	CT	Y
Sokkhey et al. (2020)	Quant. descritivo (*)	Y	Y	CT	CT	CT	CT	CT
Kumar et al. (2022)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT
Zhang, Zhu e Feng (2025)	Cat. 3 utilizada (alocação incerta)	Y	CT	CT	CT	CT	CT	CT
Depren, Aşkın e Öz (2017)	Quant. descritivo	Y	Y	Y	CT	CT	CT	CT
Zhang (2024)	Cat. 3 utilizada (alocação incerta)	Y	Y	CT	CT	CT	CT	CT
MacLellan (2017)	Cat. 4 adaptada (modelagem)	Y	Y	Y	CT	CT	CT	CT
Milićević, Marinović e Jeftić (2024)	Quant. descritivo	Y	Y	CT	CT	CT	CT	CT
Nyantah, Frempong e Larbi (2025)	Cat. 2 declarada (contraditória)	Y	Y	CT	N	Y	CT	CT
He et al. (2025)	Quant. não rand. (componente escolar)	Y	Y	CT	Y	CT	N	Y
Villegas-Ch et al. (2025)	Métodos mistos	Y	Y	Y	Y	CT	CT	CT
Özseven e Özseven (2026)	Quant. descritivo	Y	Y	Y	CT	CT	CT	Y
Xia et al. (2026)	Métodos mistos	Y	Y	Y	Y	N	Y	N
Echeveria, Bajao e Godinez (2025)	Métodos mistos	Y	Y	Y	Y	N	Y	N

Fonte: Elaborado pelo autor (2026).

Nota: S1/S2 = perguntas de triagem; Q1–Q5 = critérios da categoria; Y = sim; N = não; CT = não é possível concluir; Quant. = quantitativo; rand. = randomizado. (*) Sokkhey et al. (2020): julgamentos históricos e preliminares, não reconferidos nesta versão. Ver Seção 3.6.

Quadro 7 – Componentes qualitativos e quantitativos dos estudos de métodos mistos.

Estudo	Componente	C1	C2	C3	C4	C5	Localização na fonte
Villegas-Ch et al. (2025)	Quant. não rand.	CT	CT	CT	CT	CT	Páginas físicas 2 (450 estudantes e semestre letivo), 13–16 (delineamento, medidas e análise), 18–23 (resultados; semana 8 na p. 22) e 24–27 (testes e limites)

Continua na próxima página

Quadro 7 – Continuação

Estudo	Componente	C1	C2	C3	C4	C5	Localização na fonte
Villegas-Ch et al. (2025)	Qualitativo	Y	Y	CT	CT	CT	Páginas físicas 16–17 (Qualitative Analysis); 24–25 (satisfação quantitativa, não dados de entrevista)
Xia et al. (2026)	Quant. não rand.	CT	Y	CT	N	CT	Páginas físicas 7–8 (§4.1.1), 12–14 (§4.3–4.4.1, tabela 4) e 24 (§6)
Xia et al. (2026)	Qualitativo	Y	Y	CT	Y	CT	Páginas físicas 18 (§4.4.8) e 24 (§6)
Echeveria, Bajao e Godinez (2025)	Quant. descritivo	Y	CT	N	CT	CT	Páginas físicas 3/impressa 65 (§2.1–2.3), 6/68 (§2.6) e 7–8/69–70 (resultados)
Echeveria, Bajao e Godinez (2025)	Qualitativo	Y	Y	CT	Y	CT	Páginas físicas 3/impressa 65 (§2.1 e coleta), 11–12/73–74 (falas docentes) e 13/ 75 (conclusões)

Fonte: Elaborado pelo autor (2026).

Nota: C1–C5 = critérios da categoria; Y = sim; N = não; CT = não é possível concluir; Quant. = quantitativo; rand. = randomizado. Justificativas completas no Apêndice D; ver Seção 3.6.

Na tese de MacLellan (2017, p. 44–49, 52–56), a apreciação considera um relatório com componentes matemáticos distintos, sem duplicar os registros de frações reutilizados entre capítulos. S1, S2 e Q1 receberam Y; Q2–Q5 permaneceram CT na categoria 4 adaptada à modelagem computacional.

Em Zhang (2024, seção 4.1, p. 9–11 e Tabela 2), os cinco critérios da categoria 3 receberam CT, mantendo a alocação desconhecida. Para Nyantah, Frempong e Larbi (2025, p. 101–105), a execução da randomização recebeu CT e a comparabilidade inicial recebeu N. Os mesmos tamanhos por grupo nas tabelas pré e pós sustentaram Y provisório para completude dos testes reportados; cegamento e adesão permaneceram CT.

Em He et al. (2025, p. 1, 16, 31–35), a apreciação se restringe ao componente escolar, classificado como quantitativo não randomizado. Os demais componentes do artigo não integram essa unidade de avaliação. Essa categoria inclui controle de confundidores e administração da intervenção conforme planejada (Hong et al., 2018a).

Nos métodos mistos, Q4 corresponde ao critério 5.4, para o qual o guia orienta responder Y quando não há divergência entre os resultados quantitativos e qualitativos (Hong et al., 2018b, p. 7). Em Xia et al. (2026, p. 14, 18), as entrevistas corroboram o resultado negativo em gestão de sala ($d = -0{,}38$), sem divergência declarada entre os componentes; por isso, Q4 recebeu Y. A interpretação de luta produtiva provém de quatro dos 12 entrevistados. A adaptação

relatada até a terceira semana não explica por que a gestão de sala permaneceu inferior à do grupo de controle na avaliação pós-curso. Q3 permanece N pela extrapolação para ganhos de longo prazo, que Q4=Y não valida.

Em Echeveria, Bajao e Godinez (2025, p. 69, 73–75), Q3 recebeu N porque a conclusão associa ao modelo melhora do desempenho matemático sem medir esse efeito. Essa interpretação ultrapassa as percepções docentes e o potencial descritos na seção 3.3.4; recomendar um estudo de impacto não resolve a extrapolação da seção 4.2. Q4 recebeu Y pela concordância docente com as categorias e pela ausência de conflito declarado entre os componentes. Não se esclarece se o consenso envolve os mesmos docentes das entrevistas nem se abrange os grupos iniciais ou as previsões finais.

4.4.1 Síntese das Respostas por Critério

O Quadro 8 conta respostas por critério e categoria, mantendo as rubricas específicas do MMAT. Entre os 15 registros, S1 recebeu Y nos 15; S2 recebeu Y em 14 e CT em um, para Zhang, Zhu e Feng (2025), porque a origem humana ou simulada dos resultados não foi confirmada. Na categoria quantitativa descritiva (oito estudos, incluindo uma adaptação à modelagem), representatividade, medidas e não resposta receberam CT nos oito; a análise recebeu CT em seis e Y em dois. Nos três não randomizados, representatividade e completude receberam CT nos três. O critério de confundidores recebeu N em um e CT em dois. A categoria randomizada mantém N para comparabilidade inicial, sem confirmar o sorteio adequado. Nos três mistos, a integração recebeu Y; a interpretação recebeu dois N e um CT, e o tratamento de divergências recebeu dois Y e um CT.

Quadro 8 – Respostas MMAT por critério e categoria de desenho.

Categoria	**Critério**	**Y**	**N**	**CT**	**n**
Triagem (todos os estudos)	S1	15	0	0	15
Triagem (todos os estudos)	S2	14	0	1	15
Métodos mistos	Q1	3	0	0	3
Métodos mistos	Q2	3	0	0	3
Métodos mistos	Q3	0	2	1	3
Métodos mistos	Q4	2	0	1	3
Métodos mistos	Q5	0	2	1	3
Quantitativo descritivo	Q1	5	0	3	8
Quantitativo descritivo	Q2	0	0	8	8
Quantitativo descritivo	Q3	0	0	8	8
Quantitativo descritivo	Q4	0	0	8	8

Quadro 8 – Continuação

Categoria	Critério	Y	N	CT	n
Quantitativo descritivo	Q5	2	0	6	8
Quantitativo não randomizado	Q1	0	0	3	3
Quantitativo não randomizado	Q2	1	0	2	3
Quantitativo não randomizado	Q3	0	0	3	3
Quantitativo não randomizado	Q4	0	1	2	3
Quantitativo não randomizado	Q5	1	0	2	3
Quantitativo randomizado	Q1	0	0	1	1
Quantitativo randomizado	Q2	0	1	0	1
Quantitativo randomizado	Q3	1	0	0	1
Quantitativo randomizado	Q4	0	0	1	1
Quantitativo randomizado	Q5	0	0	1	1

Fonte: Elaborado pelo autor (2026).

Quadro 9 – Contagens separadas dos componentes dos três estudos mistos.

Categoria do componente	Critério	Y	N	CT	n
Qualitativo	C1	3	0	0	3
Qualitativo	C2	3	0	0	3
Qualitativo	C3	0	0	3	3
Qualitativo	C4	2	0	1	3
Qualitativo	C5	0	0	3	3
Quantitativo descritivo	C1	1	0	0	1
Quantitativo descritivo	C2	0	0	1	1
Quantitativo descritivo	C3	0	1	0	1
Quantitativo descritivo	C4	0	0	1	1
Quantitativo descritivo	C5	0	0	1	1
Quantitativo não randomizado	C1	0	0	2	2
Quantitativo não randomizado	C2	1	0	1	2
Quantitativo não randomizado	C3	0	0	2	2
Quantitativo não randomizado	C4	0	1	1	2
Quantitativo não randomizado	C5	0	0	2	2

Fonte: Elaborado pelo autor (2026).

Essas contagens descrevem a suficiência da evidência disponível ao revisor, além das restrições concretas registradas como N. Informação insuficiente nas passagens examinadas, exame incompleto e indisponibilidade de uma cópia verificável têm origens distintas. O registro por fonte e critério no Apêndice B distingue essas situações e indica quando a cobertura pública não permite atribuir uma origem ao CT. Não constituem escore, não tornam as rubricas Q1–Q5 equivalentes e não demonstram que o procedimento ausente no relato não tenha ocorrido.

Os componentes qualitativos e quantitativos foram contados à parte, dentro dos mesmos três estudos, sem ampliar o corpus. As adaptações de categoria e a fonte histórica não reconferida permanecem qualificadas nas avaliações individuais e na seção de Limitações.

4.5 TENDÊNCIAS E LACUNAS

Os estudos examinados apresentam tendências temáticas que relacionam técnicas computacionais a finalidades distintas, da predição de resultados à organização de trajetórias e recursos de ensino. A leitura conjunta destacou a necessidade de explicitar denominadores, unidades de análise, alocação, medidas iniciais, duração e relação entre rótulos e preditores. Esses aspectos orientaram requisitos de documentação dos dados e de avaliação da especificação.

As dimensões técnicas, éticas e pedagógicas, incluindo equidade, participação docente e integração curricular, orientaram requisitos de projeto em articulação com a fundamentação. Essa discussão é conceitual e não corresponde a uma extração sistemática codificada por dimensão em cada um dos 15 estudos. Como esses aspectos não foram codificados de modo comparável em todos os estudos, permanecem questões propostas para investigação, sem estimativa de frequência ou atribuição de ausência a toda a literatura. A reprodutibilidade também orientou decisões de projeto, sem estimativa de frequência no corpus.

4.6 LIMITAÇÕES E CONTRIBUIÇÕES DA REVISÃO

A cobertura da revisão depende das fontes, dos idiomas e das regras de seleção. Foram aceitos textos em português e inglês, mas as APIs e a ordenação dos resultados condicionam a cobertura. Não houve consulta direta à Scientific Electronic Library Online (SciELO), à Biblioteca Digital Brasileira de Teses e Dissertações (BDTD) ou ao Education Resources Information Center (ERIC). A escolha das quatro fontes limita a cobertura temática e linguística. O corte nominal em 50 resultados por consulta/API trunca a recuperação conforme relevância, ano ou amostragem, sem garantia de exaustividade. A amostragem aleatória sem semente fixa na coleta via Crossref significa que repetir a consulta não garante obter os mesmos registros. O histórico incompleto das requisições impede reconstruir toda a busca ou afirmar a data de última consulta a cada fonte. A estratégia configurada e as contagens do conjunto analisado não demonstram recuperação exaustiva da literatura.

Na triagem, 4.314 registros foram excluídos por resumo ausente ou com menos de 50 palavras; em 4.093 deles o campo registrava “Abstract não disponível”. Esse subconjunto de

4.093 registros corresponde a 34,47% dos 11.875 registros únicos e a 43,58% das 9.393 exclusões de triagem. Não se estimou a sensibilidade dessa regra nem se desagregaram esses casos por fonte ou idioma. Outras 2.076 exclusões decorreram da ausência dos termos metodológicos em inglês, filtro aplicado também às consultas em português e equivalente a 17,48% dos registros triados. Resumo ausente ou curto e ausência desses termos não demonstram falta de método; as regras podem produzir falsos negativos.

O registro público da exploração de sensibilidade informa 13 registros classificados como elegíveis entre os 45 examinados por censo na faixa de escore 3,75–3,95; 29 entre os 54 examinados por seleção dirigida na faixa 3,50–3,74; e cinco entre os 30 de uma amostra aleatória estratificada na faixa 3,00–3,49 (Batista, 2026). Esses denominadores pertencem ao levantamento original, preservado antes das correções posteriores de duplicatas e anos. As classificações registradas são exploratórias; a seleção dirigida não permite estimar a frequência de elegíveis em toda a sua faixa. Casos incertos ou sem texto recuperado não foram tratados como inelegíveis, e registros não equivalem necessariamente a estudos distintos.

O OE2 foi atendido nos termos formulados: limitações de recuperação, seleção e relato metodológico foram codificadas sistematicamente, enquanto os eixos técnico, pedagógico e ético foram discutidos conceitualmente, sem extração sistemática comparável por estudo.

A ocorrência de registros classificados como elegíveis abaixo de 4,0 indica possível perda de cobertura. Essa exploração não estima a sensibilidade de toda a busca ou dos filtros anteriores à pontuação, nem valida o corte por leitura humana de uma amostra. O limiar 4,0 e o corpus foram mantidos, sem reprocessamento da busca ou alteração dos filtros. Os 15 estudos compõem a seleção pelo corte de relevância 4,0. A priorização por metadados e resumos tampouco equivale à elegibilidade por texto completo.

O protocolo não foi registrado prospectivamente. O PRISMA 2020 orientou o relato e o PRISMA-P contribuiu parcialmente para o planejamento. Não foi aplicado teste formal de viés de publicação. A disponibilidade desigual dos textos completos restringe a síntese. A heterogeneidade de desenhos, populações e métricas impediu uma síntese quantitativa conjunta e a comparação de eficácia entre intervenções. O número de participantes não foi agregado por falta de unidades e denominadores comparáveis.

A seleção e a apreciação preliminar com o MMAT contaram com apoio de regras automatizadas e de IA generativa nas atividades descritas na Seção 3.7. A inclusão no corpus não comprova leitura integral dos textos, figuras e apêndices. A pertinência temática também

não substitui os critérios do instrumento: CT expressa insuficiência da evidência disponível, sem concluir automaticamente que o estudo tem baixa qualidade. As categorias utilizadas provisoriamente não confirmam delineamentos, e os julgamentos não foram convertidos em escore agregado ou síntese final de qualidade. Em estudos descritivos, mencionar comparação entre modelos não demonstra análise estatística apropriada sem a descrição do procedimento.

Nos estudos preditivos, a pertinência da fonte à pergunta foi distinguida da representatividade da população. A apreciação das medidas não certifica construtos mais amplos nem eficácia pedagógica. Nos componentes qualitativos, a adequação da coleta foi distinguida da forma como as categorias foram obtidas na análise, da sustentação das interpretações e da coerência do processo.

A análise por subgrupos e a avaliação de equidade não foram operacionalizadas: os dados disponíveis ao protótipo não contêm as variáveis necessárias para essa análise. Seu desenvolvimento futuro depende da disponibilidade de dados apropriados e da definição da base legal aplicável.

O texto integral de Zeng (2025) não foi recuperado e está sob embargo até 16 de maio de 2027, conforme o repositório; sua elegibilidade e apreciação MMAT permanecem pendentes. Para Sokkhey et al. (2020), foram mantidas a inclusão e as respostas históricas, sem cópia verificável para revalidação atual. Sua ficha não representa texto integral conferido nesta revisão; os CT anteriores não permitem atribuir insuficiência ao relato do artigo. A recuperação posterior de Uskov et al. (2019) confirmou a exclusão já registrada na triagem do resumo, sem alterar as contagens ou criar nova etapa. O Apêndice B distingue recuperação, leitura e extração automática de texto.

As limitações descritas a seguir dizem respeito à evidência disponível ao revisor nas passagens examinadas, com as restrições de acesso e leitura registradas por fonte. Uma informação não localizada nessa cobertura não é automaticamente uma omissão do estudo. As divergências não foram corrigidas por inferência nem atribuídas automaticamente à execução dos procedimentos. Resultados preditivos, explicações de modelos e métricas de desempenho foram interpretados em seus contextos, sem equivalência automática com aprendizagem ou eficácia pedagógica.

Em Depren, Aşkın e Öz (2017, p. 1613), a descrição da validação cruzada de dez dobras afirma que uma dobra é usada no treinamento e nove no teste. Essa distribuição inverte a partição usual de uma dobra de teste e nove de treinamento. Sem código ou dados processados,

não se determina se a inversão ocorreu apenas no relato ou também na execução; Q5 permanece como “Não é possível concluir”. A diferença entre famílias gerais de classificadores no resumo e algoritmos específicos na configuração experimental não comprova divergência entre os modelos.

Kumar et al. (2022, p. 1014–1017) apresenta classificações binária e de cinco classes, com resultados separados para matemática e português. Faltam detalhes suficientes sobre dimensão das amostras, atributos selecionados e validação. As acurácias atribuídas a *Naive Bayes* na conclusão correspondem a *Random Forest* na Tabela 8. A Tabela 7 contém reduções para alguns classificadores, contrariando a afirmação de melhoria em todos os casos. O relato limita a comparação, sem comprovar vazamento de dados ou falha executada.

Em Tjahyadi e Tude (2025), o horizonte entre os registros escolares e o desfecho precisa orientar a interpretação da predição. Esse desfecho não representa uma medida contemporânea de competência. A diferença entre acurácia agregada e revocação da classe de baixo desempenho impede caracterizar uniformemente as três classes. O experimento de classificação não demonstra ganho de aprendizagem decorrente de uma intervenção.

Em Pejić, Molcer e Gulači (2021), as três categorias operacionais não têm equivalência demonstrada com os níveis oficiais do PISA. A redução de 271.323 registros iniciais para 58.753 não é suficientemente explicada, e o relato diverge sobre o uso do conjunto de teste no treinamento. Não foi possível confirmar a independência da avaliação de teste. O estudo de Milićević, Marinović e Jeftić (2024) analisou 50 estudantes do primeiro ano de Engenharia Industrial entre 2017 e 2021, sem descrever validação independente para o classificador. A passagem sobre *k-fold* refere-se a outro estudo citado.

Em Zhang, Zhu e Feng (2025), faltam informações sobre amostra, alocação, análise inferencial e incerteza. A melhoria de aprendizagem, a redução de tempo e a satisfação são resultados reportados pelos autores; não sustentam inferência causal ou generalizável. As reduções de tempo também variam entre as comparações. Em Zhang (2024), foram informados 120 estudantes, com desfecho válido para 50 no grupo experimental e 52 no controle. O resultado basal $p = 0{,}583$ não demonstra equivalência. A comparação pré-teste informa 80 graus de liberdade para o teste *t*, embora os grupos com desfecho válido somem 102 participantes; o texto não reconcilia a diferença. Não foi localizado o procedimento de alocação nem uma explicação para os 18 casos sem desfecho válido.

A tese de MacLellan (2017) reúne análises com dados humanos preexistentes e não

uma avaliação prospectiva. As amostras de frações e de equações não formam um único grupo. O exame se restringiu aos componentes matemáticos dos capítulos 5 e 6, sem atribuir à matemática os resultados agregados de sete domínios. A categoria 4 foi adaptada para examinar a seleção de estudantes e tarefas, as medidas comparativas, a completude e a análise das simulações e dos registros humanos. Essa adaptação não confirma um desenho apenas descritivo, pois a tese também testa hipóteses. Não certifica ausência de vazamento de dados, separação independente de treino e teste, calibração, validação externa, estabilidade das explicações, validade de construtos educacionais ou eficácia pedagógica. Esses domínios exigem exame específico e não recebem certificação a partir das respostas MMAT registradas.

Em He et al. (2025, p. 1, 16, 31–35), a descrição da aplicação escolar informa oito turmas com 45 estudantes cada, o que corresponde a 360 estudantes por cálculo aritmético, enquanto o artigo declara amostra total de 90. O texto consultado não reconcilia esses denominadores. Os autores também descrevem quatro professores: um responsável pelas duas turmas de controle e os demais pelas turmas experimentais. Nas páginas examinadas, não foi identificado ajuste para a possível mistura entre efeito do professor e condição experimental. O artigo reporta testes *t* independentes para grupos de 45 estudantes, mas organiza as condições por turma e não informa se a análise considera esse agrupamento. Por isso, não se pode reconstruir se a análise tratou estudantes ou turmas como observações, nem a precisão das comparações.

Em Villegas-Ch et al. (2025, p. 2, 14, 22), a introdução descreve a avaliação em um semestre acadêmico. A seção de métodos informa um período experimental de seis semanas. Já os resultados apresentam, na subanálise de programação, progresso até a oitava semana para estudantes com alta interação. O relato não reconcilia essas janelas temporais. O resultado de programação não permite fixar uma duração única nem pode ser transportado para matemática. Já o estudo de Nyantah, Frempong e Larbi (2025, p. 101–105) apresenta descrições incompatíveis sobre a alocação das escolas: um trecho informa distribuição aleatória, e outro caracteriza o desenho como quase-experimental sem alocação aleatória. Na Tabela 3 (p. 105; página física 15), os autores reportam diferença estatisticamente significativa entre os grupos já no pré-teste ($U = 6714$, $Z = 4{,}839$, $p < 0{,}001$, tamanho de efeito=0,346) (Nyantah; Frempong; Larbi, 2025, Tabela 3, p. 105). Esse desequilíbrio inicial, somado à intervenção combinada de animação computacional e aprendizagem cooperativa, impede atribuir a diferença pós-teste exclusivamente à intervenção ou isolar a contribuição da animação.

Em Echeveria, Bajao e Godinez (2025, p. 65, 69–70), a seção de métodos situa a

matrícula no ano letivo de 2023–2024. A seção 3.1 associa os 633 estudantes ao ano letivo de 2022–2023, sem esclarecer se são grupos distintos de estudantes. Além disso, oito itens da escala de mentalidade matemática utilizados para formar as categorias também permanecem entre os preditores selecionados. O relato não estabelece, por si só, validade diagnóstica independente da classificação; por isso, o resultado não sustenta inferência de mudança na aprendizagem nem de efeito de uma intervenção precoce. A seção 3.1 informa 428 casos completos entre os 633 estudantes inicialmente descritos. A Tabela IX, na página impressa 73 (física 11), apresenta outra incompatibilidade: os totais de coluna somam 86, enquanto o total impresso é 84 (Echeveria; Bajao; Godinez, 2025). Essa divergência impede reconstruir o denominador da matriz MLP sem esclarecimento e não se estende automaticamente às métricas dos demais classificadores.

Em Xia et al. (2026), a comparação usa um grupo de controle de 2021 (n=94) e um grupo pós-reforma de 2025 (n=89), separados por quatro anos. Na seção 6, os autores afirmam que os testes de equivalência da linha de base não identificaram diferenças estatisticamente significativas ($p > 0{,}05$), sem apresentar ali estatísticas detalhadas (Xia et al., 2026, seção 6). Esse resultado de não significância não demonstra equivalência entre os dois grupos. Mudanças ocorridas entre os anos comparados podem se misturar ao efeito da intervenção, incluindo alterações de equipe e contexto reconhecidas no artigo. Os resultados não isolam o efeito do questionário ou da IA. A análise de componentes principais examina a estrutura do questionário, não seu mecanismo de personalização. Não foi identificado algoritmo de aprendizado de máquina nas passagens examinadas, sem que isso demonstre sua ausência em todo o artigo. As passagens consultadas não permitem classificar o estudo como evidência de ML nem sustentar eficácia generalizável de tutoria personalizada. A leitura foi parcial.

Em Nyantah, Frempong e Larbi (2025), duas escolas, uma por condição, e comparações pré/pós separadas impedem separar adequadamente intervenção, escola e diferenças iniciais. A escolha da categoria 2 preserva a contradição entre a declaração de sorteio e a negação de atribuição aleatória em outra seção.

A interpretação de erros e acertos considera a natureza da tarefa e a estratégia utilizada; a ausência de acerto, isoladamente, não demonstra ausência de compreensão. A descrição da modalidade cooperativa *jigsaw* também não confirma que todas as suas condições tenham sido verificadas no estudo incluído.

A especificação permaneceu documental. Não incluiu uma aplicação educacional funcional, treinamento com uma base definitiva ou validação com participantes; consequen-

temente, não produziu métricas próprias de acurácia nem evidência de eficácia pedagógica. O protocolo proposto para o OE4 ainda não foi aplicado. A implementação exploratória e os testes sintéticos disponíveis não substituem essa avaliação.

A implementação exploratória foi testada com dados sintéticos. Nenhum arquivo educacional real foi processado e nenhum modelo foi treinado com dados educacionais reais. O uso técnico do formato ASSISTments não seleciona a base empírica definitiva nem representa estudantes brasileiros. As saídas dos testes não constituem uma escala de proficiência validada. A análise documental não comprova custo de execução, utilidade prática ou alinhamento curricular validado. Métricas preditivas e explicações descrevem o comportamento do modelo; não identificam causas da dificuldade do estudante.

A revisão fundamentou requisitos de seleção de dados, validação, explicabilidade e interpretação docente, apresentados no Capítulo 5.

5 ESPECIFICAÇÃO DO PROTÓTIPO

Este capítulo apresenta a especificação conceitual do protótipo elaborada a partir dos resultados da revisão sistemática e da fundamentação pedagógica. O artefato produzido consolidou princípios de projeto, requisitos funcionais e não funcionais, critérios para fontes de dados e modelos, um protocolo de avaliação e uma arquitetura de referência.

O repositório também contém uma implementação técnica do fluxo automatizado do protótipo, acompanhada por testes sintéticos automatizados. Essa implementação verifica comportamentos de processamento e de proteção contra falhas nos casos sintéticos testados, mas não equivale a uma execução com dados educacionais reais, a uma validação de eficácia preditiva ou a uma avaliação de aprendizagem. O capítulo, portanto, descreve a especificação que orienta uma futura execução e mantém essa implementação técnica separada de qualquer alegação de resultado educacional.

A implementação examinada está em <prototype/>, na versão `1195b2a` do repositório. Essa versão contém 35 funções de teste em nove arquivos; a parametrização resulta em 44 casos sintéticos executados. A contagem se refere a essa versão do código e não a avaliações educacionais ou participantes.

5.1 PRINCÍPIOS E REQUISITOS

A especificação estabelece que o protótipo deverá apoiar a decisão pedagógica sem substituir o professor. Essa decisão de projeto implica distinguir, na representação e na interpretação dos resultados, o desempenho observado em uma atividade, a proficiência estimada por um modelo, a competência mobilizada em um contexto mais amplo e a aprendizagem como possível mudança ao longo do tempo. Uma interpretação longitudinal da aprendizagem demandaria especificação adicional. O histórico de respostas e a partição temporal existentes no código organizam evidências anteriores e a avaliação preditiva; não constituem acompanhamento de uma trajetória de mudança da aprendizagem.

As estimativas deverão ser acompanhadas de explicações, limitações e condições de validade compreensíveis para seus destinatários. A revisão humana deverá permanecer integrada ao uso das recomendações, de modo que o professor possa confrontar as evidências com o contexto da turma e decidir se há fundamento para uma intervenção.

A proteção dos dados educacionais constitui outro princípio da especificação. O

uso deverá estar associado a uma finalidade explícita, com minimização dos dados pessoais e controle de acesso compatível com essa finalidade. Também deverá ser possível reproduzir e auditar os procedimentos de preparação, treinamento e avaliação por meio do registro das versões, dos parâmetros e das dependências relevantes. A especificação também rejeita rótulos permanentes que convertam uma estimativa situada em característica fixa do estudante.

Como parte do corpus inclui estudos do ensino médio, uma aplicação poderá envolver dados de crianças e adolescentes. Se houver esse tratamento, a base legal aplicável deverá ser definida para o contexto e o melhor interesse dos titulares deverá ser observado, conforme o art. 14 da LGPD (Brasil, 2018b). A minimização necessária, os prazos de retenção e eliminação e a identificação do responsável pelo tratamento permanecem a definir. Essas condições documentais não declaram conformidade jurídica.

No plano funcional, a futura implementação deverá importar dados documentados e relacionados a objetivos curriculares, preservando os metadados necessários à leitura de sua procedência. A partir desses dados, deverá organizar evidências de desempenho por habilidade ou descritor, de modo que a análise mantenha relação explícita com o contexto curricular em que os registros foram produzidos.

Na etapa de análise, o protótipo deverá produzir estimativas para um alvo educacional explicitamente definido, acompanhadas de incertezas e limitações, e apresentar resultados individuais e agregados ao professor. Uma probabilidade preditiva de acerto ou de pertencimento a uma classe de desempenho não será denominada proficiência apenas por resultar de um modelo computacional. A interpretação como proficiência exigirá um modelo de mensuração, uma escala e evidências de validade para o uso pretendido, em consonância com a distinção entre observação e inferência discutida por National Research Council (2001, p. 42–44). Essas saídas deverão explicar as variáveis relacionadas a cada estimativa. Por fim, deverá exportar dados, parâmetros e resultados para auditoria das versões, decisões e saídas.

No plano não funcional, a especificação estabelece condições de qualidade e de governança para a implementação futura. A reprodutibilidade deverá ser assegurada pelo registro das versões dos dados, dos parâmetros, dos modelos e das dependências. Complementarmente, a rastreabilidade deverá permitir associar cada resultado à fonte de dados utilizada e à versão do experimento que o produziu. Essa associação é necessária para que uma conclusão possa ser examinada sem perder sua procedência.

A testabilidade deverá ser favorecida pela separação entre ingestão, preparação, mo-

delagem, avaliação e apresentação. A portabilidade, por sua vez, exigirá um ambiente de execução documentado e passível de reprodução. Essas condições permitem verificar e repetir os procedimentos em diferentes formas de implementação.

Os requisitos também abrangem a relação do protótipo com seus usuários e com os dados tratados. A apresentação deverá ser acessível, compreensível e compatível com diferentes perfis de usuário. A privacidade deverá orientar a minimização de dados pessoais e o controle de finalidade e de acesso. Por fim, a transparência deverá exigir que as limitações dos modelos e as condições de validade das estimativas sejam comunicadas junto aos resultados, evitando que a forma de apresentação atribua uma certeza que o procedimento não sustenta.

A escolha de fontes de dados permanece condicionada à documentação disponível, ao problema de pesquisa e às condições de execução que vierem a ser definidas. A especificação considera a possibilidade de trabalhar com microdados de avaliações educacionais, como os do Sistema de Avaliação da Educação Básica (SAEB) e do PISA, e com dados sintéticos destinados à verificação do fluxo automatizado; a seleção definitiva depende dessas condições.

A implementação técnica exploratória do repositório segue uma escolha distinta, de viabilidade, que não substitui esse critério. Seu adaptador aceita somente a versão corrigida do conjunto *Skill-builder data 2009-2010* do ASSISTments (ASSISTments, 2024)[1], que registra uma linha por par estudante–problema, com ordem das interações, indicador de acerto e habilidades associadas. O sistema que gerou esses registros é descrito por Feng, Heffernan e Koedinger (2009), referência indicada pelo próprio provedor, embora esse artigo não analise o conjunto de 2009–2010. A escolha atende a uma verificação técnica do fluxo de previsão da próxima resposta, que exige registros sequenciais por habilidade; os microdados de proficiência do SAEB e do PISA não têm essa estrutura. Ela não seleciona a base de uma investigação empírica, não representa estudantes brasileiros e não foi acompanhada do processamento de qualquer arquivo real nesta pesquisa; as demais fontes aparecem na configuração apenas como candidatas, sem adaptador implementado. Os termos de uso publicados pelo provedor deverão ser registrados e respeitados antes de qualquer aquisição.

A seleção de uma fonte deverá considerar, inicialmente, sua licença e suas condições de uso, bem como a existência de dicionário de dados e de documentação metodológica. Também deverá examinar a unidade de análise e sua relação com o problema de pesquisa, a

[1] O provedor solicita que a publicação indique a URL precisa do conjunto: <https://sites.google.com/site/assistmentsdata/home/2009-2010-assistment-data/skill-builder-data-2009-2010>. A nota identifica a versão citada; não indica processamento dos dados nesta pesquisa.

qualidade dos metadados e o tratamento previsto para valores ausentes. A representatividade da população deverá ser analisada em relação ao contexto para o qual se pretende interpretar os resultados, sem ser presumida a partir da simples disponibilidade da base. Do mesmo modo, a presença de variáveis relacionadas ao desempenho e ao contexto educacional será relevante, mas não garantirá, por si só, que seja possível associá-las a competências ou descritores curriculares. Essa associação deverá ser demonstrada e delimitada pela documentação e pelo desenho da avaliação.

Por fim, a análise da fonte deverá incluir os riscos de identificação, discriminação e uso indevido. Esses riscos são condições de governança da execução, e não apenas atributos técnicos do arquivo de dados. Dados sintéticos poderão ser usados para testar fluxos de processamento, interfaces e regras de validação.

Quanto à modelagem, a revisão identificou uso de *Random Forest*, máquinas de vetores de suporte (SVM), árvores de decisão, regressão logística e redes neurais. Na especificação, *Random Forest* e SVM também foram ancoradas em suas fontes metodológicas primárias (Breiman, 2001; Cortes; Vapnik, 1995). Modelos supervisionados simples e interpretáveis foram mantidos como referências iniciais de comparação, condicionando o uso de modelos mais complexos à demonstração de ganho e à possibilidade de interpretação adequada.

Random Forest e SVM foram registrados como alternativas de modelagem, não como algoritmos definitivamente implementados. A escolha entre eles depende da base selecionada, da distribuição das classes, do tipo de variável, do custo computacional e dos requisitos de explicabilidade. O princípio de justificar maior complexidade não fixa uma regra específica de adoção. A regra de decisão e sua justificativa deverão ser definidas antes de eventual comparação. As escolhas já configuradas no código exploratório descrevem aquele procedimento auxiliar, sem estabelecer a regra de decisão da especificação conceitual.

O código exploratório não implementa essas duas alternativas. Ele contém referências históricas simples, uma regressão logística regularizada (James et al., 2021) e, como candidato não linear exploratório, um classificador que combina modelos ajustados sequencialmente (*gradient boosting*) (Friedman, 2001) em sua variante baseada em histogramas disponível na biblioteca scikit-learn (Pedregosa et al., 2011). Essa composição foi definida para testar o fluxo com um modelo interpretável e um candidato não linear; não resulta de uma comparação com *Random Forest* ou SVM nem indica superioridade de qualquer modelo. Nenhum desses modelos foi treinado com dados educacionais reais.

O avaliador implementa erro de calibração esperado (ECE, do inglês *expected calibration error*), curva de confiabilidade, intercepto e inclinação de calibração. Os testes sintéticos exercitam esses cálculos, inclusive a resposta indefinida do intercepto e da inclinação quando há apenas uma classe. São diagnósticos das probabilidades produzidas pelo classificador: sua presença não demonstra que as previsões estejam calibradas em dados reais nem constitui calibração de itens ou validação de uma escala de proficiência.

No cenário que separa estudantes entre treino, validação e teste, o código também calcula métricas para a primeira interação elegível de cada estudante do teste, identificada como situação inicial sem histórico individual (*cold-start*). Esse recorte é distinto da avaliação das interações posteriores. Há rotina opcional de análise por subgrupos, mas a configuração vigente não define as colunas habilitadas para essa análise e a registra como sem colunas aprovadas. Isso não demonstra equidade nem operacionaliza a comparação entre grupos prevista em R23.

As configurações também delimitam o estado de execução. Os mínimos de interações por estudante e de suporte por habilidade na base do protótipo, a fonte de probabilidade do perfil e seu suporte individual permanecem indefinidos; os validadores impedem a execução correspondente enquanto essas decisões não forem registradas. Os testes fornecem valores sintéticos somente para exercitar os contratos. Esses testes não escolhem a base definitiva nem resolvem as decisões ainda abertas da especificação.

5.1.1 Alternativas de Mensuração

O rótulo “proficiência” somente poderá ser usado mediante definição de construto, escala, instrumento e evidências de validade. Se houver respostas por item e amostra adequada à calibração, a TRI poderá ser examinada, com verificação de dimensionalidade, ajuste dos itens e comparabilidade entre grupos. Os valores plausíveis do PISA são destinados a inferências populacionais; não serão tomados como diagnóstico individual (OECD, 2024, cap. 11).

Se a finalidade for acompanhar sequências de prática por habilidade, BKT e DKT constituem alternativas a comparar. BKT permite explicitar hipóteses sobre domínio, transição, acerto ao acaso e erro ocasional; DKT exige sequências suficientes e avaliação da consistência e interpretação das previsões (Abdelrahman; Wang; Nunes, 2023). Para ambos, a previsão da próxima resposta continuará identificada por esse alvo. Sem calibração e validade de mensuração, não se converterá sua probabilidade em nível de proficiência. Nenhuma dessas alternativas foi ajustada neste trabalho.

5.1.2 Critérios de Aceitação das Funções

Os critérios do Quadro 10 definem verificações propostas para uma implementação futura. Não são resultados de testes já realizados. F01–F07 identificam as funções descritas neste capítulo e remetem aos grupos R01–R26 da matriz de origem dos requisitos. A cobertura dessas funções é parcial em relação ao conjunto da matriz.

R04 tem vínculo parcial em F04 e F07, conforme os vínculos indicados no Quadro 10: F04 limita a consulta individual a perfil autorizado, e F07 prevê pseudonimização e evita dados pessoais desnecessários. A finalidade e a análise de riscos permanecem condições de governança a detalhar. A acessibilidade de R12 permanece como requisito a operacionalizar em critérios de aceitação. R13 é uma condição documental de seleção de fontes candidatas, sem implementação dos adaptadores de SAEB ou PISA. R17 circunscreve os testes sintéticos como verificação técnica, sem evidência educacional. R24 tem vínculo parcial em F05, conforme o Quadro 10: a condição de aceitação veda apresentar a contribuição de um atributo como causa, mas os limites de população, alvo e desenho permanecem condições documentais de interpretação. Esses vínculos não acrescentam funções nem demonstram que os controles propostos foram implementados.

Quadro 10 – Critérios de aceitação dos requisitos funcionais.

Cód.	**Requisito e vínculo**	**Condição observável de aceitação**
F01	Importar dados documentados (R07, R14, R16).	Em arquivo de teste com linhas válidas e inválidas conhecidas, informar os totais aceitos/rejeitados e o motivo por linha. Vincular fonte, versão, licença e dicionário. Impedir análise se faltar campo obrigatório ou permissão de uso. Critérios para dados de menores de idade deverão ser definidos antes de qualquer coleta futura e não são definidos nesta especificação.
F02	Organizar evidências curriculares (R02, R08).	Cada resultado deve indicar habilidade ou descritor e a origem desse vínculo. Registro sem associação deve aparecer como “vínculo curricular não estabelecido”, sem classificação automática de competência.
F03	Estimar um alvo definido (R09, R18–R22).	Apresentar alvo, unidade, horizonte, variáveis disponíveis antes do desfecho, partição e tamanho de treino/validação/teste. Registrar comparação com referência simples e métricas por classe. Bloquear relatório de validade quando houver sobreposição indevida de estudantes, itens ou período entre partições.
F04	Apresentar resultados individuais e agregados (R04 parcial, R09, R15).	Em conjunto sintético de contagens conhecidas, os totais por turma/habilidade devem corresponder aos registros filtrados. Exibir denominador, período e dados ausentes; limitar a visualização individual a perfil autorizado.

Quadro 10 – Continuação

Cód.	Requisito e vínculo	Condição observável de aceitação
F05	Explicar estimativas e incertezas (R03, R23 (parcial), R24 (parcial), R26).	Associar a saída ao modelo e aos atributos efetivamente usados, informando método de explicação e domínio de validade. Apresentar a probabilidade pontual com intervalo de Wilson por estudante e habilidade; probabilidade sem calibração examinada deve ser assim identificada; contribuição de atributo não deve ser apresentada como causa. Estabilidade das explicações e diferenças entre grupos, previstas em R23, não estão operacionalizadas nem abrangidas pela aceitação nesta especificação.
F06	Permitir revisão docente (R01, R05, R25).	O professor deve poder manter, rejeitar ou pedir revisão da sugestão, com justificativa e histórico. Nenhuma ação pedagógica deverá ser executada automaticamente pela previsão; o relatório deve preservar a decisão docente e a evidência que a motivou.
F07	Exportar versões, decisões e saídas (R04 parcial, R06, R10, R11).	A exportação deve reunir versão dos dados/modelo, parâmetros, dependências, critérios, métricas e revisão docente. Reabrir o pacote deve permitir vincular cada saída à entrada correspondente, com identificadores pseudonimizados e sem dados pessoais desnecessários.

Fonte: Elaborado pelo autor (2026).

Como delimitação de uso, vinculada às salvaguardas de mediação docente (F06) e de rastreabilidade das decisões (F07), as previsões não devem fundamentar retenção ou reprovação de estudantes, ranqueamento de estudantes ou docentes, agrupamento permanente por habilidade, nem ser usadas como nota ou decisão somativa.

5.1.3 Cenários de Uso e Saídas Previstas

No primeiro cenário, uma professora examina atividades de frações de uma turma. Após verificar a licença e o dicionário dos dados (F01), associa os itens às habilidades trabalhadas (F02) e consulta os registros por estudante e turma (F04). A saída ilustrativa seria: “Exemplo fictício, sem execução de modelo: estudante A; habilidade: comparação de frações; 4 acertos em 6 itens nesta atividade; 2 registros sem tempo de resposta; vínculo curricular informado pela professora; previsão não disponível”. A professora registra a necessidade de examinar as estratégias escritas antes de escolher uma nova atividade (F06). A contagem descreve aquela tarefa; não recebe o rótulo de proficiência.

No segundo cenário, um docente examina um modelo candidato de previsão da próxima resposta. A interface apresenta: “Exemplo fictício, sem treinamento real: probabilidade pontual prevista de acerto=0,65; alvo: próximo item da habilidade indicada; calibração ainda não examinada; validação externa pendente; não usar como diagnóstico de competência”. A saída apresenta probabilidade pontual acompanhada de intervalo de Wilson por estudante e habilidade, calculado sobre o número de respostas observadas, e o protótipo mantém desabili-

tado o alerta binário de risco; as ressalvas sobre calibração e validação externa delimitam sua interpretação. Como condição futura de aceitação, em avaliação com dados reais, o docente deverá poder consultar quais registros e atributos sustentam a previsão (F03/F05) e, se identificar o uso do próprio desfecho entre os preditores, solicitar revisão e impedir a liberação. A decisão e a versão examinada devem integrar a exportação (F07). Esse cenário especifica uma condição de proteção, sem afirmar que o protótipo já a cumpre nem alegar desempenho do modelo.

5.2 PROTOCOLO DE AVALIAÇÃO DA ESPECIFICAÇÃO CONCEITUAL

O protocolo proposto para o OE4 examina a especificação conceitual; sua aplicação permanece pendente. O procedimento deverá examinar a rastreabilidade dos requisitos até as fontes ou decisões autorais, a consistência entre entradas, saídas e responsabilidades da arquitetura e a correspondência entre as saídas previstas e os conceitos educacionais adotados. A viabilidade será examinada documentalmente pelas condições necessárias de acesso e uso dos dados, disponibilidade de variáveis, recursos computacionais e participação docente.

Para cada requisito examinado, deverão ser registrados seu identificador, a versão da especificação, a fonte e a localização no texto (página ou seção), o critério utilizado, a justificativa e a necessidade de ajuste. A revisão por docentes e a análise técnica serão registradas separadamente. O Quadro 11 organiza os requisitos a serem examinados; o procedimento a seguir fixa participantes, instrumento e regra de decisão.

5.2.1 Revisão Documental por Docentes

Propõe-se um painel de cinco docentes distintos, selecionados intencionalmente: três licenciados em matemática com pelo menos dois anos de docência na educação básica e dois com atuação em ensino superior ou pesquisa em educação matemática, também com pelo menos dois anos de experiência. Ao menos um deverá ter experiência em avaliação educacional ou tecnologias educacionais. Os perfis poderão se sobrepor, mas cada pessoa contará uma vez. O autor e o orientador não comporão esse painel; organizarão a documentação e registrarão as decisões. Trata-se de um plano de execução, sem participantes convidados ou avaliação realizada.

Cada docente receberá a mesma versão da especificação, a matriz de origem dos requisitos, os cenários e o formulário do Apêndice C. A primeira rodada será individual. A previsão de cerca de 30 minutos para leitura e 30 para preenchimento é uma estimativa não testada

e pode ser insuficiente para os 104 julgamentos previstos (26 requisitos e quatro dimensões); por isso, a aplicação poderá ser distribuída em sessões ou abranger uma amostra de requisitos, se a extensão exigir; essa possibilidade não altera a regra de consenso descrita abaixo. O protocolo não foi aplicado. Para cada R01–R26, serão julgadas quatro dimensões: sustentação na fonte ou decisão autoral, adequação curricular, clareza da saída para o professor e viabilidade documental das condições necessárias. A escala proposta é: 1=incoerente; 2=requer alteração substancial; 3=coerente com ajuste pontual; 4=coerente. A opção NE significa evidência insuficiente e exige justificar o que falta. O campo de aceitação funcional relacionará F01–F07 ao critério correspondente do Quadro 10.

Um requisito será considerado "coerente" se pelo menos quatro dos cinco docentes lhe atribuírem 3 ou 4 em cada dimensão e não houver problema crítico pendente. Serão críticos, para este protocolo, uma saída que trate previsão como proficiência sem mensuração validada, uma prescrição sem revisão docente ou exposição indevida de dados. Nos demais casos, o resultado será "revisar", com indicação do trecho e da alteração necessária. Essa regra de 80% é uma escolha de projeto para o painel; não constitui validação estatística do instrumento nem estimativa para uma população docente.

Após a primeira rodada, o autor reunirá as divergências e proporá uma versão revista, preservando as respostas originais. Uma reunião de até 60 minutos permitirá discutir os motivos, sem substituir os julgamentos individuais por concordância forçada. Haverá uma segunda rodada individual, com a mesma regra. Persistindo divergência que impeça atingir a regra de consenso ou problema crítico, o requisito permanecerá "revisar". Ajustes pontuais associados à resposta 3 deverão ser incorporados à versão final e conferidos pelos docentes que os solicitaram; até essa confirmação, a aceitação ficará condicionada ao ajuste. Alteração substancial exigirá manter "revisar". A especificação será classificada como coerente documentalmente apenas se todos os requisitos atenderem à regra e os ajustes estiverem confirmados; caso contrário, será apresentada com a lista dos que exigem revisão. Com menos de cinco avaliações completas, não se aplicará a regra de consenso: o painel será registrado como incompleto e o requisito permanecerá pendente, sem aprovação por omissão. A conferência técnica de dados, entradas e saídas será registrada separadamente, sem ser usada como voto docente.

Antes de recrutar participantes ou coletar respostas, o pesquisador responsável e o orientador deverão encaminhar o projeto e seus instrumentos ao comitê de ética competente, pela Plataforma Brasil, e aguardar a decisão aplicável. Serão previstos consentimento livre e es-

clarecido, participação voluntária, possibilidade de desistência, riscos de constrangimento profissional e sua redução, acesso restrito às respostas e divulgação sem identificação dos docentes (BRASIL, 2016, art. 3, 17, 23 e 28). O Instituto Federal Catarinense (IFC) disponibiliza orientações e modelos para a submissão e o consentimento (IFC, s.d.). Os dados pessoais dos docentes participantes exigirão finalidade explícita, confidencialidade e prazos definidos de retenção e eliminação, conforme a LGPD (Brasil, 2018b), como condição do protocolo futuro. A avaliação utilizará exemplos fictícios, sem dados reais de estudantes, e não avaliará o desempenho profissional dos participantes. A aplicação desse plano permanece posterior à entrega documental e à tramitação ética.

Para uma futura execução e avaliação do protótipo com dados educacionais reais, um protocolo experimental distinto deverá orientar a modelagem e a interpretação dos seus resultados. Ele deverá separar o que será observado no comportamento técnico dos modelos daquilo que exigiria evidência educacional adicional. Essa separação começa pela definição explícita dos conjuntos de treino, validação e teste e pela prevenção de vazamento de informação entre preparação, modelagem e avaliação. Os modelos candidatos deverão ser comparados com referências simples, para que diferenças de desempenho, inclusive resultados nulos ou desfavoráveis, sejam interpretadas em relação a uma base de comparação, e as métricas deverão ser analisadas por classe, além das medidas agregadas, quando a tarefa permitir essa decomposição.

Como descrição complementar dos erros e acertos, o protocolo prevê o uso de matriz de confusão, precisão, revocação e medida F1. A área sob a curva ROC e a calibração somente deverão ser calculadas quando forem compatíveis com a tarefa e com o tipo de saída produzido (Fawcett, 2006; Niculescu-Mizil; Caruana, 2005). Também deverão ser examinadas a estabilidade das explicações e possíveis diferenças entre grupos, sem converter essas análises em conclusões causais não sustentadas pelo desenho do estudo. Por fim, a execução deverá registrar as limitações de generalização relacionadas à fonte de dados, à população observada e às condições de aplicação.

Como parte da avaliação e da revisão humana, *SHapley Additive exPlanations* (SHAP) e *Local Interpretable Model-agnostic Explanations* (LIME) foram incluídos como alternativas para explicar modelos, com referência às formulações originais de Lundberg e Lee e de Ribeiro, Singh e Guestrin (Lundberg; Lee, 2017; Ribeiro; Singh; Guestrin, 2016). Seu uso deverá considerar a estabilidade das explicações, o custo computacional e a possibilidade de tradução dos resultados para uma linguagem curricular compreensível. A implementação

exploratória não inclui esses métodos, que permanecem alternativas especificadas. Para a regressão logística, a rotina de explicação local decompõe o logaritmo da razão de chances de cada previsão em intercepto e produtos entre coeficientes e valores transformados dos atributos. Essa decomposição é exata para esse modelo linear: fixados o ajuste e a transformação dos atributos, ela reproduz algebricamente o cálculo no logaritmo da razão de chances. Não demonstra estabilidade das contribuições entre ajustes ou amostras nem relações causais. A configuração examinada prevê explicações locais para até as 20 primeiras linhas do conjunto de teste, ordenadas pelo identificador do estudante (ordem textual), pela ordem da interação e pelo identificador do registro de origem. Esse recorte é uma escolha de apresentação, não uma amostra aleatória; o limite não restringe o perfil agregado por estudante e habilidade.

A importância por permutação da regressão logística é calculada sobre o conjunto de teste e descreve dependência preditiva global, adaptando o procedimento proposto por Breiman (2001) para florestas aleatórias. Ela não é uma explicação individual nem demonstra causalidade. O candidato de *gradient boosting* não possui explicação implementada. Essas saídas cobrem apenas parte de F05: não operacionalizam estabilidade das explicações, diferenças entre grupos ou compreensão docente, que permanecem condições a examinar.

O procedimento de revisão docente não foi executado; não substituiria um estudo empírico de eficácia educacional. Os limites desse procedimento e do alcance das conclusões são discutidos na Seção 4.6.

5.3 ARQUITETURA DE REFERÊNCIA

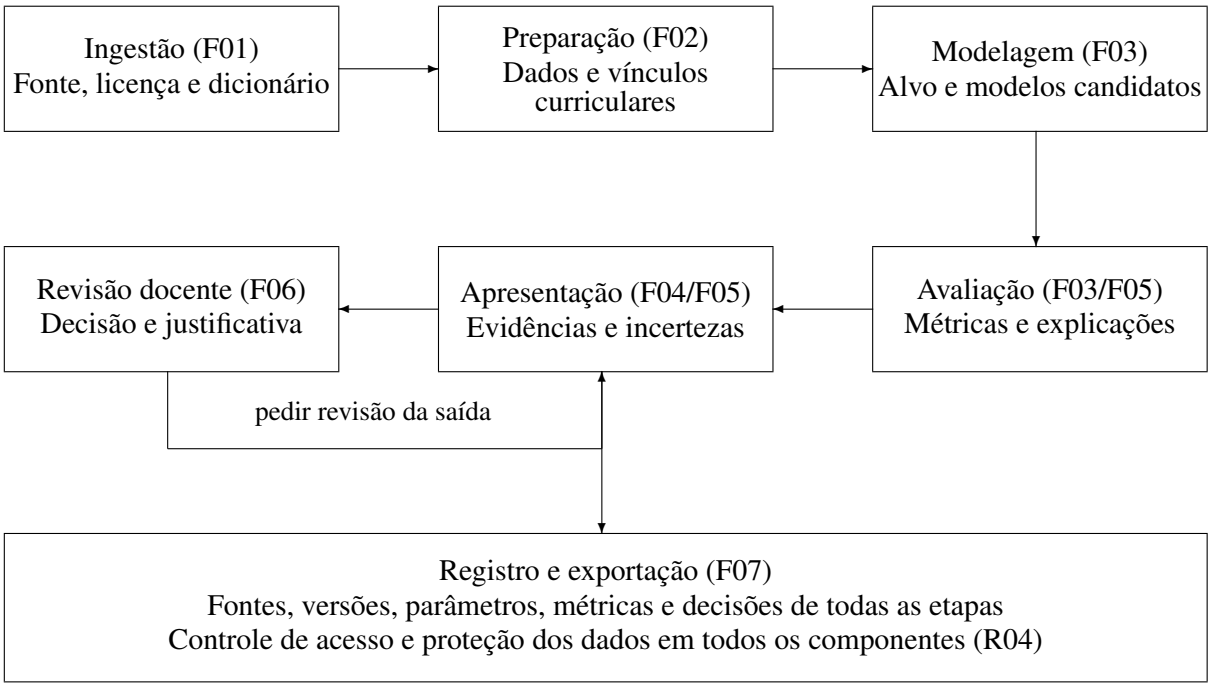
A ingestão corresponde à leitura das fontes, à validação inicial de seus formatos e à preservação das informações de procedência. Em seguida, a etapa de preparação deverá tratar valores ausentes, codificar e transformar variáveis e documentar as decisões tomadas sobre esses dados. A modelagem abrangerá o treinamento e a comparação dos modelos candidatos de acordo com a base selecionada e com o protocolo de avaliação.

A etapa de avaliação e explicabilidade deverá calcular as métricas, analisar os erros e gerar explicações cuja estabilidade e limitações serão examinadas. Por fim, a apresentação deverá disponibilizar indicadores, incertezas e limitações de modo compreensível para a análise docente. Essa arquitetura organiza responsabilidades e pontos de verificação para a implementação futura, sem fixar tecnologia ou forma de implantação.

A separação dos componentes deverá favorecer a testabilidade, a rastreabilidade e a

substituição controlada de técnicas. Ela também permite localizar em qual etapa uma decisão, uma transformação ou uma limitação foi introduzida. A arquitetura não impõe uma interface específica e poderá ser materializada como caderno computacional interativo, aplicação local, API ou sistema web. Essas formas de execução deverão preservar os requisitos da Seção 5.1.

Figura 1 – Componentes e fluxos da arquitetura conceitual.



Fonte: Elaborado pelo autor (2026).

5.4 FUNDAMENTAÇÃO E RASTREABILIDADE DOS REQUISITOS

A especificação articula três origens que não devem ser confundidas: observações localizadas nos estudos do corpus, fundamentos teóricos ou normativos e decisões de projeto do autor. Um problema de relato identificado em um artigo pode motivar uma salvaguarda, mas não demonstra que a solução proposta seja eficaz. Da mesma forma, um referencial pedagógico orienta a interpretação das saídas sem validar uma interface ou um algoritmo específico.

O Quadro 11 organiza os requisitos das seções anteriores em 26 grupos identificáveis. A coluna de origem explicita a base da decisão e a última coluna delimita a inferência permitida. Requisitos de engenharia que não receberam sustentação externa específica são apresentados como escolhas autorais, e não como achados empíricos da revisão. As referências remetem aos trabalhos discutidos na fundamentação e na síntese; as páginas ou seções que

sustentam as apreciações empíricas estão indicadas no registro de evidências dos estudos. A leitura inversa, por estudo, está no Quadro 12, que relaciona os 15 estudos a 18 grupos R. Nesta matriz, sete dos 26 grupos citam diretamente seis estudos do corpus; os demais registram bases teóricas, normativas ou autorais, por vezes combinadas.

Os grupos R01–R19 remetem aos requisitos e critérios da Seção 5.1; R07, R10, R11 e R16 também explicitam condições da arquitetura na Seção 5.3. R20–R26 correspondem às condições do protocolo de avaliação da Seção 5.2. Esses vínculos identificam onde cada grupo foi especificado, sem transformar as decisões autorais em exigências extraídas de um artigo.

Quadro 11 – Origem, derivação e limites dos requisitos da especificação conceitual.

Cód.	**Requisito ou grupo**	**Origem e base documental**	**Derivação e limite da justificativa**
R01	Apoio docente e revisão humana, sem prescrição autônoma.	Teoria e decisão autoral: mediação em Vygotsky (1978) e Wood, Bruner e Ross (1976).	A mediação orienta a participação do professor; não demonstra utilidade do protótipo nem mensuração da zona de desenvolvimento proximal.
R02	Separar desempenho, previsão, proficiência, competência e aprendizagem.	Teoria e norma: National Research Council (2001, p. 42–44), OECD (2023a) e Brasil (2018a).	Exigir construto e validade para interpretar inferências. A definição operacional de aprendizagem adotada neste trabalho não foi testada pelo protótipo.
R03	Comunicar explicações, incertezas e condições de validade.	Teoria e decisão autoral: National Research Council (2001) e Hattie e Timperley (2007).	Informação interpretável é condição proposta de uso. Explicação algorítmica não equivale automaticamente a retorno pedagógico formativo compreendido pelo docente.
R04	Finalidade, minimização, acesso e análise de riscos de identificação e uso indevido.	Fundamento normativo e decisão de governança: Brasil (2018b).	Orientar o planejamento do tratamento de dados pessoais; não declarar conformidade jurídica de uma implementação ainda não avaliada.
R05	Evitar rótulos permanentes e interpretações discriminatórias.	Fundamento teórico e salvaguarda autoral: limites de inferência em National Research Council (2001).	Restringir a interpretação à tarefa e ao contexto; não afirmar dano demonstrado no corpus nem equidade já alcançada.
R06	Registrar versões, parâmetros e dependências; exportar dados e resultados, vinculando cada saída à fonte e à versão do experimento.	Autoral: princípios e requisitos deste capítulo.	Viabilizar inspeção documental e reprodução futura. O corpus não demonstra a eficácia desse conjunto operacional.

Continua na próxima página

Quadro 11 – Continuação

Cód.	Requisito ou grupo	Origem e base documental	Derivação e limite da justificativa
R07	Importar dados documentados e preservar procedência.	Autoral: ingestão e preparação.	Preservar contexto e registrar validações de formato; não presumir qualidade pelo simples sucesso da importação.
R08	Relacionar evidências a habilidades, descritores e objetivos curriculares.	Teoria e norma: Brasil (2018a) e Ausubel (1968); aplicação operacional autoral.	Orientar o vínculo curricular e considerar conhecimentos anteriores. A associação concreta entre variáveis e habilidades ainda deverá ser demonstrada.
R09	Definir o alvo e distinguir saídas individuais de agregadas.	Corpus: alvos e unidades distintos em He et al. (2025, p. 11–12, seção de definição do resultado predito); fundamento em National Research Council (2001); decisão autoral de apresentação.	A predição de efeito de intervenções não equivale à proficiência individual. A forma de exibição ainda não foi avaliada com docentes.
R10	Separar componentes para favorecer testabilidade.	Arquitetura autoral: ingestão, preparação, modelagem, avaliação e apresentação.	Organizar responsabilidades e pontos de inspeção; não tratar modularidade como propriedade empiricamente comprovada da proposta.
R11	Documentar o ambiente e permitir substituição controlada de técnicas.	Autoral: portabilidade e interfaces.	Condicionar execução à documentação de dependências e contratos; a especificação não demonstra portabilidade entre ambientes reais.
R12	Considerar acessibilidade e diferentes perfis de usuários.	Apresentação autoral, sem validação no corpus.	Condição não implementada no protótipo nem testada nos casos sintéticos; a operacionalizar em critérios futuros de aceitação, sem declarar acessibilidade alcançada ou avaliada.
R13	Examinar SAEB e PISA como fontes candidatas, não definitivas.	Exemplo do corpus em Pejić, Molcer e Gulači (2021); documentação contextual de Brasil. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (2024) e OECD (2023b); decisão autoral.	Uso de uma edição do PISA não valida outra base, outra edição ou sua transferência ao contexto brasileiro. O uso do ASSISTments no código exploratório é teste de viabilidade, não seleção da base.
R14	Verificar licença, condições de uso, dicionário e documentação metodológica.	Autoral: seleção das fontes.	Condicionar uso à documentação e às permissões pertinentes. Disponibilidade pública e proteção de dados não substituem licença de uso.
R15	Examinar unidade de análise e representatividade da população.	Corpus: seleção e alvo em Pejić, Molcer e Gulači (2021, p. 50); distinção de unidades em He et al. (2025, p. 11–12, seção de definição do resultado predito); decisão autoral.	Exigir compatibilidade entre pergunta, amostra e inferência. Casos localizados não estimam a frequência de problemas na literatura.
R16	Documentar metadados, transformações e valores ausentes.	Decisão de projeto do autor para seleção e preparação de dados.	Tornar as decisões examináveis; não fixar regra universal de imputação nem garantir validade das variáveis.

Continua na próxima página

Quadro 11 – Continuação

Cód.	Requisito ou grupo	Origem e base documental	Derivação e limite da justificativa
R17	Restringir dados sintéticos à verificação técnica.	Delimitação autoral do escopo e do protocolo proposto.	Verificar fluxos e regras sem inferir aprendizagem, validade preditiva em dados reais ou eficácia pedagógica.
R18	Considerar famílias supervisionadas como alternativas.	Exemplos do corpus em Depren, Aşkın e Öz (2017, p. 1609, algoritmos de classificação) e Tjahyadi e Tude (2025, p. 156, Tabela 2); fontes metodológicas (Breiman, 2001; Cortes; Vapnik, 1995).	Identificar candidatos, condicionando a escolha ao tipo de variável, à distribuição das classes, ao custo e à explicabilidade. A ocorrência em artigos não estabelece superioridade ou adequação.
R19	Comparar com referências simples e justificar complexidade.	Fundamento em James et al. (2021); regra de comparação autoral.	Interpretar ganhos sob condições explícitas; não antecipar algoritmo vencedor ou limiar universal de ganho aceitável.
R20	Separar treino, validação e teste e prevenir vazamento.	Fundamento em James et al. (2021); relato contraditório de Pejić, Molcer e Gulači (2021, p. 50–51).	A ambiguidade documental motiva separação e relato inequívocos; não permite determinar qual procedimento foi efetivamente executado no artigo.
R21	Examinar confusão, precisão, revocação e F1 por classe.	Resultados por classe em Tjahyadi e Tude (2025, p. 160, Tabela 8); fundamento em James et al. (2021); decisão autoral de protocolo.	Examinar erros que a acurácia agregada pode ocultar; resultados de uma base não determinam o desempenho futuro do protótipo.
R22	Usar ROC-AUC e calibração quando compatíveis com a tarefa.	Fundamentos em Fawcett (2006) e Niculescu-Mizil e Caruana (2005).	O avaliador exploratório calcula ROC-AUC, escore de Brier e curva de confiabilidade em testes sintéticos, distinguindo discriminação e qualidade probabilística; nenhuma das métricas constitui medida de aprendizagem.
R23	Examinar estabilidade das explicações e diferenças entre grupos.	Decisão autoral de avaliação, orientada pelos limites de validade discutidos em National Research Council (2001).	Verificações futuras: o contrato canônico vigente não tem colunas de subgrupo aprovadas e a estabilidade das explicações não foi implementada. Desempenho médio não demonstra estabilidade ou equidade.
R24	Delimitar generalização e evitar causalidade automática.	Observações localizadas em Pejić, Molcer e Gulači (2021, p. 50), Milićević, Marinović e Jeftić (2024, p. 5, seção 2.2) e Zhang, Zhu e Feng (2025, p. 654, conclusão); interpretação crítica autoral.	Restringir a conclusão à população, ao alvo e ao desenho examinados; não transformar associação ou ganho relatado em efeito causal.
R25	Prever revisão documental por docentes e registrar julgamentos.	Referencial curricular em Brasil (2018a) e avaliação formativa em Hattie e Timperley (2007); procedimento proposto pelo autor.	Examinar adequação curricular e interpretativa da especificação. O procedimento não foi executado e não substituiria avaliação de eficácia educacional.
R26	Examinar SHAP e LIME, sua estabilidade, custo e comunicação curricular.	Métodos em (Lundberg; Lee, 2017; Ribeiro; Singh; Guestrin, 2016); escolha autoral de alternativas.	SHAP/LIME são alternativas; compreensão docente, estabilidade e adequação curricular não foram demonstradas. Código exploratório: somente decomposição exata da regressão logística e importância por permutação.

Fonte: Elaborado pelo autor (2026).

O quadro torna verificável a origem declarada de cada grupo, mas não encerra a apreciação científica das referências. Permanecem distintas a rastreabilidade documental, a conferência da interpretação de cada fonte e a avaliação futura do artefato. Os critérios funcionais, os cenários e a regra de revisão docente estão definidos nas Seções 5.1.2 e 5.2.1. A aplicação e as verificações de acessibilidade e estabilidade explicativa permanecem etapas futuras.

5.5 CONTRIBUIÇÃO DOS ESTUDOS PARA OS REQUISITOS

O Quadro 12 complementa o Quadro 11, que apresenta a origem e os limites de justificativa dos 26 grupos R. Os quadros têm unidades de leitura distintas: este percorre os 15 estudos e os relaciona a 18 grupos; a matriz de origem cita diretamente seis estudos em sete dos 26 grupos. Os vínculos por estudo são decisões de projeto motivadas por observações documentais e pelos fundamentos do capítulo; não significam que os artigos formularam ou validaram os requisitos. Cada estudo aparece uma vez. A linha sem fonte revalidada registra a pendência de recuperação e preserva o vínculo histórico com R14 por decisão autoral, sem derivar requisito técnico específico novo.

Quadro 12 – Observações dos estudos e sua relação com os requisitos.

Estudo e fonte	**Grupos R**	**Observação documental**	**Consequência para a especificação**
Pejić, Molcer e Gulači (2021) (páginas físicas 2–5)	R02, R09, R13, R15, R20, R21, R24	Classes operacionais, seleção do conjunto PISA e relatos divergentes sobre teste.	Exigir alvo, população e partições identificados, com métricas por classe; não equiparar classes aos níveis oficiais.
Tjahyadi e Tude (2025) (páginas físicas 2–3 e 7–8)	R09, R16, R18–R21, R24	Predição de nota posterior; validação 92%, teste 75%, revocação da classe baixa 43%.	Documentar horizonte e reamostragem; distinguir validação, teste e erros por classe.
Sokkhey et al. (2020) (texto integral não recuperado; registro histórico da revisão)	R06, R14 (decisão autoral)	Original não disponível para nova conferência.	Contribuição substantiva não revalidada; preservar identificação e pendência de recuperação, sem requisito técnico específico derivado.
Kumar et al. (2022) (páginas físicas 2–5)	R06, R09, R16, R18–R20, R24	Classificações binária e múltipla; divergência entre tabela e narrativa.	Documentar disciplina, atributos, alvo e avaliação. Conservar inconsistências sem escolher por suposição um resultado correto.
Zhang, Zhu e Feng (2025) (páginas físicas 1–5)	R03, R08, R09, R15, R19, R24	Trajetórias por conhecimentos e perfil, com relato insuficiente da avaliação.	Relacionar sugestão e contexto curricular; examinar comparadores e incerteza. Não adotar ganhos como metas do protótipo.

Quadro 12 – Continuação

Estudo e fonte	Grupos R	Observação documental	Consequência para a especificação
Depren, Aşkın e Öz (2017) (páginas físicas 4–5, 9 e 11)	R09, R15, R18–R21, R24	Classe derivada de escore TIMSS e descrição invertida das dobras.	Explicitar transformação do alvo e partições. Distinguir problema de relato de erro de execução não demonstrado.
Zhang (2024) (páginas físicas 9–12)	R06, R09, R15, R16, R24	Trajetórias e recursos; 120 iniciais, 50+52 válidos e gl=80 no pré-teste não reconciliados.	Informar perdas, grupos e denominador em cada saída; impedir aprovação de comparação com contagens incompatíveis.
MacLellan (2017) (páginas impressas 44–48 e 52–56)	R02, R07, R09, R15, R16, R24	Modelos cognitivos comparados com registros humanos secundários; domínios e frações reutilizados.	Separar domínio, tutor, agente simulado e dado humano; não duplicar amostras. Simulação científica difere de teste sintético de engenharia.
Milićević, Marinović e Jeftić (2024) (páginas físicas 4–7)	R01, R09, R15, R20, R24	Notas e atividades de 50 estudantes, sem validação independente descrita.	Definir quando atributos estão disponíveis e exigir avaliação independente antes de usar previsão para apoio.
Nyantah, Frempong e Larbi (2025) (páginas físicas 10–15)	R08, R09, R15, R24	Animação e aprendizagem cooperativa combinadas; diferenças iniciais e escola por condição.	Registrar conteúdo, intervenção conjunta e grupos; restringir inferência causal e preservar interpretação docente.
He et al. (2025) (páginas físicas 11–16 e 31–35)	R09, R15, R20, R24	Efeito agregado predito e aplicação escolar; denominadores e professores por condição.	Distinguir publicação, turma e estudante; registrar agrupamento e potenciais confundidores. Não tratar efeito agregado como proficiência individual.
Villegas-Ch et al. (2025) (páginas físicas 13–26)	R03, R09, R16, R21, R24, R25	Retorno adaptativo em STEM; precisão, progresso, tempo e percepções com janelas distintas.	Definir disciplina e período por saída; separar precisão técnica e resultado educacional; submeter clareza ao exame docente.
Özseven e Özseven (2026) (páginas físicas 7 e 10–12)	R09, R18–R21, R24	Predição de acerto por interação, partição por estudante e métricas de tarefas diferentes.	Definir classe positiva e unidade; separar regressão/classificação e evitar interpretar revocação de acerto como detecção de risco.
Xia et al. (2026) (páginas físicas 7–8 e 12–19; leitura parcial)	R08, R09, R15, R24, R25	Integração de matemática e metrologia; questionários, entrevistas e grupos de anos distintos.	Vincular conteúdo curricular e contexto; separar percepção, desempenho e mecanismo de adaptação, sem exigir biometria ou Fourier no protótipo.
Echeveria, Bajao e Godinez (2025) (páginas físicas 3 e 6–12)	R02, R05, R09, R15, R16, R20, R21, R24, R25	Categorias de mentalidade; itens usados no alvo também entre preditores.	Documentar rótulo e disponibilidade das variáveis, verificar sobreposição e perdas; separar mentalidade e domínio matemático. R05 é salvaguarda autoral, sem dano demonstrado.

Fonte: Elaborado pelo autor (2026).

6 RESULTADOS E DISCUSSÃO

Este capítulo relaciona a revisão, a apreciação metodológica e a especificação à pergunta de pesquisa. A discussão explicita as consequências dos achados para as decisões de projeto.

6.1 SÍNTESE DOS RESULTADOS

A categorização do OE1 distingue oito estudos de predição/classificação, três de personalização ou STI, dois de intervenção didática, um de modelagem cognitiva e um de integração curricular. Os Quadros 4 e 5 associam essas finalidades a técnicas, populações, alvos e validação; a Tabela 2 apresenta as frequências. A escolha de uma finalidade principal por estudo evita duplicar aplicações secundárias, como a predição de efeitos agregados no trabalho de He et al. (2025).

As contagens MMAT do Quadro 8 revelam sobretudo falta de informação suficiente para concluir sobre os critérios. As respostas CT predominam em aspectos de representatividade, medidas, completude, controle e análise, conforme a rubrica de cada categoria. Esse resultado orienta a especificação a exigir descrição do alvo, da população, das transformações e da avaliação. O quadro de componentes permanece separado, sem contar os três estudos mistos novamente ou transformar respostas em nota de qualidade.

A especificação articula esses achados à distinção entre desempenho, previsão, proficiência, competência e aprendizagem. Requisitos, critérios de aceitação, cenários, diagrama de componentes e formulário de revisão docente tornam explícito o que uma futura execução deverá demonstrar. Dados sintéticos continuam restritos à verificação técnica.

6.2 ATENDIMENTO AOS OBJETIVOS

O OE1 foi desenvolvido por categorização e frequências. O OE2 foi desenvolvido nos termos formulados: limites de recuperação, seleção e relato metodológico foram codificados sistematicamente (Seção 4.6), e dimensões técnicas, pedagógicas e éticas foram discutidas conceitualmente, sem codificação comparável por estudo. O OE3 resultou nos requisitos, nas matrizes de origem e por estudo, nas alternativas de mensuração e na arquitetura do Capítulo 5. O OE4 resultou, no escopo documental, na proposta de protocolo documental e no formulário do Apêndice C, com perfis docentes, instrumento, duas rodadas, regra de consenso e encaminha-

mento ético. A aplicação do painel e a avaliação de uma implementação não foram realizadas neste trabalho.

O componente propositivo do objetivo geral foi realizado no escopo documental pela elaboração de uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática. A entrega liga finalidades do corpus a decisões de projeto e critérios verificáveis, mantendo as condições de uso das evidências descritas na seção de Limitações.

6.3 DISCUSSÃO INTEGRADA

Os estudos preditivos indicam que a escolha do algoritmo deve ser subordinada à definição do alvo e à avaliação independente. Milićević, Marinović e Jeftić (2024) não descreve validação independente para o classificador; Pejić, Molcer e Gulači (2021, Tabela VI) reporta Kappa de até 0,46 e contém a divergência sobre uso do teste descrita na revisão. A implicação para R20 e R21 é exigir partições documentadas, referência simples, matriz de confusão e métricas por classe, em vez de selecionar um modelo pela maior acurácia isolada. Kappa, por si só, não recebe aqui um limiar universal de aprovação.

Em Tjahyadi e Tude (2025, Tabela 8), a acurácia passa de 92% na validação para 75% no teste, com revocação de 43% na classe de baixo desempenho. Isso motiva distinguir resultados de ajuste e teste (R20) e tornar visíveis os erros da classe que pode demandar apoio (R21). A saída ao professor deverá indicar alvo, período, população e limites de uso, como previsto em F03–F05. A diferença não autoriza transportar essas taxas para o protótipo.

Em Echeveria, Bajao e Godinez (2025), a acurácia de 98,8% deve ser interpretada junto à seleção de oito itens de mentalidade matemática que também participam da formação do alvo. A consequência para R09, R16 e R20 é registrar quando o desfecho é definido, quais atributos estariam disponíveis no momento de uso e se há sobreposição entre medida-alvo e preditores. O cenário de previsão explicita o bloqueio de uma saída que viole essas condições. A matriz MLP também precisa preservar seus denominadores, sem corrigir por suposição os totais divergentes; essa incompatibilidade não é atribuída à matriz SVM que sustenta os 98,8%.

As intervenções orientam requisitos de descrição do contexto e da comparação. Em Zhang (2024), os 50 e 52 desfechos válidos e os 80 graus de liberdade do teste *t* no pré-teste não são reconciliados no relato. R15 e R16 exigem denominador, perdas e unidade de análise junto a cada resultado. Em Nyantah, Frempong e Larbi (2025), diferenças iniciais e uma escola por condição tornam necessária a restrição de inferências causais em R24. O mesmo critério

exige distinguir o efeito conjunto de animação e aprendizagem cooperativa de um efeito isolado da tecnologia. A matriz estudo–requisito mantém os outros estudos ligados a observações específicas, sem usar frequência de técnica como prova de eficácia.

Os trabalhos relacionados ajudam a delimitar a contribuição. A revisão de Opesemowo e Adewuyi (2024) caracteriza métodos e ferramentas de IA em matemática; a metanálise de Yi et al. (2025), conforme seu resumo publicado, estima efeito sobre desempenho na educação básica. Este trabalho organiza finalidades de um corpus heterogêneo e converte achados em condições de uma especificação de apoio docente. Não oferece uma atualização das buscas dessas revisões nem incorpora seus estudos às contagens próprias.

A tipologia também impede confundir acompanhamento cognitivo, personalização, intervenção e integração curricular. TRI e BKT/DKT foram incluídos como alternativas condicionadas ao tipo de evidência, e a revisão docente examinará se as saídas previstas são compreensíveis e coerentes com os objetivos curriculares. Assim, a contribuição combina síntese das evidências e decisões de projeto que podem ser examinadas antes de uma execução educacional.

7 CONCLUSÃO

Uma especificação técnica e pedagógica para apoiar a interpretação docente da aprendizagem matemática pode ser estruturada vinculando o alvo educacional e sua população às evidências disponíveis, traduzindo os achados em requisitos e definindo como suas saídas serão examinadas pelo professor. Neste trabalho, essa resposta à pergunta "como estruturar" tomou forma em matrizes de síntese e de requisitos, componentes com responsabilidades definidas, cenários de uso, critérios de aceitação e um protocolo de revisão documental.

O corpus foi organizado em cinco finalidades principais: predição/classificação (oito estudos), personalização ou STI (três), intervenção didática (dois), modelagem cognitiva (um) e integração curricular (um). Essa diversidade orienta a escolha de dados e modelos conforme a finalidade. A síntese MMAT por categoria identifica limitações na evidência disponível ao revisor sobre o alvo, a amostra, a validação e as condições de interpretação. Essas limitações incluem acesso desigual às fontes e cobertura de leitura incompleta; não demonstram automaticamente falha do relato dos estudos.

A entrega propositiva tomou a forma de uma especificação técnica e pedagógica voltada à interpretação docente da aprendizagem matemática. Ela articula a categorização das técnicas nos estudos selecionados por triagem e priorização por relevância, os limites encontrados na literatura, os requisitos e a arquitetura de referência. Também propõe um protocolo para examinar a viabilidade e a coerência da especificação. Esse conjunto atende ao componente propositivo do objetivo geral no escopo documental do trabalho.

Entre as contribuições, destacam-se a síntese estruturada, os dados e o código versionados e a apreciação MMAT por critérios, separada da relevância temática. A fundamentação distinguiu desempenho observado, probabilidade preditiva, proficiência estimada, competência e aprendizagem. Essa distinção orientou critérios de explicabilidade, participação docente, avaliação e proteção de dados na especificação.

As limitações delimitam o alcance dessas contribuições. A triagem excluiu 4.314 registros por resumo ausente ou com menos de 50 palavras; em 4.093 deles o campo registrava "Abstract não disponível". Esse subconjunto de 4.093 registros corresponde a 34,47% dos 11.875 registros únicos e a 43,58% das 9.393 exclusões de triagem. Não se estimou a sensibilidade desse filtro nem se desagregaram esses casos por fonte ou idioma. Na exploração de sensibilidade abaixo de 4,0, foram classificados como elegíveis 13 de 45 registros examinados

por censo na faixa 3,75–3,95, 29 de 54 examinados por seleção dirigida na faixa 3,50–3,74 e 5 de 30 em amostra aleatória estratificada na faixa 3,00–3,49. Embora esses 47 registros indiquem possível perda de cobertura, a seleção dirigida na faixa intermediária não permite estimar a frequência de elegíveis em toda essa faixa. O limiar 4,0 e o corpus foram mantidos. A busca foi realizada em quatro fontes, com limite de 50 resultados por consulta e por API; a amostragem do Crossref não tinha semente fixa e o histórico incompleto das requisições não permite reconstruir integralmente as consultas históricas. O protocolo não foi registrado prospectivamente. A triagem e a apreciação metodológica com o MMAT foram realizadas por um único revisor, o autor. O OE2 foi atendido nos termos formulados: limitações de recuperação, seleção e relato metodológico foram codificadas sistematicamente, enquanto os eixos técnico, pedagógico e ético foram discutidos conceitualmente, sem extração sistemática comparável por estudo. Dos 15 estudos históricos, 14 têm texto recuperado; Sokkhey et al. (2020) permanece com inclusão histórica e respostas MMAT não revalidadas por falta de cópia verificável. O relatório de Zeng (2025) não foi recuperado e não integra os 15 estudos. Os julgamentos MMAT dos 15 estudos permanecem preliminares. As categorias utilizadas para Zhang, Zhu e Feng (2025), Zhang (2024), MacLellan (2017) e Nyantah, Frempong e Larbi (2025) mantêm as restrições descritas na Seção 4.6. A tese de MacLellan foi considerada como um relatório com componentes matemáticos, sem duplicar frações reutilizadas. A revisão e a especificação não constituem uma síntese conclusiva da literatura nem uma solução educacional validada. Não houve aplicação funcional com base definitiva ou participantes, e os testes sintéticos da implementação exploratória não demonstram eficácia pedagógica.

Como continuidade, propõe-se aprofundar a conferência das fontes e dos julgamentos MMAT e aplicar o protocolo de avaliação da especificação. Uma eventual aplicação educacional dependerá de decisão posterior, seleção de dados compatíveis e comparação de modelos de referência em ambiente reproduzível. Estudos com participantes exigirão avaliação ética aplicável, autorização institucional, proteção dos dados e participação de profissionais da educação.

A análise por subgrupos e de equidade não foi operacionalizada: os dados disponíveis ao protótipo não contêm as variáveis necessárias para essa análise. Seu desenvolvimento futuro depende da disponibilidade de dados apropriados e da definição da base legal aplicável.

A continuidade também poderá examinar estabilidade das explicações, diferenças de desempenho entre grupos, alinhamento curricular e utilidade das informações para o plane-

jamento docente. Essas atividades ampliam a revisão e a especificação entregues, preservando o professor como responsável pela interpretação pedagógica e pelas decisões de intervenção.

REFERÊNCIAS

ABDELRAHMAN, Ghodai; WANG, Qing; NUNES, Bernardo. Knowledge tracing: A survey. **ACM Computing Surveys**, v. 55, n. 11, p. 1–37, 2023. Artigo 224. DOI: <https://doi.org/10.1145/3569576>. Acesso em: 29 out. 2026.

ASSISTments. **Skill-builder data 2009-2010**. 2024. Página com nota de atualização em junho de 2024; descreve a versão corrigida do conjunto referente a 2009–2010. Disponível em: <https://sites.google.com/site/assistmentsdata/home/2009-2010-assistment-data/skill-builder-data-2009-2010>. Acesso em: 3 nov. 2026.

AUSUBEL, David P. **Educational Psychology: A Cognitive View**. New York: Holt, Rinehart and Winston, 1968.

BATISTA, Thales Ferreira. **CCW: código e registros da revisão sistemática**. 2026. Versão fed49b3a7afa00a80bd573631b1906757c7cb6a8. Disponível em: <https://github.com/thalesfb/ccw/tree/fed49b3a7afa00a80bd573631b1906757c7cb6a8/research>. Acesso em: 3 nov. 2026.

BLACK, Paul; WILIAM, Dylan. Assessment and classroom learning. **Assessment in Education: Principles, Policy & Practice**, v. 5, n. 1, p. 7–74, 1998. DOI: <https://doi.org/10.1080/0969595980050102>.

BRASIL. **Resolução n. 510, de 7 de abril de 2016**. Brasília, DF, 2016. Disponível em: <https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2016/resolucao-no-510.pdf>. Acesso em: 29 out. 2026.

____. **Base Nacional Comum Curricular: Educação é a Base**. 2018a. Documento normativo que define o conjunto de aprendizagens essenciais para a Educação Básica. Disponível em: <https://basenacionalcomum.mec.gov.br/>. Acesso em: 15 set. 2026.

____. **Lei nº 13.709, de 14 de agosto de 2018**: Lei geral de proteção de dados pessoais. 2018b. Disponível em: <https://planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm>. Acesso em: 11 out. 2026.

BRASIL. Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. **Relatório de resultados do Saeb 2021: volume 1: contexto educacional e resultados em língua portuguesa e matemática para o 5º e 9º anos do ensino fundamental e séries finais do ensino médio**. Brasília, DF: Inep, 2024. 261 p. ISBN 978-65-5801-078-4. Disponível em: <https://download.inep.gov.br/educacao_basica/saeb/2021/resultados/relatorio_de_resultados_do_saeb_2021_volume_1.pdf>. Acesso em: 22 out. 2026.

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: <https://doi.org/10.1023/A:1010933404324>.

CORTES, Corinna; VAPNIK, Vladimir. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273–297, 1995. DOI: <https://doi.org/10.1007/BF00994018>.

Crossref. **Tips and tricks**. 2025. Documentação da API REST; atualização indicada em 24 de outubro de 2025. Disponível em: <https://www.crossref.org/documentation/retrieve-metadata/rest-api/tips-for-using-the-crossref-rest-api/>. Acesso em: 3 nov. 2026.

DEPREN, Serpil Kılıç; AŞKIN, Öyküm Esra; ÖZ, Ersoy. Identifying the Classification Performances of Educational Data Mining Methods: A Case Study for TIMSS. **Educational Sciences: Theory & Practice**, v. 17, n. 5, p. 1605–1623, 2017. DOI: <https://doi.org/10.12738/estp.2017.5.0634>.

ECHEVERIA, Joshua M.; BAJAO, Christal Joy; GODINEZ, Charles Darwin O. Modeling Students' Mindset in Mathematics: A Data Mining Approach for Early Intervention. **European Journal of Education and Pedagogy**, v. 6, n. 6, p. 63–75, 2025. DOI: <https://doi.org/10.24018/ejedu.2025.6.6.934>.

FAWCETT, Tom. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006. DOI: <https://doi.org/10.1016/j.patrec.2005.10.010>.

FENG, Mingyu; HEFFERNAN, Neil; KOEDINGER, Kenneth. Addressing the assessment challenge with an online system that tutors as it assesses. **User Modeling and User-Adapted Interaction**, v. 19, n. 3, p. 243–266, 2009. DOI: <https://doi.org/10.1007/s11257-009-9063-7>.

FRIEDMAN, Jerome H. Greedy function approximation: A gradient boosting machine. **The Annals of Statistics**, v. 29, n. 5, p. 1189–1232, 2001. DOI: <https://doi.org/10.1214/aos/1013203451>.

HATTIE, John; TIMPERLEY, Helen. The power of feedback. **Review of Educational Research**, v. 77, n. 1, p. 81–112, 2007. DOI: <https://doi.org/10.3102/003465430298487>.

HE, Aneng et al. AI-driven predictive models for optimizing mathematics education technology: Enhancing decision-making through educational data mining and meta-analysis. **Smart Learning Environments**, v. 12, n. 1, 2025. Artigo 64. DOI: <https://doi.org/10.1186/s40561-025-00415-z>.

HIGGINS, Julian P. T. et al. (Ed.). **Cochrane Handbook for Systematic Reviews of Interventions**. [London]: Cochrane, 2024. Versão 6.5, atualizada em agosto de 2024. Disponível em: <https://www.cochrane.org/handbook>. Acesso em: 29 out. 2026.

HONG, Quan Nha et al. The mixed methods appraisal tool (MMAT) version 2018 for information professionals and researchers. **Education for Information**, v. 34, n. 4, p. 285–291, 2018a. DOI: <https://doi.org/10.3233/EFI-180221>.

____. **Mixed Methods Appraisal Tool (MMAT), version 2018: User guide**. 2018b. Disponível em: <https://mixedmethodsappraisaltoolpublic.pbworks.com/w/file/fetch/127916259/MMAT_2018_criteria-manual_2018-08-01_ENG.pdf>. Acesso em: 10 out. 2026.

IMPERATRICE, R. C. Fabiola et al. Beyond the traditional classroom: innovation and inclusion in math teaching with AI. **Journal of Inclusive Methodology and Technology in Learning and Teaching**, v. 5, n. 3, 2025. Disponível em: <https://www.inclusiveteaching.it/index.php/inclusiveteaching/article/view/449>. Acesso em: 29 out. 2026.

Instituto Federal Catarinense. **Formulário e Documentos**. s.d. Comitê de Ética em Pesquisa com Seres Humanos. Página sem data de publicação indicada. Disponível em: <https://cepsh.ifc.edu.br/documentos/>. Acesso em: 3 nov. 2026.

JAMES, Gareth et al. **An Introduction to Statistical Learning: with Applications in R**. 2. ed. New York: Springer, 2021. DOI: <https://doi.org/10.1007/978-1-0716-1418-1>.

KUMAR, Mukesh et al. Analysis of Feature Selection and Data Mining Techniques to Predict Student Academic Performance. In: **2022 International Conference on Decision Aid Sciences and Applications (DASA)**. [Piscataway, NJ]: IEEE, 2022. p. 1013–1017. DOI: <https://doi.org/10.1109/DASA54658.2022.9765236>.

LUNDBERG, Scott M.; LEE, Su-In. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems 30**. [Red Hook, NY]: Curran Associates, Inc., 2017. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>. Acesso em: 15 set. 2026.

MACLELLAN, Christopher J. **Computational Models of Human Learning: Applications for Tutor Development, Behavior Prediction, and Theory Testing**. Tese (Doutorado) — Carnegie Mellon University, 2017. DOI: <https://doi.org/10.1184/R1/6715271>.

MCKENZIE, Joanne E. et al. Defining the criteria for including studies and how they will be grouped for the synthesis. In: HIGGINS, Julian P. T. et al. (Ed.). **Cochrane Handbook for Systematic Reviews of Interventions**. [London]: Cochrane, 2024. cap. 3. Version 6.5; chapter updated August 2023; sections 3.2 and 3.3. Disponível em: <https://www.cochrane.org/authors/handbooks-and-manuals/handbook/current/chapter-03>. Acesso em: 29 out. 2026.

MILIĆEVIĆ, Marina; MARINOVIĆ, Budimirka; JEFTIĆ, Ljerka. Machine learning methods as auxiliary tool for effective mathematics teaching. **Computer Applications in Engineering Education**, v. 32, n. 6, p. e22787, 2024. DOI: <https://doi.org/10.1002/cae.22787>.

MOHER, David et al. Preferred reporting items for systematic review and meta-analysis protocols (PRISMA-P) 2015 statement. **Systematic Reviews**, v. 4, n. 1, p. 1, 2015. DOI: <https://doi.org/10.1186/2046-4053-4-1>.

MOUSAVINASAB, Elham et al. Intelligent tutoring systems: a systematic review of characteristics, applications, and evaluation methods. **Interactive Learning Environments**, v. 29, n. 1, p. 142–163, 2021. DOI: <https://doi.org/10.1080/10494820.2018.1558257>.

NATIONAL RESEARCH COUNCIL. **Knowing What Students Know: The Science and Design of Educational Assessment**. Washington, DC: The National Academies Press, 2001. DOI: <https://doi.org/10.17226/10019>.

NICULESCU-MIZIL, Alexandru; CARUANA, Rich. Predicting good probabilities with supervised learning. In: **Proceedings of the 22nd International Conference on Machine Learning**. [New York, NY]: ACM, 2005. p. 625–632. DOI: <https://doi.org/10.1145/1102351.1102430>.

NYANTAH, Rahmat Opoku; FREMPONG, Nana Kena; LARBI, Ernest. Enhancing Student Achievement in Circle Theorems: Integrating Computer Animation with the Jigsaw Cooperative Learning Model. **International Journal of Mathematics and Mathematics Education**, v. 3, n. 2, p. 91–112, 2025. DOI: <https://doi.org/10.56855/ijmme.v3i2.1299>.

OECD. **PISA 2022 Assessment and Analytical Framework**. Paris: OECD Publishing, 2023a. DOI: <https://doi.org/10.1787/dfe0bf9c-en>.

____. **PISA 2022 Results (Volume I): The State of Learning and Equity in Education**. OECD Publishing, 2023b. DOI: <https://doi.org/10.1787/53f23881-en>.

____. **PISA 2022 Technical Report**. Paris, 2024. DOI: <https://doi.org/10.1787/01820d6d-en>. Acesso em: 29 out. 2026.

OPESEMOWO, Oluwaseyi Aina Gbolade; ADEWUYI, Habeeb Omoponle. A systematic review of artificial intelligence in mathematics education: The emergence of 4IR. **Eurasia Journal of Mathematics, Science and Technology Education**, v. 20, n. 7, p. em2478, 2024. DOI: <https://doi.org/10.29333/ejmste/14762>. Acesso em: 29 out. 2026.

ÖZSEVEN, Beyza Esin; ÖZSEVEN, Turgut. A Hybrid Neuro-Fuzzy and Machine Learning Model for Student Performance Prediction in Online Mathematics Education. **International Journal of Advanced Computer Science and Applications**, v. 17, n. 5, 2026. DOI: <https://doi.org/10.14569/ijacsa.2026.0170516>.

PAGE, Matthew J. et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. **BMJ**, v. 372, p. n71, 2021. DOI: <https://doi.org/10.1136/bmj.n71>.

PEDREGOSA, Fabian et al. Scikit-learn: Machine learning in Python. **Journal of Machine Learning Research**, v. 12, n. 85, p. 2825–2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>. Acesso em: 22 out. 2026.

PEJIĆ, Aleksandar; MOLCER, Piroska Stanić; GULAČI, Kristian. Math proficiency prediction in computer-based international large-scale assessments using a multi-class machine learning model. In: **2021 IEEE 19th International Symposium on Intelligent Systems and Informatics (SISY)**. [Piscataway, NJ]: IEEE, 2021. p. 49–54. DOI: <https://doi.org/10.1109/SISY52375.2021.9582522>.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In: **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining**. [New York, NY]: ACM, 2016. p. 1135–1144. DOI: <https://doi.org/10.1145/2939672.2939778>.

ROMERO, Cristóbal; VENTURA, Sebastián. Educational data mining and learning analytics: An updated survey. **WIREs Data Mining and Knowledge Discovery**, v. 10, n. 3, p. e1355, 2020. DOI: <https://doi.org/10.1002/widm.1355>.

Scikit-learn developers. **Metrics and scoring: quantifying the quality of predictions**. [S.l.], 2025. Documentação da versão 1.6.1, seção 3.4. Disponível em: <https://scikit-learn.org/1.6/modules/model_evaluation.html>. Acesso em: 3 nov. 2026.

Social Psychology Network. **The Jigsaw Classroom**. s.d. Página sem data de publicação indicada; copyright do sítio iniciado em 2000. Disponível em: <https://www.jigsaw.org/>. Acesso em: 3 nov. 2026.

SOKKHEY, Phauk et al. Multi-models of Educational Data Mining for Predicting Student Performance in Mathematics: A Case Study on High Schools in Cambodia. **IEIE Transactions on Smart Processing and Computing**, v. 9, n. 3, p. 217–229, 2020. DOI: <https://doi.org/10.5573/IEIESPC.2020.9.3.217>.

TJAHYADI, Hendra; TUDE, Krismon N. L. The Implementation of Educational Data Mining in Predicting Students' Academic Achievement in Mathematics at a Private Elementary School. **International Journal of Information and Education Technology**, v. 15, n. 1, p. 154–163, 2025. DOI: <https://doi.org/10.18178/ijiet.2025.15.1.2228>.

USKOV, Vladimir L. et al. Machine Learning-based Predictive Analytics of Student Academic Performance in STEM Education. In: **2019 IEEE Global Engineering Education Conference (EDUCON)**. [Piscataway, NJ]: IEEE, 2019. p. 1370–1376. DOI: <https://doi.org/10.1109/EDUCON.2019.8725237>.

VILLEGAS-CH, William et al. Adaptive intelligent tutoring systems for STEM education: analysis of the learning impact and effectiveness of personalized feedback. **Smart Learning Environments**, v. 12, n. 1, 2025. Artigo 41. DOI: <https://doi.org/10.1186/s40561-025-00389-y>.

VYGOTSKY, Lev S. **Mind in Society: The Development of Higher Psychological Processes**. Cambridge, MA: Harvard University Press, 1978.

WOOD, David; BRUNER, Jerome S.; ROSS, Gail. The role of tutoring in problem solving. **Journal of Child Psychology and Psychiatry**, v. 17, n. 2, p. 89–100, 1976. DOI: <https://doi.org/10.1111/j.1469-7610.1976.tb00381.x>.

XIA, Chenxi et al. Exploring the Integration of Education for Sustainable Development into University Mathematics: Insights from SiC Thickness Measurement in Advanced Industrial Applications. **Sustainability**, v. 18, n. 4, 2026. Artigo 1900. DOI: <https://doi.org/10.3390/su18041900>.

XIE, Haoran et al. Trends and development in technology-enhanced adaptive/personalized learning: A systematic review of journal publications from 2007 to 2017. **Computers & Education**, v. 140, p. 103599, 2019. DOI: <https://doi.org/10.1016/j.compedu.2019.103599>.

XU, Xin; FRANK, Eibe. **JRip**. s.d. Documentação técnica da classe no Weka. Revisão 15519 indicada na documentação; data de publicação não informada. Disponível em: <https://weka.sourceforge.io/doc.dev/weka/classifiers/rules/JRip.html>. Acesso em: 3 nov. 2026.

YI, Linxuan et al. The effectiveness of AI on K-12 students' mathematics learning: A systematic review and meta-analysis. **International Journal of Science and Mathematics Education**, v. 23, n. 4, p. 1105–1126, 2025. DOI: <https://doi.org/10.1007/s10763-024-10499-7>. Acesso em: 29 out. 2026.

ZENG, Jialing. **Multimodal neurophysiological measurement of cognitive load during math problem solving in 4th graders**. Tese (Doutorado) — Columbia University, 2025. DOI: <https://doi.org/10.7916/2q6y-bm58>.

ZHANG, Lei; ZHU, Weihua; FENG, Ling. Design of Personalized Learning Path Optimization Algorithm Based on Deep Learning. In: **2025 International Conference on Computers, Information Processing and Advanced Education (CIPAE)**. [Piscataway, NJ]: IEEE, 2025. p. 650–655. DOI: <https://doi.org/10.1109/CIPAE66821.2025.00116>.

ZHANG, Xiaohui. An Innovative Model of Higher Mathematics Curriculum Education Incorporating Artificial Intelligence Technology. **Applied Mathematics and Nonlinear**

Sciences, v. 9, n. 1, 2024. Artigo 20231524. DOI: <https://doi.org/10.2478/amns.2023.2.01524>.

APÊNDICE A – MAPEAMENTO DO RELATO AO PRISMA 2020

Este apêndice apresenta um mapeamento do relato deste manuscrito com base no PRISMA 2020 (Page et al., 2021). O quadro desdobra os 27 itens da lista de verificação em suas alíneas aplicáveis e utiliza tópicos abreviados; os requisitos completos estão na lista de verificação oficial. O mapeamento avalia o que foi apresentado no texto, não certifica a execução do procedimento, o rigor metodológico, a ausência de viés ou a certeza da evidência. São registradas as informações localizadas e as limitações do manuscrito, sem atribuir pontuação ou declarar conformidade global ou integral.

A indicação *Localizado* identifica uma passagem pertinente, mas não certifica sua suficiência. *Parcial* indica informação disponível com limitações explicitadas. *Não apresentado* registra informação ou resultado não encontrado no manuscrito examinado, sem afirmar que o procedimento jamais ocorreu; quando a atividade não foi realizada, isso é indicado na justificativa. *Não aplicável* é empregado somente com justificativa específica; a ausência de meta-análise não dispensa o relato dos métodos de síntese narrativa.

Quadro 13 – Mapeamento do relato aos itens do PRISMA 2020.

Item	**Tópico abreviado**	**Localização e estado do relato**
1	Título	Parcial: capa e folha de rosto identificam o tema, mas o título não explicita revisão sistemática.
2	Resumo	Parcial: Resumo e Abstract apresentam objetivo, critérios gerais, fontes e data de corte, métodos, achados, limitações e conclusão, com 15 estudos e 26 grupos de requisitos como resultados quantitativos essenciais. O título não identifica o trabalho como revisão sistemática; não há total agregado de participantes, pois as unidades e os denominadores não são comparáveis, nem a data individual da última consulta a cada fonte. As declarações de financiamento e ausência de pré-registro estão no método, não nos resumos.
3	Justificativa	Localizado: Cap. 1, Justificativa.
4	Objetivos	Localizado: Cap. 1, Problema de Pesquisa e Objetivos.
5	Elegibilidade	Parcial: Cap. 3, Critérios de Seleção, e Cap. 4, Caracterização dos Estudos Incluídos, descrevem critérios e situações de inclusão. O Fluxograma 1 e a Tabela 1 apresentam a seleção pelo corte de relevância 4,0; a relação entre relevância e avaliação de elegibilidade é explicitada no método.
6	Fontes	Parcial: Cap. 3, Estratégia de Busca. Não estão discriminadas as datas da última consulta de cada fonte.
7	Buscas	Parcial: Cap. 3, Estratégia de Busca e Quadro 1. Há composição canônica e exemplos; o relato por fonte, com filtros e limites, não está completo.
8	Seleção	Parcial: Cap. 3, Processo de Seleção, e Cap. 4, Limitações e Contribuições da Revisão. A seleção empregou regras automatizadas e apoio de IA generativa, descritos na Seção 3.7.
9	Coleta de dados	Parcial: Cap. 3, Identificação e Avaliação da Qualidade Metodológica. A obtenção de metadados está descrita; a extração dos textos e sua confirmação não estão integralmente documentadas.

Continua na próxima página

Quadro 13 – Continuação

Item	Tópico abreviado	Localização e estado do relato
10a	Desfechos	Parcial: Cap. 3, Critérios de Seleção, e Quadro 3. Faltam regras completas para seleção de resultados por desfecho.
10b	Outras variáveis	Parcial: Cap. 3, Identificação. Não há definição completa das variáveis extraídas e do tratamento de informação ausente.
11	Viés nos estudos	Parcial: Cap. 3, Avaliação da Qualidade Metodológica. O apoio de IA generativa à leitura, às propostas de julgamentos e à conferência é descrito na Seção 3.7.
12	Medidas de efeito	Parcial: Quadro 3. As métricas reportadas são heterogêneas; não foi definida medida comum para combinação quantitativa.
13a	Composição das sínteses	Parcial: Cap. 3, Critérios de Seleção, e Cap. 4, Seção 4.3. A síntese empírica considera os 15 estudos selecionados pelo corte de relevância 4,0; o relatório não recuperado, a exclusão após resumo e o protocolo sem resultados concluídos estão discriminados no Quadro 3.
13b	Preparação dos dados	Não apresentado: não foi localizado procedimento específico para preparar os resultados extraídos, incluindo estatísticas ausentes ou conversões.
13c	Apresentação	Localizado: Cap. 4, Fluxo de Seleção, Estatísticas Descritivas, Seção 4.3 e Avaliação Metodológica com o MMAT. A apresentação não substitui a validação dos dados.
13d	Síntese	Parcial: Cap. 4, Seção 4.3 e Limitações e Contribuições da Revisão. A heterogeneidade é discutida; a codificação e o procedimento da síntese narrativa não estão inteiramente explicitados.
13e	Heterogeneidade	Não apresentado: não foi realizado método formal para investigar possíveis causas de heterogeneidade; diferenças entre populações, desenhos e métricas são discutidas qualitativamente.
13f	Sensibilidade	Não apresentado: não foi realizada análise de sensibilidade da síntese. A exploração do corte de seleção, discutida na Seção 4.6, tem finalidade distinta.
14	Viés de relato	Não apresentado: não foi realizada avaliação formal. Cap. 4, Limitações e Contribuições da Revisão, registra a ausência de teste de viés de publicação.
15	Certeza	Não apresentado: não foi apresentada avaliação formal da certeza do conjunto de evidências; o MMAT individual não a substitui.
16a	Fluxo	Parcial: o Fluxograma 1 e a Tabela 1 apresentam as etapas e contagens, distinguindo relatórios procurados, não recuperados, avaliados e excluídos. A priorização por relevância é explicitada como etapa automatizada, não de elegibilidade.
16b	Exclusões justificadas	Parcial: Quadro 3: Imperatrice et al. (2025), protocolo sem resultados empíricos concluídos, excluído após texto completo; Uskov et al. (2019), excluído após resumo; texto não recuperado, distinto dessas exclusões. Xia et al. (2026) foi incluído conforme o protocolo escrito. A caracterização do relato pendente limita-se aos metadados e resumos disponíveis.
17	Características	Parcial: Quadro 3. Os 18 registros da lista preliminar são identificados com sua situação no fluxo; características de amostra e desenho não estão uniformemente detalhadas. Dois relatórios não foram recuperados: Sokkhey et al. (2020), mantido apenas na seleção histórica, e Zeng (2025), fora dos 15 estudos históricos. O registro excluído após resumo pertence a etapa distinta e não foi tratado como relatório procurado.
18	Apreciação individual	Parcial: Seção 4.4 e Quadro 6. Julgamentos preliminares, com limitações de fontes e de indicação das páginas consultadas.
19	Resultados individuais	Parcial: Quadro 3. Diversas entradas descrevem a abordagem; estimativas e precisão não são apresentadas uniformemente.

Continua na próxima página

Quadro 13 – Continuação

Item	Tópico abreviado	Localização e estado do relato
20a	Síntese e limitações	Parcial: Cap. 4, Seção 4.3 e Avaliação Metodológica com o MMAT. Não está completa a ligação entre os estudos de cada síntese e seus julgamentos metodológicos.
20b	Sínteses estatísticas	Não aplicável aos resultados de combinação estatística: nenhuma síntese estatística conjunta foi realizada.
20c	Heterogeneidade	Não apresentado: não foram apresentados resultados de investigação formal das causas de heterogeneidade.
20d	Sensibilidade	Não apresentado para a síntese: a Seção 4.6 relata a exploração do corte de seleção, que não corresponde a uma análise de robustez dos resultados sintetizados.
21	Viés de relato	Não apresentado: não foram apresentados resultados de avaliação formal de viés decorrente de resultados ausentes.
22	Certeza	Não apresentado: não foi apresentada classificação formal de certeza por desfecho.
23a	Interpretação	Parcial: Cap. 6, Discussão Integrada. As interpretações dependem da consolidação da extração e da apreciação metodológica.
23b	Limites da evidência	Localizado: Cap. 4, Avaliação Metodológica com o MMAT e Limitações e Contribuições da Revisão; Cap. 7, Limitações.
23c	Limites do processo	Localizado: Cap. 3, Avaliação da Qualidade Metodológica, e Cap. 4, Limitações e Contribuições da Revisão, incluindo o acesso desigual aos textos.
23d	Implicações	Localizado: Cap. 6, Discussão Integrada, e Cap. 7, Continuidade da Pesquisa.
24a	Registro	Localizado: Cap. 3, Protocolo e Relato da Revisão Sistemática, declara que não houve registro em plataforma de pré-registro.
24b	Protocolo	Parcial: Cap. 3, Seção 3.1, descreve o planejamento inicial documentado no histórico do repositório público; não há protocolo pré-registrado.
24c	Alterações	Parcial: Cap. 3, Seção 3.1, distingue o planejamento inicial documentado no histórico do repositório dos procedimentos executados quanto ao período, aos tipos de publicação e à organização das etapas. A escolha exata do corte 4,0 não tem calibração ou justificativa empírica registrada nas fontes preservadas.
25	Apoio	Localizado: Seção 3.1, Protocolo e Relato da Revisão Sistemática. A pesquisa foi desenvolvida no Instituto Federal Catarinense – Campus Videira, com recursos próprios, sem financiamento externo ou participação de financiador nas decisões da revisão.
26	Interesses	Localizado: Seção 3.1, Protocolo e Relato da Revisão Sistemática. O autor declara não haver conflitos de interesse relacionados a esta pesquisa.
27	Materiais	Parcial: Código, protocolo de elegibilidade, escopo da síntese, manifestos e avaliações metodológicas estão versionados no repositório público do projeto, em <research/src>, <research/data> e <research/exports/reports>. Os textos integrais de algumas fontes não foram recuperados e não são redistribuídos; a disponibilidade de cada estudo é indicada no registro de fontes.

Fonte: Elaborado pelo autor (2026), com base em Page et al. (2021).

A apreciação MMAT corresponde aos itens 11 e 18 deste mapeamento e permanece preliminar. Ela não constitui avaliação formal da certeza do conjunto de evidências (itens 15 e 22), não é avaliação de viés de relato (itens 14 e 21) e não permite inferir ausência de viés ou conformidade global. As pendências indicadas restringem o alcance das conclusões e devem ser

consideradas juntamente com as limitações apresentadas no Capítulo 4.

APÊNDICE B – REGISTRO DE RECUPERAÇÃO DAS FONTES

Este registro reúne o histórico de recuperação, os limites da leitura e os arquivos de conferência das fontes. O Capítulo 4 apresenta a seleção examinada; este apêndice registra a recuperação das fontes e a extensão das conferências realizadas para esses estudos. As datas abaixo descrevem consultas posteriores à busca; não representam novas coletas nas bases.

Nas tabelas e justificativas, página física indica a posição da página no PDF, contada desde a primeira folha; página impressa indica a numeração apresentada no documento. Quando ambas são necessárias, registra-se primeiro a página impressa e, entre parênteses, a página física.

Os números citados neste parágrafo são identificadores internos dos registros na base. Na reconciliação de duplicatas, o registro 6952 foi associado ao relatório já representado pelo registro 155, e o registro 6977 ao relatório do registro 8. Na correção do ano de publicação, o ano do registro 361 passou de 2024 para 2005, e o do registro 7001, de 2015 para 1997.

B.1 HISTÓRICO DE RECUPERAÇÃO E LEITURA

A data de corte da busca foi 31 de agosto de 2026. A definição inicial do escopo do corpus foi concluída em 3 de setembro de 2026. Em 14 de outubro de 2026, uma conferência atualizada confrontou os 18 registros da lista preliminar com o planejamento escrito e com a situação de recuperação dos textos integrais, incluindo três artigos recém-recuperados e verificados. Essa atualização corrigiu a classificação das etapas de seleção, sem nova consulta às bases e sem alterar a data de corte da busca. Em 20 de outubro de 2026, a recuperação posterior do texto integral do registro excluído após a triagem do resumo confirmou que o estudo descreve cursos de Ciência da Computação e Sistemas de Informação e deixa a Matemática para trabalho futuro; essa conferência confirmou a exclusão, sem criar uma nova etapa nem alterar as contagens PRISMA.

Na atualização de 20 de outubro de 2026, conferida novamente em 29 de outubro, 16 dos 18 registros da lista preliminar dispunham de cópias locais identificadas por *hash*. Um quadro complementar registra, para cada fonte, as páginas de texto examinadas, as imagens inspecionadas e a contribuição delimitada. Os textos de Kumar et al. (2022) e Uskov et al. (2019) foram incorporados nessa atualização; os trabalhos de Zhang (2024) e Xia et al. (2026) já haviam sido recuperados em 17 de outubro. No PDF de Uskov et al. (2019), a codificação do texto

embutido estava corrompida, exigindo reconhecimento óptico de caracteres e inspeção visual seletiva. A extensão da leitura é detalhada a seguir. A conferência do texto integral confirmou a exclusão registrada após o resumo, sem criar nova etapa de seleção.

Permaneceram sem cópia verificável os trabalhos de Sokkhey et al. (2020) e Zeng (2025). Na atualização do fluxo de recuperação, dos 17 relatórios procurados, dois não puderam ser recuperados; 15 foram avaliados em texto completo, incluindo o protocolo de Imperatrice et al. (2025), excluído por não apresentar resultados concluídos. Restam 14 relatórios empíricos recuperados. Sokkhey permanece na seleção histórica de 15 estudos apenas como inclusão histórica, com as respostas MMAT anteriores preservadas sem revalidação e sem afirmação de conferência atual do texto integral. Para Zeng, o manifesto documenta embargo informado pelo repositório institucional na consulta de 13 de outubro de 2026, com liberação prevista para 2027; nenhum critério MMAT foi aplicado.

A disponibilidade dessas cópias é apresentada separadamente da seleção histórica no Fluxograma 1; os dados de recuperação não reabrem a seleção nem alteram a inclusão histórica de Sokkhey. A tese de MacLellan (2017) teve 38 de suas 108 páginas lidas na verificação de cobertura, sem leitura integral dos demais capítulos, figuras e apêndices. As consultas posteriores têm sua cobertura registrada no quadro complementar; o índice de busca textual reproduzível continua limitado às 12 fontes indexadas originalmente. A extração automática de texto não foi tratada como equivalente à leitura integral do documento, com suas figuras e tabelas.

As 15 fichas MMAT correspondem à seleção empírica histórica; esse número não representa 15 textos integrais atualmente conferidos. Há cópias identificadas para 14 desses estudos, com extensões de leitura diferentes. A ficha de Sokkhey et al. (2020) mantém somente os julgamentos registrados anteriormente, sem cópia verificável para reavaliação nem confirmação atual do texto integral. O campo de base da apreciação deve ser lido junto da situação de acesso. O registro de fontes preserva a identificação de cada documento, a data de consulta, o tipo de fonte, a situação de recuperação e os localizadores históricos cuja conferência não foi possível sem uma cópia. Para a tese de Zeng (2025), a consulta de 13 de outubro de 2026 ao Academic Commons informava disponibilidade dos arquivos a partir de 16 de maio de 2027. A consulta ao resumo não foi convertida em apreciação do texto integral.

O arquivo <research/data/mmat_followup_questions_current.csv> registra, por fonte e critério ainda CT, o localizador e o limite da evidência disponível, vinculados à ficha pública de cobertura. Distingue informação insuficiente no material examinado, exame do

critério ainda incompleto e ausência de cópia para reavaliar respostas anteriores. A pendência de Zeng (2025) identifica documento não recuperado, sem resposta MMAT. Quando a ficha registra leitura parcial sem estabelecer a origem da insuficiência de um critério, não se escolhe entre informação não localizada e trecho pertinente ainda não examinado. Os trechos fora da cobertura não autorizam conclusão de omissão do artigo.

As alterações documentais de 28 de outubro de 2026 estão registradas, com fonte, páginas, justificativas e *hashes*, em <research/data/mmat_completion_review_2026-10-28.json>. Em Depren, Aşkın e Öz (2017), Q1 (4.1) passou de CT para Y pela pertinência da fonte e do recorte (página física 4). Em Özseven e Özseven (2026), Q1 (4.1) passou de CT para Y pela descrição da seleção e limpeza dos registros (páginas físicas 3–4 e 15–16). Esses julgamentos não demonstram representatividade.

No componente qualitativo de Villegas-Ch et al. (2025), C2 (1.2) passou de CT para Y pela adequação das entrevistas à questão de percepção (página física 16). No componente qualitativo de Echeveria, Bajao e Godinez (2025), C2 (1.2) passou de CT para Y pela coleta com cinco docentes (páginas físicas 3 e 11–12); C4 (1.4) passou de CT para Y pela sustentação da interpretação descritiva nas falas (páginas físicas 11–12). Coleta pertinente não certifica todo o processo qualitativo, e percepções não demonstram efeito sobre aprendizagem. Essas mudanças já constam das matrizes; não são novas recodificações.

B.2 ARQUIVOS E REPRODUÇÃO

O arquivo <research/exports/reports/reproducibility_manifest.json> funciona como índice da origem dos dados analisados: registra a data de geração, os resumos criptográficos (*hashes*) produzidos pelo algoritmo *Secure Hash Algorithm* de 256 bits (SHA-256) dos arquivos exportados, a versão atual da avaliação MMAT, as fontes primárias consultadas e os comandos de reconstrução. Essa estrutura permite verificar a versão publicada sem distribuir o banco SQLite usado na coleta e torna explícita a diferença entre reproduzir o conjunto analisado e iniciar uma nova coleta nas APIs.

A exploração do limiar está resumida em <research/data/selection_status_current.json>, com os desenhos de exame das faixas, as contagens originais e seus limites de interpretação. Esse registro público não altera o conjunto de estudos analisado.

Os critérios documentais de seleção estão em <research/data/current_eligibility_protocol.csv>. As respostas MMAT estão em <research/data/mmat_reassessment_current.

csv>; os componentes qualitativos e quantitativos, em <research/data/mmat_component_reassessment_current.csv>. Os arquivos *JavaScript Object Notation* (JSON, notação de objetos JavaScript), CSV e BibTeX permitem conferir as versões publicadas.

Na triagem, os rótulos internos `abstract_too_short` e `no_methodology` identificam, respectivamente, a regra de comprimento do resumo e a ausência dos termos metodológicos procurados em inglês. Esses rótulos descrevem regras de processamento, não avaliações da qualidade dos estudos.

Os comandos de conferência são:

```
python -m research.src.validation.versioned_snapshot
python -m research.src.processing.adjudicated_snapshot --check
python -m research.src.validation.bibliography_audit
```

APÊNDICE C – FORMULÁRIO DE REVISÃO DA ESPECIFICAÇÃO

Este apêndice apresenta o instrumento documental proposto no OE4 para registrar a avaliação da viabilidade e da coerência da especificação. O formulário reúne identificação da versão examinada, julgamento dos requisitos R01–R26, justificativas e ficha de aceitação documental das funções F01–F07. Não contém resultados de uma avaliação realizada.

O instrumento integra o protocolo da Seção 5.2.1, ainda não aplicado. Sua utilização está condicionada à tramitação ética e ao consentimento descritos naquela seção. Os campos abaixo são modelos em branco, sem dados identificáveis de estudantes. A correspondência entre o código do participante e sua identidade tem acesso restrito.

Código do participante: _____. Rodada: _____. Data: _____.

Versão da especificação: _____.

Perfil/nível de ensino e tempo de experiência: _____.

Registrar em cada dimensão: 1=incoerente; 2=alteração substancial; 3=ajuste pontual; 4=coerente; NE=evidência insuficiente. A=sustentação na fonte ou decisão autoral; B=adequação curricular; C=clareza da saída; D=viabilidade documental. Justificar cada resposta, inclusive NE.

Quadro 14 – Ficha individual de julgamento por requisito.

Cód.	A	B	C	D	Página, justificativa e ajuste necessário
R01					
R02					
R03					
R04					
R05					
R06					
R07					
R08					
R09					
R10					
R11					
R12					
R13					
R14					
R15					

Continua na próxima página

Quadro 14 – Continuação

Participante: _____. Rodada: ____. Versão: _____.

Cód.	A	B	C	D	Página, justificativa e ajuste necessário
R16					
R17					
R18					
R19					
R20					
R21					
R22					
R23					
R24					
R25					
R26					

Fonte: Elaborado pelo autor (2026).

A ficha seguinte é um modelo reutilizável para cada função F01–F07. Ela registra o exame documental do critério de aceitação do Quadro 10; o parecer sobre a especificação não indica execução de teste de implementação.

Quadro 15 – Modelo de ficha de aceitação documental por função.

Campo	Registro
Participante, rodada e versão	
Função F e requisito R associado	
Entrada do cenário	
Saída esperada	
Critério e trecho que permite verificá-lo	
Condição faltante ou problema crítico	
Parecer e justificativa	Coerente / Revisar

Fonte: Elaborado pelo autor (2026).

A consolidação dos julgamentos e o tratamento das divergências seguem a Seção 5.2.1. Os registros deste formulário não produzem escore de qualidade dos estudos nem demonstram eficácia pedagógica de uma implementação.

APÊNDICE D – JUSTIFICATIVAS DOS COMPONENTES MMAT

As justificativas dos seis componentes dos mesmos três estudos de métodos mistos detalham o Quadro 7. São transcritas dos registros de apreciação preliminar, por critério e sem escore agregado, mantendo os julgamentos e os localizadores das fontes. A apresentação separada não acrescenta estudos ao conjunto.

Villegas-Ch et al. (2025) – Quantitativo não randomizado.

3.1 (CT): A população de recrutamento e a estratégia de amostragem não estão estabelecidas nas seções examinadas. **3.2 (CT):** As medidas de resultado são descritas, mas o relato disponível não fundamenta suficientemente sua adequação. **3.3 (CT):** A completude dos dados de resultado e as perdas de participantes não estão estabelecidas. **3.4 (CT):** A alocação dos grupos e o controle inicial de fatores de confusão não estão suficientemente documentados. **3.5 (CT):** A introdução menciona um semestre acadêmico, os métodos relatam seis semanas e os resultados mostram progresso na oitava semana para estudantes de programação com alta interação; essa divergência não estabelece a adesão ou a cronologia do componente de matemática.

Localização: Páginas físicas 2 (450 estudantes e semestre letivo), 13–16 (delineamento, medidas e análise), 18–23 (resultados; semana 8 na p. 22) e 24–27 (testes e limites)

Villegas-Ch et al. (2025) – Qualitativo.

1.1 (Y): A abordagem qualitativa é pertinente para examinar as percepções de estudantes e educadores sobre o sistema de tutoria. **1.2 (Y):** Entrevistas estruturadas com estudantes e educadores, realizadas ao fim da experiência e com tópicos pertinentes explicitados, são adequadas para explorar as percepções sobre o sistema (página física 16). Detalhes de seleção e registro continuam como perguntas de esclarecimento, sem serem tratados automaticamente como inadequação da coleta. **1.3 (CT):** O relato menciona análise temática e temas, mas não explicita suficientemente a derivação analítica a partir das entrevistas (páginas físicas 16–17). **1.4 (CT):** As interpretações das entrevistas não são suficientemente vinculadas ao material qualitativo examinado (páginas físicas 16–17); médias e percentuais de satisfação nas pp. 24–25 são dados quantitativos e não resolvem esse vínculo. **1.5 (CT):** A coerência entre fontes qualitativas, coleta, análise e interpretação permanece pouco clara.

Localização: Páginas físicas 16–17 (Qualitative Analysis); 24–25 (satisfação quantitativa, não dados de entrevista)

Xia et al. (2026) – Quantitativo não randomizado.

3.1 (CT): Os grupos pertencem a uma disciplina e estão separados por quatro anos. O artigo menciona amostragem por conglomerados, mas não define a população-alvo nem explica como as turmas de 2021 e 2025 foram escolhidas (páginas físicas 7–8). **3.2 (Y):** O questionário e os resultados da disciplina são descritos e analisados; a apreciação permanece provisória. **3.3 (CT):** A completude e o tratamento dos dados de resultado não estão suficientemente documentados nas seções examinadas. **3.4 (N):** Os grupos de controle e experimental de anos diferentes introduzem confundimento temporal reconhecido pelos autores; os testes de linha de base não controlam mudanças de equipe, contexto e uso de IA (páginas físicas 8 e 24). **3.5 (CT):** A implementação da intervenção e a adesão não estão suficientemente documentadas para este critério.

Localização: Páginas físicas 7–8 (§4.1.1), 12–14 (§4.3–4.4.1, tabela 4) e 24 (§6)

Xia et al. (2026) – Qualitativo.

1.1 (Y): As entrevistas são adequadas para explorar as perspectivas dos estudantes sobre a reforma da disciplina. **1.2 (Y):** O artigo relata entrevistas semiestruturadas com 12 estudantes do grupo experimental, selecionados aleatoriamente logo após o curso (página física 18). **1.3 (CT):** As etapas analíticas utilizadas para derivar os temas não estão suficientemente detalhadas. **1.4 (Y):** A interpretação inclui relatos dos estudantes e é apoiada por citações apresentadas no artigo (página física 18). **1.5 (CT):** A relação entre amostragem qualitativa, coleta, análise e conclusões integradas requer verificação adicional.

Localização: Páginas físicas 18 (§4.4.8) e 24 (§6)

Echeveria, Bajao e Godinez (2025) – Quantitativo descritivo.

4.1 (Y): Os registros de estudantes de uma escola são adequados à questão de classificação local descrita no estudo. **4.2 (CT):** A escola e seus estudantes delimitam uma população local; o MMAT não exige uma população-alvo mais abrangente. A correspondência dos 428 casos completos aos 633 recrutados não foi estabelecida, com anos letivos divergentes e sem comparação suficiente dos retidos e não retidos (páginas físicas 3 e 7). **4.3 (N):** Oito itens da escala usados para construir as categorias de mentalidade também permanecem entre os preditores selecionados, comprometendo a mensuração independente do alvo. **4.4 (CT):** O relato informa 633 participantes recrutados e 428 casos completos e cita os anos letivos 2023–2024 e 2022–2023 sem esclarecer a origem dos grupos nem se os casos ausentes produzem viés de não resposta. **4.5 (CT):** As descrições da divisão dos dados e da validação divergem e não permitem

apreciar claramente a adequação da análise.

Localização: Páginas físicas 3/impressa 65 (§2.1–2.3), 6/68 (§2.6) e 7–8/69–70 (resultados)

Echeveria, Bajao e Godinez (2025) – Qualitativo.

1.1 (Y): As entrevistas com professores são pertinentes aos objetivos declarados de contextualização e triangulação do estudo. **1.2 (Y):** O relato identifica entrevistas com cinco docentes de Matemática para explorar o uso do modelo e apresenta suas falas individuais (páginas físicas 3 e 11–12), constituindo coleta pertinente à questão de percepção docente. A seleção e o registro das respostas permanecem pouco detalhados. **1.3 (CT):** O procedimento analítico do material das entrevistas não está adequadamente descrito. **1.4 (Y):** As falas individuais dos docentes sustentam a interpretação descritiva de suas percepções sobre identificação, apoio e planejamento (páginas físicas 11–12). O julgamento não transforma expectativas dos entrevistados em efeito observado sobre aprendizagem. **1.5 (CT):** A coerência entre fontes, coleta, análise e interpretação qualitativas não pode ser concluída, pois o procedimento de análise das entrevistas permanece pouco explicitado (páginas físicas 3 e 11–13). A integração com dados quantitativos é examinada separadamente nos critérios de métodos mistos.

Localização: Páginas físicas 3/impressa 65 (§2.1 e coleta), 11–12/73–74 (falas docentes) e 13/75 (conclusões)

APÊNDICE E – FERRAMENTAS DE INTELIGÊNCIA ARTIFICIAL

O Quadro 16 resume as ferramentas, as famílias e versões registradas e as finalidades gerais do apoio descrito na Seção 3.7.

Quadro 16 – Ferramentas de inteligência artificial e finalidades gerais.

Ferramenta	**Modelos (famílias e versões registradas)**	**Finalidades gerais**
Claude Code	Claude Opus, Sonnet e Haiku 5.5	Revisão linguística e textual; desenvolvimento e revisão do código versionado; conferência por agentes.
Codex	`gpt-6-luna` e `gpt-6.1-sol`	Revisão linguística e textual; desenvolvimento e revisão do código versionado; apoio à triagem e à apreciação MMAT; conferência por agentes.
Antigravity/`agy`	Gemini Flash 3.8	Revisão textual e do código; apoio à apreciação MMAT; conferência por agentes.
OpenCode	Qwen 3.7 Max; DeepSeek V4 Flash; GLM 5.3 Flash	Revisão textual e do código; apoio à triagem e à apreciação MMAT; conferência por agentes.

Fonte: Elaborado pelo autor (2026).

O histórico das interações é parcial e não permite atribuir cada trecho do texto ou do código a um modelo específico. Os modelos de prompts disponíveis em <.github/prompts/> não representam todas as instruções utilizadas. O autor permanece responsável pela verificação das fontes, pela validação do texto e do código incorporados e pelas análises, interpretações e decisões de pesquisa.